



UNIVERSIDAD DE LA RIOJA

TESIS DOCTORAL

Título
Modelos de predicción a corto plazo de la generación eléctrica en instalaciones fotovoltaicas
Autor/es
Andrés Muñoz Jiménez
Director/es
Luis Alfredo Fernández Jiménez
Facultad
Escuela Técnica Superior de Ingeniería Industrial
Titulación
Departamento
Ingeniería Eléctrica
Curso Académico
2013-2014



Modelos de predicción a corto plazo de la generación eléctrica en instalaciones fotovoltaicas, tesis doctoral

de Andrés Muñoz Jiménez, dirigida por Luis Alfredo Fernández Jiménez (publicada por la Universidad de La Rioja), se difunde bajo una Licencia Creative Commons Reconocimiento-NoComercial-SinObraDerivada 3.0 Unported. Permisos que vayan más allá de lo cubierto por esta licencia pueden solicitarse a los titulares del copyright.

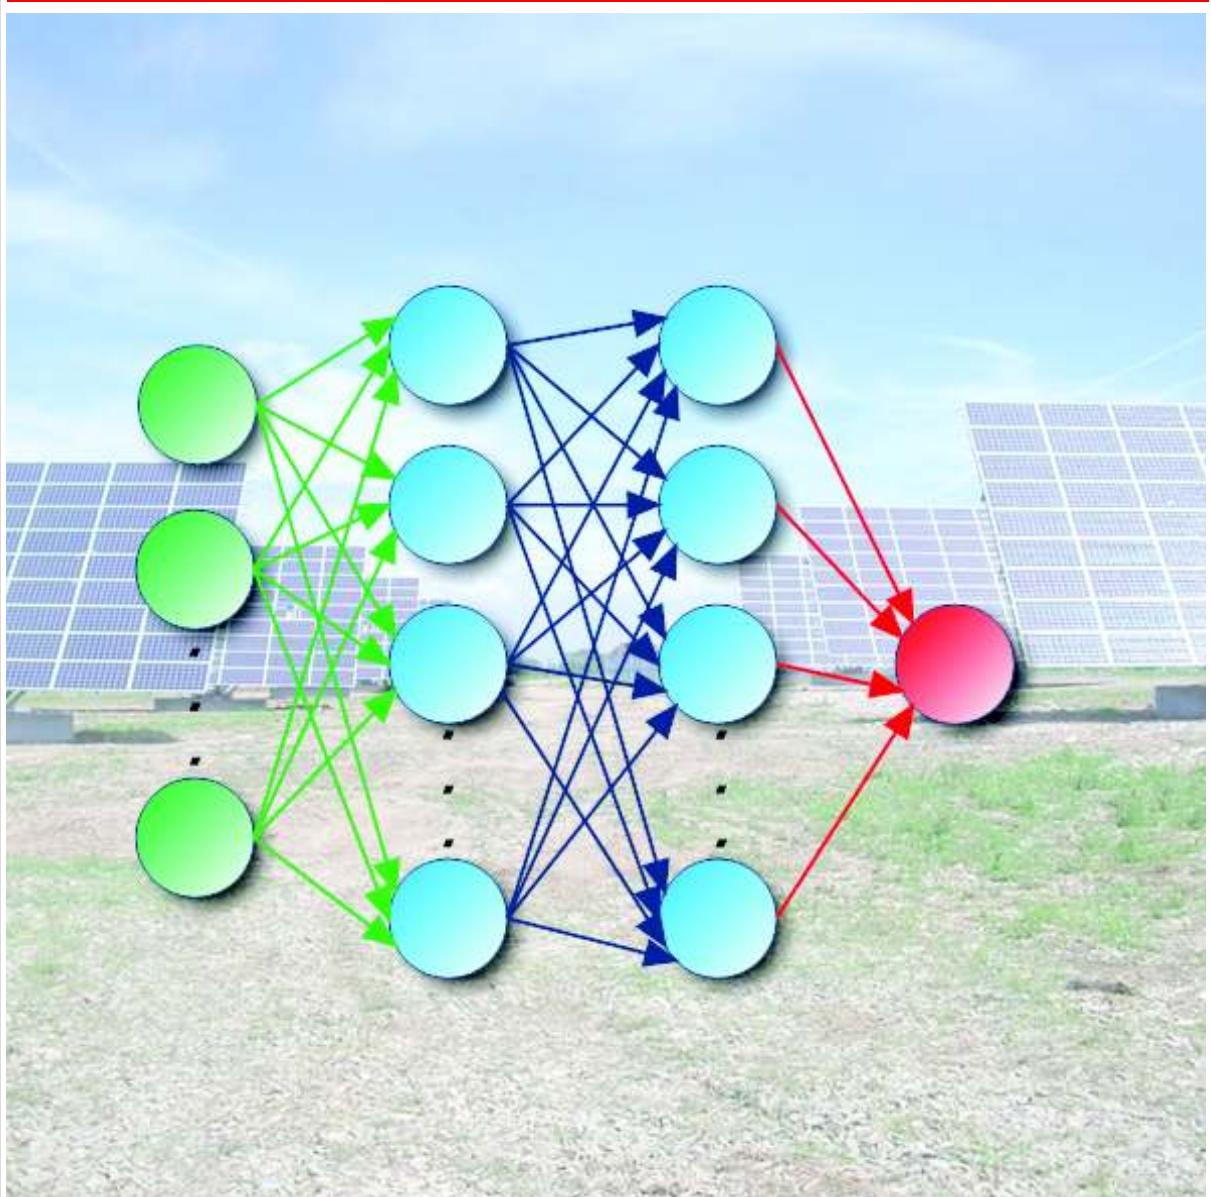


UNIVERSIDAD
DE LA RIOJA

Doctorado en Ingeniería Eléctrica, Matemáticas y Computación

TESIS DOCTORAL:

MODELOS DE PREDICCIÓN A CORTO PLAZO DE LA GENERACIÓN ELÉCTRICA EN INSTALACIONES FOTOVOLTAICAS

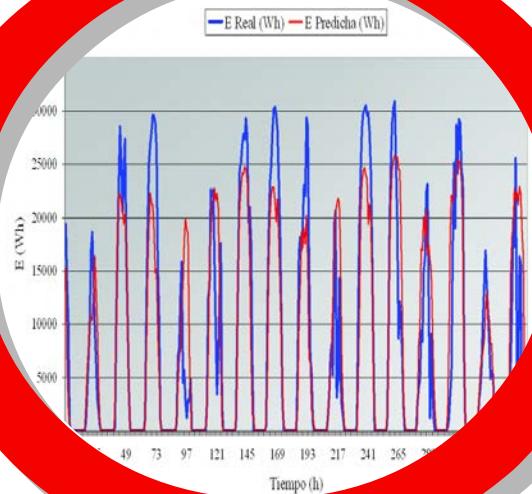
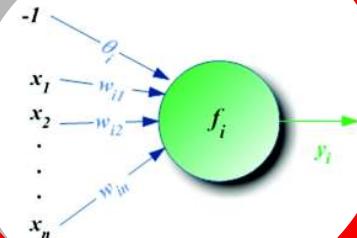


AUTOR: ANDRÉS MUÑOZ JIMÉNEZ

DIRECTOR: LUIS ALFREDO FERNÁNDEZ JIMÉNEZ

¿Qué busca esta investigación?

El objetivo principal es el desarrollo de un modelo de predicción que nos permita obtener las predicciones energéticas para el día siguiente (hora a hora) de una instalación solar fotovoltaica conectada a una red de distribución de energía eléctrica concreta.



Andrés Muñoz Jiménez

andres.munoz@alum.unirioja.es

RESUMEN

Las energías renovables, ya sea eólica, hidroeléctrica o solar, presentan un comportamiento que es harto complicado de prever. Pero conocer, estimar, la energía eléctrica que un sistema basado en energías renovables va a producir es de vital importancia. Hoy en día, la investigación y el desarrollo de modelos de predicción de producción fotovoltaica está creciendo ostensiblemente, además, si tenemos en cuenta la evolución de este tipo de energía durante los últimos años, es obvio que estos modelos van a ser necesarios, por lo que las investigaciones a las que se hace referencia en la presente Tesis Doctoral quedan justificadas.

Concretamente, el objetivo principal de dichas investigaciones es el desarrollo de un modelo de predicción que nos permita obtener las predicciones energéticas para el día siguiente (hora a hora) de una instalación solar fotovoltaica conectada a una red de distribución de energía eléctrica concreta. Además, como finalidad adicional nos encontramos con el desarrollo de modelos de predicción para horizontes mayores.

La razón por la que se ha fijado como plazo de predicción principal el día siguiente, es que, al igual que recientemente ocurrió con la energía eólica, los productores de energía fotovoltaica previsiblemente pasarán a participar en los mercados eléctricos para vender la energía producida, debido al incremento de la potencia en instalaciones fotovoltaicas, unido a un abaratamiento de los costes de producción de energía eléctrica en las mismas.

Podemos descomponer el desarrollo del modelo de predicción en dos partes diferenciadas que se relacionan entre sí. La primera que conlleva la elección del modelo de predicción meteorológica y su puesta en marcha. La segunda consiste en el estudio, desarrollo y evaluación de modelos de predicción de series temporales con el fin de obtener unos resultados que se aproximen en la mayor medida posible a la realidad. Además, se ha creído interesante desarrollar un conjunto de aplicaciones que nos permita utilizar el modelo desarrollado de una manera sencilla, obteniendo las predicciones energéticas.

Palabras clave: predicción a corto plazo, sistemas fotovoltaicos, redes neuronales artificiales, modelos atmosféricos, predicción numérica.

AGRADECIMIENTOS

Quiero aprovechar la ocasión para agradecer a las personas que, directa o indirectamente, han hecho posible el desarrollo de la presente Tesis Doctoral.

A mi tutor del Programa de Doctorado y Director de Tesis Doctoral, Luis Alfredo Fernández Jiménez, por su cercanía, su apoyo constante, sus consejos, en definitiva, por convertirse en mi padre académico.

Al resto de componentes del Grupo de Investigación de “Planificación, Operación y Control de Sistemas de Energía Eléctrica” del Departamento de Ingeniería Eléctrica de la Universidad de La Rioja, por su trato familiar y por su ayuda.

A Electra de Autol S.A., por proporcionarme los datos de producción eléctrica del parque fotovoltaico de Autol.

A mis compañeros de Los Boscos, Ángel, Enrique, Manuel, Miguel Ángel y Diego, por su amistad y su apoyo.

A mi grupo de Vecinos, por las barbacoas en familia que nos han hecho pasar tan buenos momentos.

A mi amigo Julio, por convertirse en mi crítico personal, dándome buenos consejos sobre cómo encauzar las explicaciones sobre la temática de las investigaciones vinculadas a la Tesis Doctoral.

A mi amigo Eladio, por esos domingos de película y palomitas en el sofá, en los períodos en los que el trabajo se hacía cuesta arriba.

A mi hermano Luis por ir abriéndome las puertas y a su hija Uxue, por esa fuerza que proporciona su sonrisita.

A mis padres, por habérmelo puesto todo tan fácil y por la educación que me han proporcionado.

A quién ha sabido comprenderme en todo momento, por su paciencia, por la valentía con la que se enfrenta a los momentos duros y por ser ella... a María.

“Un hombre con una idea nueva es un loco hasta que la idea triunfa.”

Mark Twain (1835-1910)

ÍNDICE

CAPÍTULO 1. INTRODUCCIÓN	1
1.1 ANTECEDENTES	1
1.2 MOTIVACIÓN.....	8
1.3 OBJETIVOS	9
1.4 ESTRUCTURA DE LA TESIS	11
CAPÍTULO 2. GENERACIÓN ELÉCTRICA EN PARQUES SOLARES FOTOVOLTAICOS	15
2.1 LA ENERGÍA SOLAR FOTOVOLTAICA.....	15
2.1.1 EL SOL Y SU RADIACIÓN	15
2.1.2 FUNDAMENTOS DE LA GENERACIÓN FOTOVOLTAICA.....	19
2.1.3 EVOLUCIÓN HISTÓRICA DEL MERCADO FOTOVOLTAICO	21
2.2 VENTAJAS DE LA PREDICCIÓN FOTOVOLTAICA	23
2.3 HORIZONTES DE PREDICCIÓN.....	26
2.4 INCERTIDUMBRE EN LA PREDICIÓN	28
CAPÍTULO 3. ESTADO DEL ARTE.....	29
3.1 PROCESO GENERAL DE DESARROLLO	29
3.2 CRITERIOS DE EVALUACIÓN DE LOS MODELOS DE PREDICCIÓN	31
3.3 ESTADO ACTUAL DE LOS MODELOS DE PREDICCIÓN	35
3.3.1 MODELOS BASADOS EN DATOS PASADOS.....	37
3.3.2 MODELOS BASADOS EN MODELOS ATMOSFÉRICOS.....	49
3.4 CONCLUSIONES.....	59
CAPÍTULO 4. MODELOS ATMOSFÉRICOS.....	63
4.1 FUNDAMENTOS DE LA MODELIZACIÓN NUMÉRICA	63
4.2 ESCALAS DE LOS MODELOS ATMOSFÉRICOS	64
4.3 MODELOS ATMOSFÉRICOS GLOBALES.....	66

4.4 MODELOS ATMOSFÉRICOS LOCALES	67
4.5 COMPONENTES DE UN NWP	69
4.6 MODELO MM5.....	74
4.7 MODELO WRF-NMM	77
4.8 CONCLUSIONES	81

CAPÍTULO 5. MODELOS DE PREDICCIÓN DE SERIES TEMPORALES.....83

5.1 MODELOS ARIMA	84
5.1.1 MODELOS AUTO-REGRESIVOS	85
5.1.2 MODELOS DE MEDIA MÓVIL.....	87
5.1.3 MODELOS ARMA.....	88
5.1.4 MODELOS ARIMA.....	88
5.1.5 MODELOS ARIMA CON ESTACIONALIDAD	89
5.1.6 IDENTIFICACIÓN DE MODELOS ARIMA.....	90
5.1.7 VENTAJAS E INCONVENIENTES	91
5.1.8 APLICACIÓN EN LA PREDICCIÓN DE LA PRODUCCIÓN	92
5.2 REDES NEURONALES ARTIFICIALES (ANN).....	92
5.2.1 RED NEURONAL MLP (PERCEPTRÓN MULTICAPA)	95
5.2.2 RED NEURONAL RBF	98
5.2.3 RED NEURONAL WAVELET	100
5.2.4 OPTIMIZACIÓN CON ALGORITMOS GENÉTICOS	104
5.2.5 OPTIMIZACIÓN PSO (PARTICLE SWARM OPTIMIZATION)	109
5.2.6 VENTAJAS E INCONVENIENTES	111
5.2.7 APLICACIÓN EN LA PREDICCIÓN DE LA PRODUCCIÓN	111
5.3 SISTEMAS DE INFERENCIA DIFUSA O FUZZY.....	112
5.3.1 ESTRUCTURA DE LOS SISTEMAS DE INFERENCIA DIFUSA.....	114
5.3.2 SISTEMAS DE INFERENCIA DIFUSA DE TAKAGI-SUGENO	116
5.3.3 PARTICIÓN DEL ESPACIO DE ENTRADA.....	117
5.3.4 SISTEMAS NEURO-DIFUSOS.....	120
5.3.5 VENTAJAS E INCONVENIENTES	122
5.3.6 APLICACIÓN EN LA PREDICCIÓN DE LA PRODUCCIÓN	123
5.4 OTROS MODELOS	124
5.4.1 MODELO DE LOS K VECINOS MÁS PRÓXIMOS (K-NN)	124
5.4.2 MODELOS GRISES.....	126
5.4.3 MÁQUINAS DE VECTORES SOPORTE (SVMs).....	128
5.4.4 MODELO DE DÍA CLARO (CIELO CLARO)	130

5.4.5 OTROS MODELOS	132
5.5 MODELOS HÍBRIDOS	133
5.6 ASPECTOS A TENER EN CUENTA.....	134
CAPÍTULO 6. DESARROLLO DE LOS MODELOS	137
6.1 GENERALIDADES SOBRE EL DESARROLLO	138
6.1.1 ESTRUCTURA GENERAL	138
6.1.2 FLUJOGRAMA DEL DESARROLLO: MODELO MM5	140
6.1.3 FLUJOGRAMA DEL DESARROLLO: MODELO WRF	141
6.2 DATOS DE PARTIDA: MODELOS BASADOS EN MM5.....	142
6.2.1 SELECCIÓN Y NORMALIZACIÓN DE VARIABLES DE ENTRADA.....	143
6.2.2 CLASIFICACIÓN DE DATOS PARA EL DESARROLLO	146
6.2.3 FILTRADO DE DATOS.....	149
6.3 DATOS DE PARTIDA: MODELOS BASADOS EN WRF	150
6.3.1 SELECCIÓN Y NORMALIZACIÓN DE VARIABLES DE ENTRADA.....	151
6.3.2 CLASIFICACIÓN DE DATOS PARA EL DESARROLLO	152
6.3.3 INCORPORACIÓN DE DATOS ESTADÍSTICOS COMO NUEVAS ENTRADAS	156
6.3.4 FILTRADO DE DATOS.....	161
6.4 MODELO MM5	162
6.4.1 CONFIGURACIÓN DEL MM5	163
6.4.2 PROGRAMA DE EJECUCIÓN AUTOMÁTICA: PREDICEFV	171
6.5 CONFIGURACIÓN DEL MODELO WRF-NMM	174
6.6 MODELOS DESARROLLADOS BASADOS EN MM5	176
6.6.1 MODELOS CLÁSICOS Y OTROS.....	177
6.6.2 MODELOS BASADOS EN REDES NEURONALES ARTIFICIALES	178
6.6.3 MODELOS BASADOS EN INFERENCIA NEURODIFUSA.....	192
6.7 MODELOS DESARROLLADOS BASADOS EN WRF	193
6.7.1 MODELOS DESARROLLADOS EN LA 1 ^a FASE	196
6.7.2 MODELOS DESARROLLADOS EN LA 2 ^a FASE	203
6.7.3 COMBINACIÓN DE MODELOS	210

CAPÍTULO 7. EVALUACIÓN DE LOS MODELOS 213

7.1 RESULTADOS GENERALES: MODELOS BASADOS EN MM5	215
7.2 ANÁLISIS DETALLADO DEL MODELO ÓPTIMO BASADO EN MM5	224
7.3 RESULTADOS GENERALES: MODELOS BASADOS EN WRF	228
7.3.1 MODELOS DESARROLLADOS EN LA 1 ^a FASE.....	228
7.3.2 MODELOS DESARROLLADOS EN LA 2 ^a FASE.....	234
7.3.3 COMBINACIÓN DE MODELOS	242
7.4 ANÁLISIS DETALLADO DE LOS MODELOS ÓPTIMOS BASADOS EN WRF	247
7.4.1 MODELODEFINITIVO24H	248
7.4.2 MODELODEFINITIVO48H	250
7.4.3 MODELODEFINITIVO72H	252
7.4.4 TABLAS RESUMEN	252

CAPÍTULO 8. CONCLUSIONES 257

8.1 CONCLUSIONES DE LAS INVESTIGACIONES.....	257
8.2 FUTURAS LÍNEAS DE INVESTIGACIÓN.....	260

REFERENCIAS 263

ANEXO 1. DESARROLLO DE LA APLICACIÓN INFORMÁTICA PREFO-RED 281

I.1 ESTRUCTURA DE PREFO-RED	283
I.2 APLICACIÓN GENERAL PREFO-RED	285

LISTA DE FIGURAS

Figura 1. 1 Evolución histórica de la potencia fotovoltaica instalada por región [EPIA14]	3
Figura 1. 2 Potencia instalada total/incremento 2013 por país (Europa)	4
Figura 1. 3 Potencia FV instalada por país	5
Figura 1. 4 Evolución de la potencia solar fotovoltaica instalada en España.....	6
Figura 1. 5 Demanda de Energía Eléctrica en tiempo real (www.ree.es)	10
Figura 2. 1 Regiones solares	16
Figura 2. 2 Espectro de radiación del cuerpo negro.....	16
Figura 2. 3 Radiación directa y difusa	18
Figura 2. 4 Radiación incidente sobre un panel fotovoltaico	18
Figura 2. 5 Circuito equivalente del panel solar fotovoltaico	20
Figura 2. 6 Evolución histórica de la potencia fotovoltaica instalada (MW) en Europa [EPIA13]	23
Figura 3. 1 Representación esquemática del modelo de predicción de [Bofinger06] ..	50
Figura 4. 1 Ejemplo de anidamiento de dominios	68
Figura 4. 2 Estructura general de los componentes de los modelos numéricos de predicción	69
Figura 4. 3 Figura genérica de la radiación solar	70

Figura 4. 4 Incidencia del tipo de suelo y vegetación en la modelización numérica	71
Figura 4. 5 Nubes de gran escala y su precipitación	71
Figura 4. 6 Esquema de la dinámica convectiva.....	72
Figura 4. 7 Representación esquemática de la estructura vertical del MM5 (σ)	73
Figura 4. 8 Estructura del MM5	75
Figura 4. 9 Esquema de funcionamiento del Regrid	76
Figura 4. 10 Estructura del WRF-NMM	78
Figura 4. 11 Esquema de funcionamiento del WPS.....	79
Figura 5. 1 Estructura de una neurona.....	93
Figura 5. 2 MLP con una capa oculta.....	96
Figura 5. 3 Estructura general de una red RBF	98
Figura 5. 4 Red neuronal Wavelet simple	102
Figura 5. 5 Red neuronal Wavelet general (multidimensional)	103
Figura 5. 6 Ejemplo de funciones de pertenencia de tipo gaussiano.....	114
Figura 5. 7 Estructura de un sistema de inferencia difusa	114
Figura 5. 8 Sistema de inferencia difusa con dos entradas y dos reglas	120
Figura 5. 9 Red equivalente al sistema de inferencia difusa de dos entradas y dos reglas.....	122

Figura 6. 1 Estructura General del Modelo.....	139
Figura 6. 2 Flujograma de tareas para desarrollar el Modelo de Predicción basado en MM5	140
Figura 6. 3 Flujograma de tareas para desarrollar el Modelo de Predicción basado en WRF	141
Figura 6. 4 Energía generada desde el 2 hasta el 6 de Junio de 2007 (Rincón de Soto)	142
Figura 6. 5 Energía generada desde el 2 hasta el 6 de Junio de 2009 (Autol)	150
Figura 6. 6 Disposición de los Dominios	163
Figura 6. 7 Zona de los datos de altimetría (A: W020N90.DEM y B: W020N40.DEM)	165
Figura 6. 8 Flujograma de funcionamiento de PREDICEFV	172
Figura 6. 9 Definición de dominios mediante WRF Domain Wizard.....	175
Figura 6. 10 Flujograma de desarrollo de los Modelos de Predicción.....	176
Figura 6. 11 Estructura de la red neuronal MLP de dos capas ocultas.....	179
Figura 6. 12 Red neuronal unidireccional multicapa generalizada, FFBP, con una capa oculta.....	180
Figura 6. 13 Estructura de la red neuronal FFBPP de dos capas ocultas.....	180
Figura 6. 14 Estructura de la red neuronal MNN de dos capas ocultas.....	182
Figura 6. 15 Principio de red neuronal PCA.....	183
Figura 6. 16 Mapa auto-organizado (SOM).....	186
Figura 6. 17 Red neuronal Recurrente de Elman.....	187
Figura 6. 18 Estructura de la red neuronal Elman de dos capas ocultas	188

Figura 6. 19 Red neuronal TDNN focalizada	190
Figura 6. 20 Flujograma de desarrollo de los Modelos de Predicción 1 ^a Fase	194
Figura 6. 21 Flujograma de desarrollo de los Modelos de Predicción 2 ^a Fase	195
Figura 6. 22 Definición de parámetros modelo ANFIS (ejemplo).....	202
Figura 6. 23 Flujograma del proceso de combinación final.....	210
Figura 7. 1 Representación gráfica del error RMSE en función del horizonte de predicción del ARIMA (3,0,2)(1,0,0)24	217
Figura 7. 2 Representación gráfica del error RMSE en función del nº de vecinos del modelo del vecino más próximo.....	218
Figura 7. 3 Representación gráfica del grupo de testeo frente a sus predicciones (ANFIS 2A).....	219
Figura 7. 4 Gráfico de sensibilidad de las variables de entrada (MLP 2A)	225
Figura 7. 5 Gráfico de comparación entre la energía real generada y la predicha	226
Figura 7. 6 Representación gráfica del grupo de testeo frente a sus predicciones (ANFIS224)	229
Figura 7. 7 Estructura de los modelos globales desarrollados en la 2 ^a fase.....	242
Figura 7. 8 Estructura de los Modelos Definitivos	247
Figura 7. 9 Comparación entre la energía real generada y la predicha (ModeloDefinitivo24H).....	250
Figura 7. 10 Comparación entre la energía real generada y la predicha (ModeloDefinitivo48H).....	251
Figura 7. 11 Comparación entre la energía real generada y la predicha (ModeloDefinitivo48H).....	252

Figura A1. 1 Estructura de carpetas de PREFO-RED..... 282

Figura A1. 2 Flujograma de funcionamiento de la aplicación general PREFO-RED.. 286

LISTA DE TABLAS

Tabla 3. 1 Características principales de los modelos de predicción basados en datos históricos	47
Tabla 3. 2 Principales variables relacionadas con la producción fotovoltaica.....	49
Tabla 3. 3 Características principales de los modelos de predicción basados en modelos atmosféricos	58
Tabla 4. 1 Escalas espacio-temporales de los modelos atmosféricos	65
Tabla 4. 2 Modelos NWP Globales	66
Tabla 6. 1 Variables utilizadas (Modelos s/MM5).....	145
Tabla 6. 2 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos (División tipo A)	147
Tabla 6. 3 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos (División tipo B)	148
Tabla 6. 4 Variables utilizadas inicialmente (Modelos s/WRF)	151
Tabla 6. 5 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos (1 ^a Fase).....	153
Tabla 6. 6 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos para día claro (2 ^a Fase).....	154
Tabla 6. 7 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos para día nublado (2 ^a Fase).....	154

Tabla 6. 8 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos para día muy nublado o lluvioso (2 ^a Fase).....	155
Tabla 6. 9 Información de los dominios escogidos.....	164
Tabla 6. 10 Archivos de datos de altimetría del terreno utilizados.....	164
Tabla 6. 11 Archivos de usos del suelo utilizados.....	165
Tabla 6. 12 Categorías de usos del suelo de la NCAR.....	166
Tabla 6. 13 Archivos de vegetación	166
Tabla 6. 14 Categorías de vegetación de USGS	167
Tabla 6. 15 Archivos de zonas de tierra inundada	167
Tabla 6. 16 Categorías de Suelo.....	168
Tabla 6. 17 Categorías del suelo de la FAO+STATSGO	168
Tabla 6. 18 Lista de archivos del gfs model utilizados para el MM5	169
Tabla 6. 19 Parametrizaciones físicas	170
Tabla 6. 20 Condiciones de Contorno	171
Tabla 7. 1 Coeficientes del modelo ARIMA (3, 0, 2)(1, 0, 0)24	216
Tabla 7. 2 Resultados iniciales con redes neuronales	220
Tabla 7. 3 Errores RMSE para los modelos de predicción desarrollados	222
Tabla 7. 4 Errores MAE y ME para el modelo de predicción MLP 2A.....	225
Tabla 7. 5 Diferencia entre la energía total real y predicha para el grupo de testeo propio	226

Tabla 7. 6 Diferencia entre la energía total real y predicha para el grupo de testeo común.....	226
Tabla 7. 7 Resultados de los modelos de la 1 ^a Fase (Horizonte 1 día)	231
Tabla 7. 8 Resultados de los modelos de la 1 ^a Fase (Horizonte 2 días).....	232
Tabla 7. 9 Resultados de los modelos de la 1 ^a Fase (Horizonte 3 días).....	233
Tabla 7. 10 Resultados de los modelos de la 2 ^a Fase (Horizonte 1 día – Día Claro) 236	
Tabla 7. 11 Resultados de los modelos de la 2 ^a Fase (Horizonte 1 día – Día Nublado)	237
Tabla 7. 12 Resultados de los modelos de la 2 ^a Fase (Horizonte 1 día – Día Muy Nublado/lluvioso).....	237
Tabla 7. 13 Resultados de los modelos de la 2 ^a Fase (Horizonte 2 días – Día Claro)	238
Tabla 7. 14 Resultados de los modelos de la 2 ^a Fase (Horizonte 2 días – Día Nublado)	238
Tabla 7. 15 Resultados de los modelos de la 2 ^a Fase (Horizonte 2 días–Día Muy Nublado/lluvioso).....	238
Tabla 7. 16 Resultados de los modelos de la 2 ^a Fase (Horizonte 3 días – Día Claro)	239
Tabla 7. 17 Resultados de los modelos de la 2 ^a Fase (Horizonte 3 días – Día Nublado)	239
Tabla 7. 18 Resultados de los modelos de la 2 ^a Fase (Horizonte 3 días–Día Muy Nublado/lluvioso).....	240
Tabla 7. 19 Resultados globales del Modelo24H de la 2 ^a Fase.....	240
Tabla 7. 20 Resultados globales del Modelo48H de la 2 ^a Fase.....	241
Tabla 7. 21 Resultados globales del Modelo72H de la 2 ^a Fase.....	241

Tabla 7. 22 Mejores redes neuronales (Horizonte 1 día – Día Claro)	243
Tabla 7. 23 Mejores redes neuronales (Horizonte 1 día – Día Nublado)	243
Tabla 7. 24 Mejores redes neuronales (Horizonte 1 día – Día Muy nublado / lluvioso)	243
Tabla 7. 25 Mejores redes neuronales (Horizonte 2 días – Día Claro)	244
Tabla 7. 26 Mejores redes neuronales (Horizonte 2 días – Día Nublado)	244
Tabla 7. 27 Mejores redes neuronales (Horizonte 2 días – Día Muy nublado / lluvioso)	244
Tabla 7. 28 Mejores redes neuronales (Horizonte 3 días – Día Claro)	245
Tabla 7. 29 Mejores redes neuronales (Horizonte 3 días – Día Nublado)	245
Tabla 7. 30 Mejores redes neuronales (Horizonte 3 días – Día Muy nublado / lluvioso)	245
Tabla 7. 31 Resultados globales del ModeloDefinitivo24H	246
Tabla 7. 32 Resultados globales del ModeloDefinitivo48H	246
Tabla 7. 33 Resultados globales del ModeloDefinitivo72H	247
Tabla 7. 34 Errores MAE y ME para el ModeloDefinitivo24H.....	248
Tabla 7. 35 Mejoras del ModeloDefinitivo24H.....	249
Tabla 7. 36 Mejora del ModeloDefinitivo24H respecto a [Yona13]	249
Tabla 7. 37 Errores MAE y ME para el ModeloDefinitivo48H.....	250
Tabla 7. 38 Errores MAE y ME para el ModeloDefinitivo72H.....	252
Tabla 7. 39 Leyenda de variables de entrada	253
Tabla 7. 40 Resumen de las características de las redes neuronales que componen el ModeloDefinitivo24H	254

Tabla 7. 41 Resumen de las características de las redes neuronales que componen el
ModeloDefinitivo48H 255

Tabla 7. 42 Resumen de las características de las redes neuronales que componen el
ModeloDefinitivo72H 256

Tabla A1. 1 Modelo de tabla de la hoja Predicciones 284

ABREVIATURAS

11CHLIE: 11^a Conferencia Hispano-Lusa de Ingeniería Eléctrica

ACF: Función de Auto-Correlación

AIC: Criterio de Información de Akaike

ANCFIS: sistemas neurodifusos Complejos

ANFIS: Adaptive Neuro-Fuzzy Inference Systems (sistemas neurodifusos)

ANN: Artificial Neural Network (red neuronal artificial)

ARIMA: Modelos Auto-regresivos Integrados de Medias Móviles

ARPS: Advanced Regional Prediction System

ART: Teoría de la Resonancia Adaptativa

AVN: Aviation Model

CMNUCC: Convención Marco de las Naciones Unidas sobre el Cambio Climático

COAMPS: US Navy's Coupled Ocean/Atmosphere Mesoscale Prediction System

DTDNN: red neuronal retardada en el tiempo distribuida

ECaSS : Sistema condensador de energía

ECMWF: European Center for Midrange Weather Forecast

EKF: Filtro Kalman Extendido

ETSII: Escuela Técnica Superior de Ingeniería Industrial

FAO: Food and Agriculture Organization

FDDA: Four Dimensional Data Assimilation

FDT: Fuzzy Decision Tree (árbol de decisiones Fuzzy)

FF: algoritmo de optimización FireFly

FFBP (FFBPNN): Unidireccional multicapa generalizada (red neuronal)

FTDNN: red neuronal retardada en el tiempo focalizada

FV: Fotovoltaica

GA: Algoritmo Genético

GEI: Gases con Efecto Invernadero

GEM: Global Environmental Multiscale Model

GFS: Global Forecast System

GM: Modelo gris

HIRLAM: High Resolution Limited Area Model (NWP)

IDW: Inverse Distance Weighted

IGCM: Intermediate General Circulation Model

k-NN: k-nearest neighbor model (modelo del vecino más próximo)

LHFLUX: Surface Latent Heat FLUX

LWDOWN: LongWave DOWNward radiation

LWOUT: Top OUTgoing LongWave radiation

MAE: Error Absoluto Medio

MASS: Mesoscale Atmospheric Simulation System

MC2: Mesoscale Compressible Community Model

ME: Error Medio

MEMO: Mesoscale Model

Meso-NH: Mesoscale no-Hidrostatic Atmospheric Simulation System

MFS: membership functions

Mibel: Mercado Ibérico de la Electricidad

MLP (MLPNN): Perceptrón Multicapa (red neuronal)

MM5: Penn State/NCAR Mesoscale Model, Version 5

MMA: Ministerio de Medio Ambiente

MNN: red neuronal modular

MOS: Model Output Statistics

MPPT: Punto de máxima potencia

MRAN: algoritmo de optimización Minimal Resource Allocating Network

MSC: Meteorological Service of Canada

NCAR: National Center Atmospheric Research

NCEP: National Centers for Environmental Prediction

NEA: National Environment Agency

NN: Red neuronal

NOAA: National Oceanic and Atmospheric Administration

NPD/JMA: Agencia Meteorológica Japonesa

NWP: Numerical Weather Prediction (modelos atmosféricos de predicción numérica)

OMEL: Operadora del Mercado Ibérico de Energía - Polo Español, S.A

PACF: Función de Auto-Correlación Parcial

PCA: Análisis de componentes principales (red neuronal)

PREFO-RED: sistema de PREdicción de generación eléctrica FOtovoltaica para instalaciones solares conectadas a RED

PSO: Particle Swarm Optimization (optimización por enjambre o nube de partículas)

PSU: Pennsylvania University

PVGIS: Photovoltaic Geographical Information System

RBF (RBFNN): Función de base radial (red neuronal)

RD: Real Decreto

REE: Red Eléctrica de España

RMSE: Error cuadrático medio

RMSE: Raíz del Error cuadrático Medio

SHFLUX: Surface Sensible Heat FLUX

SOM: Mapas auto-organizados

STATSGO: U.S. General Soil Map

SVM: Máquinas de Vector Soporte

SVR: Support Vector Regression (tipo de máquina de vector soporte)

SWDOWN: ShortWave DOWNward radiation

SWOUT: Top OUTgoing ShortWave radiation

TDNN: Red neuronal retardada en el tiempo

TSK: Takagi-Sugeno-Kang

UM: Unified Model

UR: Universidad de La Rioja

USGS: U.S. Geological Survey

WRF: Weather Research and Forecast Model

WRF-NMM: Weather Research and Forecast Nonhydrostatic Mesoscale Model

WSVM: Máquinas de Vector Soporte con asignación de pesos

MODELOS DE PREDICCIÓN A CORTO PLAZO DE LA GENERACIÓN
ELÉCTRICA EN INSTALACIONES FOTOVOLTAICAS

DOCTORADO EN INGENIERÍA ELÉCTRICA, MATEMÁTICAS Y COMPUTACIÓN

CAPÍTULO

1

INTRODUCCIÓN

La presente Tesis Doctoral ha sido realizada en el programa de Doctorado en Ingeniería Eléctrica, Matemáticas y Computación, en la Escuela Técnica Superior de Ingeniería Industrial (ETSII) de la Universidad de La Rioja (UR).

En este primer capítulo se expondrá la temática de la Tesis, con el fin de remarcar la importancia en el panorama energético actual de las investigaciones expuestas, así como la motivación y los objetivos asociados a dicha línea de investigación. Al final del capítulo se presenta una breve descripción sobre la estructura adoptada en el presente documento.

1.1 ANTECEDENTES

Las energías renovables han captado la atención tanto de las autoridades como de la opinión pública en los últimos años. El aprovechamiento de las energías renovables implica importantes ventajas ambientales, entre ellas el hecho de que se tratan de energías con una contaminación mínima y además no dependen de fuentes energéticas exteriores. Además las instalaciones de generación eléctrica basadas en recursos renovables pueden servir como factor de estabilización de la población en zonas con riesgo de despoblación [MMA10a].

Es cierto, que hoy en día el uso de los combustibles fósiles es fundamental para las necesidades presentes en la economía, sobre todo el aseguramiento de

abastecimiento energético, pero su uso también implica elevados impactos ambientales, a nivel local y global, sobre todo si no se respeta la emisión de gases con efecto invernadero (GEI) [MMA10b].

Dentro del marco de la Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC), el 11 de diciembre de 1997 los países industrializados se comprometieron, en la ciudad de Kioto, a ejecutar un conjunto de medidas para reducir los gases de efecto invernadero. Los gobiernos signatarios de dichos países pactaron reducir en al menos un 5% en promedio las emisiones contaminantes entre 2008 y 2012, tomando como referencia los niveles de 1990. El acuerdo entró en vigor el 16 de febrero de 2005, después de la ratificación por parte de Rusia el 18 de noviembre de 2004. En este ámbito, España se obligó a limitar el aumento de sus emisiones a un 15 % respecto al año base [Naciones98].

Teniendo en cuenta el ritmo actual de explotación de los combustibles fósiles se prevé que en un futuro próximo las reservas se agoten, por esta razón, con el fin de evitar este hecho y prevenir una crisis energética, el uso de las energías renovables se hace indispensable.

La apuesta por las energías renovables implica una gran exigencia, por lo que se hace necesario evolucionar con las tecnologías de fabricación. Concretamente, en el caso de los paneles solares fotovoltaicos, se han desarrollado recientemente nuevas células solares que reducen en gran medida el coste de las actuales, las dimensiones (por unidad de potencia) y, además, mejoran ostensiblemente su rendimiento [Liu10].

Del mismo modo, es preciso establecer un justo equilibrio entre los incentivos dados a los productores y además mantener unas tarifas competitivas.

Las tecnologías asociadas a las energías renovables reciben gran atención por parte de los gobiernos, industria y consumidores, reflejando la creciente concienciación de los beneficios sociales, económicos y ambientales, que estas ofrecen [MNRC06].

La energía eólica ha sido la energía renovable que más se ha desarrollado en los últimos años. La potencia instalada en los parques eólicos existentes en todo el mundo, pasó de 7.5 GW en 1997 a 121 GW a finales de 2008, alcanzando así el 1.5% de la

energía eléctrica generada en todo el mundo [WWEA09]. Al finalizar Junio de 2013 ya se alcanzaron los 296 GW, superando hoy en día los 320 GW.

Tras el gran interés mostrado por la energía eólica, el interés por la energía solar fotovoltaica (FV) sigue un curso similar. Mundialmente la potencia instalada ha pasado de 0.1 GW en 1992 a 24 GW en 2009, 40 GW en 2010, 70 GW en 2011, 100 GW en 2012 y superando los 138 GW en 2013, [EPIA12], [EPIA13] y [EPIA14].

En el siguiente gráfico, Figura 1. 1, podemos observar la evolución de la potencia fotovoltaica instalada a nivel mundial desde el 2000 hasta el 2013:

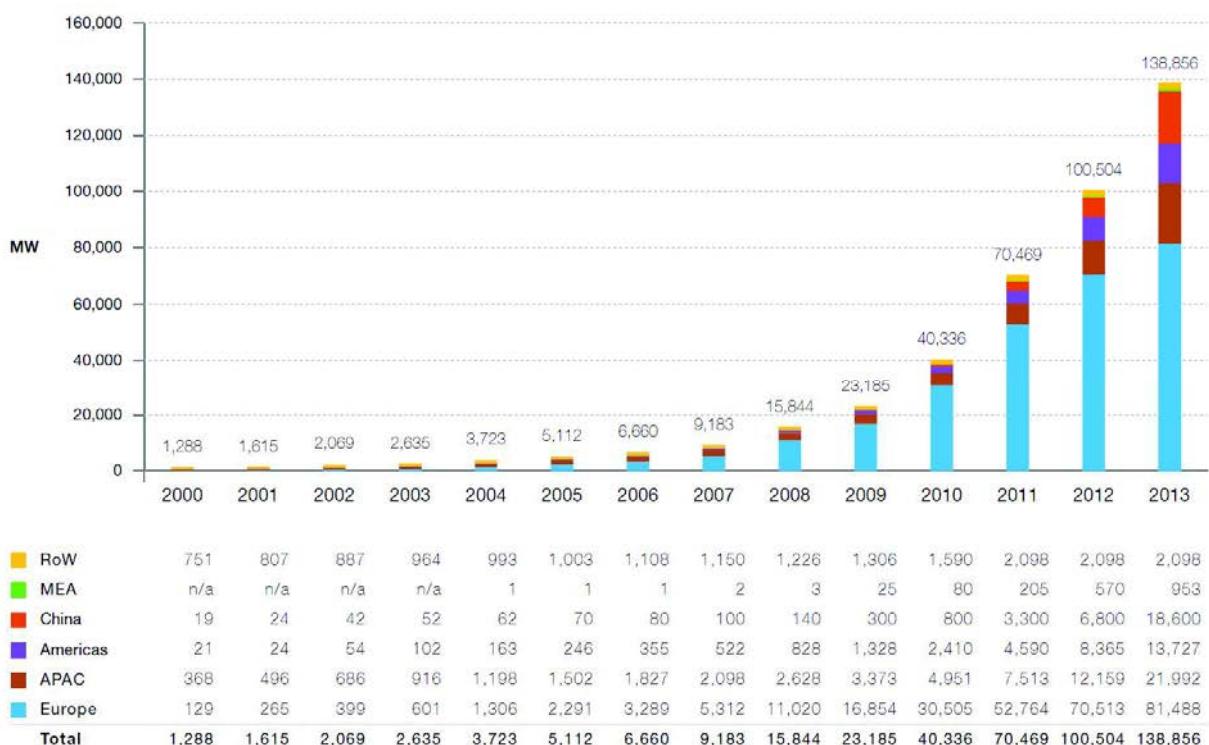


Figura 1. 1 Evolución histórica de la potencia fotovoltaica instalada por región [EPIA14]

Tal y como se comentaba con anterioridad al finalizar 2013 la potencia instalada ya superaba los 138 GW. A la vista de la gráfica la superioridad de Europa frente al resto del mundo es patente (casi el 60% de la potencia total instalada), siendo destacable el incremento sufrido por China en los últimos años.

A continuación, Figura 1. 2, podemos ver la potencia total instalada (naranja) y el incremento de 2013 (azul) por país en Europa [EurObserv14].

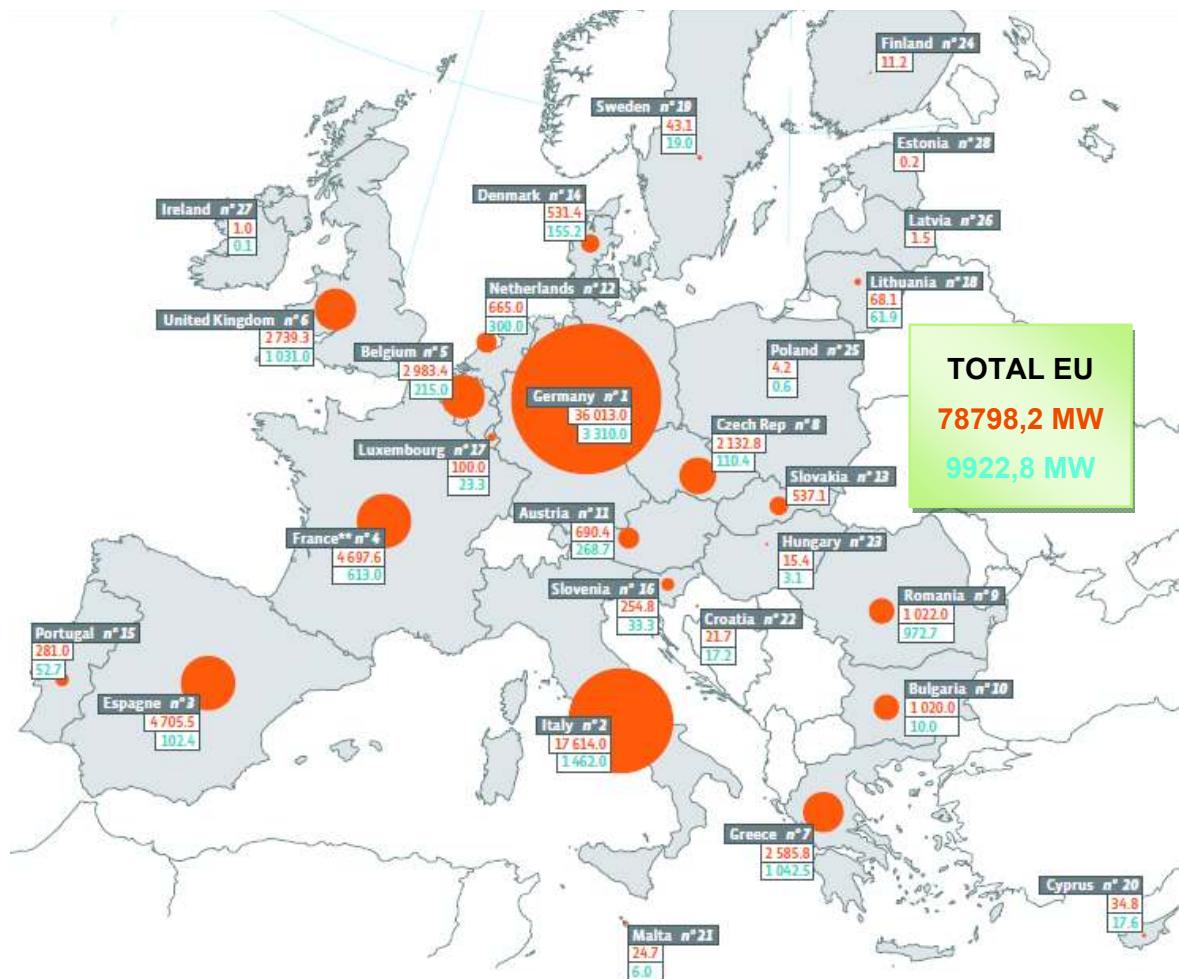


Figura 1. 2 Potencia instalada total/incremento 2013 por país (Europa) [EurObserv14]

Actualmente (2014), el crecimiento de la potencia instalada en España se ha decelerado debido a la crisis económica actual, en 2008 era el país con mayor potencia instalada, mientras que ahora se encuentra en tercer lugar tras Alemania e Italia. A continuación, en la Figura 1. 3, aparece un gráfico de sectores en el que se representa la capacidad fotovoltaica presente en los países punteros en 2013 [EPIA14].

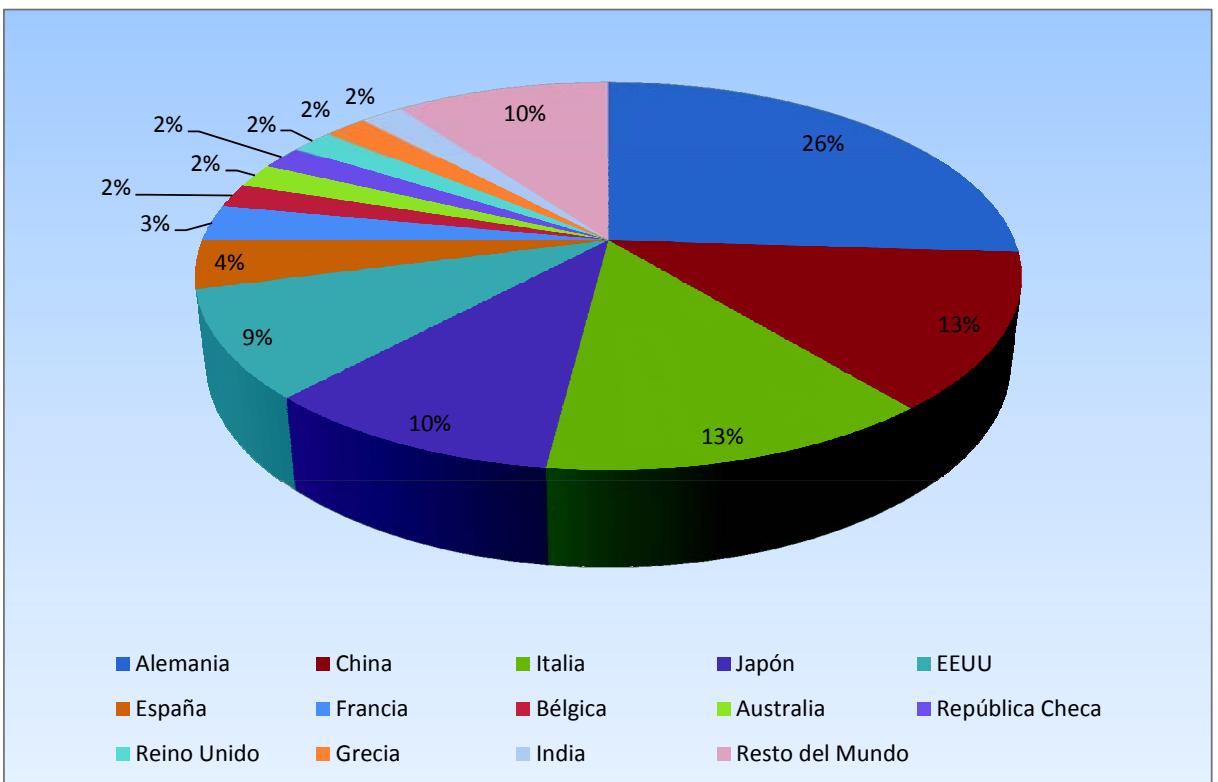


Figura 1. 3 Potencia FV instalada por país

Los sistemas fotovoltaicos se pueden dividir en dos grandes grupos, los sistemas conectados a red y los sistemas autónomos. En los sistemas autónomos, el aprovechamiento de la energía solar tiene que estar ajustado a la demanda de energía y, puesto que la energía producida no coincide con la demanda en la mayoría de los casos, se debe disponer de otra fuente generadora de energía. Por lo tanto, es imprescindible considerar los sistemas de almacenamiento (baterías) y los medios de apoyo, o la producción de energía adicional (sistemas híbridos) [GREEN04].

Se ha pasado de pequeñas instalaciones cuya potencia instalada era, como mucho, de decenas de kW, a las más modernas instalaciones con una potencia instalada de decenas de MW. La potencia instalada en estos parques solares fotovoltaicos recuerda a la de los parques eólicos hace prácticamente dos décadas. En un primer momento, los parques eólicos vertían a la red eléctrica la energía eléctrica generada, recibiendo la compensación económica correspondiente. Estas compensaciones podían incluir subvenciones o primas para hacer competitivas a este tipo de instalaciones y estimular así su proliferación. Pero la reducción de los costes de instalación y nuevas

políticas energéticas, con nuevos incentivos, propiciaron que, en algunos países, la mayoría de los parques eólicos pudieran vender la energía eléctrica producida en el mercado eléctrico. Este es el caso de España, donde desde el año 2004 la mayoría de los parques eólicos actúan como un productor más en el mercado eléctrico.

Teniendo en cuenta lo comentado en el párrafo anterior, es de esperar que con la energía solar fotovoltaica ocurra algo similar, ya que el crecimiento que ha sufrido durante los últimos años en España [CNE13], ver Figura 1. 4, recuerda en gran medida al sufrido por la energía eólica.

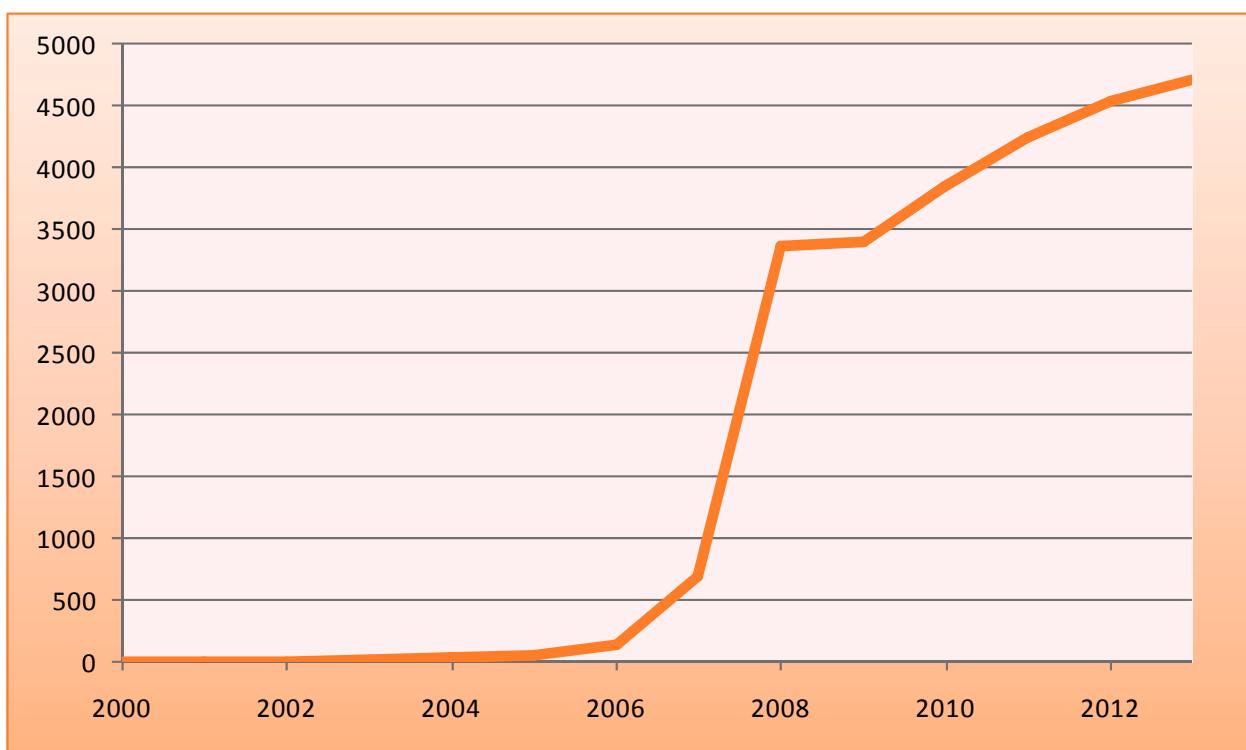


Figura 1. 4 Evolución de la potencia solar fotovoltaica instalada en España

Los productores de energía eléctrica fotovoltaica, no dedicados al autoconsumo, vierten la energía producida a la red y reciben por ella una compensación económica, cuyas primas eran considerables hasta 2011-2012, momento a partir del cual el Gobierno comenzó a introducir medidas restrictivas y con carácter retroactivo que disminuyen la rentabilidad de las instalaciones fotovoltaicas. Por todo lo comentado con anterioridad, si los productores de energía solar fotovoltaica pasan a participar en el Mercado Eléctrico Español, tendrán que cumplir unas directrices. Las reglas del mercado eléctrico obligan a

que cada productor proporcione al operador del mismo, en los periodos establecidos, los valores de la energía que va a verter en la red para cada una de las horas cubiertas por la sesión correspondiente. La sesión más importante en el mercado eléctrico es la sesión diaria, para la que los productores deben presentar sus valores de generación para cada una de las 24 horas del día siguiente. La hora a la que se celebra la sesión del mercado diario difiere según el país; en el caso de España [BOE06], esta sesión tiene lugar a las 10:00. Actualmente el Operador del Mercado Eléctrico es la compañía OMEL (Operadora del Mercado Ibérico de Energía - Polo Español, S.A.), operadora española dentro del Mercado Ibérico de la Electricidad (Mibel).

Si los valores de energía ofertada no se corresponden con la realmente generada, el productor es penalizado económicoamente de acuerdo a las reglas del mercado. Obviamente, los valores de generación aportados por el gestor de un parque eólico no son sino predicciones de generación. Por tanto, cuanto menor sea el error cometido en estas predicciones menor es la penalización y por tanto, mayor es el beneficio obtenido por la venta de la energía producida. La necesidad, por parte de los gestores de los parques eólicos, de disponer de predicciones de la generación eléctrica en sus instalaciones, ha impulsado el desarrollo de modelos de predicción que determinen, con el menor error posible, la producción eléctrica horaria para el día siguiente. Así, en los últimos años se han desarrollado un conjunto de modelos de predicción de la generación eléctrica a corto plazo en un parque eólico por varios equipos de investigación [Costa08], pero en el ámbito fotovoltaico apenas se han publicado modelos.

Como ya se ha comentado con anterioridad, la potencia fotovoltaica instalada ha crecido considerablemente y, unido al abaratamiento de costes en paneles fotovoltaicos [Curtright08] (se ha pasado de un precio medio de 3 €/Wp en 2008 a 0,5-0,6 €/Wp en 2013) hace que esta tecnología sea cada vez más competitiva, en términos económicos, frente a otras fuentes de energía. Así, el incremento de la potencia en instalaciones fotovoltaicas, unido a un abaratamiento de los costes de producción de energía eléctrica en las mismas, permitirá en un futuro próximo que estas instalaciones puedan, con incentivos o sin ellos, participar en los mercados eléctricos para vender la energía producida. Concretamente, se prevé que en 2020 la energía solar fotovoltaica pase a ser competitiva, sin ninguna subvención, en ciertas localizaciones [IEA10].

Por ello, los gestores de los parques solares fotovoltaicos conectados a red necesitarán modelos de predicción que les permitan determinar de la manera más exacta posible la producción horaria de energía eléctrica con una anticipación cercana a los dos días. Varios grupos de investigación internacionales están trabajando en el desarrollo de herramientas de este tipo, aunque en los primeros trabajos publicados los modelos predicen los valores de la radiación solar, y a partir de dicha predicción obtienen la producción de energía eléctrica. Los modelos más recientes ya predicen directamente la potencia eléctrica media horaria generada, esto podrá verse con mayor detalle en el *Capítulo 3. Estado del Arte*.

1.2 MOTIVACIÓN

El tema central de las investigaciones a las que se hace referencia en la presente Tesis Doctoral, la obtención de un modelo de predicción a corto plazo de la generación eléctrica fotovoltaica, vino condicionado por la concesión al autor del presente documento de una Beca de Iniciación a la Investigación (con el Departamento de Ingeniería Eléctrica) relacionada con las energías renovables y las predicciones meteorológicas y energéticas. Durante dicho período, tras varias conversaciones con el Tutor del Doctorado, quedó patente la importancia y posible utilidad futura de generar un modelo de predicción de energía solar fotovoltaica, lo que constituyó el inicio de las investigaciones vinculadas a esta Tesis.

El concepto de predicción o previsión, se define como “la demostración probabilista, que tiene por objeto el describir una situación futura estimada como posible, en razón de la evolución esperada de un cierto número de variables existentes o anticipadas” (Decouflé).

Pues bien, el conocer o estimar hechos futuros ha sido una de las principales inquietudes de los hombres. La importancia de las predicciones radica en la ventaja que aporta conocer de antemano de la manera más aproximada posible, lo que va a ocurrir, en lo que en un principio era una situación de incertidumbre.

En nuestro caso, las predicciones energéticas, la importancia se acrecenta, ya que entran en juego cuestiones económicas.

La disponibilidad de energía a través de la energía solar fotovoltaica conlleva una considerable incertidumbre y no permite al usuario una adecuada planificación energética. La predicción de esta energía depende de los pronósticos meteorológicos, los cuales tienen bastante imprecisión. No obstante los últimos avances científicos permiten simular el comportamiento de la atmósfera y el océano mediante modelos, que junto con el incremento de la potencia de cálculo en los nuevos ordenadores, logran realizar unas predicciones del tiempo cada vez con menor error.

Gracias a estos avances tecnológicos grandes empresas ya han lanzado sus propios programas, generalmente de alto coste, para la predicción energética en parques eólicos. La promulgación de nuevas leyes energéticas les ha obligado a realizar una planificación energética a corto plazo. Pero para el caso central de las investigaciones llevadas a cabo en esta Tesis, la predicción de la energía solar fotovoltaica, apenas existen modelos que permitan al usuario una predicción de generación eléctrica que ofrezca una planificación energética apropiada. Es por ello que, la presente Tesis Doctoral, tiene como fin intentar cubrir esa falta. Hoy en día, debido a la política gubernamental relacionada con la energía solar fotovoltaica, no es preciso conocer de antemano lo que se va a producir, pero tal y como se ha explicado en el punto anterior, llegará el día en el que se deba prever para competir en el mercado (al igual que ocurre con la mayoría de energías). Es más, hubo un tiempo en que se a los productores fotovoltaicos se les dio la oportunidad de participar en el mercado, mediante el RD 436/2004, aunque la actual regulación no lo hace.

1.3 OBJETIVOS

Las investigaciones vinculadas a la Tesis tienen como objetivo principal el desarrollo de un modelo de predicción que nos permita obtener las predicciones energéticas para el día siguiente para una instalación solar fotovoltaica conectada a una red de distribución de energía eléctrica concreta.

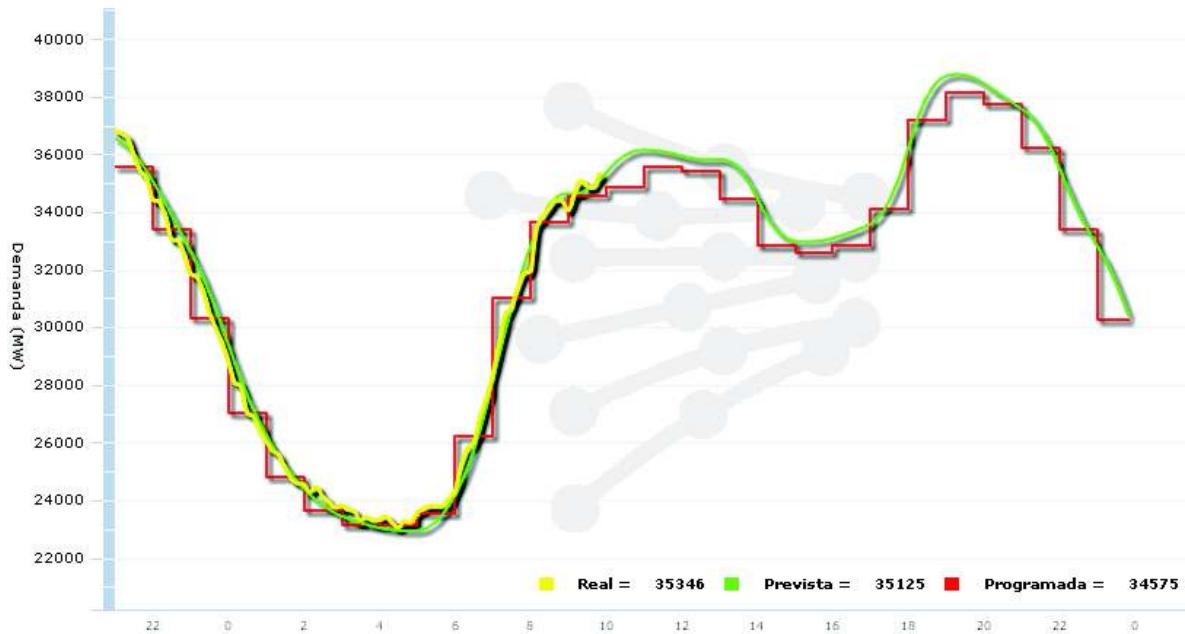


Figura 1. 5 Demanda de Energía Eléctrica en tiempo real (www.ree.es)

Es decir, cumpliendo este objetivo, se obtiene una curva de la energía que se va a generar, con lo que, el gestor de la instalación podría planificar de antemano el uso de dicha energía. Además, en el mejor de los casos, si llegará a ser necesario, la suma de los resultados obtenidos por los modelos individuales de cada planta conectada a la red podría ser tenida en cuenta por Red Eléctrica de España [REE13] en su planificación diaria (Figura 1. 5).

En la Figura 1. 5, aparece la demanda real (curva amarilla) que refleja el valor instantáneo de la demanda de energía eléctrica. Su evolución recoge las peculiaridades estacionales y horarias, así como la actividad y el ritmo vital del país. También aparece la previsión de la demanda (curva verde) que es elaborada por Red Eléctrica con los valores de consumo en períodos precedentes similares, corrigiéndola con una serie de factores que influyen en el consumo como laboralidad, climatología y actividad económica.

En nuestro caso lo que nos interesa es la **programación horaria operativa** (línea escalonada roja) que es la producción programada para los grupos de generación a los que se haya adjudicado el suministro de energía en la casación de los mercados diario e intradiario así como en los mercados de gestión de desvíos y regulación terciaria (gestionados por Red Eléctrica).

Hoy en día, debido a la política gubernamental existente, la energía solar fotovoltaica no es tenida en los procesos de fijación de los precios de la energía en el mercado eléctrico. **Pero el día que esta política cambie y la energía solar fotovoltaica deba competir en el mercado, será preciso disponer de las predicciones energéticas para el día siguiente (objetivo del presente documento), para lo cual hoy en día existen muy pocos modelos de predicción.**

Por tanto, a modo de resumen, podemos decir que el objetivo principal de las investigaciones descritas en el presente documento es el siguiente:

- Determinar, de la manera más aproximada posible, la energía que va a ser generada por el parque solar fotovoltaico a corto plazo, concretamente al día siguiente.

A partir de la consecución del objetivo principal de la Tesis se derivarán una serie de ventajas, como las dos citadas a continuación:

- Cuando llegue el momento, poder competir en el mercado eléctrico de manera eficiente.
- Gracias a lo anterior, conseguir el máximo beneficio económico de la instalación fotovoltaica.

1.4 ESTRUCTURA DE LA TESIS

La presente Tesis Doctoral está dividida en 9 capítulos y un anexo. El Capítulo 1 corresponde a la introducción y el 2 nos explica los fundamentos sobre la generación eléctrica de origen fotovoltaico. El Capítulo 3 es un estudio sobre el estado del arte, es decir, sobre investigaciones actuales semejantes a las aquí desarrolladas. Los Capítulos 4 y 5 corresponden a los modelos atmosféricos y a los modelos para la predicción de series temporales. Los Capítulos 6 y 7 corresponden al desarrollo del modelo y a su evaluación. A modo de cierre, el Capítulo 8 presenta todas las conclusiones relevantes obtenidas a partir de la elaboración de las investigaciones vinculadas a la Tesis. El último

capítulo corresponde a las referencias bibliográficas citadas a lo largo del documento. A su vez, aparece el anexo final, relacionado con la aplicación informática desarrollada.

En el Capítulo 1, tal y como ha podido verse, se presenta una introducción al documento, donde se exponen las razones que justifican su realización, la motivación personal para desarrollarlo así como sus objetivos.

En el Capítulo 2, aparecen los fundamentos sobre la generación eléctrica fotovoltaica. Se describe el panorama actual de la energía eléctrica de origen solar fotovoltaico, las ventajas que aporta la predicción de la potencia horaria media generada y la repercusión de los horizontes de predicción.

El Capítulo 3 corresponde al estado del arte de los modelos de predicción de la producción eléctrica en parques solares fotovoltaicos. En él se comentan los diferentes modelos descritos en artículos publicados en la literatura internacional, con las limitaciones de dichos modelos de predicción. Así, se han explicado los modelos más relacionados con los desarrollados en las investigaciones vinculadas a la presente Tesis y, además de especificar la metodología y los criterios de evaluación más habituales, se han dividido los modelos de predicción en dos categorías (basados en datos pasados y basados en modelos atmosféricos). El capítulo finaliza con una serie de conclusiones que se pueden extraer del análisis de todos los modelos descritos.

El Capítulo 4 corresponde a los fundamentos generales de los modelos atmosféricos. En primer lugar se describirán las bases y características principales de los modelos de predicción meteorológica, analizando los diferentes tipos existentes (modelos numéricos, atmosféricos globales y atmosféricos locales). Tras describir los tipos anteriores, se explicará con mayor detalle uno de los dos modelos atmosféricos elegido, el MM5, para realizar las predicciones atmosféricas que servirán como entradas del modelo de predicción de series temporales. Para finalizar se hará una descripción similar del otro modelo atmosférico elegido, el WRF, utilizado para el desarrollo de los modelos de predicción desarrollados en la segunda etapa de las investigaciones.

En el Capítulo 5 se explicarán las diferentes metodologías que han sido aplicadas para la predicción de series temporales, en este caso para la predicción de la producción fotovoltaica. Se van a describir tanto las técnicas clásicas más importantes (modelos ARIMA), como otras técnicas meta-heurísticas, considerablemente modernas (redes

neuronales artificiales, sistemas de inferencia difusa...), entroncadas en el conocido ámbito del llamado “*soft-computing*”. Además también se presentarán otros modelos como el clásico persistente, el denominado modelo del vecino más próximo (*k-nearest neighbor*), el de día claro... Cabe destacar que se describirán los algoritmos genéticos utilizados para la optimización de los modelos de predicción y que dentro de las redes neuronales artificiales se explicarán algunos de los diferentes tipos estudiados.

El Capítulo 6, presenta el desarrollo de los nuevos modelos creados en las investigaciones llevadas a cabo durante el Período de Investigación. Inicialmente se presentan las generalidades para el desarrollo de los modelos, su estructura general, su fluograma y los datos disponibles para el desarrollo de las investigaciones, con sus características más relevantes, su modo de clasificación y la metodología de normalización de variables. A continuación se describen los modelos desarrollados en la primera etapa de las investigaciones, se explica el modo en que se ha configurado el primero de los modelos de predicción meteorológica, el MM5, a partir de los resultados de los estudios de sensibilidad correspondientes. Además, también se explica el modo de funcionamiento de las aplicaciones de ejecución automática desarrolladas para automatizar el proceso de obtención de predicciones. Tras esto se describe la metodología de desarrollo de los modelos de predicción y, finalmente, se describen uno a uno los nuevos modelos desarrollados para acometer la predicción, a corto plazo, de la producción eléctrica en parques solares fotovoltaicos. Cada modelo de predicción descrito está diseñado para utilizar diferentes variables de entrada: las disponibles en cada caso. El horizonte de predicción del modelo tal y como se ha especificado anteriormente es para todo el día siguiente. La parte final del presente capítulo es similar a la anterior pero en este caso tomando como base el otro modelo atmosférico, el WRF. Además en este caso, el horizonte de predicción no solo abarca el día siguiente, sino que también se han desarrollado modelos para los siguientes dos días.

En el Capítulo 7 aparecen los resultados computacionales obtenidos utilizando los nuevos modelos desarrollados (explicados en el capítulo anterior). Se comentan y definen los indicadores estadísticos que se van a utilizar para realizar la evaluación de los diferentes modelos de predicción desarrollados. La adecuación de los modelos no será evaluada con los datos utilizados en su ajuste, sino con otro conjunto de valores (valores de testeo) de las variables explicativas. Esta prueba permitirá la comparación de los resultados (valores de predicción) entre diferentes modelos y la selección del modelo que

arroje los menores errores de predicción. Tras esto, separado por las dos etapas diferenciadas en las que se han dividido las investigaciones, pasan a describirse los resultados obtenidos para cada uno de los modelos desarrollados, gráfica y numéricamente, para finalmente, realizar un análisis detallado de los resultados del modelo óptimo para cada caso.

En el Capítulo 8, se presentan las conclusiones obtenidas a partir del desarrollo de las investigaciones vinculadas a la presente Tesis Doctoral. Se procura hacer un análisis crítico de los resultados obtenidos, encontrando posibles errores y puntos de mejora. Además, se incluye también una relación de las líneas de investigación futuras que se pretenden emprender.

El Capítulo 9 corresponde a las referencias bibliográficas citadas a lo largo del documento. Así en este capítulo se detallan cada una de estas referencias siguiendo una estructura adecuada.

Tras esto, en el Anexo 1, se describe el desarrollo de la aplicación informática desarrollada para obtener predicciones a partir del modelo óptimo, se explica tanto su estructura como su modo de funcionamiento.

CAPÍTULO

2

GENERACIÓN ELÉCTRICA EN PARQUES SOLARES FOTOVOLTAICOS

En este segundo capítulo se expondrá el panorama actual de la energía eléctrica de origen fotovoltaico, tanto a nivel nacional como internacional, y las ventajas de predecir la potencia que se generará en plantas basadas en dicha tecnología. También se analizan en este capítulo los horizontes de predicción más importantes bajo los puntos de vista del funcionamiento de los sistemas eléctricos de potencia. Además, se describe una de las principales causas de incertidumbre en la predicción de la producción eléctrica en parques solares fotovoltaicos: los errores de predicción propios de los modelos atmosféricos.

2.1 LA ENERGÍA SOLAR FOTOVOLTAICA

2.1.1 EL SOL Y SU RADIACIÓN

El Sol es una esfera compuesta por gas que se calienta debido a las reacciones nucleares que se dan en su centro [Quaschning03]. Las temperaturas internas alcanzan los 20 millones de Kelvin. Tal y como puede verse en la Figura 2. 1, la intensa radiación del interior es absorbida por la capa de iones de hidrógeno (zona convectiva) presente casi en la superficie del sol. La energía es transferida por convección a través de esta barrera óptica y vuelve a ser irradiada por la superficie externa del sol, la fotosfera. Esto

emite una radiación cercana a la equivalente a un *cuerpo negro* con una temperatura de casi 6000 K (Figura 2. 2).

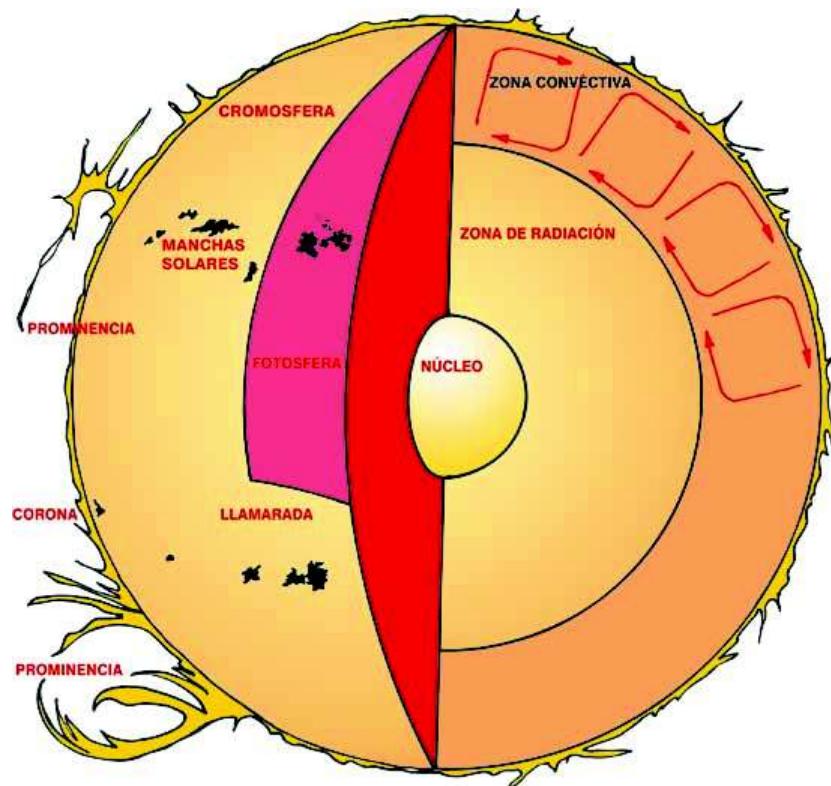


Figura 2. 1 Regiones solares (Fuente: Edición Impresa ABC – Suplemento Escolar 06/09/05)

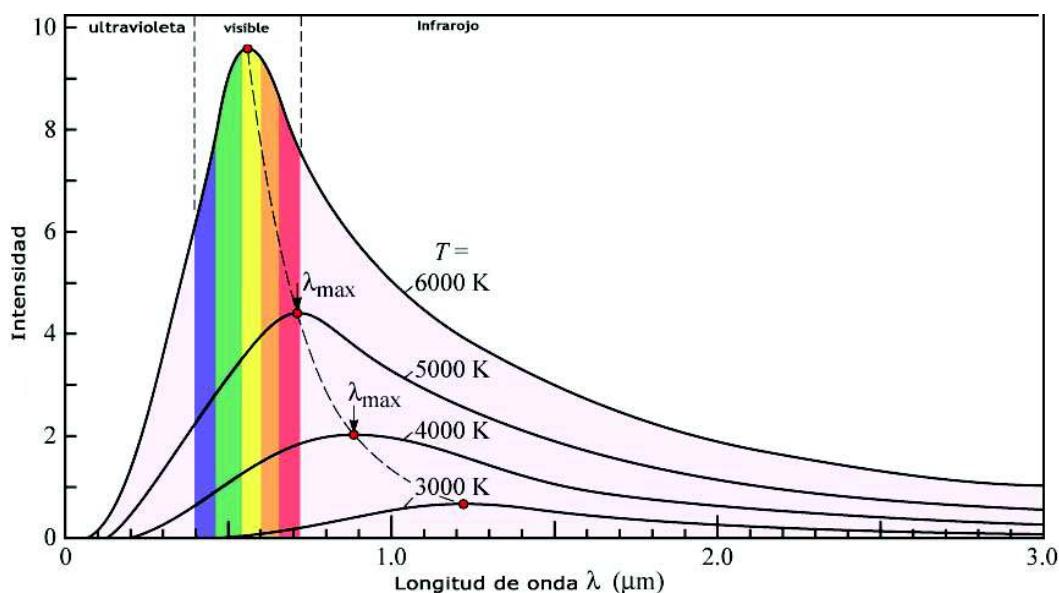


Figura 2. 2 Espectro de radiación del cuerpo negro (Adaptado de: www.physicsforums.com)

La irradiancia solar es la magnitud empleada para indicar el valor de la radiación incidente en una superficie. En el caso del Sol, se define como la energía solar recibida por cada m^2 en un segundo. A lo largo de un día despejado varía, sobre todo, por la inclinación de los rayos solares. Esta inclinación es mayor en invierno, disminuyendo entonces la irradiancia solar.

La irradiancia solar en la cima de la atmósfera terrestre, en dirección perpendicular a los rayos solares, tiene un valor medio de 1.367 W/m^2 , y se denomina constante solar ([ASTM03], [Gueymard04]) porque se mantiene prácticamente constante durante decenas o centenares de años, ya que, al ser básicamente dependiente de factores astronómicos o astrofísicos, su variación es muy lenta. Aunque la radiación de la superficie del sol sea prácticamente constante [Wilson88], a su paso por la atmósfera, la radiación solar se atenúa debido a procesos de absorción y difusión que producen los gases y partículas de la atmósfera y las nubes. La irradiancia solar incidente en la superficie de la Tierra no suele superar los 1000 W/m^2 , dependiendo mucho del lugar, la hora del día, época del año y estado del cielo.

La radiación solar que atraviesa la atmósfera es atenuada, o reducida, alrededor de un 30% hasta alcanzar la superficie terrestre debido a efectos como los descritos a continuación ([Gast60], [Iqbal83]):

1. Dispersión *Rayleigh*, debida a la interacción con moléculas atmosféricas y otras partículas pequeñas cuyo diámetro es menor que la longitud de onda de la radiación incidente. Las longitudes de onda más cortas tienden a ser más afectadas por esta modalidad de dispersión, que las longitudes de onda más largas. El color azul del cielo es un ejemplo de este tipo de dispersión.
2. Dispersión por aerosoles y partículas de polvo.
3. La absorción por los gases atmosféricos tales como oxígeno, ozono, vapor de agua y dióxido de carbono (CO_2).

Una parte de la radiación solar que incide en el suelo proviene directamente del disco solar (radiación solar directa) y otra proviene del cielo y las nubes (radiación solar difusa) (ver Figura 2. 3).

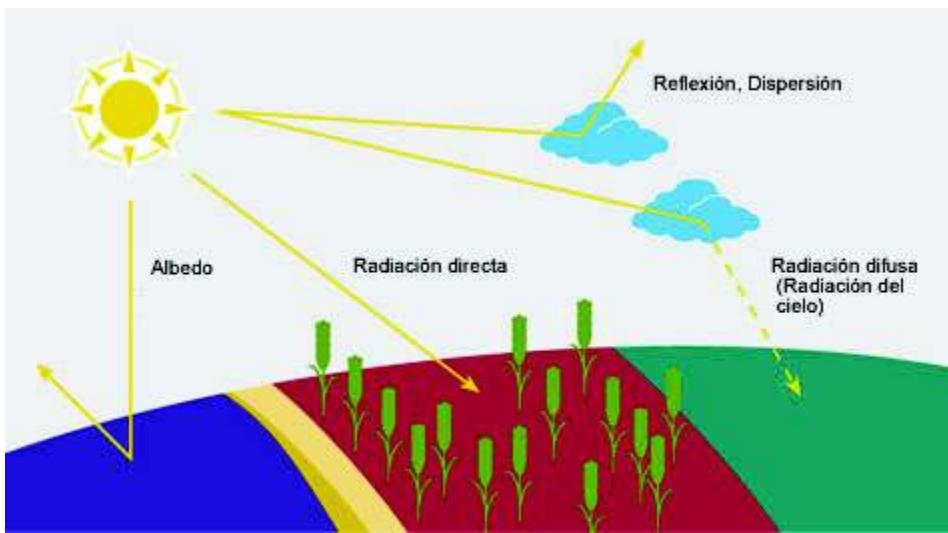


Figura 2. 3 Radiación directa y difusa (Adaptado de: www.kalzip.com)

Para cielos despejados, la radiación directa predomina en las horas centrales del día, y varía con el coseno del ángulo cenital del sol. Cuando el sol está oculto por las nubes o en los crepúsculos, casi toda la radiación es difusa. La suma de la radiación solar directa y difusa se llama radiación solar global. Además, a la hora de concretar cuanta irradiancia incide sobre un cuerpo habrá que tener en cuenta también la radiación reflejada (Figura 2. 4).

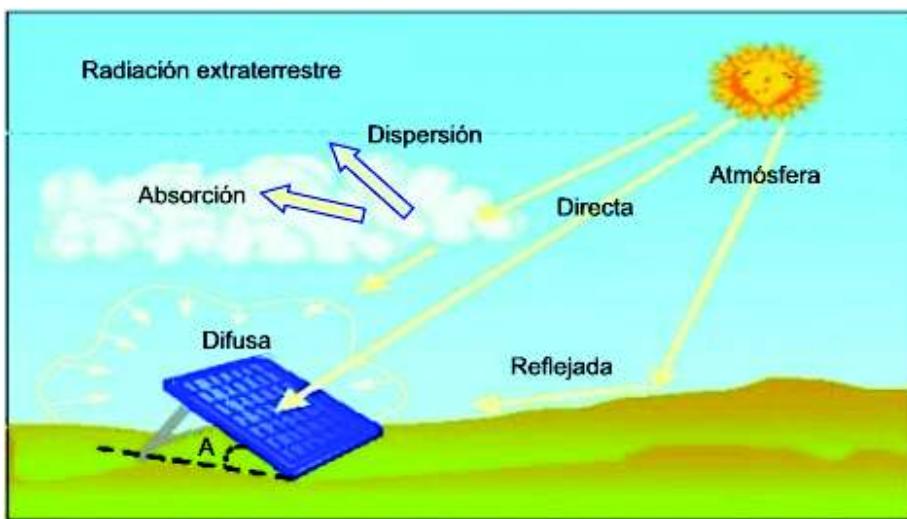


Figura 2. 4 Radiación incidente sobre un panel fotovoltaico (Adaptado de: www.pce-iberica.es)

2.1.2 FUNDAMENTOS DE LA GENERACIÓN FOTOVOLTAICA

La energía solar fotovoltaica es aquélla que se obtiene a través de la transformación directa de la energía del sol en energía eléctrica. El principal encargado de dicha transformación es el panel fotovoltaico.

El efecto fotovoltaico fue reconocido por primera vez en 1839 por el físico francés Alexandre-Edmond Becquerel, pero la primera célula solar no se construyó hasta 1883. Su autor fue Charles Fritts, quien recubrió una muestra de selenio semiconductor con un pan de oro para formar el empalme. Este primitivo dispositivo presentaba una eficiencia de sólo un 1%. En 1905 Albert Einstein dio la explicación teórica del efecto fotoeléctrico. Russell Ohl patentó la célula solar moderna en el año 1946, aunque Sven Ason Berglund había patentado, con anterioridad, un método que trataba de incrementar la capacidad de las células fotosensibles.

Los paneles fotovoltaicos están compuestos por módulos y éstos a su vez por células fotovoltaicas. Sus células están formadas por una o varias láminas de material semiconductor y recubiertas de un vidrio transparente que deja pasar la radiación solar y minimiza las pérdidas de calor.

Las células solares fotovoltaicas convencionales se fabrican de silicio. Las fabricadas con este material son bastante eficientes, con unos rendimientos medios de 14-17%, aunque también más caras de producir por la alta dependencia en la disponibilidad del silicio. El esperado abaratamiento de costes en paneles fotovoltaicos [Curtright08] propiciará que esta tecnología sea en un futuro próximo competitiva, en términos económicos, con respecto a las tecnologías de generación de energía basadas en combustibles fósiles. También se han empezado a utilizar otros materiales más baratos, denominándose estas células "de segunda generación", aunque sus rendimientos son ligeramente inferiores.

El proceso de obtención de energía eléctrica a través de un sistema fotovoltaico es sencillo. La luz del sol (que está compuesta por fotones) incide en las células fotovoltaicas de la placa, creándose de esta forma un campo eléctrico entre las capas. Cuanto mayor sea la radiación incidente, mayor será la energía producida. Cada célula fotovoltaica está compuesta de, al menos, dos delgadas láminas de silicio. Una dopada con elementos con menos electrones de valencia que el silicio, denominada P y otra con

elementos con más electrones que los átomos de silicio, denominada N. Aquellos fotones procedentes de la fuente luminosa, que presentan energía adecuada, inciden sobre la superficie de la capa P, y al interactuar con el material liberan electrones de los átomos de silicio los cuales, en movimiento, atraviesan la capa de semiconductor, pero no pueden volver. La capa N adquiere una diferencia de potencial respecto a la P. Si se conectan unos conductores eléctricos a ambas capas y estos, a su vez, se unen a un dispositivo o elemento eléctrico consumidor de energía que, usualmente y de forma genérica se denomina carga, se iniciará una corriente eléctrica continua. El campo eléctrico establecido a través de la creación de la unión P-N crea un diodo que permite el flujo de corriente en un solo sentido a través de dicha unión. Los electrones pueden pasar del lado de tipo N hacia el interior del lado P, y los huecos pueden pasar del lado de tipo P hacia el lado de tipo N. Esta región donde los electrones se han difundido en la unión se llama región de agotamiento porque no contiene nada más que algunos portadores de carga móviles. Es también conocida como la región de espacio de cargas.

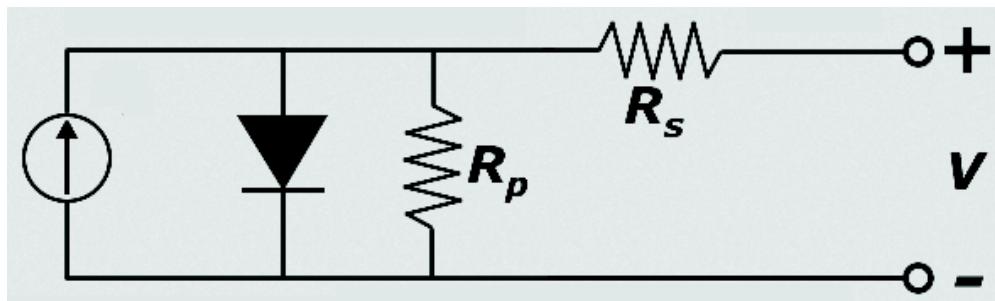


Figura 2. 5 Circuito equivalente del panel solar fotovoltaico

Las células fotoeléctricas transforman la energía solar en electricidad en forma de corriente continua, y ésta suele transformarse a corriente alterna para su aprovechamiento. El dispositivo que se encarga de esta transformación se denomina inversor. El inversor transforma la corriente continua en corriente alterna con las mismas características que la de la red eléctrica a la que va a verterse, controlando la uniformidad y calidad de la señal. Esta corriente alterna generada finalmente pasa por un contador (que la cuantifica) y de allí es inyectada a la red eléctrica.

En cuanto a la eficiencia de un panel solar fotovoltaico, η , es el porcentaje de potencia convertida en energía eléctrica de la luz solar total absorbida por un panel, cuando una célula solar está conectada a un circuito eléctrico. Este término se calcula usando la relación del punto de potencia máxima, P_m , dividido entre la radiación incidente

(RAD), bajo condiciones estándar (25°C , masa de aire espectral, AM , de 1,5) y el área superficial del panel (A).

$$\eta = \frac{P_m}{RAD \cdot A} \quad (2.1)$$

Otro término para definir la eficacia de una célula solar es el factor de llenado o *fill factor* (FF), que se define como la relación entre el máximo punto de potencia dividido entre el voltaje en circuito abierto, V_{oc} , y la corriente en cortocircuito, I_{cc} :

$$FF = \frac{P_m}{V_{oc} \cdot I_{cc}} = \frac{\eta \cdot RAD \cdot A}{V_{oc} \cdot I_{cc}} \quad (2.2)$$

2.1.3 EVOLUCIÓN HISTÓRICA DEL MERCADO FOTOVOLTAICO

La energía solar fotovoltaica ha crecido de forma considerable durante la última década (a pesar de la complicada situación económica) y está en proceso de convertirse en una de las principales fuentes de energía del mundo. Tras el gran crecimiento sufrido en 2011, en el 2012 dicho crecimiento prácticamente se repitió y en 2013 aún fue superior [EPIA14].

A finales de 2009, la potencia fotovoltaica instalada en todo el mundo se hallaba en torno a los 24 GW. Un año después era de 40,3 GW y al finalizar 2011 era de 70,5 GW. Al finalizar 2012 había más de 100 GW instalados entre todas las instalaciones del mundo, pasando en 2013 a una potencia total de 139,9 GW con una capacidad de producción de al menos 160 TWh anuales. Este volumen de energía es suficiente para cubrir la demanda energética de unos 45 millones de hogares europeos.

En la actualidad Europa sigue siendo la región con más potencia fotovoltaica instalada, en 2013 tenía 81,5 GW (en torno al 59% de la mundial, bajando del 70% de 2012). La siguiente en el ranking es China (18,6 GW), seguida por Japón y EEUU (un 10% y un 9% de la potencia mundial respectivamente). Muchas de las regiones no pertenecientes a Europa (en particular, China, EEUU, Japón, Australia e India), han

aprovechado únicamente una pequeña parte de su enorme potencial. Por otro lado hay otras regiones con mucho potencial que están a punto de dar el salto, como ciertos países de África, el sureste de Asia y Sudamérica. La evolución histórica de la potencia instalada puede verse también en la Figura 1.1 del capítulo anterior.

Regionalmente, Europa es seguida de cerca por Asia-Pacífica (APAC), que además de Japón y China incluye a Corea, Australia, Taiwán y Tailandia. La tercera región en estos términos es Norteamérica. Además, como se ha comentado hay que destacar el gran potencial de África y Sudamérica, donde se prevé que la demanda energética crezca significativamente en los próximos años, y donde ya han aparecido diversos proyectos para desarrollarse en un futuro próximo.

En 2013 por séptima vez en 14 años, Alemania era el país con más potencia fotovoltaica instalada en todo el mundo, seguida por China, Italia, Japón, EEUU y España.

Si tenemos en cuenta particularmente a Europa, después del boom sufrido por España en 2008, Alemania se convirtió en el único líder a partir de 2009. Esto puede ser visto en retrospectiva como una consecuencia de la primera fase de la crisis financiera, pero también como un año de estabilización después del auge experimentado en 2008. Este crecimiento reapareció en 2010, con una gran cantidad de nuevas instalaciones en Alemania, seguida por Italia y República Checa. En 2011, de nuevo se produjo un gran crecimiento debido sobre todo a las nuevas instalaciones realizadas en Alemania e Italia. En el 2012 la potencia instalada en Europa creció en 17,2 GW, debido de nuevo, sobre todo, a Alemania e Italia, ya que aportaron 11 GW entre las dos. Esta tendencia se repitió en 2013, ya que de los 11 GW que creció la potencia fotovoltaica europea, 5 GW correspondían a Italia y a Alemania. La potencia instalada y el crecimiento sufrido en 2013 para cada país Europeo pueden verse en la Figura 1.2 del capítulo anterior, y la evolución sufrida durante los últimos años por los principales países aparece a continuación en la Figura 2. 6.

Queda patente que, hoy en día, Europa no tiene rival en lo que a energía fotovoltaica se refiere. EEUU y Japón, pioneros fotovoltaicos, ahora se encuentran años por detrás de Europa y han sido superados por China en unos años con un rápido desarrollo.

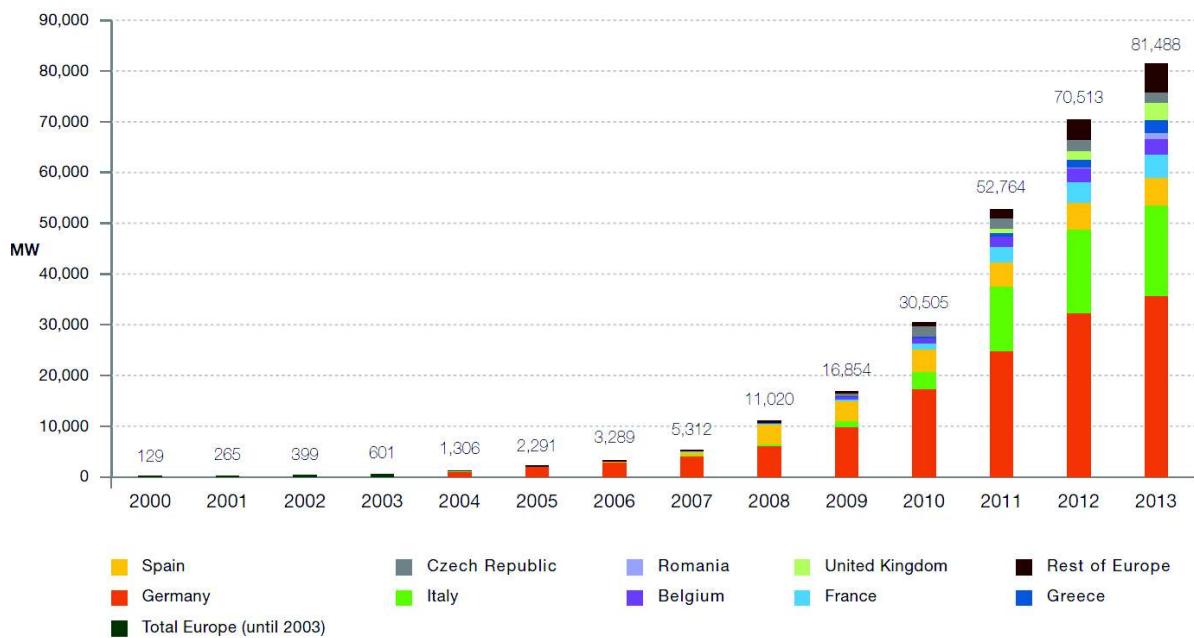


Figura 2. 6 Evolución histórica de la potencia fotovoltaica instalada (MW) en Europa [EPIA13]

En cuanto al crecimiento que ha sufrido la potencia fotovoltaica durante los últimos años en España, cabe destacar el boom de 2008 ya comentado con anterioridad. Concretamente, de los 146 MW de 2006 se pasó a 690 MW en 2007, siendo en su momento considerado como un gran salto, pero llegó 2008 y sus 3375 MW, en 2009 el crecimiento se estancó, debido sobre todo a la crisis económica, aunque posteriormente la potencia instalada ha seguido creciendo hasta superar los 4,7 GW en 2013 [CNE13], (gráficamente se puede ver en la Figura 1. 4 del capítulo anterior).

2.2 VENTAJAS DE LA PREDICCIÓN FOTOVOLTAICA

Una de las características actuales más peculiares de la energía eléctrica producida en parques solares fotovoltaicos es su carácter no gestionable. Entendemos como carácter gestionable de la generación de energía eléctrica, a la capacidad de afrontar lo desconocido en términos de producción de potencia eléctrica. La energía eléctrica producida en parques fotovoltaicos no es gestionable por las características indicadas a continuación.

- Régimen de generación eléctrica con alta intermitencia (en función de la evolución de las condiciones climatológicas, sobre todo de la cobertura de nubes, que puede presentar importantes cambios en intervalos cortos de tiempo).
- Imposibilidad de control de la producción eléctrica (se genera toda la energía eléctrica que el sol “aporte”, sin que sea posible aumentar esa energía eléctrica, ni sea económicamente rentable reducirla).
- Escasa fiabilidad en los valores futuros de la producción de energía eléctrica (frente a la programación de la generación eléctrica de las centrales clásicas, en los parques fotovoltaicos sólo se puede llegar a unas predicciones de potencia eléctrica generada afectadas por un error de predicción).

Los sistemas eléctricos (sistemas de energía eléctrica o sistemas eléctricos de potencia) presentan como problema característico, frente a otros sistemas de energía, el de la imposibilidad actual (desde un punto de vista práctico) de poder almacenar energía eléctrica a gran escala. Por otra parte, un sistema eléctrico fiable debe asegurar que la demanda de energía eléctrica, por parte de los usuarios, va a estar suficientemente cubierta por la generación eléctrica disponible en cada momento. Como consecuencia de esto, se hizo evidente desde los primeros momentos de puesta en funcionamiento de los sistemas de generación, transporte, reparto y distribución de energía eléctrica, la necesidad de disponer de herramientas de predicción de valores futuros de las variables que intervienen en el funcionamiento del Sistema Eléctrico.

La primera variable que fue objeto de atención fue la demanda de energía eléctrica. La previsión de la demanda de energía eléctrica se utiliza para la planificación de la energía eléctrica producida, en la planificación de las compras de combustible para las centrales eléctricas que lo precisen, para la secuenciación de los períodos de mantenimiento de los elementos del Sistema Eléctrico, para la planificación de las redes eléctricas, e incluso para la determinación de las tarifas eléctricas [Bunn85].

La dependencia que tiene la energía eléctrica generada en un parque solar fotovoltaico de las condiciones meteorológicas, y la alta variabilidad de éstas, hacen que el problema de la predicción de la energía generada en el mismo sea una labor compleja. Sobre todo la naturaleza intermitente de la cobertura de nubes origina que, incluso para

horizontes temporales pequeños, sea difícil asegurar cual va a ser exactamente el valor de la radiación incidente sobre el parque en cuestión.

Un funcionamiento seguro del sistema de energía eléctrica no sólo debe cubrir la demanda, sino que debe dar respuesta inmediata a los problemas que en ella puedan surgir, garantizando el suministro al mayor número de usuarios y, obviamente, respetar todas las restricciones técnicas que pueda presentar la Red Eléctrica. Sólo bajo ese aspecto ya es importante disponer de herramientas para la predicción de la producción eléctrica en parques solares fotovoltaicos, por las repercusiones económicas que un conocimiento de antemano de los valores de energía generada puede tener en la determinación de la programación de las centrales eléctricas clásicas, y en la determinación de la reserva de generación y de los cambios en el despacho de las unidades generadoras convencionales.

Esa importancia en la disposición de herramientas para la producción eléctrica en parques solares fotovoltaicos se ve reforzada si tenemos en cuenta lo ocurrido con los parques eólicos, los cuales, en un primer momento, vertían a la red eléctrica la energía eléctrica generada, recibiendo la compensación económica correspondiente. Estas compensaciones podían incluir subvenciones o primas para hacer competitivas a este tipo de instalaciones y estimular así su proliferación. Pero la reducción de los costes de instalación y nuevas políticas energéticas, con nuevos incentivos, propiciaron que en algunos países la mayoría de los parques eólicos pudieran vender la energía eléctrica producida en el mercado eléctrico. Este es el caso de España, donde desde el año 2004 la mayoría de los parques eólicos actúan como un productor más en el mercado eléctrico. Y para ello precisan de las predicciones con antelación, siendo mayor el beneficio cuanto más precisas sean estas.

Teniendo en cuenta lo comentado en el párrafo anterior, es de esperar que con la energía solar fotovoltaica ocurra algo similar, ya que el crecimiento que ha sufrido durante los últimos años en España, recuerda en gran medida al sufrido por la energía eólica. Debido a ello, la necesidad de las predicciones de generación se hace aún mayor.

Así, nos encontramos con una doble necesidad de predicción de la energía eléctrica producida en los parques solares fotovoltaicos. Por una parte, el Operador del Sistema Eléctrico necesita conocer de antemano la potencia eléctrica que se va a inyectar en el Sistema para un periodo de programación (el más importante es el día

siguiente), sobre una base horaria; y, además, el Operador necesita conocer el nudo en el que se va a inyectar esa potencia eléctrica para poder realizar los análisis del funcionamiento previsto del Sistema. Por otra parte, los propietarios de los parques solares fotovoltaicos, es posible que en un futuro próximo sean obligados a realizar una previsión de la energía vertida en la red eléctrica para cada una de las 24 horas del día siguiente, o para el posterior (que es el caso de la venta de la energía eléctrica generada a tarifa regulada en parques eólicos conectados a la red de transporte).

2.3 HORIZONTES DE PREDICCIÓN

Para el desarrollo de cualquier modelo de predicción se debe contemplar, desde el primer momento de diseño, el horizonte de predicción, esto es, el periodo de tiempo (contabilizado desde un instante determinado en que realizamos la predicción), que determina el momento futuro para el que realizamos las predicciones. En otros problemas de predicción relacionados con el Sistema Eléctrico, como es el caso de la predicción de la demanda eléctrica, según el valor del horizonte la predicción puede clasificarse como de muy corto plazo, corto plazo, medio plazo o largo plazo.

Para el caso de la predicción de la potencia eléctrica producida en un parque solar fotovoltaico no existe unanimidad en cuanto cuales son las fronteras que separan una clasificación de otra; es más, la mayoría de los autores de artículos relacionados con el tema rehuyen cuantificar los términos y los que si lo hacen dan valores diferentes, en especial para la predicción a muy corto plazo. El horizonte de predicción y el interés de la predicción para cada grupo es el indicado a continuación.

- **Predicciones a muy corto plazo:** el horizonte de predicción es de unas horas, no existiendo unanimidad en su valor. Así, como valores extremos [Usaola04] propone 4 horas y [Möhrlen04] propone 9 horas. Para el operador de la red eléctrica estas predicciones son de interés para el mantenimiento de la seguridad del Sistema Eléctrico. En caso de poder participar en el mercado las predicciones en este periodo son de interés con objeto de poder actuar en el mercado intradiario. Si se reduce el horizonte de predicción, también disminuyen los errores de predicción.

- **Predicciones a corto plazo:** el horizonte de predicción abarca desde el límite con el muy corto plazo hasta las 48 ó 72 horas. En la mayoría de los trabajos publicados se limita a 48 horas, o incluso se limita a 36 horas. Esta predicción es la de mayor interés para poder actuar en el mercado diario eléctrico. Para el caso español, dado que el plazo de presentación de ofertas de venta en el mercado diario se cierra a las 10 horas, un horizonte de predicción de 38 horas cubriría todo el día siguiente. En otros países el momento de cierre de recepción de ofertas puede diferir del caso español, con lo que el número de horas de horizonte para cubrir las predicciones del día siguiente puede variar.
- **Predicciones a “más largo plazo”:** corresponden a un horizonte por encima de las 48 ó 72 horas llegando a un límite de 7 días. Cuanto mayor sea el horizonte, mayores son los errores de predicción, resultando a día de hoy difícil realizar predicciones fiables de variables atmosféricas por encima de esos 7 días. Estas predicciones (hasta 7 días) pueden ser de interés para la previsión del despacho de centrales eléctricas convencionales, y/o la programación de las labores de mantenimiento en algunas de esas centrales (en la programación del sistema de generación).

En todo caso, dada la importante trascendencia económica del tema, la mayor parte de los trabajos publicados describiendo modelos de predicción se han centrado en la predicción de la producción eléctrica en un corto plazo, sobre todo para el día siguiente.

2.4 INCERTIDUMBRE EN LA PREDICCIÓN

Los modelos usados para las predicciones de la producción eléctrica a corto plazo (hasta las 48 o 72 horas de horizonte de predicción) pueden usar, como entradas a los mismos, las predicciones (meteorológicas) generadas por otros modelos, los modelos atmosféricos. Estos son, generalmente, propiedad de los institutos meteorológicos nacionales, que proporcionan las predicciones de los valores numéricos de las variables meteorológicas: radiación, temperatura, presión atmosférica, cobertura nubes, velocidad y dirección del viento... A partir de estos valores numéricos, fruto de la predicción de los modelos atmosféricos, se calcula la predicción de la potencia eléctrica generada en un parque solar fotovoltaico por aproximaciones estadísticas o físicas. Pero la predicción de la producción eléctrica que realizan estos últimos modelos tiene una gran limitación: los modelos de predicción de la producción eléctrica, en principio, no pueden mejorar las predicciones (meteorológicas) de los modelos atmosféricos.

Las fuentes de error en los modelos atmosféricos pueden ser varias: desde un deficiente modelado de la superficie del terreno, hasta condiciones iniciales incorrectas, consecuencia de errores en el proceso de medida o interpretación de las variables meteorológicas que definen el estado de partida de la atmósfera. El primer tipo de error, el causado por un deficiente modelado de la superficie del terreno, puede ser corregido estadísticamente. El segundo tipo de error (condiciones iniciales incorrectas) no puede ser corregido de antemano y es responsable de diferencias importantes entre los valores de predicción y los reales, tanto en magnitud como en el instante de tiempo en que ocurren (el llamado “error de fase”, que se refiere a las variaciones o cambios previstos en el valor de la variable meteorológica que ocurren antes o después de lo previsto).

Con todo, la predicción de la potencia eléctrica generada en el corto plazo por un parque solar fotovoltaico constituye una tarea difícil, no exenta de importantes errores. Pero a pesar de su dificultad, resulta ser actualmente imprescindible, tanto desde un punto de vista técnico como económico.

CAPÍTULO

3

ESTADO DEL ARTE

Este capítulo corresponde al estado del arte de los modelos de predicción de la producción eléctrica en parques solares fotovoltaicos. Se van a describir algunos de los diferentes modelos descritos en artículos publicados en la literatura internacional, con las limitaciones de dichos modelos de predicción y sus resultados (si estos han sido publicados). Se explican los modelos más relacionados con los desarrollados a lo largo de las investigaciones en las que se fundamenta la presente Tesis Doctoral. Además, este capítulo comienza con dos breves apartados en los que se especifican el proceso a seguir para desarrollar y evaluar la adecuación de un modelo, así como una serie de criterios de evaluación que permiten valorar y comparar los resultados de los diferentes modelos de predicción.

3.1 PROCESO GENERAL DE DESARROLLO

A la hora de desarrollar y evaluar la adecuación de cualquier modelo de predicción se deben seguir una serie de pasos o pautas comunes ([Makridakis98], [DeLurgio98]). Estas etapas son las que se describen brevemente a continuación:

1. **Planteamiento Inicial:** se trata de establecer los objetivos que persigue el modelo de predicción. Para ello habrá que ver qué tipo de predicciones son las que más se adecuan a las necesidades actuales para lo cual será necesario consultar la máxima información disponible relacionada con el campo estudiado.
2. **Recopilación de datos:** en segundo lugar es preciso recabar una (o varias) series temporales con los datos históricos de las variables de interés, entre las

cuales, obligatoriamente, deberá aparecer la variable que el modelo tiene la finalidad de predecir, ya que será la que permita desarrollar y evaluar el modelo.

3. **Pre-Procesado de los datos:** una vez que se dispone de los datos históricos será preciso verificar la validez de dichos datos. Para ello será preciso hacer un estudio estadístico minucioso de los mismos, de forma que permitirá eliminar los outliers presentes en la serie temporal, intuir cuáles serán las variables de mayor peso... Además, en muchas ocasiones es aconsejable normalizar algunas de las variables, permitiendo un entrenamiento más preciso del modelo.
4. **Entrenamiento y desarrollo de los modelos de predicción:** esta es la etapa central de todo el proceso. En ella se ajustará o entrenará el modelo, que fundamentalmente se trata de una serie de relaciones lógicas acompañadas de un sistema de ecuaciones (de mayor o menor complejidad) que permiten estimar el valor futuro de la variable deseada para un horizonte de predicción concreto a partir de las entradas correspondientes. El ajuste o entrenamiento del modelo se fundamenta en la optimización de sus diferentes parámetros buscando reducir al máximo el error de predicción, es decir, cuanto más pequeño sea el error más preciso será el modelo, o lo que es lo mismo, más exactas serán las relaciones encontradas entre las entradas y la variable de salida.
5. **Evaluación de los modelos de predicción:** A la hora de elegir, desarrollar o comparar modelos de predicción es preciso que sean evaluados. Para ello habrá que utilizar una serie de criterios (que se especificarán en el siguiente apartado) que permitan calcular la adecuación de las predicciones (resultados) a la realidad. Obviamente dicha evaluación deberá realizarse sobre una serie de datos históricos diferentes a los utilizados en el desarrollo del modelo. Por ello la serie temporal a la que se hace referencia en el segundo paso deberá dividirse en dos conjuntos diferenciados, uno para desarrollar o entrenar el modelo y otro para evaluarlo. De esta forma se podrá escoger el modelo con los menores errores de predicción.
6. **Aplicación del modelo:** una vez finalizado todo el proceso de desarrollo el modelo ya puede ser aplicado a una instalación a tiempo real para obtener las predicciones deseadas.

3.2 CRITERIOS DE EVALUACIÓN DE LOS MODELOS DE PREDICCIÓN

Del apartado anterior se puede deducir que el paso más importante a la hora de seleccionar el modelo de predicción definitivo de entre todos los desarrollados es el correspondiente a su evaluación. De esta forma, a partir una serie de relaciones o criterios, se pueden analizar los resultados de los modelos desarrollados determinando su adecuación a la realidad.

En la literatura internacional nos encontramos con diversos indicadores de evaluación, en este apartado se van a reflejar los diferentes criterios de evaluación más habituales en los modelos de predicción, siendo aplicables no sólo a los modelos de predicción de producción fotovoltaica, sino que también se aplican a los de radiación, eólicos...

Se define el error de predicción, ecuación (3.1), como la diferencia entre el valor real y el valor de predicción.

$$e(t) = P(t) - \hat{P}(t) \quad (3.1)$$

Siendo:

$e(t)$: error de predicción para el instante t

$P(t)$: verdadero valor de la variable en el instante t

$\hat{P}(t)$: valor previsto para esa variable en el instante t

Cuando se dispone de varios valores de predicción para la variable en el instante t , $\hat{P}(t)$, correspondientes a previsiones realizadas con diferentes horizontes de predicción, esto es, en diferentes instantes de tiempo, el error de predicción para la predicción realizada hace k unidades de tiempo viene expresado en la ecuación (3.2).

$$e(t+k|t) = P(t+k) - \hat{P}(t+k|t) \quad (3.2)$$

En la ecuación (3.2), el término $e(t+k|t)$ corresponde al error de la predicción realizada en t para el instante $t+k$.

El error de predicción puede descomponerse en dos componentes: el error sistemático, $\mu_e(t)$, y el error aleatorio, $\xi_e(t)$, tal y como indica la ecuación (3.3). El error sistemático en un proceso puede estar originado por medidas erróneas (aparatos mal calibrados) o por factores humanos. En algunos casos, el error sistemático es considerado como si fuese una constante, siempre que no se produzca un cambio en los procesos de toma de datos o medidas.

$$e(t) = \mu_e(t) + \xi_e(t) \quad (3.3)$$

El error sistemático se conoce también como *Bias* o sesgo. El sesgo de un modelo se puede determinar calculando el error medio para conjunto de datos de evaluación (los datos correspondientes a un periodo de tiempo). Cuando el modelo de predicción permite varios horizontes de predicción distintos, puede calcularse el sesgo para cada uno de los horizontes de predicción según la ecuación (3.4).

$$\text{sesgo}(k) = \frac{1}{N} \sum_{t=1}^N e(t+k|t) \quad (3.4)$$

Siendo:

N : número total de datos del conjunto de predicciones para el horizonte k

Se define el error medio, *ME* (mean error), como el valor medio del error de predicción. Se calcula, para cada horizonte de predicción, por medio de la ecuación (3.5).

$$ME(k) = \frac{1}{N} \sum_{t=1}^N e(t+k|t) \quad (3.5)$$

Los indicadores estadísticos más usuales para evaluar el funcionamiento de un modelo de predicción son el error absoluto medio, MAE , y la raíz del error cuadrático medio, $RMSE$. En la expresión del error absoluto medio intervienen las dos componentes que hemos definido para el error (en el caso del sesgo únicamente interviene el error sistemático, al suponer que el error aleatorio presenta una distribución estadística normal con valor medio nulo). El indicador MAE se calcula según la ecuación (3.6).

$$MAE(k) = \frac{1}{N} \sum_{t=1}^N |e(t+k|t)| \quad (3.6)$$

El indicador $RMSE$ se calcula, tal como expresa la ecuación (3.7), como la raíz del error medio cuadrático (raíz del valor medio del cuadrado del error). El indicador $RMSE$ tiene las mismas unidades que la serie temporal que predecimos: por ejemplo, en la predicción de la radiación, el indicador $RMSE$ tiene unidades de radiación (las mismas que presente la serie utilizada en la predicción).

$$RMSE(k) = \sqrt{\frac{1}{N} \sum_{t=1}^N (e(t+k|t))^2} \quad (3.7)$$

En la predicción de la potencia eléctrica generada en un parque solar fotovoltaico, tanto el indicador MAE como el indicador $RMSE$ se suelen referir a la máxima potencia que el parque fotovoltaico puede producir (potencia instalada). En ese caso, se denominan estos errores como errores normalizados. Así el indicador MAE normalizado se obtiene mediante la ecuación (3.8), y el indicador $RMSE$ normalizado según la ecuación (3.9), siendo P_{inst} la potencia instalada del parque solar.

$$MAE_n(k) = \frac{1}{P_{inst}} \frac{1}{N} \sum_{t=1}^N |e(t+k|t)| \quad (3.8)$$

$$RMSE_n(k) = \frac{1}{P_{inst}} \sqrt{\frac{1}{N} \sum_{t=1}^N (e(t+k|t))^2} \quad (3.9)$$

En muchos casos para cuantificar la mejora en el error de predicción que presenta un modelo con respecto a otro, que se toma como referencia, se realiza una comparación relativa entre los valores de alguno de los indicadores de error definidos anteriormente. De esta forma, se define dicha mejora mediante la ecuación (3.10).

$$mejora_{ref,CE}(k) = \frac{CE_{ref}(k) - CE(k)}{CE_{ref}(k)} \quad (3.10)$$

En la ecuación (3.10), $mejora_{ref,CE}(k)$ representa la reducción porcentual del indicador o criterio de error escogido, CE , en el modelo evaluado, con respecto al mismo valor del indicador en el modelo de referencia. Los criterios de error escogidos suelen ser el *MAE* y el *RMSE*, especialmente este último.

En la literatura especializada sobre técnicas de predicción de series temporales ([Wei90], [Makridakis98], [DeLurgio98], [Armstrong01]) pueden encontrarse otros criterios o indicadores de error, como pueden ser el coeficiente de correlación, la desviación estándar del error, el criterio de información de Akaike, criterio de información Bayesiano de Schwarz... Para el problema de producción que nos ocupa el criterio más utilizado es el indicador *RMSE* normalizado a la potencia instalada en el parque solar fotovoltaico.

En [Madsen05], los autores sugieren utilizar como criterios de medida del error los siguientes: sesgo, *MAE* y *RMSE*, todos ellos normalizados. Además sugieren también utilizar el indicador “mejora” para comparar la eficiencia de los modelos.

3.3 ESTADO ACTUAL DE LOS MODELOS DE PREDICCIÓN

El crecimiento sufrido durante los últimos años en instalaciones de energía solar fotovoltaica [CNE10] recuerda en gran medida al sufrido por las instalaciones de energía eólica. Por ello, al igual que ocurrió con los productores de energía eólica, es previsible que en un futuro próximo los productores de energía fotovoltaica pasen a participar en los mercados eléctricos para vender la energía producida. Es más, hubo un tiempo en que se a los productores fotovoltaicos se les dio la oportunidad de participar en el mercado, tal y como recogía el RD 436/2004, aunque la actual regulación no lo hace.

Por ello, debido a los beneficios económicos que podría aportar un sistema de predicción, el desarrollo de los modelos de predicción queda justificado.

Hasta el año 2010 la investigación y el desarrollo de modelos de predicción de producción fotovoltaica era mínima, además la mayor parte de ellos se basaban en la predicción de la radiación, y se habían publicado pocos modelos de predicción de la producción a parte de los desarrollados por las investigaciones iniciales en las que se fundamenta la presente Tesis Doctoral ([Muñoz09], [Fernández12]). A partir de 2011 las publicaciones de nuevos modelos de predicción fotovoltaicos ha crecido considerablemente, así como los estudios sobre las características de los mismos.

Uno de los primeros modelos de predicción de energía fotovoltaica es el que se presenta en [Rahman04], desarrollado para un pequeño sistema de distribución de energía, conectado a red, compuesto de paneles fotovoltaicos y baterías ECS (*Energy Capacitor System*). En este caso, el modelo de predicción de la energía producida por los paneles fotovoltaicos al que se hace referencia, fue desarrollado mediante el cálculo de la radiación solar. En dicho artículo identifican los parámetros más importantes (claramente dependientes de las condiciones meteorológicas), para lo cual fue utilizado un ajuste estadístico, comparando características de los paneles, producción real y producción estimada por el fabricante.

Teniendo en cuenta los diferentes modelos de predicción publicados se pueden realizar múltiples clasificaciones según el criterio que se tenga en cuenta. Así, podríamos clasificarlos en modelos lineales y no lineales, o, siendo más restrictivo, en modelos

regresivos o basados en técnicas de Inteligencia Artificial... Pero la clasificación más adecuada para poder comparar los datos de forma apropiada es la siguiente:

1. **Modelos basados en valores pasados:** utilizan como entrada únicamente valores pasados, pudiendo ser únicamente de la variable a predecir o complementados con otras variables que pueden influir en la misma. Dentro de estas variables se pueden incluir no sólo las correspondientes al instante de tiempo en que se dieron, sino que pueden tratarse de variables meteorológicas medidas localmente en dichos instantes pasados.
2. **Modelos atmosféricos:** los modelos incorporan como entradas los valores de predicción de variables meteorológicas obtenidos por los programas de predicción numérica existentes en diferentes institutos meteorológicos, además, dichas entradas podrán estar complementadas por las indicadas en el grupo anterior.

Como ya se ha comentado con anterioridad, algunos de los modelos de predicción desarrollados proporcionan la radiación que va a incidir sobre el parque solar fotovoltaico, calculando en algunos casos la potencia eléctrica producida a partir de dicho valor. Para ello generalmente utilizan la gráfica proporcionada por el fabricante del panel solar fotovoltaico, o una serie de relaciones empíricas conocidas, aunque cabe destacar que en algunos casos desarrollan modelos más complejos como puede verse en [Piliougue14]. En dicho artículo los autores destacan como, gracias al modelo que desarrollan, se reduce el error que se comete al calcular la potencia eléctrica producida directamente a través de las curvas I-V del fabricante.

Existen dos revisiones bibliográficas en la literatura internacional ([Inman13] y [Diagne13]) sobre las características más relevantes, así como del estado actual de los modelos de predicción a corto plazo de energía solar fotovoltaica.

3.3.1 MODELOS BASADOS EN DATOS PASADOS

En este subapartado nos centraremos en el primero de los dos tipos de modelos especificados con anterioridad, es decir, los que utilizan como entrada únicamente valores pasados.

Antes de entrar a detallar los diferentes modelos de predicción publicados en la literatura internacional, es conveniente comenzar nombrando el modelo *Persistente*. Cuando se va a evaluar un modelo de predicción es necesario comprobar que los resultados que se obtienen son mejores que los que se obtendrían con un modelo trivial, de ahí que gran parte de los investigadores tomen como referencia un modelo de sencilla implementación como es el modelo persistente. En estos casos, el modelo supondrá que la potencia eléctrica producida (o en su caso la radiación incidente) para el instante $t+1$ es igual que lo que valía en el instante t , tal y como se refleja en la relación 3.11.

$$\hat{P}(t+1) = P(t) \quad (3.11)$$

Como era de esperar la efectividad del modelo persistente decrece a medida que se aumenta el horizonte de predicción debido a las variaciones meteorológicas. Generalmente, este modelo, no es nada apropiado si el horizonte de predicción es superior a 1 h, y por ello se usa únicamente como una referencia para comparar la mejora que suponen los modelos desarrollados.

El modelo de predicción de la energía producida por los paneles fotovoltaicos que se presenta en [Rahman07] fue desarrollado mediante el cálculo de la radiación solar. En dicho artículo para el cálculo de la radiación solar fueron utilizadas las ecuaciones de *Hottel* [Hottel58] y *Liu-Jordan* [Liu60] con algunas modificaciones. Calculan la potencia producida mediante la multiplicación del valor de la radiación solar (calculada) por la superficie del panel, por la eficiencia del panel fotovoltaico, por la eficiencia del MPPT (inversor) y por el coseno del ángulo de incidencia. Para mejorar los resultados, obtuvieron experimentalmente una relación o factor corrector (η) entre el valor real medido de producción para los diferentes estados climáticos (soleado, nublado, lluvia o nieve) y la producción prevista.

Los modelos basados en la metodología de Box-Jenkins [Box76], o modelos ARIMA, han sido utilizados en numerosas áreas de investigación, sin embargo, sólo recientemente han sido empleados para desarrollar modelos de predicción referentes a la producción solar fotovoltaica. Generalmente los resultados obtenidos mediante estos modelos son mejores cuanto menor sea el horizonte de predicción, aunque también se obtienen resultados aceptables en el cálculo de parámetros menos restrictivos que la potencia media horaria producida, como pueden ser la potencia media diaria o mensual.

Uno de estos modelos ARIMA es el que aparece en [Santos03] donde se utiliza un modelo ARIMA (1, 1, 1) para calcular la radiación solar media diaria tomando como punto de partida la radiación media mensual para diferentes localizaciones en España (Madrid y Valencia). Concretamente lo hace teniendo en cuenta el modelo de día claro y calculando su índice K_t (mensual y diario). Para desarrollar el modelo dispone de los datos reales correspondientes a siete años en cada una de las dos localizaciones. Obtiene un error absoluto medio en torno al 16%.

En [Li14] utilizan un modelo ARMAX para predecir la potencia media diaria que producirá al día siguiente un parque solar fotovoltaico de 2,1 kW de potencia compuesto por paneles fijos. Para ello utilizan como entrada del modelo la radiación horizontal global medida localmente 24 horas antes de la predicción. Para entrenar el modelo se ha utilizado un histórico de datos, de aproximadamente un año y medio, que contiene tanto la radiación horizontal (entrada) como el valor real de la potencia media diaria del día siguiente (salida).

Otra serie de modelos ARIMA aparecen en [Craggs00], donde los desarrollan para determinar la radiación media (horizontal y sobre plano inclinado) con horizontes de 10, 20, 30 min y 1 h para una localización concreta de Reino Unido. Para ello utilizan como entradas medidas reales de ambos tipos de radiación. Para el desarrollo del modelo se utilizan los datos correspondientes a 4 períodos de 15 días de dos inviernos y dos veranos diferentes. A la hora de demostrar la eficiencia de sus modelos aportan el coeficiente de correlación entre la curva real de radiación y la prevista. Concretamente obtienen coeficientes de correlación de 0,867 (horizonte de 10 min) a 0,792 (horizonte de 1 h) en verano y de 0,920 (horizonte de 10 min) a 0,612 (horizonte de 1 h) en invierno. A partir de dichos resultados se concluye que la eficiencia de los ARIMA decrece considerablemente con el aumento del horizonte de predicción.

En [Kärner09] los autores comparan varios modelos ARIMA con otras técnicas más avanzadas para diferentes horizontes de predicción (5, 15, 30 y 60 min) utilizando como entrada la radiación global en el instante anterior a la predicción. El autor refleja como puede apreciarse que la variabilidad de las condiciones meteorológicas y de la cobertura de nubes provoca un comportamiento no estacional que dificulta su aplicación en horizontes mayores, pero que a muy corto plazo el dominio del comportamiento de los ciclos de 24 horas justifica la validez de los modelos auto-regresivos. Finalmente en la mayor parte de sus pruebas los menores errores se cometen con los modelos ARIMA, reforzando su validez para horizontes a muy corto plazo.

Para representar la componente estacional en la predicción de la energía eléctrica fotovoltaica, los modelos ARIMA se utilizan como parte integrante de modelos híbridos, es decir, que combinan varias técnicas ([Ji11], [Voyant11]). Se presentarán diversos modelos híbridos al finalizar el presente subapartado.

Otros de los tipos de modelos para la predicción de energía eléctrica fotovoltaica se clasifican dentro de las denominadas *Técnicas de Inteligencia Artificial*. Cabe destacar el uso de las redes neuronales artificiales. Esta técnica había sido ya utilizada en la predicción a corto plazo de otras variables de interés para los sistemas eléctricos, fundamentalmente en la predicción de la demanda de energía eléctrica ([Hsu91], [Park91], [Lee92], [Ho92], [Peng92], por citar sólo los primeros trabajos). Poco antes del año 2000 se aplicó el uso de esta técnica en el campo de la predicción de energía solar. Concretamente, en [Al-Alawi98] se usan variables meteorológicas como entradas de una red neuronal para predecir los valores medios mensuales de radiación global horizontal (GHI) a lo largo del año en localizaciones diferentes a las de los datos que utiliza para entrenar el modelo. Concretamente comete unos MAE que van del 5,43 al 7,30 %.

En [Wang12] desarrollan un modelo de predicción de la radiación media horaria con un horizonte de 24 horas basado en una red neuronal, siendo destacable que los autores realizan un pre-proceso de los datos exhaustivo, calculando diferentes parámetros y normalizando variables con el fin de aumentar la eficiencia de la red neuronal. Una de las tareas que realizan es normalizar el valor de la radiación que van a utilizar como entrada. A su vez incluyen el nº de horas de sol, y dos parámetros nuevos (TOD_{max} y NDD) calculados a partir de la diferencia entre la radiación extraterrestre (calculada) y la de superficie (medida el día previo a la predicción). Concretamente,

TOD_{max} es el valor máximo de la tercera derivada de la diferencia entre ambas radiaciones (de forma que las variaciones bruscas de radiación vienen denotadas por un valor alto de esta variable) y NDD es la raíz de la diferencia cuadrática entre ambas radiaciones normalizadas (útil para clasificar los días en nublados o claros). Las entradas de la red neuronal son la radiación media diaria y la temperatura media diaria para el día previo a la predicción (medidas localmente), además de los parámetros TOD_{max} y NDD de dicho día y el día del año al que corresponde la predicción.

En [Chow12] desarrollan un modelo de predicción para aplicarlo a muy corto plazo (10 y 20 min) y a tiempo real. Dicho modelo predice la potencia media generada para los intervalos comentados en una instalación de 40 kW compuesta por paneles fijos sobre un tejado. La serie temporal que utiliza está compuesta por los datos históricos de 15 días. La red neuronal, que concretamente se trata de una MLP, utiliza un vector de entradas compuesto por el azimut, la altura solar y los valores de temperatura y radiación medidos localmente. El factor de correlación entre la curva de la potencia media generada real y la prevista oscila de 0,81 a 0,98 entre los diferentes días utilizados.

Siguiendo el hilo de los modelos de predicción a tiempo real, en [Mellit13] se presenta un modelo que estima la potencia media generada a tiempo real así como la potencia media diaria que va a ser generada por un módulo fotovoltaico en dicho día. Se desarrollan dos redes neuronales diferentes aplicando una u otra según sea considerado el día de estudio nublado o soleado. Para clasificar el día utilizan la radiación media diaria del último día, de forma que si es inferior a 400 W/m^2 se considera nublado y en caso contrario soleado. La serie temporal utilizada para desarrollar el modelo comprende un período de 13 meses. La red neuronal utiliza como entradas la temperatura y la radiación horizontal medidas localmente. La relación entre la potencia estimada y la real tiene un factor de correlación que va del 0,96 al 0,97.

Otro modelo de predicción a muy corto plazo que utiliza una red neuronal es desarrollado en [Izgi12], concretamente con un horizonte de 5 a 35 min, aunque amplían el horizonte para el mes de Agosto a 30-300 min. La red neuronal utiliza un vector de entradas compuesto por la temperatura ambiente, la temperatura del panel, la radiación horizontal y la potencia generada (todas ellas medidas localmente en el instante previo a la predicción). Los autores presentan la correlación entre los valores pronosticados y los reales, así como los RMSE obtenidos para ambos casos. Concretamente en el caso

general el RMSE oscila del 4,5 % (5 min) al 8,5 % (35 min), mientras que en el caso de Agosto va del 5 % al 10,5 % aproximadamente.

En la misma línea que los modelos anteriores nos encontramos con el desarrollado en [Al-Messabi12] con un horizonte de predicción que va de los 10 min a 1 hora. Desarrollan dos modelos diferentes basados en redes neuronales recurrentes, concretamente uno compuesto por una red focalizada (FTDNN) y el otro por una distribuida (DTDNN). El vector de entrada de ambas redes está compuesto por la potencia generada en los 9 instantes anteriores a la predicción. Para el desarrollo del modelo disponen de las potencias generadas durante 6 días (en intervalos de 10 min), 4 de los cuales utilizan para entrenar el modelo y los otros dos para probarlo o testearlo. A partir de los resultados obtenidos los autores muestran que los modelos desarrollados obtienen unas predicciones aceptables con un número de entradas muy reducido. Además muestran que la FTDNN obtiene unos resultados ligeramente mejores que los de la DTDNN, pese a ser esta última una red más compleja que requiere de más tiempo y que presenta mayor capacidad de proceso. Los autores concluyen, a partir de las pruebas realizadas, que los modelos basados en datos históricos (los tratados en el presente subapartado) son buenos para plazos muy cortos (5 min a 2 h), mientras que los que utilizan entradas procedentes de modelos atmosféricos (los que se tratarán en el siguiente subapartado) son mejores a medida que el horizonte va aumentando.

En [Zhang12] también desarrollan un modelo de predicción a muy corto plazo basado en redes neuronales recurrentes para predecir la radiación media. Pero lo característico de este modelo es que usan en el aprendizaje el algoritmo de retropropagación de Levenberg-Marquardt. A partir de los resultados obtenidos los autores comentan que la utilización de dicho algoritmo para el entrenamiento de modelos de predicción fotovoltaicos es una buena opción a tener en cuenta.

Tal y como se ha comentado con anterioridad, hay modelos de predicción de la producción fotovoltaica que en realidad predicen la radiación media y después, a partir de esta, calculan la potencia media generada (ya sea mediante la curva I-V proporcionada por el fabricante o mediante relaciones empíricas). En la línea de lo anterior, en [Piliougue14] nos encontramos con un modelo de predicción a tiempo real que modeliza el comportamiento del módulo fotovoltaico para obtener directamente, a partir del valor de radiación media, el de la potencia generada en lugar de utilizar la curva I-V u otras relaciones. Dicho modelo se trata concretamente de una MLP cuyo vector de entradas no

solo está compuesto por variables meteorológicas (radiación y temperatura) sino que además tiene en cuenta el ángulo de incidencia y el índice de claridad. Mediante los resultados obtenidos los autores muestran que la predicción a tiempo real de la potencia media generada mediante la aplicación de su modelo es más precisa que la que se obtiene a partir de las curvas I-V proporcionadas por el fabricante de los módulos solares fotovoltaicos.

Otra de las técnicas de inteligencia artificial ligada a las redes neuronales son las máquinas de soporte vectorial o máquinas de vectores de soporte (Support Vector Machines, SVMs). En [Xu12] desarrollan dos modelos, uno basado en una red neuronal (una FFBPNN) y otro basado en un tipo de SVM, concretamente en una WSVM que se diferencia de las SVM convencionales por asignar diferentes pesos a los parámetros que controlan el error. En este caso las predicciones también son para el día siguiente, pero se centran en predecir únicamente la potencia media horaria generada a las 12:00 por un parque solar fotovoltaico de 500 kW en China. Utiliza diferentes entradas en ambos modelos. En el caso de la FFBPNN, las entradas utilizadas son los valores de radiación global horizontal y de temperatura medidos localmente en la instalación los 8 días previos a la predicción, mientras que, en el caso de la WSVM, el vector de entradas está formada por la potencia media generada en los cinco días más similares al de la predicción presentes en los datos históricos disponibles. Para seleccionar estos días, asignando a cada uno mayor o menor peso en función de su similaridad, utiliza una serie de relaciones que tienen en cuenta la estacionalidad, la radiación y la temperatura. Finalmente, a la vista de los resultados la WSVM obtiene mejores resultados que la FFBPNN.

Durante el desarrollo de gran parte de los modelos de predicción se usan técnicas de optimización, siendo una de las más utilizadas los algoritmos genéticos (GA), pero no la única. En [Zhang13] presentan un modelo que usa una red neuronal recurrente (Elman) y la optimiza mediante una combinación de GA y de la optimización por nube de partículas u optimización por enjambre de partículas (*PSO, Particle Swarm Optimization*). En este caso nos encontramos de nuevo con un modelo de predicción a muy corto plazo (5 min) de radiación, para el desarrollo del cual dispone de una serie temporal de 20 días en la que se han ido registrando cada 5 min las medidas locales de las variables meteorológicas correspondientes. A la vista de los resultados los autores concluyen que este algoritmo híbrido de optimización proporciona las ventajas de ambos, es decir, por

un lado la PSO permite guardar la información del mejor individuo mientras que las mutaciones proporcionadas por los GA permiten mantener la diversidad de la población de la PSO.

En [Yang13] de nuevo aparece un modelo con un horizonte de predicción de 24 horas (las siguientes 24 h al instante en que se realiza la predicción, es decir, no es para el día siguiente) en el que se realiza una clasificación de los días según sus condiciones meteorológicas, pero además, se tiene en cuenta la estación. Concretamente han entrenado una red neuronal wavelet (esta clase de redes neuronales emplean wavelets como funciones de activación en sus neuronas) según el tipo de día. Para seleccionar el tipo de día utilizan un SOM 5x4 que ha sido entrenado mediante un histórico de datos meteorológicos reales. El vector de entradas de la Wavelet NN está compuesto por la potencia media generada durante los cuatro días previos con el mismo tipo de día (según SOM). Los autores destacan que, gracias al uso de la clasificación de los días según sus condiciones meteorológicas, los resultados mejoran considerablemente. En este caso, los resultados los proporcionan para cuatro días de otoño con un comportamiento bastante regular obteniendo un MAE del 7,24% y un RMSE de 9,75%.

Una comparación entre diversos tipos de modelos aparece en [Pedro12], se describen tipos de modelos de los ya comentados previamente (persistente, ARIMA, ANNs...) y, además, el modelo del vecino más próximo (*k*-NN, *K Nearest Neighbours*). A pesar de la similaridad del acrónimo, este método no está relacionado con las redes neuronales, aunque ambos se pueden encontrar dentro de las técnicas de Inteligencia Artificial. El origen de este método puede ser rastreado hasta un informe técnico no publicado por Fix y Hodges, que pese a no haber sido publicado es muy reconocido en libros de texto y artículos sobre clasificación ([Silverman89], [Ripley96] y [Duda01]). Aunque hay pocos artículos en los que se use uno de estos modelos para predecir radiación o potencia fotovoltaica, los *k*-NN han sido utilizados como técnica de predicción en diversos problemas, como la predicción de la demanda energética o del precio de la electricidad ([Lora02], [Lora03]), o las predicciones meteorológicas [Bannayan08]. Volviendo a los modelos que aparecen en [Pedro12], todos los modelos de predicción son a muy corto plazo, concretamente tienen un horizonte de 1 – 2 h. Dispone de una serie temporal en la que se han recogido las potencias medias horarias de 22 meses en una instalación de 1 MW compuesta por paneles fotovoltaicos con seguidor de un eje. Todos los modelos utilizan como entradas las potencias medias horarias anteriores, no

usan variables meteorológicas. A la hora de calcular los errores los separa en tres períodos: muy variable (enero-abril), medio variable (mayo-junio) y poco variable (julio-agosto). De todos los modelos desarrollados los mejores resultados se obtienen con las redes neuronales optimizadas mediante algoritmos genéticos, obteniendo un RMSE medio del 7,3% para 1 h de horizonte y del 10,4% para 2 h de horizonte. Comparándolo con el modelo persistente se obtienen unas mejoras del 32.2% (horizonte 1h) y del 35.1% (horizonte 2h).

Es interesante destacar un modelo de predicción a muy corto plazo (15 min – 4 h) basado en modelos “grises” [Deng89] desarrollado en [Li13]. Los modelos grises constituyen una teoría de reciente aplicación, desarrollada principalmente en China, y de la que comienzan a aparecer diversas aplicaciones. En este caso los autores utilizan dos modelos grises avanzados, GM1(1,1) y GM2(1,1), cada uno para un intervalo de tiempo, de 8:00 a 12:00 y de 12:15 a 15:00, respectivamente. En este caso, se predice la potencia media generada utilizando como entrada las potencias medias reales precedentes al instante en el que se realiza la predicción. En este caso, los resultados que aparecen son para un día que podríamos considerar como claro, y se puede intuir que el RMSE está en el rango del 5% al 8%. Los autores comentan que debido a la variabilidad de la radiación, y en consecuencia de la producción fotovoltaica, esta técnica puede no ser la más adecuada, pero concluyen que resultaría interesante combinarla o integrarla en un modelo más avanzado.

En [Liang07] nos encontramos con un modelo de predicción para sistemas eólicos y solares basado en otra de las técnicas que se pueden encontrar dentro de la Inteligencia Artificial: la lógica fuzzy o sistemas de inferencia difusa. Teniendo en cuenta el objetivo principal de las investigaciones de la Tesis, en este apartado únicamente se analizará la parte de este modelo fuzzy referente a la predicción de la producción de energía solar fotovoltaica. En este caso, mediante el modelo fuzzy desarrollado se prevé el valor de radiación solar, siendo el modelo optimizado mediante algoritmos genéticos. A partir de este valor y de una serie de relaciones empíricas, se obtienen los valores de predicción para la producción solar fotovoltaica.

Siguiendo con este tipo de sistemas en [D'Andrea12] se desarrolla un modelo fuzzy de predicción a muy corto plazo (15 min) en el que las salidas únicamente se clasifican en tres categorías (bajo, medio y alto). Para ello en primer lugar partitiona los datos de entrada, radiación y temperatura del panel, en las tres categorías. Tras esto

realiza un preprocesado de los datos, quitando outliers y partiendo el dominio de entradas. Para realizar dicha partición divide la distribución de puntos en áreas, eliminando las no significativas y chequeando sólo las de dominio mayoritario (áreas con gran densidad de datos). Tras este preprocesado sólo toma como válidos el 23% de los datos históricos disponibles. La clasificación que el modelo realiza de las salidas acierta en un 92,2% de los casos testeados.

En [Prokop12] desarrollan y comparan dos modelos de predicción a tiempo real de la producción fotovoltaica en un parque solar de 1,1 MW de la República Checa, uno basado en redes neuronales (concretamente una MLP) y otro en los sistemas neurodifusos (ANFIS). Ambos modelos utilizan un vector de entradas compuesto por el histórico de radiación y potencia media además de la radiación medida localmente en el instante de la predicción. Disponen de una serie temporal de 5 meses, de la cual utilizan la mitad de los datos para entrenar los modelos y la otra mitad para probarlos. Los resultados que se obtienen con ambos modelos se encuentran en torno a un MAE del 2% siendo ligeramente mejor el obtenido mediante el ANFIS.

Basándose en los principios de los modelos descritos en los párrafos anteriores en [Yazdanbaksh13] desarrollan un modelo basado en la lógica fuzzy *Compleja* (ANCFIS) y lo comparan con un ANFIS y una RBFNN. En este caso los autores destacan que se trata de un modelo de predicción a muy corto plazo pero no concretan el horizonte. Para el desarrollo del modelo los autores se sirven de datos históricos de radiación y temperatura medidos localmente cada minuto durante 7 días (de los cuales utilizan 4 para entrenar y 3 para probar). El ANCFIS predice el valor de la radiación media ya a partir de dicho valor, mediante el modelo de referencia especificado en [Bellini09], calculan o predicen, la potencia media generada. Los autores comentan que a la vista de los resultados obtenidos profundizarán sus investigaciones con modelos ANCFIS para mejorar su eficacia en la predicción fotovoltaica.

Cómo ya se había comentado con anterioridad existen modelos de predicción híbridos, es decir, que combinan varias técnicas. Por ejemplo, en [Shi11] y [Shi12] nos encontramos con un modelo basado en máquinas de vector soporte (SVMs) pero que utiliza el modelo del vecino más próximo (k-NN) en la selección de parte de las variables de entrada. Concretamente se trata de un modelo de predicción de la potencia media horaria generada con un horizonte de predicción de 24 horas en un parque solar

fotovoltaico de 20 MW formado por paneles fijos. Mediante el *k-NN* se selecciona como entrada para las SVMs las potencias medias generadas más próximas (según *k-NN*). El resto de variables de entrada está formado por las predicciones de temperatura de un servicio de pronósticos locales. A su vez desarrollan cuatro SVMs, uno para cada tipo de día (soleado, nublado, lluvioso o con niebla) determinado por el pronóstico local. Los autores dan los resultados medios entre el grupo de entrenamiento y el de testeo, obteniendo un MAE del 8,64% y un RMSE próximo al 11%.

Otro modelo híbrido se presenta en [Mandal12] pero en este caso se trata de un modelo con un horizonte de predicción de 12 h para una instalación fotovoltaica de 15 kW. Este modelo combina la descomposición Wavelet con una red neuronal, una RBFN. Concretamente el proceso del modelo sería el siguiente, en primer lugar tomando como entradas la potencia media generada al realizar la predicción, la medida 12 horas antes y la medida 20 horas antes se realiza una descomposición Wavelet, esta salida junto con la temperatura y la radiación medidas localmente en dichos instantes conforman el vector de entradas de la RBFN. A su vez la salida de la RBFN es reconstruida por Wavelet obteniendo la predicción de la potencia media que se generará dentro de 12 horas. En este caso a la vista de los resultados puede calcularse un RMSE de aproximadamente el 9%, aunque cabe destacar que únicamente han sido evaluados dos días seleccionados de cada estación.

Esta combinación entre Wavelets y redes neuronales también aparece en el modelo que se describe en [Capizzi12], aunque en este caso se trata de un modelo de predicción cuyo resultado es lo que denomina como radiación total diaria para el día siguiente. Los datos de entrada son tratados (descomposición Wavelet) antes de convertirse en las entradas la red neuronal cuya salida es recomputada a su vez. En este caso las entradas son los valores de temperatura, radiación horizontal y velocidad del viento medidos localmente.

Otro modelo híbrido con un horizonte de predicción de 12 horas aparece en [Wang11], dicho modelo combina un modelo gris, GM(1,1), con una red neuronal FFBPNN, con el fin de predecir la potencia media horaria generada. Para el desarrollo del modelo se dispone de una serie temporal que recoge el histórico de generación horaria de la instalación durante 6 días soleados de abril, de los cuales utiliza 5 para entrenar y uno para testear. La red neuronal se entrena como un post-filtro, es decir, para determinar el error que cometerá el modelo gris en su predicción de la potencia media

generada y así corregir dicho valor. El modelo gris utiliza como entradas la potencia media de los días previos (en este caso 5) para la misma hora de la predicción. El modelo se testea en un día soleado con un comportamiento muy regular obteniendo una MAE del 4,8% y un RMSE del 6,6%.

Con un horizonte de predicción de 1 h – 12 h, en [Haque13] aparece un modelo híbrido que combina tres técnicas diferenciadas. Aplica la transformación por medio de Wavelets y un algoritmo de optimización denominado FireFly (FF) con una red neuronal cuya arquitectura es conocida como Fuzzy ARTMAP. La Teoría de la Resonancia Adaptativa (*Adaptive Resonance Theory, ART*), propone una modelización matemática de las dinámicas que rigen las conexiones entre neuronas de una red neuronal natural. La arquitectura neuronal Fuzzy ARTMAP, puede verse como una arquitectura capaz de aprender reglas difusas aunque formalmente no describe un sistema difuso [Cano96]. El modelo se desarrolla para una instalación de 15 kW a partir de un histórico que recoge los valores de radiación y potencia media generada durante 60 días. La potencia media generada en el instante de realizar la predicción y la generada 24 horas antes son descompuestas mediante Wavelets, formando el vector de entradas del sistema Fuzzy ARTMAP junto con la radiación medida localmente en dichos instantes. La salida del sistema Fuzzy ARTMAP es optimizada mediante el algoritmo FireFly obteniendo la predicción de la potencia media generada. Los autores presentan el MAE por estaciones y según el tipo de día (soleado, nublado, lluvioso), obteniendo un MAE promedio del 8%. El RMSE lo presentan por estaciones y sólo para los días soleados, obteniendo un RMSE medio del 12,64%.

A modo de resumen general en la Tabla 3. 1 se presentan las características más relevantes de los modelos de predicción, presentes en la literatura internacional, a los que se ha hecho referencia en el presente subapartado, es decir los que utilizan como entrada únicamente valores reales pasados (aunque alguno de ellos utiliza también pronósticos locales para la clasificación de los datos). En esta tabla se indica la variable que predicen (radiación o potencia eléctrica media horaria), el tipo de modelo, el horizonte de predicción, los criterios de evaluación y su valor (si los indican).

Tabla 3. 1 Características principales de los modelos de predicción basados en datos históricos

Ref.	Variable predicha	Tipo de Modelo	Horizonte	Criterio de evaluación	Valor
Rahman04	RAD _{mediah}	Ecs. Solares	24h	-	-
Rahman07	RAD _{mediah}	Ecs. Solares	24h	-	-
Santos03	RAD _{mediadia}	ARIMA	24h	MAE	16%
Li14	P _{mediah}	ARMAX	24h	-	-
Craggs00	RAD _{mediah}	ARIMA	10' - 1h	R ²	0,92-0,612
Kärner09	RAD _{mediah}	ARIMA	5' - 1h	-	-
Wang12	RAD _{mediah}	ANN	24h	MAE	-
Chow12	P _{mediah}	ANN (MLP)	0 - 20'	R ²	0,98-0,81
Mellit13	P _{mediah} P _{mediaDia}	ANN	0 (Inst.)	R ²	0,96-0,97
Izgi12	P _{mediah}	ANN	5-35' 30-300'(Ag)	RMSE	4,5% (5')-8,5% (35') 5% (30')-10,5% (300')
Al-Messabi12	P _{mediah}	ANN: FTDNN DTDNN	10' - 1h	-	-
Zhang12	RAD _{mediah}	ANN	Muy corto	-	-
Piliougue14	P _{mediah}	ANN (MLP)	0 (Inst.)	-	-
Xu12	P _{mediah}	ANN (FFNN) SVM (WSVM)	24h	-	-
Zhang13	RAD _{mediah}	ANN (ELMAN)	5'	-	-
Yang13	P _{mediah}	SOM+WAV.NN	24h	MAE/RMSE	7,24%/9,75%
Pedro12	P _{mediah}	VARIOS	1-2h	RMSE	7,3%(1h)-10,4%(2h)
Li13	P _{mediah}	MOD. GRIS	5' - 4h	RMSE	5-8%
Liang07	RAD _{mediah}	FUZZY + GA	24h	-	-
D'Andrea12	-	FUZZY	15'	-	-
Prokop12	P _{mediah}	ANN (MLP) Neurodifuso (ANFIS)	0 (Inst.)	MAE	2%
Yazdanbaksh13	P _{mediah}	Neurodifuso Comp. (ANCFIS)	Muy corto	-	-
Shi11y12	P _{mediah}	k-NN + SVM	24h	MAE/RMSE	8,64%/11%
Mandal12	P _{mediah}	WAV. + RBFNN	12h	RMSE	9%
Capizzi12	RAD _{mediadia}	WAV. + ANN	24h	-	-
Wang11	P _{mediah}	M.GRIS + ANN	12h	MAE/RMSE	4,8%/6,6%
Haque13	P _{mediah}	WAV. + FUZZY ARTMAP	1-12h	MAE/RMSE _{Sol}	8%/12,64%

3.3.2 MODELOS BASADOS EN MODELOS ATMOSFÉRICOS

La introducción de los valores de predicciones de variables meteorológicas (obtenidas a partir de modelos numéricos de predicción atmosférica o NWP, desarrollados fundamentalmente por los institutos meteorológicos nacionales) en los modelos de predicción de energía eléctrica de origen fotovoltaico, ha permitido reducir considerablemente los errores cometidos en las predicciones a medida que el horizonte de predicción aumenta [Al-Messabi12]. Existen varios modelos de predicción meteorológica siendo los más utilizados MM5, WRF, HIRLAM Y ECMWF. Estos modelos atmosféricos se van perfeccionando año tras año, permitiendo en la actualidad la previsión aceptable de las variables meteorológicas relacionadas con la producción fotovoltaica con una antelación de 72 horas.

Antes de comenzar a describir los diferentes modelos publicados en la literatura internacional que se han considerado más relevantes, es interesante destacar un artículo [Mori12] que busca las variables meteorológicas más importantes para predecir la potencia eléctrica media horaria en sistemas fotovoltaicos. Realiza un estudio comparativo, desarrolla un modelo de selección basado en un fluograma separado por estación (verano/invierno), para determinar el peso como entradas de las diferentes variables meteorológicas que tienen, o pueden tener, relación con la generación fotovoltaica. En la Tabla 3. 2 aparecen las 7 variables de mayor peso (en orden decreciente) según el periodo estacional en el que nos encontremos:

Tabla 3. 2 Principales variables relacionadas con la producción fotovoltaica

INVIERNO	VERANO
1. RADIACIÓN	1. RADIACIÓN
2. HORAS DE SOL	2. HORAS DE SOL
3. ALTITUD SOLAR	3. ALTITUD SOLAR
4. TIEMPO	4. HUMEDAD
5. POSICIÓN SOLAR	5. TEMPERATURA
6. HUMEDAD	6. TIEMPO
7. TEMPERATURA	7. POSICIÓN SOLAR

Uno de los primeros modelos desarrollados de este tipo aparece en [Bofinger06], concretamente consiste en la previsión de la producción eléctrica tomando como base las previsiones meteorológicas del Centro Europeo de Predicción a Plazo Medio (*European*

Center for Midrange Weather Forecast - ECMWF), afinada localmente mediante los modelos estadísticos de salida (Model Output Statistics – MOS) asociados a las estaciones meteorológicas locales. El esquema que sigue el modelo puede verse gráficamente a continuación, en la Figura 3. 1.



Figura 3. 1 Representación esquemática del modelo de predicción de [Bofinger06]

Por tanto, la metodología usada para el desarrollo del modelo, denominada MOS, tiene en cuenta la estacionalidad de la variable a predecir considerando diferentes parámetros meteorológicos, y a los valores horarios previstos de las variables meteorológicas se les asocian una serie de pesos o coeficientes [Glahn72].

Con este ajuste se obtienen predicciones locales de temperatura y radiación más afinadas. Sin embargo, es necesario que todos los datos sean manipulados por PCs, utilizando su potencia de cálculo y los correspondientes medios de interpolación. Para obtener una predicción más fiable, tuvieron que incluir como variables de entrada la distribución, la orientación y la inclinación de los paneles de los sistemas fotovoltaicos. En una primera fase fue necesario convertir la radiación horizontal en radiación incidente sobre plano inclinado. Posteriormente, fue necesario proceder a simular el comportamiento del módulo del sistema eléctrico fotovoltaico, del cableado y del inversor. La validación de los resultados de simulación de la producción eléctrica fue realizada

para los meses de Julio y Agosto, calculando el RMSE entre los valores de predicción y los valores reales medidos para cada sistema. Concretamente, en un análisis hora a hora se obtuvo un RMSE del 34,7 %, y en análisis diario el RMSE es del 24,5 %.

Otro modelo que sigue la misma línea que el anterior aparece en [Lorenz07], en este caso se basa en predicciones de radiación para tres días, procedentes del ECMWF (afinadas localmente mediante MOS). Seguidamente las predicciones de radiación global horizontal son convertidas, para el plano del panel, siguiendo la formulación matemática anisotrópica, propuesta en [Klucher79]. La fase final consiste en aplicar un modelo de simulación fotovoltaico, [Drews08], para obtener la predicción de potencia generada por el sistema. Las predicciones fueron investigadas tanto para sistemas individuales como para grupos de sistemas fotovoltaicos. Los resultados de las predicciones fueron mejores para los grupos de sistemas fotovoltaicos debido al efecto de las medias. En el caso de sistemas aislados los RMSE varían considerablemente (en el mejor de los casos un 13%).

En [Pelland11] aparece un modelo de predicción para el día siguiente basado en el modelo atmosférico GEM (Global Environmental Multiscale) desarrollado por el Centro Meteorológico Canadiense. Se basa en optimizar las predicciones de radiación que da directamente el GEM para calcular a partir de una serie de relaciones empíricas el valor de la potencia media horaria generada. Las variables meteorológicas que utiliza se corresponden con la radiación horizontal, la temperatura y la cobertura total de nubes. La predicción inicial de la radiación es optimizada mediante dos métodos de post-proceso, un Filtro Kalman y un promediado espacial (*spatial averaging*). Para desarrollar los modelos dispone de un histórico de dos años, de los cuales utiliza uno para entrenar el modelo y otro para probarlo.

Otro modelo de predicción con horizonte de 24 horas es desarrollado en [Ding11] basándose también en la aplicación de una red neuronal para predecir la potencia media horaria generada. Los autores desarrollan un algoritmo de selección de “día similar” para tomar los valores de radiación captados en la instalación estudiada para dicho día. De forma que estos valores junto con las temperaturas mínima, media y máxima de dicho día y las temperaturas mínima, media y máxima pronosticadas para el día siguiente por una web (la cual las obtiene a partir de un NWP) se convierten en las entradas de la red neuronal.

Con un horizonte de 24 h, en [Yona07] desarrollan tres modelos basados en redes neuronales diferentes (FFBPNN, RBFNN y una NN de Elman) con el fin de obtener la radiación horizontal media horaria para posteriormente poder estimar la potencia producida mediante la relación correspondiente. En este caso el modelo atmosférico utilizado es el desarrollado por la Agencia Meteorológica Japonesa (NPD/JMA). La serie temporal disponible para el desarrollo del modelo abarca un total de 48 días. A partir de los resultados obtenidos los autores determinan que el uso de las redes neuronales combinadas con un NWP son una buena opción para desarrollar modelos de predicción de energía fotovoltaica.

En [Chen11a], utilizan una serie de redes neuronales para crear un modelo de predicción de la potencia media horaria generada para el día siguiente en una instalación solar fotovoltaica de 18 kW compuesta por paneles fijos sobre un tejado. En primer lugar clasifica los días, según las condiciones climatológicas del mismo, en soleado (sunny), nublado (cloudy) o lluvioso (rainy), para ello desarrollan un SOM, o mapa auto-organizado, cuyas entradas son las variables meteorológicas medidas localmente el día previo a la predicción (radiación, cobertura de nubes total y cobertura de nubes bajas). A su vez, para cada *tipo de día* entrena una red neuronal, concretamente una RBFNN, que será la encargada de estimar la potencia generada. Obviamente las entradas de estas redes son las variables meteorológicas predichas por el NWP utilizado por los autores (no especifican cuál). Concretamente son la humedad media diaria, la velocidad media diaria del viento, la radiación media diaria y la temperatura media diaria, además del instante de predicción (día y hora) y de la potencia generada. Para evaluar el modelo los autores escogen 4 días soleados, 4 nublados y 4 lluviosos, mostrando el MAE para cada uno de ellos. A la vista de los resultados que muestran puede verse que el modelo se adapta bastante bien a días soleados e incluso a los nublados pero que en los días lluviosos los errores aumentan considerablemente.

Con un horizonte de predicción de 24 horas estricto, es decir que no es para el día siguiente sino para las 24 horas siguientes al instante en el que se realiza la predicción, se desarrollan dos modelos basados en una RBFNN en [Ciabattoni12a]. Las variables atmosféricas se han obtenido de la Web PVGIS (cuyos datos se obtienen a través de un NWP) [re.jrc.ec.europa.eu/pvgis/]. Estos modelos predicen la radiación horizontal media horaria, para estimar con posterioridad la potencia media horaria, en un parque solar fotovoltaico de 14 kW. La única diferencia entre ambos modelos son los datos con los

que los entrena. Concretamente desarrollan el primero de los modelos entrenándolo con los 12 primeros días de cada mes y el segundo modelo con el resto. Para ello disponen de una serie temporal donde se ha registrado un histórico de prácticamente un año. Cabe destacar que antes de proceder con el entrenamiento de los modelos se normalizan todas las variables, con el fin de mejorar la eficiencia de las redes neuronales. Para probar los modelos cada uno utiliza los datos con los que se ha entrenado el otro modelo. En cuanto a los resultados, el RMSE obtenido al predecir la radiación va del 6,67% al 9,51%. En cuanto a la predicción de la producción, los autores comentan que obtienen un RMSE del 12% en los datos de validación, además presentan el error en la estimación de la energía total diaria que se produce obteniendo un RMSE medio del 7,70%.

Otro modelo de predicción de la potencia media horaria generada en tres instalaciones fotovoltaicas en Italia (229 kW + 425 kW + 212 kW) aparece en [Ciabattoni12b], con un horizonte de predicción de 24 h (no para el día siguiente sino para las siguientes 24 horas al instante en que se realiza la predicción). En este caso las variables atmosféricas también se han obtenido de la Web PVGIS (cuyos datos se obtienen a través de un NWP) [re.jrc.ec.europa.eu/pvgis/]. En este artículo comparan el modelo desarrollado con el modelo descrito en el párrafo anterior [Ciabattoni12a]. El modelo desarrollado es denominado MRANEKF, se basa en una RBFN optimizada por medio del algoritmo denominado MRAN (*Minimal Resource Allocating Network*). El algoritmo MRAN se basa en la aplicación de un filtro Kalman Extendido (EKF) y de un algoritmo de aprendizaje secuencial ([Platt91], [Kadirkamanathan93]). El filtro Kalman se programa por código para corregir las predicciones de PVGIS que se introducen como entradas de la RBFNN. Para desarrollar el modelo utilizan una serie temporal de aproximadamente un año. Los autores dicen que se obtiene un RMSE del 9,5% frente al 13,5% que se obtiene de aplicar directamente la RBFNN, aunque cabe destacar que prueban el modelo con todo el período (es decir, incluye los datos de entrenamiento).

En [DaSilva11] desarrollan dos modelos de predicción de la potencia media generada en un parque solar fotovoltaico de 1 MW situado en Japón para dos horizontes de predicción, uno para un horizonte de 2 h y otro para un horizonte de 25 h. Ambos modelos se basan en un caso particular de una SVM conocido como SVR (*Support Vector Regression*). Las variables meteorológicas que utilizan como entradas proceden del modelo de predicciones atmosféricas de la Agencia Meteorológica de Japón (GPV-MSM). Para entrenar el modelo disponen de una serie histórica de un año. El vector de

entradas está compuesto por las predicciones de temperatura, humedad relativa, cobertura de nubes (baja, media y alta), además de la radiación extraterrestre calculada según [Notton02]. El artículo estudia las diferencias entre los errores que se obtienen al pasar del horizonte de 2h a 25h, aumentando el MAE en un 13% y el RMSE en un 17%. Los resultados han sido calculados para todo el período (también incluyen los datos de entrenamiento), obteniendo un MAE del 6,5% (2h) y 7,6% (25h) y un RMSE del 10,4% (2h) y 11,8% (25h).

A partir del modelo anterior en [DaSilva12] desarrollan un modelo de predicción de la potencia media horaria generada, pero en este caso para un horizonte de predicción de 3 horas. La instalación fotovoltaica y la serie de datos disponible, y en consecuencia las entradas, son las mismas que se han descrito en el párrafo anterior. En este caso realizan un estudio comparativo entre el uso, o no, de las variables meteorológicas referentes a la cobertura de nubes. El modelo desarrollado también es un SVR. Los resultados que se obtienen con el modelo se comparan con el que se obtendría aplicando el modelo persistente y con el que se obtendría sin usar como entradas las variables de la cobertura de nubes. Concretamente se obtiene un MAE del 5,8% frente al 12,64% del modelo persistente y del 8,26% que se obtendría sin tener en cuenta la cobertura de nubes y un RMSE del 9,5% frente al 20,2% del modelo persistente y del 12,57% que se obtendría sin tener en cuenta la cobertura de nubes.

Los modelos anteriores básicamente se centraban en una sola técnica mientras que los que se especifican a partir de este punto combinan varias técnicas o métodos dentro del modelo de predicción correspondiente.

En [Bacher09] nos encontramos con un modelo de predicción de la potencia media horaria en una instalación fotovoltaica de 3 kW cuyo horizonte de predicción es para el día siguiente, concretamente de 12 a 36 h. En este caso se desarrollan y comparan tres modelos diferentes para elegir el que proporciona mejores resultados. Estos modelos se basan el modelo de día claro y predicen el valor de la variable τ , que representa la relación entre la potencia generada y la potencia que hubiera sido generada con día claro. Los datos históricos disponibles abarcan un periodo de un año, siendo el modelo atmosférico utilizado el HIRLAM, del Instituto Danés de Meteorología. Para desarrollar los tres modelos presentan como posibles entradas las τ anteriores y la τ que se puede obtener como transformación de las variables meteorológicas proporcionadas por el modelo HIRLAM. El primero de los modelos toma como entradas únicamente las τ

anteriores por lo que podría incluirse en los descritos en el subapartado anterior y se trata de un modelo autoregresivo (AR). El segundo de los modelos se basa únicamente en la transformación de las variables proporcionadas por el HIRLAM para obtener el supuesto valor de τ (LM_{nwp}). El tercer modelo incluye todas las entradas y se trata de un modelo autorregresivo con entradas exógenas (ARX). En cuanto a los resultados los autores especifican que para el día siguiente los resultados que se obtienen con el segundo y tercer modelo son prácticamente los mismos, aunque sí que eligen como modelo óptimo el tercero. Además, indican que los resultados pueden ser más optimistas de los que se obtendría en realidad, ya que para calcular uno de los coeficientes de corrección que utilizan, el denominado *forgetting factor* (que reduce exponencialmente el peso de las muestras de error más antiguas), los datos de testeo también se han utilizado. Concretan que proporciona una mejora en el RMSE respecto al modelo persistente del 36%. No concretan el valor exacto del RMSE obtenido pero a partir de la gráfica proporcionada para un horizonte de 19 a 29 h, se puede entender que su media se halla en torno al 11%.

En [Detyniecki12] aparece un modelo de predicción cuyo objetivo es determinar la energía total diaria producida por un minipanel solar fotovoltaico de Arduino durante el día de la predicción, es decir, tienen un horizonte de predicción que va de las 0 a las 8 o 10 horas (las horas de sol del día en cuestión). Las variables meteorológicas que utiliza las obtiene de la NOAA (*National Oceanic and Atmospheric Administration*) justo antes del amanecer. También clasifica los días en claro, poco nublado, medio nublado, nublado, lluvioso... a partir de las predicciones de la NOAA. El modelo se basa en la lógica Fuzzy, concretamente en un caso particular de la misma conocido como árbol de decisiones Fuzzy (FDT, *Fuzzy Decision Tree*), que básicamente consiste en aplicar la lógica Fuzzy a un árbol de decisiones tradicional. A pesar de no dar el valor del RMSE, los autores especifican que en la predicción de la energía total diaria se obtiene una mejora del 27% respecto al modelo persistente.

Siguiendo con los modelos de predicción híbridos que combinan la lógica difusa con otras técnicas en [Chen13] nos encontramos con un modelo de predicción a corto plazo (0 - 10 h) de la radiación media que combina la lógica Fuzzy con las redes neuronales. Los datos meteorológicos se obtienen de la NEA (*National Environment Agency*), usando como entradas para los modelos la temperatura y lo que denomina como información del cielo (soleado, nublado o lluvioso). En primer lugar el modelo

chequea la hora de la predicción, después tiene en cuenta el tipo de día previsto y, mediante la lógica Fuzzy, el modelo separa las entradas en función de la temperatura en tres niveles (alto, medio y bajo), para cada uno de los cuales una FFBPNN realiza un pronóstico de la radiación media horaria. En cuanto a los resultados obtenidos los autores comentan que el MAE oscila del 6,03 al 9,65%.

En la misma línea de los anteriores en [Yona13] desarrollan un modelo de predicción de la potencia media horaria que combina otras técnicas con la lógica fuzzy. El horizonte de predicción comprende las 24 horas siguientes al instante en el que se realiza la predicción. Los autores no concretan de qué modelo atmosférico obtienen los valores de las variables meteorológicas utilizadas como entradas. Las entradas utilizadas comprenden la temperatura, la humedad y la cobertura de nubes. Dichas entradas son sometidas a un conjunto de reglas fuzzy para predecir un valor de radiación media el cual se corrige mediante otras reglas fuzzy basadas en datos históricos. Finalmente este valor de radiación estimado es tomado como entrada por una red neuronal recurrente (RNN) la cual estima el valor de la potencia media horaria generada. En cuanto a los resultados los autores no proporcionan valores exactos para los errores cometidos pero presentan varias gráficas. A partir de ellas se puede estimar que el valor medio normalizado del MAE se halla próximo al 7%.

Un modelo de predicción con una optimización híbrida aparece en [Quan13] utilizando, como en el anterior, variables meteorológicas de un modelo atmosférico no mencionado por los autores. En este caso la pieza central del modelo se trata de una red neuronal cuyos resultados son optimizados mediante una combinación de GA y de la optimización por nube o por enjambre de partículas (*PSO, Particle Swarm Optimization*), al igual que el modelo desarrollado en [Zhang13], ya comentado en el subapartado anterior (por no usar NWP). Las variables meteorológicas del NWP utilizadas como entradas comprenden el día, la radiación horizontal, la temperatura, humedad, presión, velocidad del viento y cobertura de nubes. El modelo predice la potencia generada por un sistema eólico y otro fotovoltaico. Cabe destacar que los resultados presentados por los autores son para todo el periodo (incluidos, por tanto, los datos de entrenamiento) obteniendo un MAE del 14% en el caso eólico. En el caso fotovoltaico no lo concreta.

En [Monteiro13a] aparece un modelo de predicción de la potencia eléctrica media horaria generada en una instalación fotovoltaica de 2,8 MW con un horizonte de predicción de 1-24 h, que es comparado con un modelo basado en una red neuronal MLP

basada en uno de los trabajos desarrollados en las investigaciones iniciales vinculadas a la presente Tesis Doctoral (descrito con más detalle en [Muñoz09] y [Fernández12]) durante el periodo de elaboración de la misma. El modelo desarrollado se trata de un modelo de similaridad histórica denominado HISIMI. El modelo atmosférico utilizado es el WRF. Como entradas utiliza la temperatura y la radiación predicha por el WRF correspondientes al instante de la predicción y al instante previo, además del día del año normalizado (a partir del cálculo de su seno y su coseno). Además se realiza una optimización mediante algoritmos genéticos. Los resultados obtenidos con el HISIMI proporcionan un RMSE del 10,14% mejorando ligeramente el correspondiente a la MLP, que es del 10,22%.

En dos de los artículos publicados como consecuencia de los trabajos de investigación de la presente Tesis [Muñoz09] y [Fernández12], se desarrollan numerosos modelos de predicción fotovoltaica a corto plazo para una instalación de 36 kW que tienen en cuenta gran parte de las técnicas a las que se ha hecho referencia en el presente capítulo, como son el persistente, ARIMA, k-NN, ANFIS, diversas redes neuronales... Además varios de ellos han sido optimizados mediante algoritmos genéticos. Estos modelos serán descritos con más detalle en el correspondiente capítulo de la presente Tesis, pero resulta relevante destacar sus características principales. El modelo atmosférico utilizado en este caso es el MM5, y el horizonte de predicción de todos los modelos es el día siguiente, concretamente 16 – 39 horas. Para desarrollar los modelos se dispone de un histórico de un año donde aparecen registradas tanto las variables meteorológicas correspondientes como la potencia media generada en cada instante. Los datos son sometidos a diversos tratamientos que ya serán especificados. Cabe destacar que para algunos modelos las variables meteorológicas se han triplicado como entradas, ya que se dan para el instante de la predicción, para el anterior y para el posterior. De los resultados cabe destacar el RMSE del modelo que proporciona los mejores resultados, una red neuronal denominada MLP2A, su valor es del 11,79% para uno de los grupos de evaluación y de 13,17% para el otro grupo de test.

En el tercero de los artículos a los que han dado lugar las investigaciones vinculadas a la presente Tesis Doctoral, [Monteiro13b], aparece un modelo de predicción de la potencia eléctrica media horaria generada en la misma instalación fotovoltaica a la que se hace referencia en el párrafo anterior, basado en el modelo de día claro, que es comparado con el modelo MLP2A ya mencionado. Concretamente el nuevo modelo,

denominado APVF, se trata de un modelo analítico basado en el modelo de día claro en el que se utiliza la variable τ , que al multiplicarla por la potencia de día claro, calculada mediante las correspondientes ecuaciones solares, proporciona el valor previsto de la potencia generada. En cuanto a los resultados obtenidos el RMSE empeora ligeramente mientras que el MAE mejora ligeramente.

A modo de resumen general en la Tabla 3. 3 se presentan las características más relevantes de los modelos de predicción, presentes en la literatura internacional, a los que se ha hecho referencia, es decir, los que utilizan variables meteorológicas predichas por un modelo atmosférico. En esta tabla se indica la variable que predicen (radiación o potencia eléctrica media horaria), el tipo de modelo, el modelo atmosférico utilizado, el horizonte de predicción, los criterios de evaluación y su valor (si los indican).

Tabla 3. 3 Características principales de los modelos de predicción basados en mod. atmosféricos

Ref.	Variable predicha	Tipo de Modelo	NWP	Horizonte	Criterio de evaluación	Valor
Bofinger06	P _{mediah}	MOS+Simul.PV	ECMWF	24h	RMSE	34,70%
Reindl90	P _{mediah}	MOS+Simul.PV	ECMWF	24h	RMSE	-
Pelland11	P _{mediah}	Kalman + Opt.	GEM	24h	-	-
Yona07	RAD _{mediah}	3 ANNs	GPV-MSM	24h	-	-
Chen11a	P _{mediah}	SOM + ANN	-	24h	MAE	-
Ciabattoni12a	RAD _{mediah}	ANN (RBFNN)	PVGIS	24h	RMSE	6,67%-9,5%
Ciabattoni12b	P _{mediah}	RBFN+MRAN+EKF	PVGIS	24h	RMSE	9,60%
DaSilva11	P _{mediah}	SVM (SVR)	GPV-MSM	2h 25h	MAE/RMSE	6,5%/10,4% 7,6%/11,8%
DaSilva12	P _{mediah}	SVM (SVR)	GPV-MSM	3h	MAE/RMSE	5,8%/9,5%
Ding11	P _{mediah}	ANN (FFNN)	-	24h	MAE	-
Bacher09	P _{mediah}	M.Día Claro	HIRLAM	24h	RMSE	-
Detyniecki12	E _{TotalDiaria}	FDT (Fuzzy Dec. Tree)	NOAA	0 - 10h	Mejora Pers.	27%
Chen13	RAD _{mediah}	FUZZY + FFNN	NEA	0 - 10h	MAE	6,03-9,65%
Yona13	P _{mediah}	FUZZY + ANN	-	24h	MAE	7%
Quan13	P _{mediah}	ANN + PSO + GA	-	24h	MAE	-
Monteiro13a	P _{mediah}	HISIMI	WRF	24h	RMSE	10,14%
Muñoz09 Fernández12	P _{mediah}	VARIOS	MM5	24h	RMSE	11,79%
Monteiro13b	P _{mediah}	APVF vs. MLP	MM5	24h	-	-

3.4 CONCLUSIONES

A partir de la revisión bibliográfica sobre modelos de predicción de la producción eléctrica en parques solares fotovoltaicos, realizada con el propósito de redactar el presente capítulo, se pueden obtener una serie de conclusiones. Dichas conclusiones se exponen a continuación.

1. Los modelos de predicción son descritos con un nivel de detalle que difiere mucho de unos artículos a otros. Mientras que en algunos artículos tanto el modelo como sus resultados se presentan detalladamente, en otros simplemente hacen una descripción del modelo con unos resultados muy poco específicos.
2. Al mismo tiempo, los resultados publicados y obtenidos con diferentes modelos difieren bastante, no solo por su precisión, sino porque no es posible obtener una predicciones equiparables entre dos instalaciones fotovoltaicas situadas en lugares geográficos alejados. Esto es así porque en la radiación incidente intervienen diversos factores dependientes de la localización. Por un lado nos encontramos con el fenómeno de estacionalidad, ya que la radiación varía en función del día del año (según a que estación pertenezca) en que nos encontramos. Además, la altitud también influye debido a que en zonas de alta montaña el aire es más limpio y más delgada la capa atmosférica que deben recorrer los rayos solares, de manera que a mayor altitud mayor radiación. Además en función de la ubicación geográfica, de la latitud, se modifica la posición del sol, las horas de sol y la forma en la que sus rayos inciden sobre la instalación. Por estos y otros factores dependientes de la localización (nubes, precipitaciones...), pese a que dos modelos de predicción obtengan unos errores similares, no tienen por qué ser igual de eficaces, y en consecuencia, un modelo desarrollado para una localización concreta no será de aplicación a cualquier otra instalación.
3. Queda patente que las variables atmosféricas de mayor interés para la predicción de la producción eléctrica en un parque solar fotovoltaico son la radiación, la cobertura de nubes, la altitud y posición solar, la humedad y la temperatura [Mori12] además de otras variables como son el tiempo (día y hora) y las horas de sol.

4. En algunos artículos se desarrollan varios modelos y se comparan entre sí con el fin de ver cuál es el más eficiente al ser evaluados mediante el mismo grupo de prueba o test. Pero cuando se desarrolla un solo modelo de predicción, si se compara con otro, suele ser con el modelo persistente.
5. A la vista de los resultados que se obtienen con los diferentes modelos de predicción descritos en el apartado anterior, queda patente que los modelos basados en datos históricos presentan mejores resultados que los modelos que utilizan modelos atmosféricos para plazos muy cortos (5 min – 2h) mientras que a medida que el horizonte aumenta, los modelos que utilizan como entradas variables meteorológicas previstas se van volviendo cada vez más eficientes [Al-Messabi12].
6. Los modelos de predicción basados únicamente en datos históricos se usan tanto para plazos muy cortos (menos de 3 – 4 h) como para horizontes en torno a las 24 horas. En cambio la mayor parte de los modelos de predicción que utilizan modelos atmosféricos están más orientados a realizar la predicción con un horizonte de 24 h o para el día siguiente (con algunas excepciones [DaSilva11], [DaSilva12]).
7. En cuanto a los criterios de evaluación utilizados por los diferentes autores, se puede decir que siguen una línea similar a la mostrada en el segundo apartado del presente capítulo, pero destacan por encima de todos el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE), aunque no siempre son calculados por el mismo método.
8. Queda claro que los errores de predicción aumentan al mismo tiempo que lo hace el horizonte de predicción. Sin embargo, la mejora que suponen los modelos de predicción desarrollados respecto al uso directo del persistente generalmente aumenta al hacerlo el horizonte.
9. Cabe destacar que a la hora de presentar los resultados no todos los autores tienen en cuenta el grupo de prueba completo. Se dan casos en los que únicamente se muestra el resultado para algunos días seleccionados o incluso para varios modelos se dan los resultados para toda la serie temporal disponible, es decir, para los datos de entrenamiento además de los de prueba.

10. Tal y como puede apreciarse en [Lorenz07], los errores de predicción se pueden reducir si pasamos de aplicarlos a un único parque solar fotovoltaico a aplicarlo a un conjunto de parques situados en una misma región o a un conjunto de parques de una misma localización [Ciabattoni12b].
11. Se demuestra que el uso de variables adicionales [Wang12], que pueden calcularse a través de diversas relaciones empíricas o ecuaciones solares, permiten una mejora en la clasificación de datos y en el entrenamiento de los modelos de predicción.
12. Como puede verse en varios de los modelos citados, la separación de los datos según las condiciones meteorológicas generales del día (soleado, nublado, lluvioso...) para entrenar diferentes modelos permiten obtener una mejora sustancial en los resultados.
13. En el caso de los modelos de predicción basados en la utilización de modelos atmosféricos, su eficacia, sus errores, están muy ligados a la eficacia de las predicciones del modelo atmosférico en cuestión. Para reducir los errores de dichas predicciones se aumenta la resolución del modelo atmosférico o se aplican filtros, siendo el más utilizado el filtro Kalman.
14. En caso de que un modelo desarrollado para una instalación solar fotovoltaica concreta quiera ser adaptado a otra instalación diferente se han de tener muy en cuenta la similaridad geográfica y el tipo de paneles fotovoltaicos, ya que no es lo mismo que los paneles sean fijos o con seguidor a uno o dos ejes.

CAPÍTULO

4

MODELOS ATMOSFÉRICOS

En este capítulo se van a describir los fundamentos en los que se basan los modelos atmosféricos utilizados en el desarrollo de los modelos de predicción creados a partir de las investigaciones a las que se hace referencia a lo largo del documento. Concretamente se presentan las principales características y los fundamentos del desarrollo de los modelos atmosféricos o modelos de predicción meteorológica numérica (*Numerical Weather Prediction, NWP*) en el corto plazo. Se presentan las características de resolución espacial y temporal de estos modelos de predicción numérica, describiendo los aspectos más relevantes de los modelos globales y meso-escalares. Se analizan más en detalle dos modelos meso-escalares de predicción numérica, el MM5 y el WRF, bien conocidos a nivel internacional, ya que son los que se han utilizado en el desarrollo de los modelos de predicción derivados de las investigaciones vinculadas a la presente Tesis Doctoral. Concretamente, estos modelos son los que proporcionan las predicciones de las variables meteorológicas que se utilizarán, junto con otras, como entradas de los modelos de predicción definitivos.

4.1 FUNDAMENTOS DE LA MODELIZACIÓN NUMÉRICA

La modelización numérica meteorológica es el proceso en el cual se obtiene un pronóstico objetivo del estado futuro de la atmósfera mediante la solución de un grupo de ecuaciones que describen la evolución de un grupo de variables (radiación, temperatura,

velocidad y dirección del viento, humedad, presión...) que a su vez definen el estado de la atmósfera [SENAMHI02].

El proceso se inicia con el análisis del estado actual de la atmósfera utilizando un pronóstico a muy corto plazo y adicionando las observaciones disponibles para ello con el fin de lograr una mejor descripción del verdadero estado actual de la atmósfera. A partir de allí se ejecuta un modelo en computador para producir el pronóstico.

Todos los modelos numéricos de la atmósfera se basan en el mismo grupo de ecuaciones que gobiernan la atmósfera y las cuales son descritas en términos no-matemáticos (de advección, de conservación de la masa o de continuidad, hidrostáticas, termodinámicas, de estado, de vapor de agua). Los modelos numéricos difieren entre sí en las aproximaciones y suposiciones hechas en la aplicación de éstas ecuaciones y en como ellas son resueltas para la representación de los diferentes procesos físicos.

4.2 ESCALAS DE LOS MODELOS ATMOSFÉRICOS

No todos los modelos atmosféricos trabajan con la misma escala espacio-temporal. Cada modelo atmosférico trata de seguir la evolución de la atmósfera para la escala que lo define. Por ejemplo, para la predicción de la radiación en la superficie del terreno la escala del modelo atmosférico debe ser pequeña: pequeña en lo espacial por la influencia que tiene la orografía sobre la radiación, y pequeña en lo temporal por la variabilidad que puede presentar la cobertura de nubes (vinculada a la variabilidad del viento). Así, en función de la escala espacio-temporal, se distinguen tres clases de modelos: macro-escala, meso-escala y micro-escala.

En [Orlanski75] se plantea una normalización para las distintas escalas, proponiendo 8 subdivisiones contenidas en las tres escalas. La escala correspondiente a cada subdivisión se adapta mejor para el estudio de algún fenómeno atmosférico concreto. Estas subdivisiones, con su escala espacial y temporal, figuran en la Tabla 4. 1. En dicha tabla se da el límite inferior para cada una de las subdivisiones. En general, un modelo atmosférico con alta resolución espacial (escala espacial pequeña) tendrá un bajo alcance (validez) de las predicciones que realice (escala temporal pequeña). Por el

contrario los modelos con una baja resolución espacial (escala espacial grande) tendrán un alcance temporal mucho mayor.

Tabla 4. 1 Escalas espacio-temporales de los modelos atmosféricos

Nombre	Escala espacial	Escala temporal
Macro- α	10000 km	1 mes
Macro- β	2000 km	1 semana
Macro- γ	200 km	1 día
Meso- β	20 km	6 horas
Meso- γ	2 km	1 hora
Meso- δ	200 m	30 minutos
Micro- β	20 m	1 minuto
Micro- γ	2 m	1 segundo

Tanto los modelos atmosféricos de macro-escala como los de micro-escala estudian fenómenos cuyas escalas escapan de las variables de interés en la predicción de la producción eléctrica en parques solares fotovoltaicos. Para esta tarea, los modelos atmosféricos que pueden aportar la información con mayor interés son los modelos de meso-escala. La escala temporal de un modelo de meso-escala puede aumentarse si sus condiciones iniciales se establecen a partir de un modelo de mayor escala. Por ejemplo, es posible realizar predicciones con un modelo de meso-escala con una escala temporal de varios días, sobre la base de encadenar predicciones para intervalos de varias horas, tomando las condiciones iniciales de la atmósfera, para cada intervalo, a partir de las predicciones de un modelo de macro-escala. Por ello, se van a describir con mayor detalle los modelos de macro-escala y de meso-escala.

4.3 MODELOS ATMOSFÉRICOS GLOBALES

Los modelos atmosféricos globales o de macro-escala son los que ofrecen predicciones meteorológicas de mayor alcance (escala mundial). Estos modelos poseen una resolución del orden de 200 km y su objetivo es identificar el comportamiento general de la atmósfera sobre una determinada zona. Por tanto, son modelos con capacidad para identificar fenómenos meteorológicos de gran escala.

A continuación, se recogen en la Tabla 4. 2 los principales modelos globales desarrollados.

Tabla 4. 2 Modelos NWP Globales

Modelo	Desarrollado por:
GFS – <i>Global Forecast System</i>	<i>National Centre for Environmental Prediction</i>
GEM – <i>Global Environmental Multiscale Model</i>	<i>MSC – Meteorological Service of Canada</i>
IGCM – <i>Intermediate General Circulation Model</i>	<i>Department of Meteorology at the University of Reading</i>
UM – <i>Unified Model</i>	<i>UK Met Office</i>
GME	<i>German Weather Service</i>

El modelo atmosférico GFS, con resolución espacial de 1°, es resuelto 4 veces al día, concretamente con la asimilación de los datos de la atmósfera a las 0, 6, 12 y 18 horas GMT. Produce predicciones de las variables meteorológicas para los puntos de la rejilla con horizontes de 3 a 180 horas a intervalos de 3 horas. Los resultados, en ficheros con un formato específico llamado GRIB, están disponibles desde unas 3 horas y media después de la asimilación de datos (los primeros datos con un menor horizonte de predicción), hasta unas 4 horas y media después de la asimilación de datos (los últimos).

Para la zona de España la resolución horizontal del modelo GFS 1° es de unos 100 km (distancia media entre dos puntos contiguos). Evidentemente esta resolución no es suficiente para poder predecir las variables de interés para un parque fotovoltaico situado en un lugar no coincidente con los puntos de análisis, lo que obliga a utilizar un modelo atmosférico con mayor resolución espacial.

4.4 MODELOS ATMOSFÉRICOS LOCALES

Los modelos atmosféricos globales aportan información de la evolución de la atmósfera para todo el planeta, pero en ocasiones sólo se necesita información para las zonas continentales (la información para las zonas oceánicas no tiene tanto interés). Esto dio lugar al nacimiento de los modelos atmosféricos llamados locales o regionales, que abarcan en su análisis, grandes zonas: Europa, Norteamérica, etc. Siguen siendo modelos atmosféricos de macro-escala pero con la desventaja frente a los modelos atmosféricos globales de necesitar, además de las condiciones iniciales, unas condiciones de contorno en las fronteras del dominio. Estas condiciones de contorno se consiguen interpolando los valores de salida de un modelo atmosférico global. La ventaja que tienen frente a los modelos atmosféricos globales es el menor esfuerzo computacional en su ejecución (por estar limitados espacialmente).

Pero la predicción de los diferentes tipos de radiación y otras variables de interés, en el corto plazo, para una localización geográfica concreta exige la utilización de un modelo atmosférico con mayor resolución espacial que la de los modelos atmosféricos de macro-escala, aunque sean modelos atmosféricos regionales. La solución está en la utilización de modelos atmosféricos meso-escalares.

Son varios los modelos atmosféricos no hidrostáticos desarrollados por la comunidad científica, alguno de ellos implementados en software de acceso público. Entre estos pueden citarse el modelo atmosférico WRF (*Weather Research and Forecast Model*), el MM5 (*Penn State/NCAR Mesoscale Model, Version 5*), COAMPS (*US Navy's Coupled Ocean/Atmosphere Mesoscale Prediction System*), ARPS (*Advanced Regional Prediction System*), MASS (*Mesoscale Atmospheric Simulation System*), MC2 (*Mesoscale Compressible Community Model*), Meso-NH (*Mesoscale no-Hidrostatic Atmospheric Simulation System*) y MEMO (*MEsoscale MOdel*). La mayoría de los modelos atmosféricos están programados en Fortran, con algunas rutinas en C, y pensados para ser ejecutados en ordenadores con sistema operativo Unix.

Una característica muy interesante que incluyen muchos de los modelos atmosféricos citados, es la posibilidad de anidamiento. Cuando se pretende obtener una gran resolución espacial, sobre una zona geográfica concreta, el mayor problema viene impuesto por la necesidad de establecer las condiciones de contorno para las fronteras

del dominio (zona geográfica estudiada). La baja resolución de los modelos atmosféricos globales hace que estas condiciones de contorno, en dominios muy pequeños, no queden bien definidas. Por ejemplo, la resolución espacial del modelo atmosférico GFS 1º para la zona de España es de unos 100 km; si queremos utilizar este modelo atmosférico para obtener las condiciones de contorno para un dominio de 50x50 km, a lo sumo dispondremos de dos puntos por dimensión sobre los que interpolar, lo cual difícilmente podrá servir para realizar una simulación verosímil de la evolución atmosférica.

El anidamiento consiste en definir unos dominios menores, con mayor resolución espacial, dentro de otros dominios. Volviendo al ejemplo anterior, el dominio de 50x50 km puede corresponder a un dominio anidado a otro mayor 150x150 km, que a su vez está anidado con otro mayor de 450x450 km, que a su vez está anidado con otro de 1350x1350 km. El dominio mayor toma las condiciones de contorno de un modelo global. Para la latitud de España significará unos 13 puntos distintos por dimensión, por lo que los puntos del dominio de 1350x1350 km situados en la frontera presentarán valores diferenciados, resultado de la interpolación con 13 puntos, lo que permitirá obtener una simulación más precisa. Si el dominio de 1350x1350 km tiene una rejilla de análisis con una resolución horizontal de 45 km, puede transferir unas buenas condiciones de contorno al siguiente dominio de 450x450 km, y así sucesivamente.

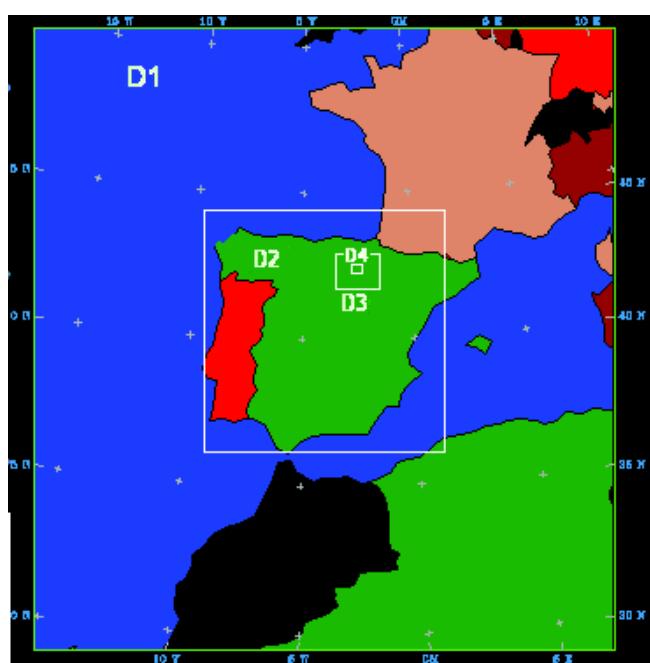


Figura 4. 1 Ejemplo de anidamiento de dominios

El anidamiento de dominios puede ser unidireccional o bidireccional. El anidamiento es unidireccional cuando la información pasa del dominio de mayor dimensión al de menor dimensión. Por el contrario, el anidamiento es bidireccional cuando la transferencia de información (resultados de las integraciones de las ecuaciones primitivas) es en ambos sentidos.

4.5 COMPONENTES DE UN NWP

La estructura básica de un modelo numérico está compuesta por un grupo de componentes que interactúan entre sí en orden de producir un pronóstico objetivo.

Estos componentes básicos (Figura 4. 2) son la asimilación de datos, las parametrizaciones, la dinámica del modelo (dinámica atmosférica), y finalmente el módulo de predicción misma del modelo en consideración.

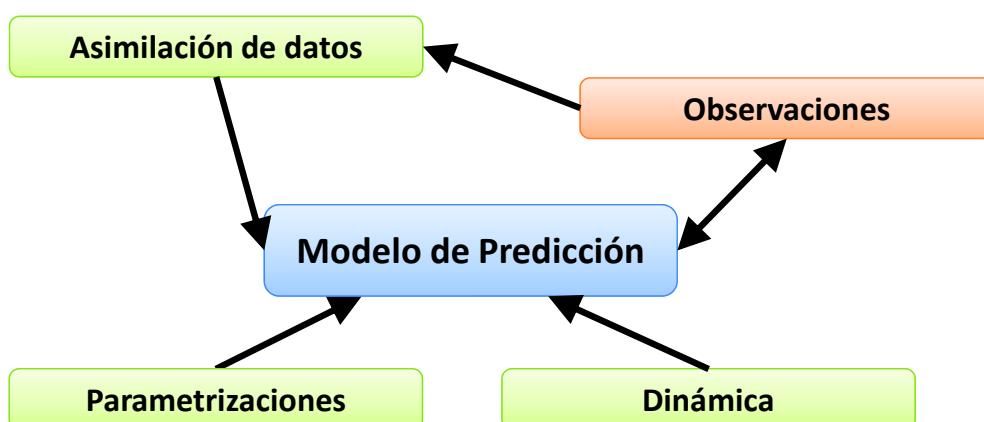


Figura 4. 2 Estructura general de los componentes de los modelos numéricos de predicción

El primer paso es la asimilación de los datos la cual se hace usualmente en forma secuencial. El modelo organiza y propaga la información desde observaciones y medidas previas. La información de nuevas observaciones es usada para modificar el estado del modelo y hacerlo lo más consistente posible.

Luego viene la parametrización de los diferentes procesos físicos de la atmósfera, tales como la radiación, la convección y los intercambios en los bordes o límites del modelo.

Estos procesos necesitan ser representados numéricamente; algunos de los mismos ocurren en una escala que es demasiado pequeña para ser resuelta de acuerdo a la resolución del modelo.

Los esquemas de parametrización pueden hacer suposiciones de acuerdo a restricciones computacionales involucradas en el proceso. El desarrollo de estos esquemas ha significado una alta cooperación entre grupos de investigación, muchas veces de diferentes países e instituciones. Los grupos de investigación en procesos atmosféricos ejecutan estudios de observaciones y modelización independientes que ayudan a entender los procesos físicos que ocurren en la atmósfera. Algunos procesos a parametrizar son:

- La **Radiación**, la cual está dada por la emisión del sol y su representación, es esencial en un modelo numérico de predicción. La radiación en la atmósfera se divide en onda corta y onda larga. La onda corta es debida a la emisión directa del sol sobre la superficie de la tierra, y puede ser absorbida por las nubes, algunos gases atmosféricos; también puede ser reflejada al espacio.

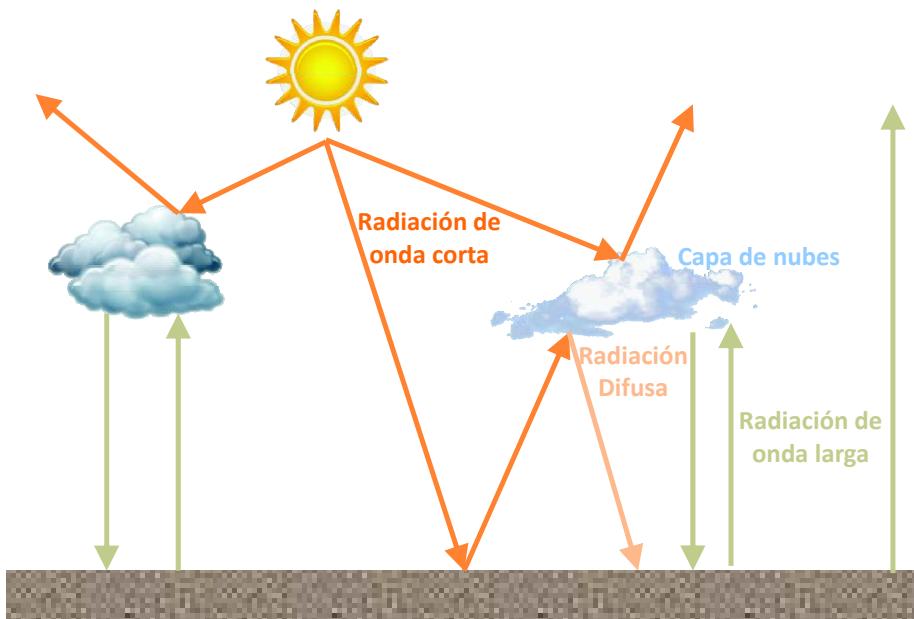


Figura 4. 3 Figura genérica de la radiación solar

Los flujos de onda corta dependen principalmente del ángulo del cenit del sol, el cual varía de acuerdo a la latitud, época del año y hora del día; también depende de la nubosidad y del tipo de albedo del suelo. Los flujos de onda larga dependen de la cantidad de emisión media y la emisividad de la tierra.

- Los **procesos superficiales y sub-superficiales**, donde se determina, por ejemplo, la influencia del tipo de suelo y de vegetación.

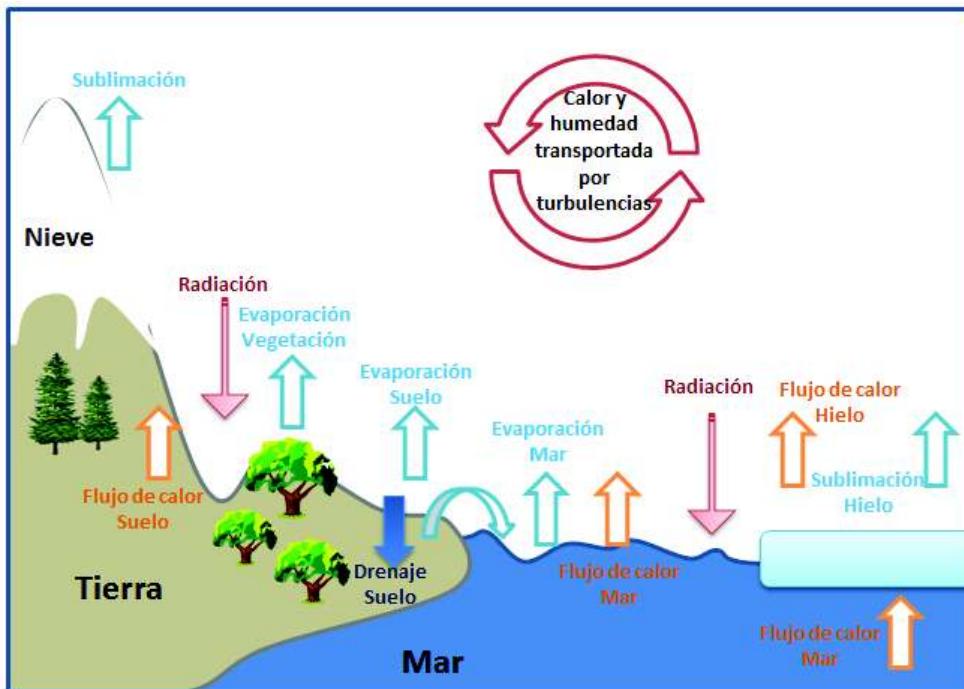


Figura 4. 4 Incidencia del tipo de suelo y vegetación en la modelización numérica

- Nubes de gran escala y su precipitación**, donde se considera valores explícitos de cantidad de cielo cubierto, junto con valores separados de vapor de agua y razón de mezcla en nubes de hielo [Estebananz96].



Figura 4. 5 Nubes de gran escala y su precipitación

- **La precipitación convectiva**, Figura 4. 6, la cual se inicia por una prueba de inestabilidad convectiva; si la temperatura potencial de algún nivel es mayor que la del nivel inmediatamente superior, se inicia la convección [García96]. Esta continuará mientras que el aire caliente continúe ascendiendo, debido a su menor densidad.

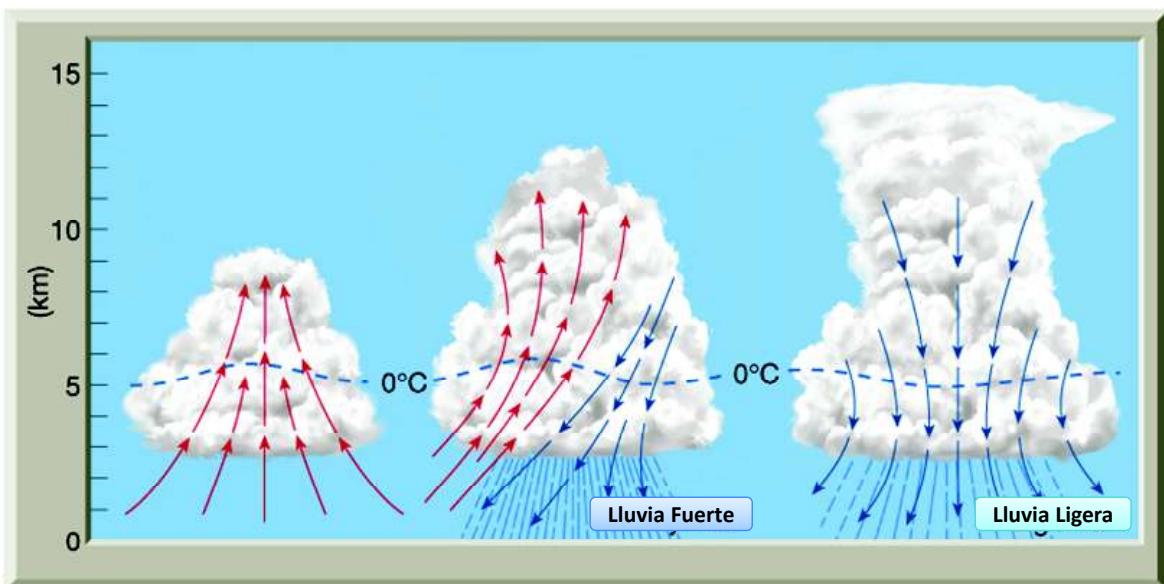


Figura 4. 6 Esquema de la dinámica convectiva (Adaptado de: www.atmos.umd.edu)

- **La orografía.** El esquema de orografía parametriza los efectos en la capa límite de la atmósfera y su topografía en escalas de 10 km o menos. Esta parametrización se calcula en términos de un coeficiente constante de arrastre y depende linealmente de la silueta de la orografía, y considera un coeficiente de rugosidad dependiendo del tipo de vegetación. Esta fórmula se basa en la teoría de Monin-Obukov, usada para calcular los flujos superficiales.

Seguidamente se considera la dinámica del modelo numérico, la cual es condicionada por las ecuaciones que gobiernan la atmósfera.

Estas ecuaciones son escritas en un sistema de coordenadas esféricas y discretizadas horizontalmente en una rejilla regular en latitud-longitud. En la configuración global, la rejilla de los polos coincide con los polos geográficos.

En la vertical, se usa un sistema de coordenadas basado en la presión atmosférica. La coordenada es la denominada en la mayoría de modelos como "terrain", la cual sigue un comportamiento sigma en superficie, normalizado a la presión superficial, ($\sigma = 1$), y un comportamiento de presión en las capas superiores, las cuales tienden a ser más horizontales [Dudhia05].

Entre la superficie sigma, (en superficie), y la capa límite superior, los niveles de coordenadas disminuyen su espesor gradualmente. El sistema de coordenadas terrain tiene la ventaja de no tener superficies que corten la superficie del terreno y tienen la condición de la capa superficial baja (la velocidad vertical en el sistema sigma es cero en la superficie y en el límite superior del modelo).

Finalmente se considera los campos de superficie, cuya representación describe el comportamiento de la tierra, para determinar situaciones como orografía, tipo de suelo y vegetación, temperatura del mar, humedad del suelo y cantidad de nieve acumulada, entre otros.

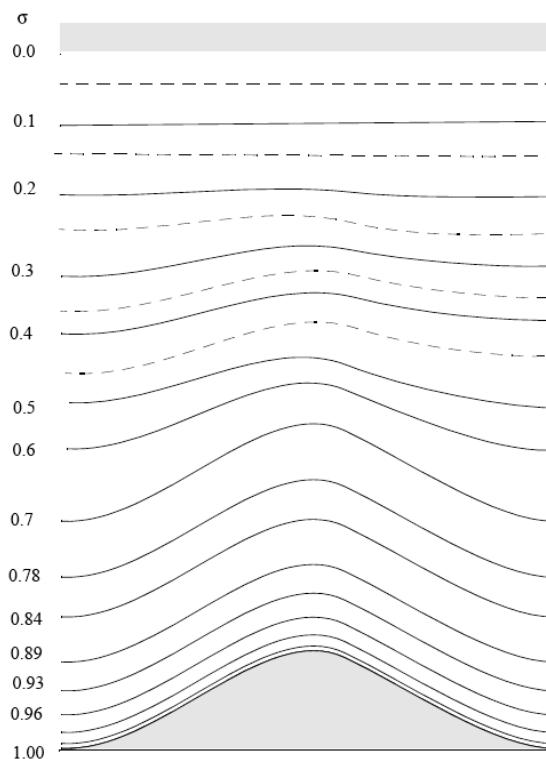


Figura 4. 7 Representación esquemática de la estructura vertical del MM5 (σ) [Dudhia05]

4.6 MODELO MM5

Según los estudios publicados, este es uno de los modelos más utilizados en aplicaciones científicas. Es por ello que este ha sido uno de los dos modelos atmosféricos elegidos, además de porque es un modelo de libre distribución.

El MM5 es un modelo de meso-escala, desarrollado por PSU/NCAR (*Pennsylvania University and National Center for Atmospheric Research*), de área limitada, no hidrostático, el cual tiene un diseño de coordenadas sigma, las cuales están diseñadas para seguir la regularidad del terreno en superficie.

Este modelo está elaborado para simular o predecir la circulación atmosférica en la meso-escala, o en la escala regional. Entre sus características básicas se destaca:

1. La capacidad de simular anidamientos múltiples.
2. Poseer una dinámica no-hidrostática, la cual permite al modelo ser utilizado para una resolución de unos pocos kilómetros.
3. La capacidad de funcionamiento en máquinas de multitarea o de memoria compartida y distribuida.
4. La capacidad de asimilación de datos cuadradimensional.
5. La posibilidad de escoger diferentes parametrizaciones.

La estructura de programas que componen el MM5 puede verse a continuación en la Figura 4. 8.

Está compuesto por más de 100000 líneas de código Fortran y C y más de 100 subrutinas, es adaptable a cualquier zona del mundo y permite múltiples dominios anidados. El modelo esta soportado por algunos programas auxiliares, los cuales en su conjunto conforman el MM5.

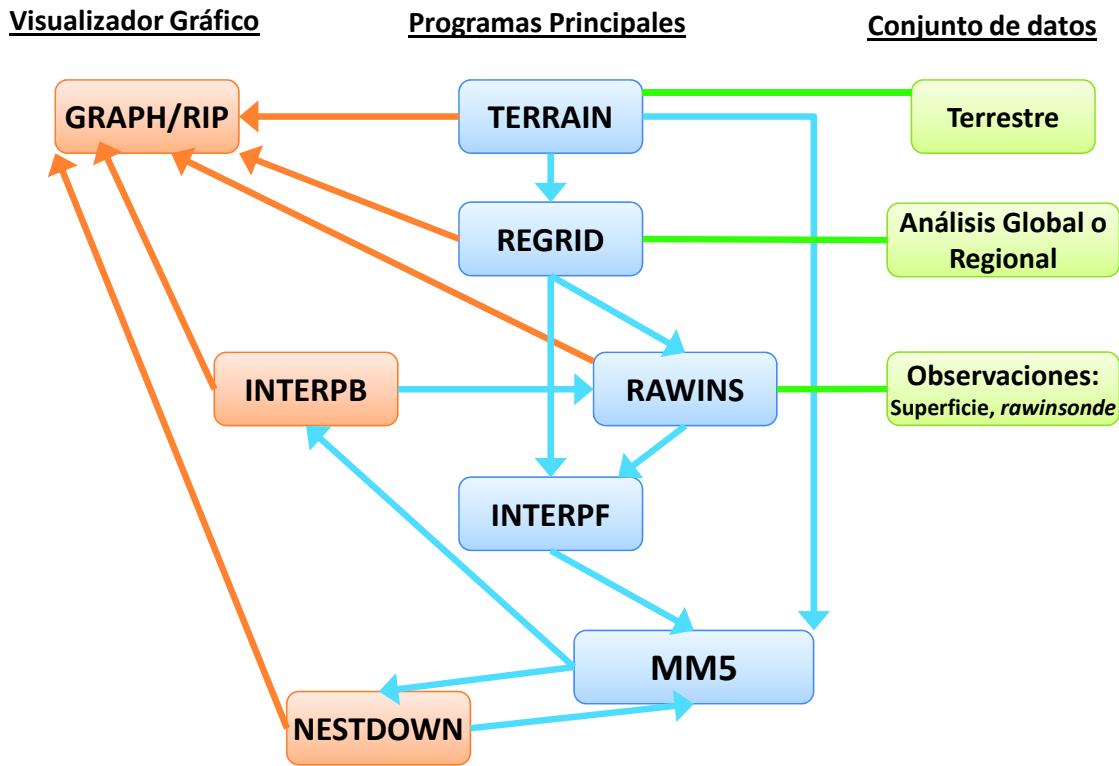


Figura 4. 8 Estructura del MM5

Para cada uno subprogramas que componen el MM5, que se describen brevemente a continuación, se debe realizar su instalación independiente seleccionado correctamente sus diferentes parámetros con el fin de obtener unas predicciones lo más precisas posibles.

- **Terrain:** Este programa interpola horizontalmente en latitud y longitud, la elevación del terreno y la vegetación (uso del suelo) sobre los dominios elegidos de meso-escala.
- **Regrid:** Su propósito es el de leer los análisis y pronósticos meteorológicos en niveles de presión, e interpolar éstos análisis a la rejilla horizontal del modelo definida en el *Terrain*.

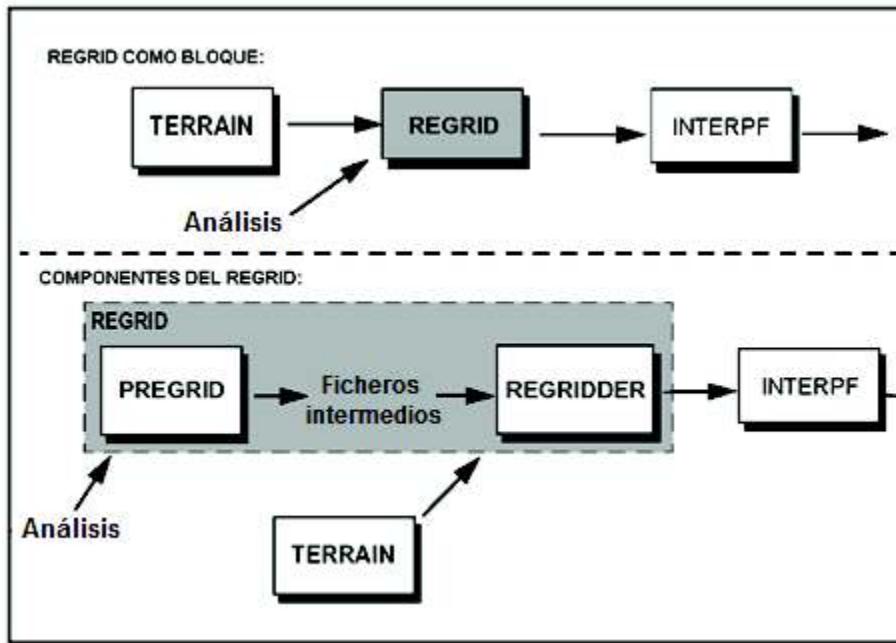


Figura 4. 9 Esquema de funcionamiento del Regrid (Adaptado de [Dudhia05])

- **Interpf.** Realiza la transformación de los datos requerida para ir de los programas de análisis meteorológico al modelo de meso-escala. Esto exige la interpolación vertical a niveles sigma, un diagnóstico de los datos, y el cambio de formato de los mismos. *Interpf* toma los datos de la salida de *Regrid* como entrada para generar las condiciones límite con la superficie, con los límites laterales del modelo y con el límite superior.
- **MM5:** este programa es el núcleo del modelo. En él se realiza la resolución de las ecuaciones que modelizan la dinámica de la atmósfera para todos los puntos de la rejilla definida por *Terrain*. La integración se realiza por diferencias finitas, a partir de un paso de integración definido por el usuario, quien también define el horizonte final de predicción y el intervalo de tiempo entre ficheros de salida con predicciones intermedias.

4.7 MODELO WRF-NMM

El otro modelo elegido, también de libre distribución, es el WRF (*Weather Research and Forecasting Model*), otro de los modelos más utilizados en aplicaciones científicas, y que incluye todos los avances realizados hasta el momento en modelización meteorológica. Concretamente se va a usar el WRF-NMM (*Nonhydrostatic Mesoscale Model*), que el fondo responde a una versión mejorada y actualizada del modelo MM5.

El WRF es un modelo de meso-escala, desarrollado por NOAA/NCEP (*National Oceanic and Atmospheric Administration / National Centers for Environmental Prediction*), de área limitada, no hidrostático, pero con una opción hidrostática ([Janjic01], [Janjic03a], [Janjic03b]). Además tiene un diseño de coordenadas sigma, las cuales están diseñadas para seguir la regularidad del terreno en superficie.

Este modelo está elaborado para simular o predecir la circulación atmosférica en la meso-escala, o en la escala regional. Actualmente, la versión que se está utilizando es la 3, que permite trabajar en un rango que va de pocos metros hasta miles de kilómetros. Entre sus características básicas se destaca:

1. La capacidad de realizar anidamientos múltiples.
2. Poseer una dinámica no-hidrostática, la cual permite al modelo ser utilizado para una resolución de unos pocos kilómetros.
3. La capacidad de funcionamiento en máquinas de multitarea o de memoria compartida y distribuida.
4. La capacidad de asimilación de datos cuadradimensional.
5. La posibilidad de escoger diferentes parametrizaciones.

La estructura de programas que componen el WRF puede verse a continuación en la Figura 4. 10.

Cabe destacar que es adaptable a cualquier zona del mundo y permite múltiples dominios anidados. El modelo esta soportado por algunos programas auxiliares, los cuales en su conjunto conforman el WRF-NMM.

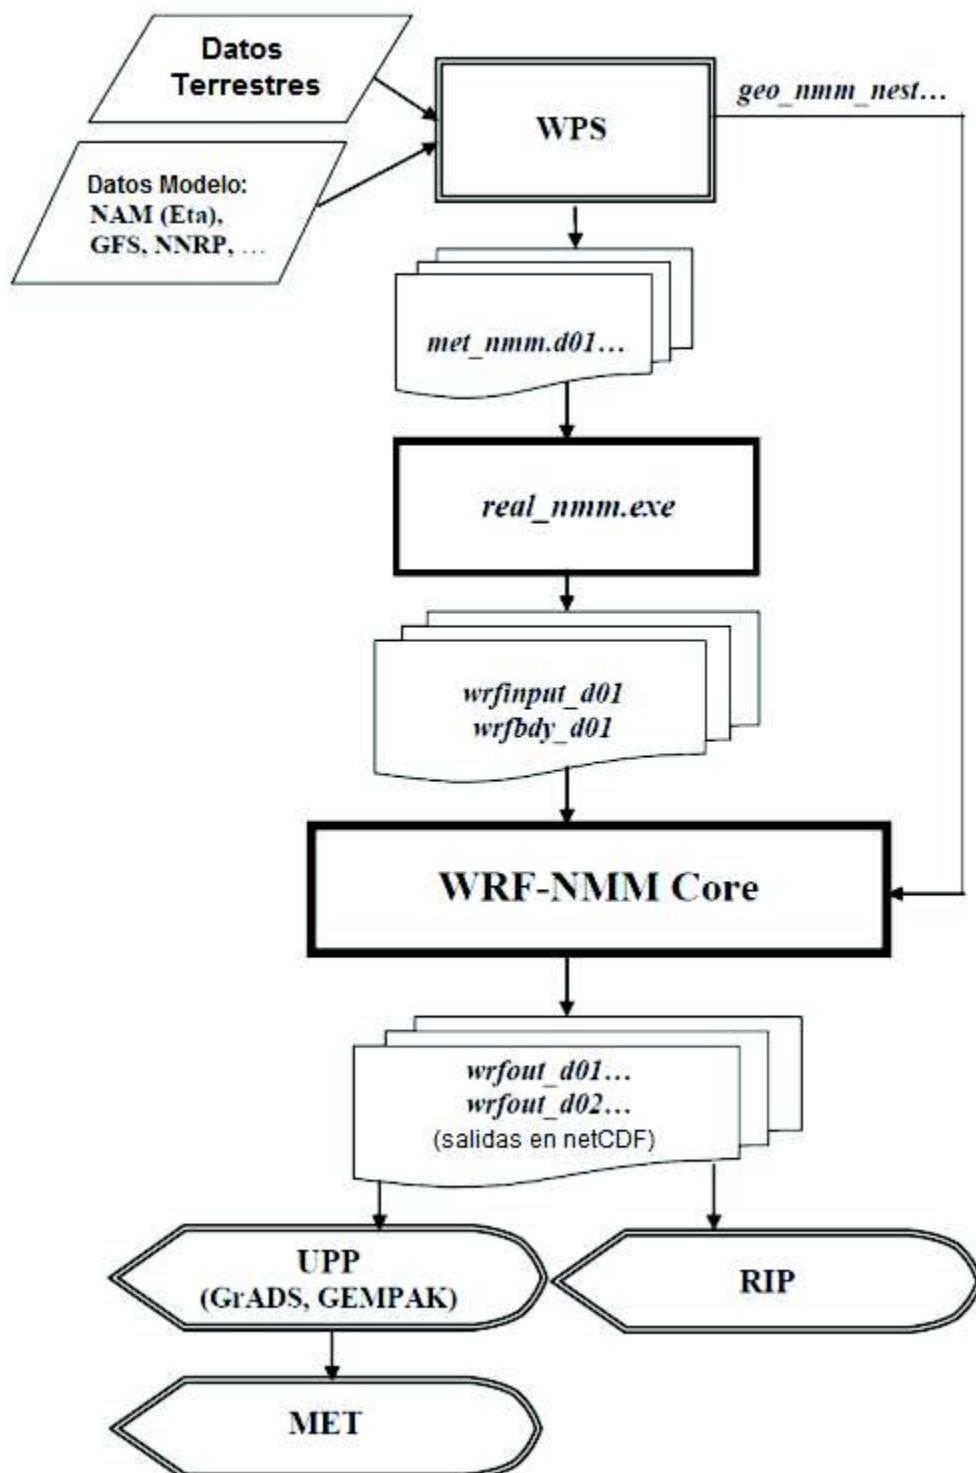


Figura 4. 10 Estructura del WRF-NMM (Adaptado de [Janjic14])

Para cada uno subprogramas que componen el WRF-NMM, que se describen brevemente a continuación, se debe realizar su instalación independiente seleccionado correctamente sus diferentes parámetros con el fin de obtener unas predicciones lo más precisas posibles.

- **WRF Preprocessing System (WPS):** este programa realiza la simulación con datos reales. Entre sus funciones se incluyen la definición de los dominios de meso-escala, la interpolación de los datos terrestres horizontalmente en latitud y longitud, la elevación del terreno y la vegetación (uso del suelo) sobre los dominios elegidos de meso-escala, y trasladar e interpolar los datos meteorológicos procedentes de otro modelo atmosférico, como GFS, al dominio de simulación y las coordenadas deseadas.

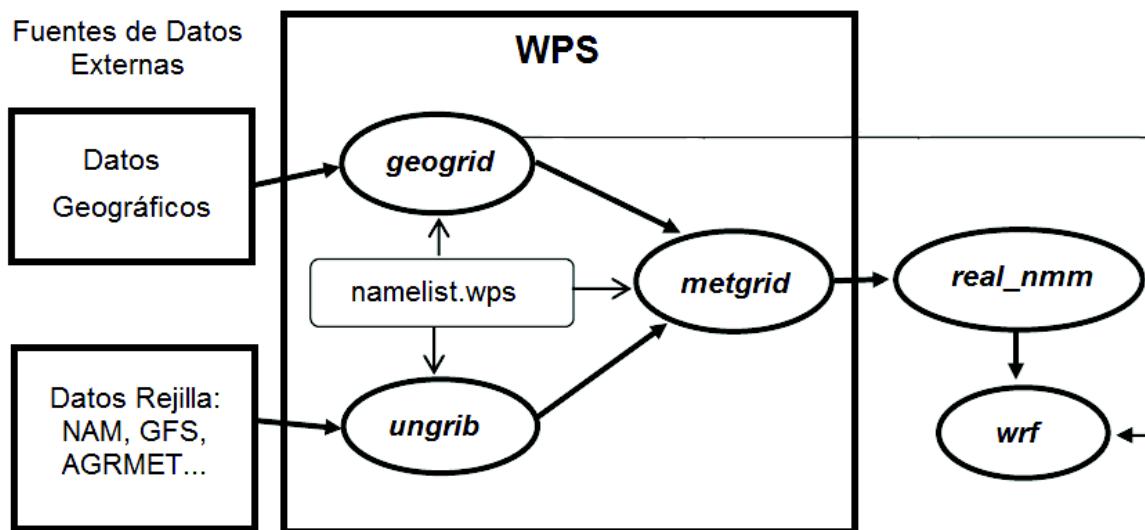


Figura 4. 11 Esquema de funcionamiento del WPS (Adaptado de [Janjic14])

- **Inicialización del WRF-NMM (`real_nmm.exe`):** genera las condiciones iniciales, las condiciones límite con la superficie, con los límites laterales del modelo y con el límite superior para el modelo WRF-NMM (`wrf.exe`) a partir de los ficheros de salida proporcionados por el WPS. Esto exige la interpolación vertical a niveles sigma, un diagnóstico de los datos, y el cambio de formato de los mismos. Además chequea el valor de las diferentes variables para verificar su coherencia.

- **WRF-NMM Core:** este programa es el núcleo del modelo. Contiene el programa de integración numérica *wrf.exe*. En él se realiza la resolución de las ecuaciones que modelizan la dinámica de la atmósfera para todos los puntos de la rejilla definida con anterioridad. La integración se realiza por diferencias finitas, a partir de un paso de integración definido por el usuario, quien también define el horizonte final de predicción y el intervalo de tiempo entre ficheros de salida con predicciones intermedias. Este programa proporciona los archivos de salida donde se encontrarán las predicciones de las variables meteorológicas.

Además de los anteriores el modelo dispone de dos aplicaciones para el post-procesado de los datos y otra de evaluación del modelo.

- **Post-Procesado de datos:**

- *Unified Post Processor (UPP)*: este programa se encarga de interpolar las predicciones del WRF-NMM al estándar NWS, para poder ser interpretadas por otras aplicaciones.
- *Read Interpolate Plot (RIP)*: con las predicciones interpoladas al formato RIP, este programa es capaz de generar diversos gráficos con las variables meteorológicas.

- **Evaluación del modelo:**

- *Model Evaluation Tools (MET)*: este programa puede utilizarse para verificar las predicciones comparándolas con las observaciones correspondientes a los mismos puntos de la rejilla.

4.8 CONCLUSIONES

Como se ha podido ver a lo largo del presente capítulo existen diversos modelos atmosféricos, que se diferencian fundamentalmente en la resolución espacial y temporal. Cuanto mayor es la resolución espacial de un modelo atmosférico, menor es su alcance temporal (plazo de validez de las predicciones). Los modelos atmosféricos clasificados como de macro-escala son los que tienen una resolución espacial menor. Están implementados en los llamados modelos atmosféricos globales o en los grandes modelos atmosféricos regionales.

Gracias al ritmo al que progresan los equipos microinformáticos cada vez tienen una capacidad de procesamiento y de ejecución en paralelo mayor, lo cual permite la implementación, en forma de programas, de los modelos numéricos de predicción atmosférica (NWP). Estos programas permiten la asimilación masiva de datos meteorológicos para poder determinar las condiciones iniciales de la atmósfera, tarea esencial para poder predecir el futuro estado meteorológico de la misma.

Para la situación particular a la que se hace referencia, la predicción de las variables meteorológicas relacionadas con la predicción de la producción fotovoltaica para un lugar concreto (parque solar fotovoltaico), los modelos atmosféricos que ofrecen una mayor resolución son los modelos atmosféricos meso-escalares, alguno de ellos implementado en software de libre distribución. Los dos modelos elegidos, el MM5 y el WRF-NMM, se encuentran entre los de mayor aceptación en la comunidad científica. Ambos proporcionan, como resultado de la simulación, el valor de determinadas variables meteorológicas para todos los puntos de la rejilla tridimensional de análisis, y para todos los intervalos temporales definidos por el usuario. Tras ello se pueden obtener series temporales de varias variables meteorológicas, entre ellas las más relacionadas con la producción fotovoltaica.

CAPÍTULO

5

MODELOS DE PREDICCIÓN DE SERIES TEMPORALES

En este capítulo se van a describir los tipos de modelos o técnicas más habituales para la predicción de futuros valores de series temporales, centrándonos en sus características principales y destacando tanto sus ventajas como sus desventajas.

Se van a describir tanto las técnicas clásicas más importantes (modelos ARIMA), como otras técnicas meta-heurísticas, considerablemente modernas (redes neuronales artificiales y sistemas de inferencia difusa), entroncadas en el conocido ámbito del llamado “*soft-computing*”.

Una serie temporal consiste en un conjunto de valores, correspondientes a una variable, ordenados según el instante en que fueron tomados, y normalmente tomados a intervalos regulares de tiempo. Los sucesivos valores contenidos en una serie temporal se designan por un número de índice, correspondiente al número de observación (número del instante en que fue tomado el valor). Así, suponiendo una serie temporal X , está vendría expresada como indica la ecuación (5.1).

$$X = \{X_1, X_2, X_3, \dots\} \quad (5.1)$$

La predicción del valor futuro de una serie temporal significa determinar los siguientes valores que tomará la variable que forma la serie temporal a partir del instante presente. Esa determinación del valor futuro de la variable puede realizarse desde dos perspectivas, indicadas a continuación.

1. La predicción de valores futuros se puede realizar por extrapolación de los valores pasados.
2. Se puede establecer un modelo matemático que explique las relaciones entre los valores de la variable en el pasado y utilizar ese modelo para predecir los futuros valores de la variable.

Precisamente nos centraremos en la segunda perspectiva comentada, la de extraer información del pasado. Presentaremos el modelo que mejor explique las relaciones entre los valores pasados de la variable, para ser utilizado posteriormente en la predicción de los valores futuros.

5.1 MODELOS ARIMA

Los modelos ARIMA son, sin duda, el método lineal más usado para identificar y construir modelos de predicción para series temporales univariantes y estacionarias [Box76].

El acrónimo ARIMA significa Auto-regresivos Integrados de Medias Móviles, por tanto queda claro que un modelo ARIMA tiene tres componentes, la auto-regresiva (AR), la integrada (I) y la de media móvil (MA).

Estos modelos se definen como ARIMA (p, d, q), siendo p el orden del término auto-regresivo, d el orden del término integrador o diferenciador, y q el orden del término de media móvil.

En el presente subapartado se va a describir de una forma breve cada uno de los tres términos del modelo general ARIMA, describiendo por último el modelo completo, incluyendo la posible estacionalidad.

5.1.1 MODELOS AUTO-REGRESIVOS

Definimos un modelo como auto-regresivo si el valor de la variable en un instante t es explicado por las observaciones de ella misma correspondientes a instantes anteriores añadiéndose un término de error. Hay que tener en cuenta que se está tratando con modelos lineales por lo que X_t se expresará como una combinación lineal de sus valores pasados (parte sistemática) más un término de error (innovación).

Los modelos auto-regresivos se abrevian con la palabra AR tras la que se indica el orden del modelo: AR(p). El orden del modelo expresa el número de observaciones retasadas de la serie temporal analizada que intervienen en la ecuación. Así, por ejemplo, un modelo AR(p) tendría la siguiente expresión:

$$X_t = \phi_0 + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + e_t \quad (5.2)$$

Pudiéndose escribir de forma abreviada como:

$$\phi_p(B)X_t = \phi_0 + e_t \quad (5.3)$$

Donde $\phi_p(B)$ se conoce como el operador polinomial de retardos:

$$\phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p \quad (5.4)$$

Siendo el término B lo que se conoce como operador retardo tal que, aplicado al valor de una variable en el instante t , dé como resultado el valor de esa misma variable en el instante $t-1$, tal como muestra la ecuación (5.5). Además aplicando p veces B a la variable X_t se obtiene el valor de dicha variable p periodos antes, como muestra la ecuación (5.6).

$$BX_t = X_{t-1} \quad (5.5)$$

$$B^p X_t = X_{t-p} \quad (5.6)$$

Normalmente, se suele trabajar con modelos auto-regresivos de órdenes bajos: AR(1) o AR(2), o bien con órdenes coincidentes con la periodicidad de los datos de la serie analizada (si es trimestral AR(4), si es mensual AR(12)...).

Para el modelo auto-regresivo AR(1), existe un límite para el coeficiente ϕ_1 llamado el límite de estacionariedad, de tal forma que se debe cumplir la condición expuesta a continuación para que la serie temporal representada por el modelo AR(1) sea estacionaria.

$$|\phi_1| < 1 \quad (5.7)$$

El término de error, e_t , de los modelos de este tipo, siempre que la variable este modelada correctamente, se denomina “ruido blanco”, cumpliendo a lo largo del tiempo las tres hipótesis básicas detalladas a continuación:

- Media nula.
- Varianza constante.
- Covarianza nula entre errores correspondientes a observaciones diferentes.

Por tanto si tomamos la ecuación (5.2) obviando el error, tendremos el valor de predicción para la variable X en el periodo t de un modelo AR(p), \hat{X}_t :

$$\hat{X}_t = \phi_0 + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} \quad (5.8)$$

A la hora de determinar o calcular los coeficientes del modelo se puede optar por el método de verosimilitud (con la herramienta informática correspondiente) o por el método de mínimos cuadrados (siempre que el número de valores de la serie temporal sea superior al doble del número de coeficientes a determinar).

5.1.2 MODELOS DE MEDIA MÓVIL

Un modelo de los denominados de medias móviles es aquel que explica el valor de una determinada variable en un período t en función de un término independiente y una sucesión de errores correspondientes a períodos precedentes, ponderados convenientemente. Estos modelos se denotan normalmente con las siglas MA, seguidas, como en el caso de los modelos auto-regresivos, del orden entre paréntesis. Así, un modelo con q términos de error MA(q), respondería a la siguiente expresión:

$$X_t = \mu - \theta_1 e_{t-1} - \theta_2 e_{t-2} - \cdots - \theta_k e_{t-k} - \cdots - \theta_q e_{t-q} + e_t \quad (5.9)$$

Siendo:

e_{t-k} : valor del error para la variable X en el instante $t-k$

μ : Constante numérica

Esta ecuación de nuevo puede abreviarse utilizando el polinomio de retardos, ecuación (5.3):

$$X_t = \theta_q(B)e_t + \mu \quad (5.10)$$

Siendo el valor del operador polinomial de retardos el expresado en la siguiente ecuación:

$$\theta_q(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q \quad (5.11)$$

Así como un modelo auto-regresivo es intuitivamente sencillo de comprender, la formulación de un modelo de medias móviles resulta menos obvia, aunque en realidad, un modelo de medias móviles puede obtenerse a partir de un modelo auto-regresivo sin más que realizar sucesivas sustituciones.

5.1.3 MODELOS ARMA

Este modelo es la combinación del modelo auto-regresivo y el de media móvil, de ahí que se denomine ARMA (auto-regresivo y de media móvil).

Para obtener su expresión basta con combinar las expresiones de los modelos AR(p) y MA(q), (5.2) y (5.9) respectivamente, siendo el resultado el siguiente:

$$X_t = \phi_0 + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} - \theta_1 e_{t-1} - \theta_2 e_{t-2} - \cdots - \theta_q e_{t-q} + e_t \quad (5.12)$$

Es muy importante destacar que ahora dentro del coeficiente ϕ_0 , queda integrado el término μ que aparecía en el modelo MA(q).

La ecuación (5.11) puede expresarse de una forma abreviada, tal como aparece en la ecuación (5.12) utilizando de nuevo los operadores retardo.

$$\phi_p(B)X_t = \phi_0 + \theta_q(B)e_t \quad (5.13)$$

Las expresiones correspondientes a $\phi_p(B)$ y a $\theta_q(B)$ son las expresadas en las ecuaciones (5.4) y (5.11), respectivamente.

5.1.4 MODELOS ARIMA

Cuando una serie presenta un comportamiento periódico o una tendencia determinística (no estacionaria), se puede representar por medio del modelo ARMA combinado con el operador diferencia, dando lugar al modelo general ARIMA(p, d, q).

De esta forma se puede decir que se está realizando una transformación de la serie original X , de la variable a predecir, en otra, Y , que ya no presentará ese comportamiento periódico o que es ya estacionaria, tal como muestra la ecuación (5.14), donde τ representa el periodo.

$$Y_t = X_t - X_{t-\tau} \quad (5.14)$$

Generalmente, lo que se hace, es aplicar esta técnica de diferenciación a una serie no estacionaria para convertirla en estacionaria.

Un modelo ARIMA(p, d, q) responde a la ecuación (5.15), siendo d el número de diferencias aplicadas hasta convertir la serie temporal en estacionaria.

$$\phi_p(B)(1-B)^d X_t = \phi_0 + \theta_q(B)e_t \quad (5.15)$$

En estos modelos tras determinar el número de diferencias, d , necesarias para convertir la serie temporal en estacionaria se determinan los otros coeficientes, p y q , por mínimos cuadrados no lineales.

5.1.5 MODELOS ARIMA CON ESTACIONALIDAD

El último componente para añadir a los modelos ARIMA, es el más complejo, la estacionalidad (el patrón de comportamiento periódico de la serie temporal se va incrementando con el tiempo).

El modelo resultante se conoce como modelo ARIMA con estacionalidad multiplicativa, para ello se introducen unos nuevos términos: auto-regresivo P , diferenciación D y de media móvil Q , todos ellos referidos a los valores retrasados en el tiempo un múltiplo del índice de estacionalidad s .

El modelo se denota como ARIMA(p, d, q)(P, D, Q) $_s$, y se expresa según la siguiente ecuación:

$$\phi_p(B)\Phi_P(B^s)(1-B^s)^D(1-B)^d X_t = \phi_0 + \theta_q(B)\Theta_Q(B^s)e_t \quad (5.16)$$

Estando referidos los coeficientes derivados de $\Phi_P(B^s)$ y de $\Theta_Q(B^s)$ a la parte estacionaria.

5.1.6 IDENTIFICACIÓN DE MODELOS ARIMA

Debido a la cantidad de modelos ARIMA disponibles, puede ser complicado decidir qué modelo es el más apropiado para una serie temporal concreta. En la literatura se explican multitud de formas y métodos para identificar estos modelos, como puede ser en [Box76], [Wei90], [DeLurgio98] y [Makridakis98].

El índice de estacionalidad sería el más sencillo de determinar, ya que dependerá de la naturaleza de la variable de la serie temporal, por ejemplo para el caso de la radiación o de la producción fotovoltaica, el índice de estacionalidad, en el caso que pueda ser considerado, será de 24 horas.

Lo que ya es más complicado es determinar el orden de los procesos o componentes que definen el modelo: p , d , q , P , D y Q .

A continuación expongo los pasos a seguir, recomendados por los expertos, para identificar un modelo ARIMA:

1. Representar en un gráfico la serie temporal. De esta forma, podemos apreciar observaciones inusuales (“outliers”) y un comportamiento no estacionario en la media o en la varianza. Los outliers pueden sustituirse por otros valores más acordes, el comportamiento no estacionario de la media se puede corregir utilizando diferenciación y el de la varianza mediante una transformación (logarítmica...).
2. Examinar las gráficas de la función de auto-correlación (ACF) y de la función de auto-correlación parcial (PACF) para confirmar si hace falta aplicar otra diferenciación para alcanzar la estacionariedad de la serie temporal.
3. Una vez alcanzada la estacionariedad de la serie, observar de nuevo las gráficas de ACF y PACF para determinar si queda algún patrón en la misma. A partir de las gráficas de ACF y PACF se puede determinar también los valores de los parámetros p y q del modelo ARIMA.

Para seleccionar el modelo más adecuado, se requiere de mucha experiencia previa.

A la hora de seleccionar el modelo en primer lugar se tendrá en cuenta el RMSE, pero no sólo se tendrá en cuenta dicho valor, sino que, además, tendremos en cuenta otros criterios como el criterio de información de Akaike (*AIC*) [Akaike76], que penaliza aquellos modelos que requieren mayor número de parámetros, es decir, se centra en el principio de la parsimonia (si una serie temporal puede ser explicada por dos modelos, el más simple es el mejor). El valor aproximado de *AIC* se calcula mediante la siguiente ecuación:

$$AIC = n \cdot \ln(MSE \cdot n) + 2m \quad (5.17)$$

Siendo:

n: número de observaciones

m: número de parámetros del modelo (*p* + *d* + *q*)

5.1.7 VENTAJAS E INCONVENIENTES

Si hablamos de las ventajas de los modelos ARIMA, la más destacada es que nos permiten proporcionar intervalos de confianza en sus predicciones con una base estadística fiable. Además, pese a tener un cálculo complejo, es fácil encontrar herramientas informáticas para su desarrollo, por su gran uso en los ámbitos de predicción económica.

El mayor de los inconvenientes, es sin duda, su carácter lineal, lo cual dificulta que se puedan modelar de manera adecuada todos los problemas (el caso de la producción eléctrica fotovoltaica tiene características de no linealidad). También cabe destacar la necesidad de tener gran experiencia en el desarrollo de modelos de predicción. Por último comentar que son modelos muy sensibles a outliers, lo que obliga a revisar la serie temporal para detectarlos y corregirlos antes de diseñar el modelo de predicción.

5.1.8 APLICACIÓN EN LA PREDICCIÓN DE LA PRODUCCIÓN

Los modelos ARIMA constituyen una opción a considerar en el diseño de modelos de predicción de la producción eléctrica fotovoltaica, al menos como un modelo más con el que poder comparar los nuevos modelos desarrollados y descritos en el presente Trabajo de Investigación.

5.2 REDES NEURONALES ARTIFICIALES (ANN)

Los modelos lineales, como los ARIMA descritos con anterioridad, están limitados. Por esta razón se crearon modelos no lineales derivados de los ARIMA, pero estos modelos solo son precisos para un tipo concreto de no linealidades.

Para no tener este tipo de limitación aparecen las redes neuronales artificiales, ya que son auténticos “aproximadores universales” de funciones incluyendo, evidentemente, las no lineales.

Las redes neuronales artificiales se tratan de sistemas que se basan en los sistemas neuronales biológicos (cerebro animal). Las redes neuronales artificiales (en lo sucesivo redes neuronales) constan de un conjunto de elementos simples de procesamiento, llamados neuronas o nodos, conectados entre sí por conexiones que tienen asignado valor numérico modificable llamado peso. Cada neurona puede recibir información de otras neuronas (que actúan para ella como entradas) o de una entrada externa, y a su vez generar información en una salida que puede servir de información de entrada a otras neuronas. El procesamiento que cada neurona hace con la información que recibe consiste en generar un valor (información) de salida que es función de una combinación lineal de los valores de sus entradas, tal como recoge la ecuación (5.18).

$$y_i = f_i \left(\sum_{j=1}^n w_{ij} x_j - \theta_i \right) \quad (5.18)$$

Siendo:

y_i : valor de la salida de la neurona i

x_j : valor de la entrada j (o valor de la salida de otra neurona j)

w_{ij} : peso de la conexión entre las neuronas i y j

θ_i : umbral o sesgo (bias) de la neurona i

f_i : función de activación

La función de activación puede ser lineal, pero generalmente es de tipo no lineal (sigmoide, gaussiana...). Esa no linealidad de la función de activación constituye la base para que una red neuronal pueda ser el aproximador universal de funciones no lineales.

A continuación, en la Figura 5. 1, podemos ver la estructura de una neurona de una red neuronal:

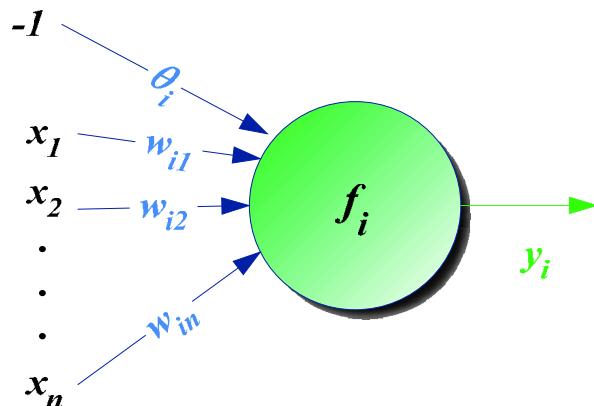


Figura 5. 1 Estructura de una neurona

La estructura de una red neuronal viene determinada por la disposición de las neuronas y de sus funciones de activación. Las neuronas se agrupan en capas, considerándose como “ocultas” aquellas que no corresponden a la capa de entradas (las neuronas que actúan como entrada de señales o valores externos) y la capa de salidas

(las neuronas que proporcionan su salida al exterior). El conjunto de valores que se presentan a las neuronas de la capa de entradas (un valor por neurona), correspondientes a las entradas de la propia red neuronal, se denomina valor del vector de entradas, mientras que el conjunto de valores de salida (una red neuronal puede tener más de una salida) se denomina vector de salida.

La característica más importante de las redes neuronales es **el aprendizaje**. Para ello van ajustando los pesos (w_{ij}) de las conexiones entre neuronas de forma iterativa para conseguir su objetivo, es decir, para “aprender” las relaciones presentes entre los vectores de entrada-salida con los que se entrena a la red neuronal y/o encontrar un patrón común para clasificar los datos de entrada.

En redes neuronales hay tres tipos de aprendizajes:

- **Aprendizaje supervisado:** es el más habitual en aproximación de funciones no lineales con redes neuronales. Se suministran tanto el valor del vector de entradas, como el valor del vector de salidas (valor del vector de salidas esperado correspondiente a cada valor del vector de entradas). Durante el proceso de aprendizaje, la red neuronal ajusta sucesivamente el peso de las conexiones de forma que se minimiza el error entre los valores del vector de salidas de la red neuronal y los valores del vector de salidas esperado.
- **Aprendizaje no supervisado:** la red neuronal no recibe ningún valor esperado del vector de salidas, pero busca en los valores del vector de entradas alguna propiedad o correlación para clasificarlos.
- **Aprendizaje reforzado:** es un caso especial de aprendizaje supervisado en el que el valor del vector de salidas esperado no es suministrado, únicamente se suministra a la red neuronal la información precisa de si el valor del vector de salidas es igual, o no, al esperado.

A continuación se enumeran los tipos de redes neuronales más utilizados con el fin de obtener buenos resultados en la predicción de la producción eléctrica fotovoltaica de instalaciones conectadas a red.

- Red neuronal MLP (Perceptrón Multicapa)
- Red neuronal unidireccional multicapa generalizada (FFBP)
- Red neuronal modular
- Red neuronal de función de base radial (RBF)
- Red neuronal de análisis de componentes principales (PCA)
- Mapas auto-organizados (SOM)
- Redes neuronales recurrentes:
 - Red neuronal de Elman
 - Redes neuronales retardadas en el tiempo
 - Redes recurrentes generales
- Redes neuronales Wavelet

A continuación, se van a explicar tres de estos tipos de red neuronal, concretamente la MLP y la RBF, con el fin de hacernos una idea de su funcionamiento, y las Wavelet, puesto que recientemente están siendo utilizadas en diversos modelos de predicción. Las características más relevantes de cada uno de los otros tipos de red neuronal pueden verse en el *Capítulo 6 Desarrollo de los Modelos*.

5.2.1 RED NEURONAL MLP (PERCEPTRÓN MULTICAPA)

La red neuronal MLP (*Multilayer Perceptron*) es un tipo de red neuronal unidireccional (las neuronas están conectadas siguiendo el sentido de entrada hacia salida) en el que las neuronas están organizadas en capas, de forma que una neurona situada en una capa intermedia sólo puede tener como entradas las salidas de la capa precedente y su salida sirve de entrada para neuronas de la siguiente capa.

Para entender esto de una forma más clara, podemos ver a continuación en la Figura 5. 2, la representación gráfica de este tipo de red neuronal:

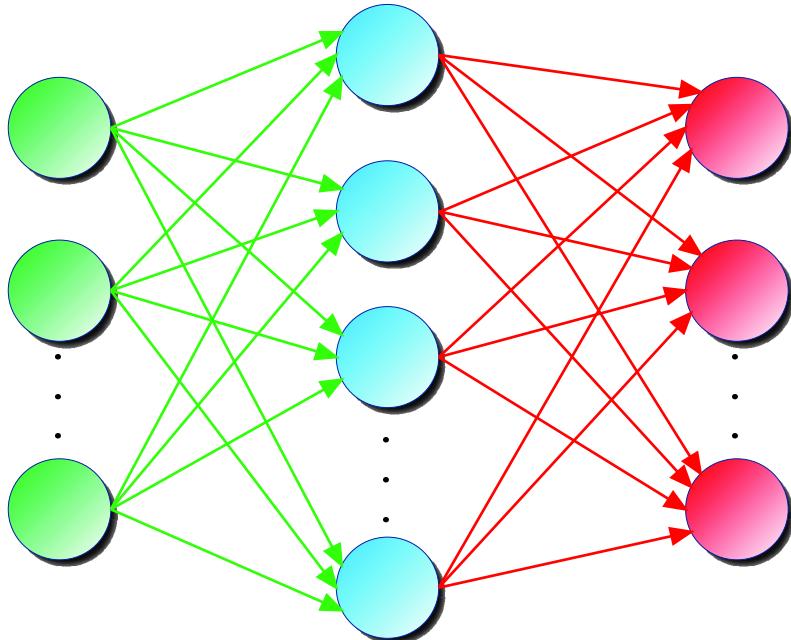


Figura 5. 2 MLP con una capa oculta

Las neuronas de color verde forman la capa de entradas (cada neurona de la capa de entradas recibe un valor externo), las neuronas de color azul forman una capa intermedia o capa oculta, y las neuronas rojas forman la capa de salidas (el valor de salida de cada una de las neuronas constituye una de las salidas de la red neuronal).

Una red neuronal MLP puede tener varias capas ocultas, si bien con una sola capa oculta sería capaz de aproximar, con un error arbitrariamente pequeño, cualquier función continua (lineal o no) acotada, y con dos capas ocultas cualquier función continua [Cybenko89]. En este trabajo se han utilizado redes neuronales MLP con dos capas ocultas debido a la complejidad de las predicciones a obtener. No se incluyen más capas ocultas ya que pasar de dos a tres capas ocultas supone un gasto computacional mayor en el aprendizaje y en la literatura científica no aparece ningún caso donde el uso de más de dos capas ocultas haya proporcionado ninguna mejora.

Existen diversas técnicas para el aprendizaje o entrenamiento de las redes neuronales MLP. El más extendido es el de retropropagación del error (backpropagation) [Haykin94], que ha sido adaptado al entrenamiento de más tipos de redes neuronales, aparte de las MLP.

La técnica de retropropagación de error consiste, básicamente, en actualizar los pesos de las conexiones entre neuronas proporcionalmente a su contribución al error. Existen dos versiones en la aplicación de esta técnica, la conocida como versión “*on-line*” (también conocida como “*instance-based*”) y la versión “*off-line*” (“*batch*”). En la versión “*on-line*” de entrenamiento, la actualización de los pesos de la red neuronal se realiza tras la presentación de cada valor del vector de entradas. En la versión “*off-line*”, la actualización de los pesos de la red neuronal se realiza tras la presentación de todo el conjunto de valores del vector de entradas de los datos de entrenamiento (lo que constituye un “*epoch*”). En los trabajos recogidos en este documento se ha utilizado siempre este segundo método.

A la hora de diseñar una red neuronal MLP se debe seleccionar el número de capas ocultas y el número de neuronas de cada capa. Cuanto mayor sea el número de capas y de neuronas, mayor será la capacidad de la red neuronal MLP de ajustar cualquier función, pero aumentará el tiempo necesario para entrenarla (para que “aprenda”) y, sobre todo, se corre el riesgo de sobre-entrenar la red. El sobre-entrenamiento consiste en que la red neuronal ajusta perfectamente los valores que se le han dado en el vector de entradas, proporcionando el valor deseado del vector de salidas o un valor relativamente muy próximo, pero se ha “adaptado” demasiado a esos datos perdiendo su capacidad de generalización en la predicción. Cualquier valor del vector de entradas diferente de los utilizados en el entrenamiento de la red neuronal puede dar resultados con errores considerables.

Hay varias técnicas cuyo propósito es evitar el sobre-entrenamiento de la red neuronal, como:

- La limitación del número de epochs en el entrenamiento (“*early-stopping*”).
- La adición de ruido blanco sobre los valores de las variables de entrada.
- La utilización de la validación cruzada (“*Cross Validation*”).

La técnica de validación cruzada es la más extendida y la que se ha usado en los modelos de predicción desarrollados en las investigaciones ligadas a la presente Tesis Doctoral.

Con la validación cruzada se dividen los datos que va a utilizar la red neuronal durante el aprendizaje en dos grupos: entrenamiento y validación cruzada. Los datos del grupo de entrenamiento son los que se utilizan para el ajuste de los parámetros de la red neuronal utilizando el método de entrenamiento elegido. Los datos del grupo de validación cruzada no se utilizan en la determinación del error que se pretende minimizar con el entrenamiento de la red neuronal, sino que se presentan a la red neuronal tras cada epoch de entrenamiento. El proceso de entrenamiento se interrumpe cuando haya transcurrido un número predeterminado de epochs sin reducción del error con los datos de validación cruzada.

Gracias a su capacidad de aproximar funciones no lineales, la red neuronal MLP permite diseñar de una manera sencilla modelos auto-regresivos no lineales para la predicción utilizando como variables de entrada para la red neuronal los valores pasados de la propia variable que forma la serie temporal.

5.2.2 RED NEURONAL RBF

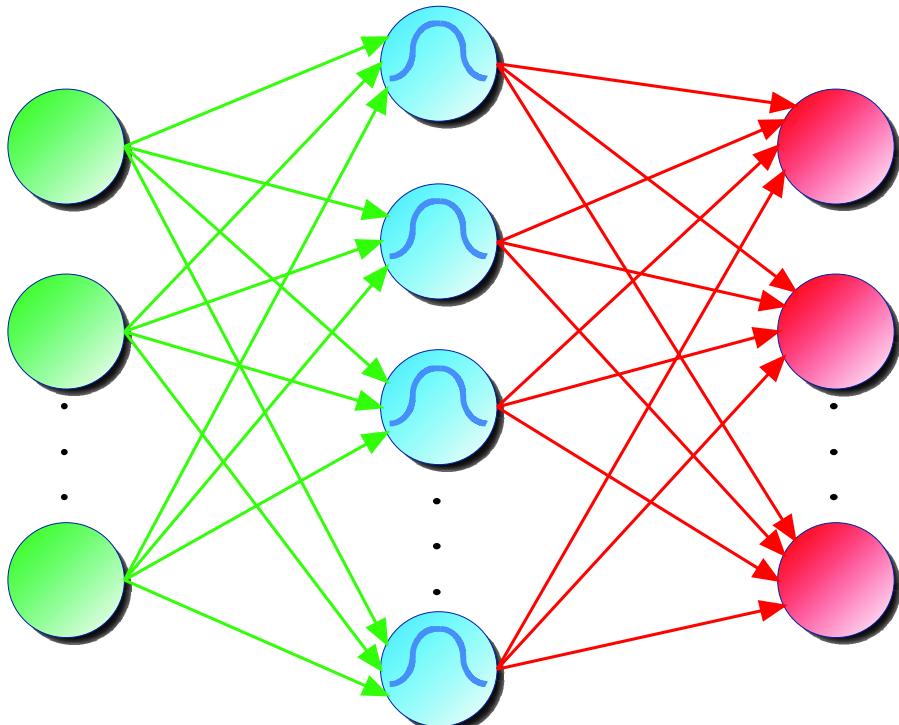


Figura 5. 3 Estructura general de una red RBF

Este tipo de red neuronal tiene un aprendizaje híbrido, es decir, combina el aprendizaje no supervisado con el aprendizaje supervisado. La red neuronal con función de base radial, (*RBF: radial basis function*), es una red con tres capas de neuronas: capa de entradas, capa oculta y capa de salidas. Además, es una red neuronal unidireccional y sólo se permiten conexiones entre neuronas de capas consecutivas en el orden de entrada a salida, tal como muestra la Figura 5. 3. Por tanto es muy similar a la red neuronal MLP diferenciándose fundamentalmente en la función de activación de las neuronas de la capa oculta.

En una red neuronal MLP, las neuronas de la capa oculta realizan una suma ponderada de los valores de las entradas (el factor de ponderación son los pesos de las conexiones) y aplica a esta suma una función de activación, generalmente de tipo sigmoidal. En una red neuronal RBF las neuronas de la capa oculta calculan la distancia euclídea entre el valor del vector de entradas y un valor del vector previamente almacenado en cada neurona, que recibe el nombre de centro, y sobre esa distancia aplica una función con forma gaussiana.

Puesto que una función gaussiana es una función no lineal, una única capa oculta puede ser suficiente para aproximar cualquier tipo de función, si bien en las investigaciones vinculadas a la Tesis, y con el fin de mejorar la capacidad de aproximación a funciones no lineales, se ha dispuesto de una o dos capas ocultas adicionales. Estas capas ocultas son similares a las de una red neuronal MLP, es decir, con función de activación sigmoidal en cada neurona.

Así, el entrenamiento de una red neuronal RBF consta de dos fases. En una primera fase se realiza el aprendizaje no supervisado donde cada valor del vector de entradas pertenecerá a un único grupo, correspondiente al del centro más cercano (en términos de distancia euclídea), y el centro de cada grupo es el centroide (valor medio) de los valores del vector de entradas que pertenecen a dicho centro. En la segunda fase se realiza un aprendizaje supervisado, donde se actualizan los pesos de las neuronas de la capa de salidas (con función de activación lineal) y los de las capas ocultas (con función de activación sigmoidal).

Comparando las redes neuronales RBF con las redes neuronales MLP, la ventaja de las RBF es su mayor rapidez en el entrenamiento y la necesidad de un menor número de neuronas para aproximar con igual grado de exactitud una función no lineal.

5.2.3 RED NEURONAL WAVELET

Para entender mejor el funcionamiento de estas ANN de aplicación más reciente es recomendable comenzar describiendo en que consiste el procesamiento wavelet. El análisis wavelet consiste en la descomposición de una señal en un conjunto jerárquico de aproximaciones y detalles. En cada nivel de la jerarquía se obtiene una señal de aproximación y una señal de detalle, la señal de aproximación obtenida es una aproximación de la señal original que toma en cuenta las frecuencias bajas mientras que la señal de detalles corresponde a los componentes de alta frecuencia. Las wavelets son funciones que permiten descomponer una señal en distintos componentes de frecuencia y después analizar cada uno en una resolución acorde a su escala. La teoría de las funciones wavelet fue desarrollada en distintos campos del conocimiento como las matemáticas, física e ingeniería eléctrica [Walker08].

Las funciones wavelet deben satisfacer ciertas requerimientos matemáticos y son usadas para representar datos o aproximar otras funciones. La idea de aproximar funciones mediante la superposición de otras tiene sus orígenes en el trabajo de Joseph Fourier quien introdujo el concepto de aproximación de funciones mediante la suma de funciones seno y coseno. Las funciones wavelet surgen como una respuesta a las demandas de los científicos de aproximar señales discontinuas mediante funciones más apropiadas que senos y cosenos dado que estas son no locales y se extienden hasta infinito, teniendo como consecuencia un desempeño pobre en la detección de cambios repentinos. Tomando en cuenta las limitaciones señaladas anteriormente surge la transformada wavelet la cual permite una mejor localización en el espacio frecuencia [Grafs95].

Dentro del análisis wavelet se adopta una función prototipo llamada madre wavelet. El análisis temporal es llevado a cabo mediante una versión de alta frecuencia de la función wavelet madre mientras que el análisis de frecuencia es desarrollado por una versión de baja frecuencia.

Desde la aparición de la base Haar, renombrada años después como la wavelet Haar, han surgido a través de los años distintas familias como la Gaussiana, Meyer y Daubechies. Durante los primeros 10 años de historia de la teoría wavelet aparecieron numerosas familias pero recientemente la creación se ha vuelto menos regular dado que se ha limitado la construcción a contextos específicos [Misiti07]. Las diferencias entre una

familia y otra definen propiedades distintas como: soporte de las funciones, velocidad de convergencia a cero, simetría, número de momentos cero, regularidad, existencia de una función de escalamiento, ortogonalidad y la existencia de una fórmula explícita.

Dentro de cada familia wavelet existen subclases que se distinguen por el número de coeficientes y el nivel de iteración. Las wavelets son clasificadas dentro de una familia a menudo por el número de momentos de desvanecimiento.

Las redes neuronales wavelet combinan la teoría de procesamiento wavelet con las redes neuronales. La estructura de una red neuronal wavelet es similar a la red neuronal 1+1/2 [Cybenko89]. Existe una capa de entrada que conecta con una o más entradas, una capa oculta donde se efectúa el procesamiento de las entradas, y finalmente una capa de salida que consiste en uno o más combinadores lineales que toman la salidas de la capa oculta.

Existen dos enfoques principales para la creación de redes neuronales wavelet. En el primero el procesamiento wavelet y la red neuronal son desarrollados de manera independiente, es decir que la señal de entrada es descompuesta por la transformada wavelet en los nodos de la capa oculta y los coeficientes resultantes son enviados a los sumadores cuyos pesos son modificados de acuerdo a algún algoritmo de aprendizaje. A las redes neuronales con esta estructura se les conoce como *wavenet*. El segundo enfoque es combinar ambas teorías y dejar que los parámetros de traslación y escalamiento sean también ajustados en el proceso de aprendizaje, este tipo de estructura se conoce como red neuronal wavelet.

La arquitectura más sencilla de una red neuronal wavelet consta de una sola entrada y una sola salida. En esta arquitectura la capa oculta está formada por un tipo especial de neurona, las llamadas *wavelons*, cuyos parámetros de entrada están definidos por peso, parámetro de traslación y escalamiento. La salida de la red es una combinación lineal de las funciones wavelet de cada *wavelon*. La salida de un *wavelon* con una entrada sencilla está dada por [Rao94]:

$$\psi_{\lambda,t}(u) = \psi\left(\frac{u-t}{\lambda}\right) \quad (5.19)$$

La arquitectura de una red neuronal wavelet se muestra en la Figura 5. 4, la capa oculta consiste en M wavelons y la capa de salida consiste en un sumador.

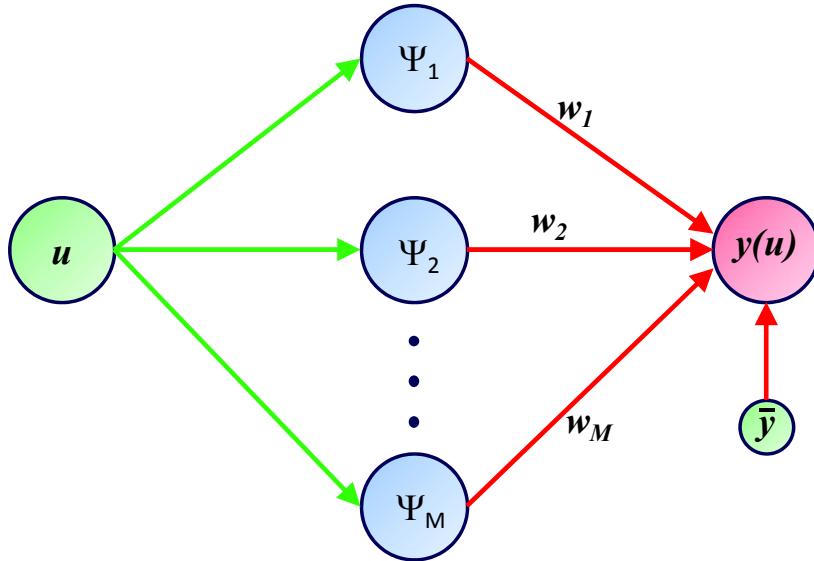


Figura 5. 4 Red neuronal Wavelet simple

De forma que la salida será:

$$y(u) = \sum_{i=1}^M w_i \cdot \psi_{\lambda i, t i}(u) + \bar{y} \quad (5.20)$$

La arquitectura de una wavenet es similar a la de red neuronal wavelet, a excepción de que los parámetros de traslación y escalamiento se mantienen fijos desde la inicialización y no son alterados durante el proceso de aprendizaje. Su salida está dada por:

$$y(u) = \sum_{i=1}^M w_i \cdot \phi_{\lambda i, t i}(u) \quad (5.21)$$

Donde $\phi_{\lambda i, t i}(u)$ representa la función de escalamiento y traslación manteniendo las restricciones mencionadas anteriormente.

En el caso general de una red neuronal wavelet, nos encontramos con una red multidimensional, en este caso, la entrada es un vector multidimensional, por lo tanto los

wavelons operan con wavelets multidimensionales. Las salidas de estos nodos están dadas por la multiplicación de wavelets unidimensionales correspondientes a cada una de las entradas que llegan a él.

La salida de cada *wavelon* multidimensional está dada por [Zhang92]:

$$\psi(u_1, u_2, \dots, u_N) = \prod_{i=1}^N \psi_{\lambda_i, ii}(u_i) \quad (5.22)$$

La arquitectura de la red neuronal wavelet general, es decir, multidimensional, se muestra en la Figura 5. 5, consta de M *wavelons* multidimensionales y la capa de salida consta de K sumadores que recolectan los resultados de la capa oculta.

De forma que el valor de cada una de las salidas estará dado por la siguiente relación:

$$y_j = \sum_{i=1}^M w_i \cdot \psi_i(u_1, u_2, \dots, u_N) + \bar{y}, \quad \text{para } j = 1 \dots K \quad (5.23)$$

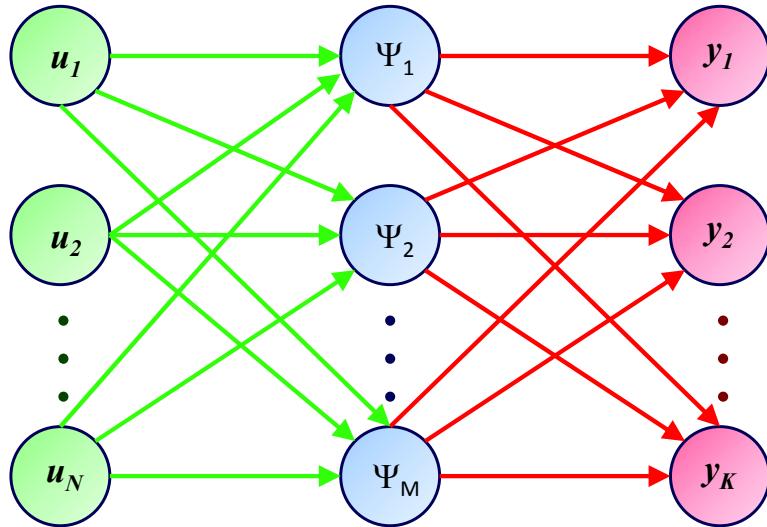


Figura 5. 5 Red neuronal Wavelet general (multidimensional)

5.2.4 OPTIMIZACIÓN CON ALGORITMOS GENÉTICOS

En el desarrollo de los modelos de redes neuronales, muchos de los parámetros que los definen quedan a juicio del propio diseñador (número de neuronas en capas ocultas, número de componentes principales en PCA...). La utilización de procesos de optimización basados en el uso de algoritmos genéticos permitirá una selección óptima de valores para los parámetros que definen la estructura de cada uno de los modelos de predicción.

Hoy en día los algoritmos genéticos constituyen unas herramientas de optimización que han demostrado su gran utilidad para la búsqueda de soluciones satisfactorias en problemas de campos científicos muy diversos (ingeniería, economía, medicina...).

El algoritmo genético, GA (Genetic Algorithm), fue desarrollado por J.H. Holland en la década de los 70 del pasado siglo como una técnica de búsqueda basada en los mecanismos de la selección natural. A finales de los 80 se descubrió la eficacia de esta técnica para la optimización, la adaptación y el aprendizaje, necesarias en la resolución de los más variados problemas [Goldberg89].

A la hora de desarrollar los modelos de predicción, los algoritmos genéticos han sido utilizados como técnica de optimización para el diseño automático de dichos modelos. Los algoritmos genéticos pueden ser usados en múltiples procedimientos de diseño y requieren muy poca información específica para poder realizar la optimización. Por ejemplo, relacionado con los modelos a los que se hace referencia en el presente documento, los GA han sido utilizados en la optimización de redes neuronales [Yao99], en la identificación de modelos ARIMA estacionales [Blake95], o como método de eliminación de reglas menos importantes en sistemas de inferencia difusa [Leng06].

Si los describimos de una manera breve, podemos decir que los procesos de optimización con algoritmos genéticos comienzan con la creación de una población inicial de individuos, generados de una forma aleatoria. Cada individuo constituye una solución potencial al problema que se esté considerando. El conjunto de individuos va evolucionando de una manera iterativa. Cada uno de los pasos del proceso iterativo recibe el nombre de generación. En cada generación, todos los individuos de la población son evaluados usando un criterio especificado de medida de la bondad de la solución al

problema que representan (aptitud o fitness). La población para la siguiente generación se crea, a partir de la población existente, mediante la aplicación de operadores genéticos. El proceso iterativo, con sucesivas generaciones, termina cuando se cumple un criterio específico establecido previamente.

Cada solución debe estar codificada en forma de una cadena numérica o alfanumérica, que recibe el nombre de individuo. La codificación más usada es la numérica, con una representación de los números en formato binario, bien en forma de números enteros o de coma flotante. Así, la cadena estará compuesta por un conjunto de bits. A su vez, esta cadena puede considerarse como un cromosoma compuesto por n genes, tal y como representa la expresión (5.24), donde n representa los diferentes parámetros o características que definen la solución contenida en la cadena. La estructura de la cadena recibe el nombre de genotipo y su contenido el nombre de fenotipo [Sakawa02].

$$s_1 s_2 \cdots s_j \cdots s_n \quad (5.24)$$

La aptitud, o criterio de bondad, puede consistir en el valor que proporciona cada solución potencial (codificada en forma de cromosoma) para la variable a maximizar en problemas de maximización. En cambio, en el caso de problemas de minimización, como puede ser minimizar el error de la predicción, la aptitud puede consistir en la diferencia entre un valor constante y el valor que proporciona cada solución (individuo) para la variable a minimizar. La combinación de aptitud y tres operadores fundamentales proporciona, tras un número razonable de generaciones, la solución óptima o aproximadamente óptima al problema de optimización.

Seguidamente indicamos los tres operadores fundamentales usados en la creación de una nueva generación.

- **Reproducción:** atendiendo a su valor de aptitud, cada individuo de una población tendrá una probabilidad de reproducción determinada. Básicamente la reproducción consiste en realizar un número de copias de cada individuo relacionado con su valor de aptitud. El individuo con mayor valor de aptitud se copiará más veces que el individuo con peor valor. Con esto se crea una población intermedia entre la de la última generación y la siguiente.

- **Cruce:** dos individuos seleccionados aleatoriamente de entre los que componen la población intermedia intercambian parte de sus cromosomas con una probabilidad definida y conocida como el índice de cruce o tasa de cruce. El intercambio se realiza seleccionando de forma aleatoria (probabilidad uniforme) un punto o dos puntos de las cadenas, e intercambiando los fragmentos de las mismas desde el punto seleccionado al principio o final de la cadena, o intercambiando los fragmentos comprendidos entre los dos puntos. A partir del cruce se crean dos nuevos individuos para la siguiente generación. Dado que en la población intermedia los individuos con mayor aptitud estaban más veces repetidos que los de menor aptitud, los individuos con mayor aptitud tienen mayor probabilidad de ser seleccionados para la operación de cruce que aquellos con un menor valor de la misma.
- **Mutación:** Consiste en la alteración de una o más partes de un individuo seleccionado, con una probabilidad definida y conocida como índice o tasa de mutación. En este caso, los individuos se seleccionan de la población de la última generación, no de la población intermedia de la ruleta. Este operador proporciona un carácter aleatorio a la búsqueda de soluciones, de forma que se evita que, tras unas pocas generaciones, todas las soluciones sean muy similares entre sí. El operador mutación facilita una vía para "escapar" de posibles óptimos locales (de la aptitud) en el proceso de búsqueda de la solución óptima.

Es muy importante seleccionar de manera adecuada los valores de las tasas de cruce y mutación para obtener soluciones óptimas. Para dicha selección habrá que tener en cuenta que un elevado valor de la tasa de cruce se traduce en un proceso dirigido de búsqueda de soluciones, mientras que un alto valor de la tasa de mutación se traduce en un proceso de búsqueda aleatorio. Para evitar caer en ninguno de los dos extremos, búsqueda dirigida propensa a encerrarse en óptimos locales y búsqueda aleatoria que no converge a soluciones satisfactorias, se utilizan tasas de cruce inferiores al 90%, y tasas de mutación muy pequeñas (sobre un 1%).

Hasta ahora hemos definido los algoritmos genéticos desde un punto de vista general, a partir de este punto vamos a centrarnos en la aplicación de dichos algoritmos a los modelos de redes neuronales.

Una vez escogido el tipo de la red neuronal (MLP, FFBP, PCA...) un algoritmo genético adecuado permite determinar el valor óptimo de varios parámetros, a continuación se destacan los de mayor interés:

- **Entradas de la red neuronal:** de entre todas las entradas disponibles, los mejores modelos de predicción son aquellos que usan aquellas variables de entrada que realmente aportan información relevante para la predicción.
- **Número de capas ocultas:** como ya se ha comentado con anterioridad, para aproximación de funciones no lineales, una o dos capas ocultas son suficientes.
- **Función de activación de las neuronas:** en la mayoría de los casos se escoge una función de activación común para todas las neuronas de una capa. Si bien es cierto, en el caso más complejo podríamos seleccionar una función de activación diferente por neurona, escogiendo entre sigmoidal, lineal, tangente hiperbólica...
- **Número de neuronas en cada capa:** el número de neuronas en las capas ocultas tiene relación directa con la capacidad de aproximación no lineal de la red neuronal. Cuanto mayor sea el número de neuronas, mayor es esa capacidad, pero también es mayor la probabilidad de sobre-entrenar la red neuronal. Gracias al algoritmo genético se puede seleccionar su valor óptimo.
- **Valores de inicialización de pesos:** para entrenar una red neuronal hay que partir de unos valores iniciales de los pesos de las conexiones entre neuronas. La asignación de valores a estos pesos se hace de forma aleatoria, pero su valor inicial influye en el comportamiento final de la red neuronal. Con unos valores iniciales u otros, el comportamiento de la red neuronal, una vez entrenada, puede ser completamente diferente. Un adecuado algoritmo genético permite la selección idónea del valor medio de los pesos iniciales y de su varianza. Posteriormente se asignan de forma aleatoria valores iniciales a los pesos, siguiendo una distribución estadística con aquel valor medio y aquella varianza.

- **Parámetros del algoritmo de entrenamiento utilizado:** hace referencia al factor de aprendizaje, o step, y al momento. Cada capa de neuronas puede tener sus propios valores, pero su valor óptimo puede ser determinado con la ayuda del algoritmo genético. En el caso de entrenamiento no supervisado, otros parámetros que lo definen pueden tener el mismo tratamiento.
- **Número de componentes principales:** en las redes neuronales PCA el número de componentes principales, que se van a considerar en las entradas, tiene influencia en el posterior funcionamiento de la red neuronal. Gracias al algoritmo genético se puede seleccionar su valor óptimo.
- **Número de neuronas de función de base radial:** en una red neuronal RBF las neuronas de la capa siguiente a la capa de entradas tienen una función de activación de tipo gaussiano, cuyo valor de centro, y de varianza, es determinado por aprendizaje no supervisado. Sin embargo, queda a elección del diseñador el número de neuronas de ese tipo. Gracias al algoritmo genético se puede seleccionar su valor óptimo.
- **Número de unidades de retardo:** en las redes neuronales recurrentes con retardo en el tiempo, el número de unidades de retardo también es susceptible de ser escogido por medio de un algoritmo genético.

Cada red neuronal tras ser configurada, debe ser entrenada, de acuerdo a los posibles valores de los parámetros que definen el entrenamiento. Estos parámetros hacen referencia al número máximo de epochs, criterio de interrupción de entrenamiento o criterio de evaluación, los cuales deben haber sido definidos desde el primer momento por el diseñador. El criterio de evaluación corresponde a la función objetivo que marca la aptitud de cada uno de los individuos. El criterio puede ser el error cuadrático medio con los datos de entrenamiento, con los datos de validación, o una media ponderada de los dos. Evidentemente, en este caso lo que busca la optimización es minimizar el error.

Para realizar los modelos vinculados a la presente Tesis Doctoral, se ha utilizado una herramienta que, mediante un algoritmo genético, permite optimizar la mayor parte de los parámetros antes indicados. El diseñador ha de fijar de antemano el número de capas ocultas y el tipo de función de activación.

5.2.5 OPTIMIZACIÓN PSO (PARTICLE SWARM OPTIMIZATION)

La optimización por nube o enjambre de partículas (*Particle Swarm Optimization, PSO*) es una técnica de computación evolucionaria desarrollada por Kennedy ([Kennedy95] y [Kennedy01]) y Eberhart [Eberhart01]. Semejante a los algoritmos genéticos (GA), aunque en este caso, la optimización por enjambre de partículas es una herramienta de optimización basada en el comportamiento de los enjambres de insectos en la naturaleza. En concreto, podemos pensar en un enjambre de abejas, ya que éstas a la hora de buscar polen buscan la región del espacio en la que existe más densidad de flores, porque la probabilidad de que haya polen es mayor. Este método ha sido portado al campo de la computación en forma de algoritmo y se emplea en la actualidad en la optimización de distintos tipos de sistemas.

El método cuenta con un conjunto o población de *partículas* (individuos), las cuales representan diferentes posiciones dentro del espacio de búsqueda y poseen, además, una velocidad mediante la cual actualizan sus posiciones. En el contexto de la optimización, cada posición dentro del espacio de búsqueda tiene asociado un valor numérico que es cuantificado mediante la función objetivo; de manera que el óptimo de la función se encuentra en la posición en la que se toma el valor máximo (o mínimo, dependiendo del caso). Dado que las partículas tienen la capacidad de "recordar" tanto la mejor posición en la que estuvieron como la mejor posición hallada por todo el enjambre, se puede usar esta información para guiar los movimientos de las partículas en la dirección de los valores óptimos de la función.

Hay una serie de parámetros que afectan al desempeño de la optimización y eventualmente a los resultados obtenidos. Concretamente son:

- **Cantidad de partículas (tamaño o población del enjambre):** Permite variar la cantidad de individuos que conforman la población del enjambre. Para construir enjambres mixtos, es decir, compuestos por partículas de distinto tipo, se puede especificar la proporción a utilizar.
- **Posición inicial:** Es un vector que indica la posición alrededor de la cual se distribuirán las partículas antes de comenzar el proceso iterativo.

- **Dispersión o distribución inicial:** Las partículas se distribuyen inicialmente en forma aleatoria alrededor de la posición inicial; el rango de dichos valores aleatorios está dado por la dispersión inicial.
- **Factores de corrección:** La técnica PSO emplea tres parámetros numéricos que gobiernan el comportamiento del enjambre. La elección de sus valores resulta de gran importancia ya que influyen directamente en los resultados hallados.
 - El primer parámetro es el factor de inercia (ω), que permite controlar la capacidad exploratoria del enjambre. Como las partículas no cambian su dirección de avance instantáneamente, al emplear un valor alto de inercia se cubren mayores espacios de búsqueda.
 - Los otros dos factores de corrección, Φ_p y Φ_g , regulan la importancia de los óptimos local y global del enjambre respectivamente. Los óptimos locales del enjambre son las mejores posiciones donde han estado cada una de las partículas y el óptimo global es la mejor posición conocida por todo el enjambre. Variando sus valores, se orienta el movimiento del enjambre hacia los óptimos locales o hacia el óptimo global del enjambre, por ello, en cierto modo, se está controlando la independencia de cada partícula.
- **Velocidad máxima:** este parámetro limita el valor máximo que pueden tomar cada una de las componentes del vector de velocidad de las partículas. Permite regular la dispersión del enjambre durante el proceso de optimización.
- **Límites para el espacio de búsqueda:** por defecto, el espacio de búsqueda es infinito, sin embargo, en algunos casos es necesario limitar esta región. Este sería el caso si se emplearan funciones que no estén definidas en todo el espacio. Los límites del espacio de búsqueda actúan como barreras impidiendo que las partículas sobrepasen los límites indicados.

5.2.6 VENTAJAS E INCONVENIENTES

En el caso de las redes neuronales la mayor ventaja es que no es preciso conocer la naturaleza del conjunto de datos que se quiere representar, sino que es la propia red neuronal quien recoge las características principales de dicho conjunto a través del proceso de entrenamiento. A continuación se comentan otras ventajas:

- Gran capacidad de aproximación a consecuencia del comportamiento no lineal de las funciones de activación de las neuronas.
- No requieren de gran experiencia previa o de la colaboración de expertos en la materia, como ocurría por ejemplo con los ARIMA cuyo cálculo es muy complejo.
- Si el conjunto de datos evoluciona o cambia, la red neuronal se puede readaptar volviéndola a entrenar.

Como desventajas se pueden citar las señaladas a continuación:

- Para realizar un entrenamiento correcto cuando hay muchas entradas, hay que disponer de gran cantidad de datos (valores del vector de entradas y de los correspondientes valores del vector de salidas). Esta desventaja hay que tenerla muy en cuenta porque hay muchos casos en los que resulta difícil obtener gran cantidad de datos (como en el presente caso), necesaria para que la red neuronal sea entrenada adecuadamente.
- Además se debe tener cuidado con la aparición de algún mínimo local en el entrenamiento.

5.2.7 APLICACIÓN EN LA PREDICCIÓN DE LA PRODUCCIÓN

Los modelos basados en redes neuronales artificiales se han manifestado como candidatos ideales en la aproximación de funciones no lineales. En el caso de las redes neuronales unidireccionales es sencillo construir un modelo auto-regresivo no lineal, sin más que utilizar los valores pasados de la serie temporal como variables de entrada de la

red neuronal. En el caso de redes neuronales recurrentes es posible construir modelos más complejos, capaces de proporcionar una salida distinta no sólo en función del valor del vector de entradas, sino en función del valor de dicho vector en el pasado próximo.

Para el caso concreto de la predicción de la producción eléctrica en instalaciones solares fotovoltaicas conectadas a red, como problema de características no lineales que es, los modelos basados en redes neuronales constituyen una de las opciones, a priori, más interesantes a considerar.

Los modelos de predicción a desarrollar corresponden a una aproximación de funciones no lineales, en la que las variables de entrada al modelo corresponden a las predicciones del modelo atmosférico para el horizonte de predicción y para los instantes previos. Los modelos de predicción a crear pueden corresponder tanto a redes neuronales unidireccionales, como a redes recurrentes.

5.3 SISTEMAS DE INFERENCIA DIFUSA O FUZZY

Estos sistemas se basan en lo que conocemos como lógica fuzzy o difusa [Zadeh65], que es una técnica para la incorporación del conocimiento estructurado humano en algoritmos eficientes [Kecman01].

Los modelos de inferencia difusa, junto con los modelos basados en redes neuronales artificiales, se tratan de un conjunto de herramientas de representación o modelización que pertenecen al campo conocido como “soft-computing”.

Este tipo de sistemas quizás es más sencillo de comprender que las redes neuronales puesto que se basan en un razonamiento inductivo, presente en muchos procesos intelectuales humanos. Los más representativos son los razonamientos que responden a estructuras lógicas del tipo “SI ... ENTONCES ...”. Podemos, así, argumentar que el conocimiento humano se estructura en reglas del tipo “SI ... ENTONCES ...”, y que esa combinación de reglas lleva a unas consecuencias concretas. Una regla de este tipo relaciona las variables asociadas al “SI” (antecedentes o causas) con las variables asociadas al “ENTONCES” (consecuentes o efectos).

Algo también muy común en el ser humanos es describir las situaciones, elementos..., en unos términos vagos o difusos.

De esta forma, los seres humanos cuando ven a una persona de más de dos metros de altura, piensan que es una persona “muy alta”. Pero este pensamiento es difuso, tiene una incertidumbre inherente: ¿cuál es la frontera entre una persona muy alta y otra que no lo es? Esta incertidumbre puede ser acotada en términos matemáticos mediante lo que denominamos función de pertenencia, que es la expresión matemática del grado (entre 0 y 1) en que se valora la pertenencia de un elemento a un conjunto determinado por un específico término difuso (en este caso “muy alta”).

Un conjunto difuso se representa por una etiqueta, por ejemplo Z , que toma valores dentro del universo de discurso X , o límites entre los que está definido, y lo caracteriza mediante una función de pertenencia μ_Z que tomará valores comprendidos entre 0 y 1.

La expresión matemática para un conjunto difuso es la reflejada en la ecuación (5.25).

$$\begin{aligned} A &= \{(x, \mu_Z(x)) \mid x \in X\} \\ \mu_Z &: X \rightarrow [0,1] \end{aligned} \tag{5.25}$$

La función de pertenencia es una función que asocia a cada elemento (del conjunto difuso) un valor dentro del intervalo $[0,1]$ y dentro del universo de discurso. Las funciones de pertenencia más usuales son: triangular, trapezoidal, gaussiana, sigmoidal y campana. La Figura 5. 6 muestra tres funciones de pertenencia, para otros tantos conjuntos difusos, definidos para un universo de discurso en el intervalo $[0,50]$. Las tres funciones de pertenencia de dicha figura son del tipo gaussiano, con centros en los valores 0, 25 y 50, y varianza de valor 8.

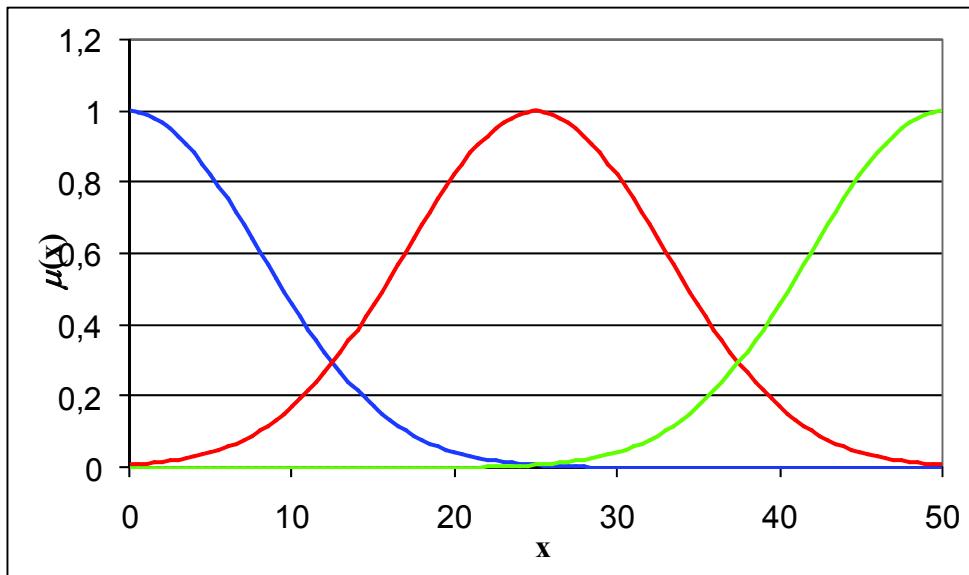


Figura 5. 6 Ejemplo de funciones de pertenencia de tipo gaussiano

5.3.1 ESTRUCTURA DE LOS SISTEMAS DE INFERENCIA DIFUSA

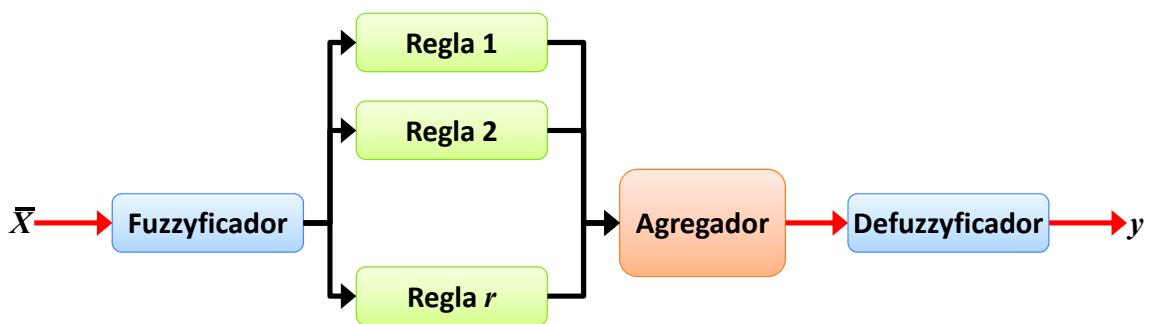


Figura 5. 7 Estructura de un sistema de inferencia difusa

El conjunto de valores numéricos de las variables de entrada del sistema componen el vector de entradas, \bar{X} . El primer paso que sigue el sistema es convertir las variables del vector de entradas en variables que pueda manipular ese sistema de inferencia difusa. De eso se encarga el bloque “fuzzyficador” que calcula los niveles de pertenencia de los valores de entrada a los diferentes conjuntos difusos en los cuales se ha dividido el universo de discurso de las diferentes variables de entrada al sistema.

A partir de lo anterior queda claro que la base del razonamiento difuso son las reglas del tipo “SI ... ENTONCES ...”. El conjunto de reglas (base de reglas) constituye el conocimiento lingüístico que “posee” el sistema de inferencia difuso y que le permite resolver el problema. Cada una de las reglas responde a una expresión como la reflejada en la ecuación (5.26), donde x_1 y x_2 representan dos de las variables de entrada e y representa la variable de salida.

$$\text{SI } x_1 \text{ es } A \text{ Y } x_2 \text{ es } B \text{ ENTONCES } y \text{ es } C \quad (5.26)$$

En la ecuación (5.26) A , B y C son conjuntos difusos definidos en el universo de discurso de x_1 , x_2 e y , y representados por la etiqueta lingüística correspondiente. A la proposición difusa “ x_1 es A Y x_2 es B ” se le llama antecedente o premisa y a la proposición difusa “ y es C ” se le llama consecuente o conclusión. Una regla expresa un tipo de relación entre A , B y C que se denomina implicación lógica.

Los resultados de las distintas reglas son manipulados por el bloque agregador para producir un resultado, todavía en términos difusos. Este resultado es convertido en una variable numérica por medio del bloque “defuzzificador”.

Atendiendo a la parte consecuente de las reglas, el método de agregación y la correspondiente “defuzzyficación” posterior existen varios tipos de sistemas de inferencia difusa. Entre estos sistemas, los más conocidos son los de Mandani y los de Takagi-Sugeno. De ellos, el utilizado en las investigaciones vinculadas a la Tesis ha sido el sistema de inferencia difusa de Takagi-Sugeno [Takagi85], descrito en el siguiente punto.

5.3.2 SISTEMAS DE INFERENCIA DIFUSA DE TAKAGI-SUGENO

Este sistema también es conocido como sistema de inferencia difusa TSK (Takagi-Sugeno-Kang). El signo distintivo de este sistema se halla presente en la formulación de la parte consecuente de las reglas. Las partes consecuentes son combinaciones lineales (polinomios) de las variables de entrada al sistema.

Atendiendo al grado del polinomio de la parte consecuente de las reglas se puede distinguir entre sistemas de orden cero (el polinomio es de grado cero, es decir, una constante numérica), sistemas de primer orden (el polinomio es de primer grado), o sistemas de orden superior (polinomio de segundo grado o superior). En la práctica los sistemas se limitan a orden cero o primer orden, ya que el esfuerzo en la obtención de los polinomios de la parte consecuente con orden igual o superior a 2 no justifica la posible mejora en los resultados.

La ecuación (5.27) representa la expresión de la regla i para un sistema de inferencia difusa TSK de primer orden, donde x_1 y x_2 son las entradas del sistema, y_i es la salida de la regla i , y p_{0i} , p_{1i} y p_{2i} son constantes numéricas.

$$\text{SI } x_1 \text{ es } A_i \text{ Y } x_2 \text{ es } B_i \text{ ENTONCES } y_i = p_{0i} + p_{1i} \cdot x_1 + p_{2i} \cdot x_2 \quad (5.27)$$

A la vista de la ecuación anterior queda claro que la salida de cada regla es numérica, por lo que no se precisa de bloque “defuzzyificador”. La salida y_s del sistema de inferencia difusa se obtiene como la media ponderada de la salida de cada una de las reglas, tal como expresa la siguiente ecuación:

$$y_s = \frac{\sum_{i=1}^r w_i \cdot y_i}{\sum_{i=1}^r w_i} \quad (5.28)$$

En la ecuación (5.28) el número total de reglas del sistema es r , y_i representa la salida para la regla i , y w_i representa el producto (o el valor mínimo) de los valores de pertenencia de acuerdo a la ecuación (5.29).

$$w_i = \mu_{A_i}(x_1) \cdot \mu_{B_i}(x_2) \quad (5.29)$$

Siendo:

$\mu_{A_i}(x_1)$: valor de pertenencia de la variable x_1 al conjunto difuso A_i

$\mu_{B_i}(x_2)$: valor de pertenencia de la variable x_2 al conjunto difuso B_i

En función del método de la partición del espacio de entrada, es decir, de cómo se hayan escogido los conjuntos difusos con sus familias de pertenencia para cada variable de entrada, y de cómo se hayan compuesto las reglas, quedará determinado el número de reglas del sistema.

5.3.3 PARTICIÓN DEL ESPACIO DE ENTRADA

El presente apartado se va a centrar en los dos métodos más utilizados en la partición del espacio de entrada: partición en rejilla (*grid partitioning*) y partición espaciada o por agrupamiento (*scatter partitioning*).

La partición en rejilla divide el rango de cada variable en un número determinado de intervalos (partes) y es conveniente aplicarla en sistemas que contengan puntos distribuidos por todo el espacio y no existan zonas con alta densidad de puntos donde es preferible el otro método de partición.

La partición por agrupamiento selecciona los lugares del espacio de entrada con mayor densidad de puntos por medio del agrupamiento o clusterización.

El número máximo de reglas queda fijado por el número de combinaciones que se pueden formar con los intervalos en que hemos dividido cada una de las variables de entrada, tomando un único intervalo por variable. Así, un sistema con 5 variables de entrada y en el que se ha partido el espacio de entrada en rejilla con cada variable en 2 partes, dará un total de $2^5 = 2 \cdot 2 \cdot 2 \cdot 2 \cdot 2 = 32$ reglas. La parte consecuente de cada regla se calcula como la ecuación del hiperplano que mejor se ajusta (regresión por mínimos cuadrados) a los puntos pertenecientes a todos los intervalos de las variables de entrada correspondientes a la combinación escogida.

Para la partición del espacio de entrada por agrupamiento se utilizan diferentes métodos, siendo los más utilizados los de K-means, fuzzy C-means y el subtractivo [Chiu94]. Todos estos métodos son procedimientos iterativos que determinan las posiciones de los centros de los grupos o clusters que mejor agrupan en torno a sí los valores del vector de entradas. Mientras que en el caso de los métodos K-means y fuzzy C-means el número de clusters es establecido de antemano, en el método del agrupamiento subtractivo el número de clusters se calcula durante el proceso de agrupamiento.

El método de agrupamiento subtractivo se fundamenta en la selección de los centros de los grupos o clusters en función de la “densidad” de cada punto. Considerando cada valor del vector de entradas al sistema de inferencia difusa como un punto de un espacio multi-dimensional, podemos definir la densidad de un punto como una medida de la cercanía de otros puntos. Inicialmente se calcula la densidad de todos los puntos (valores del vector de entradas) y se toma como centro de un grupo al punto con mayor densidad (con mayor número de puntos vecinos cercanos). Seguidamente, la densidad de los puntos situados dentro de un radio establecido del centro del grupo se reduce y el algoritmo busca un nuevo centro (siguiente punto con mayor densidad). Este proceso continúa hasta que la densidad de los puntos restantes es menor a un valor predeterminado. El resultado final es un conjunto de puntos (valores del vector de entradas) correspondientes a los centros de los grupos. En definitiva, el agrupamiento subtractivo identifica las regiones del espacio con mayor densidad de puntos de entrada, caracterizándolas por uno de sus puntos: el centro del grupo.

Como ya se ha comentado con anterioridad, al comienzo el número de centros no es conocido en un proceso de agrupamiento subtractivo; concretamente, depende de los parámetros que lo definen, en especial del llamado radio de vecindad, r_a . Un valor pequeño para el radio de vecindad puede conducir a obtener un excesivo número centros y ocasionar un posterior sobre-ajuste (equivalente al sobre-entrenamiento de las redes neuronales) del modelo. En algunas ocasiones en lugar de utilizar el radio de vecindad, r_a , se utiliza en su lugar el llamado “rango de influencia” cuyo significado es equivalente al de radio de vecindad, pero con la condición de que todas las variables de entrada han sido normalizadas a valores entre 0 y 1.

Tras seleccionar los centros de los grupos mediante el agrupamiento subtractivo, los siguientes pasos para la construcción de un sistema de inferencia difusa son la de determinación del número de conjuntos difusos por variable de entrada, el ajuste de las correspondientes funciones de pertenencia a cada conjunto difuso, el establecimiento del número de reglas y el cálculo de los coeficientes de las partes consecuentes de las reglas. La solución más utilizada consiste en tomar, para cada variable de entrada, un número de conjuntos difusos igual al número de clusters identificados (determinados con el agrupamiento subtractivo), utilizar funciones de pertenencia gaussianas y tomar, como centro de cada función de pertenencia, el valor de la variable considerada en cada uno de los centros de los cluster (por ejemplo, en un sistema con n clusters, para una variable x_1 , los centros de las n funciones de pertenencia gaussianas correspondientes a los n conjuntos difusos definidos para la variable x_1 , tienen como valores los de la variable x_1 para cada uno de los centros de los clusters). La varianza de las funciones de pertenencia gaussianas se toman iguales para todos los conjuntos difusos de una misma variable de acuerdo al valor de la ecuación (5.30), en la que σ_{ij} representa la varianza de la función de pertenencia del conjunto difuso i de la variable j , x_j corresponde a la variable de entrada j , y r_a es el radio de vecindad definido para el agrupamiento subtractivo.

$$\sigma_{ij} = r_a \frac{\max(x_j) - \min(x_j)}{\sqrt{8}} \quad (5.30)$$

El cálculo de las funciones de pertenencia es mucho más sencillo utilizando el agrupamiento subtractivo que cualquier otro de los dos algoritmos citados (K-means y fuzzy C-means), ya que la forma bien definida de las funciones de pertenencia gaussianas evita la pérdida de información. Además, los centros calculados por el algoritmo subtractivo son tomados directamente como centros de las funciones de pertenencia gaussianas de la parte antecedente de las reglas y la varianza es calculada directamente al escoger el valor del radio de vecindad para los grupos, r_a . Por ello, el agrupamiento subtractivo es el algoritmo ideal para obtener un modelo difuso inicial de cualquier sistema a modelar. Este modelo inicial puede ser optimizado posteriormente mediante técnicas neuro-difusas [Ferreyra05].

5.3.4 SISTEMAS NEURO-DIFUSOS

En estos sistemas se combina la capacidad de aprendizaje supervisado de una red neuronal con la representación del conocimiento de un sistema de inferencia difusa. Una denominación muy común de este tipo de sistemas es *Adaptive Neuro-Fuzzy Inference Systems, ANFIS* [Jang97].

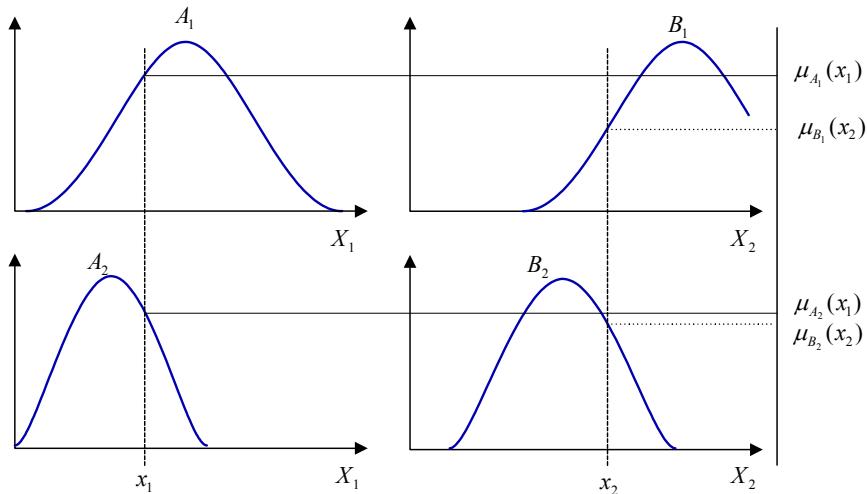


Figura 5. 8 Sistema de inferencia difusa con dos entradas y dos reglas

Para describir estos sistemas de una forma clara y precisa, supongamos un sistema de inferencia difusa TSK de primer orden con dos variables de entrada, X_1 y X_2 ; dos conjuntos definidos para cada una de las variables de entrada (conjuntos A_1 y A_2 para la variable X_1 ; y conjuntos B_1 y B_2 para la variable X_2); y dos reglas. Las familias de pertenencia para los conjuntos definidos para cada una de las variables de entrada están representadas en la Figura 5. 8. El valor de salida de cada una de las dos reglas viene determinado por las ecuaciones (5.31), donde los coeficientes θ son constantes numéricas, y x_1 y x_2 son los valores que toman las variables X_1 y X_2 , respectivamente.

$$\begin{aligned} y_1 &= \theta_{01} + \theta_{11} x_1 + \theta_{21} x_2 \\ y_2 &= \theta_{02} + \theta_{12} x_1 + \theta_{22} x_2 \end{aligned} \tag{5.31}$$

El valor de la salida del sistema viene dado por la ecuación (5.32), donde el valor de los coeficientes w_1 y w_2 corresponde al producto de los valores de pertenencia de x_1

en A_1 y de x_2 en B_1 , y al producto de los valores de pertenencia de x_1 en A_2 y de x_2 en B_2 , respectivamente, tal y como indican las ecuaciones (5.33).

$$y = \frac{w_1 \cdot y_1 + w_2 \cdot y_2}{w_1 + w_2} \quad (5.32)$$

$$\begin{cases} w_1 = \mu_{A_1}(x_1) \cdot \mu_{B_1}(x_2) \\ w_2 = \mu_{A_2}(x_1) \cdot \mu_{B_2}(x_2) \end{cases} \quad (5.33)$$

La ecuación (5.33) puede expresarse también como la ecuación (5.34), donde el valor de los nuevos coeficientes viene determinado por la ecuación (5.35).

$$y = \overline{w_1} \cdot y_1 + \overline{w_2} \cdot y_2 \quad (5.34)$$

$$\overline{w_i} = \frac{w_i}{w_1 + w_2} \quad (i = 1, 2) \quad (5.35)$$

Se puede llegar a la misma expresión con la red representada en la Figura 5.9, en la que en los nodos de la capa de entradas calculan el valor de pertenencia de las variables de entrada a cada uno de los conjuntos difusos definidos para cada entrada; los nodos de las dos siguientes capas calculan los coeficientes de la ecuación (5.35); los nodos siguientes calculan el valor de la salida de cada regla; y el nodo de salida calcula el valor de salida de la red (idéntico al valor de salida del sistema de inferencia difusa).

La red puede entrenarse como una red neuronal bajo entrenamiento supervisado, de forma que se ajusten el valor de sus parámetros, y se minimice el error (entrenamiento equivalente al entrenamiento supervisado de las redes neuronales artificiales).

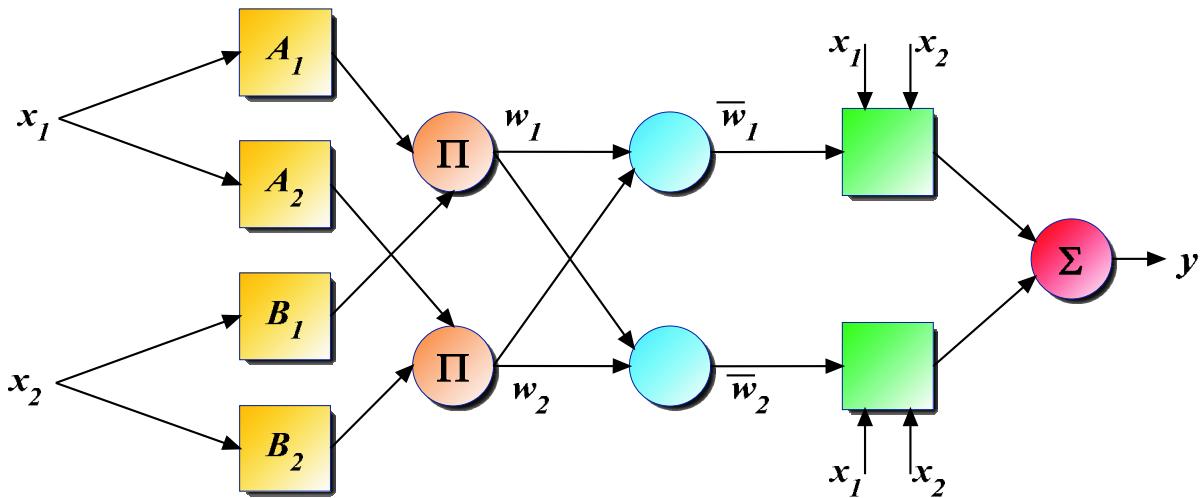


Figura 5. 9 Red equivalente al sistema de inferencia difusa de dos entradas y dos reglas

La técnica de entrenamiento utilizada es una técnica híbrida, derivada del método de retropropagación de error de las redes neuronales. El resultado final del proceso de entrenamiento es el ajuste de los coeficientes de los polinomios de la parte consecuente de las reglas, y de los parámetros de las premisas (funciones de pertenencia para los conjuntos definidos en las entradas). Para evitar el sobre-ajuste de los modelos se utilizan las mismas técnicas que las usadas en el entrenamiento de redes neuronales, en especial la de uso del grupo de validación cruzada, interrumpiéndose el proceso de entrenamiento cuando el error con los datos del grupo de validación cruzada no se ha reducido tras un número predeterminado de epochs.

5.3.5 VENTAJAS E INCONVENIENTES

En la introducción a los sistemas de inferencia difusa ya se ha comentado la facilidad que representa para la mente humana entender este tipo modelos, siendo esta sin duda la mayor ventaja que presentan. En el caso de las redes neuronales al comportarse como una “caja negra” su comprensión era más complicada.

A continuación se presentan otras ventajas:

- Los sistemas de inferencia difusa tiene la capacidad integrar términos lingüísticos en el razonamiento (conjuntos difusos para alguna de las variables).

- La posibilidad que ofrece un sistema de inferencia difusa de ser entrenado (modelo neuro-difuso) permite ajustar los parámetros de dicho sistema, y reducir los errores si se utiliza como aproximador de funciones (lineales o no).

Si hablamos de sus limitaciones, cabe destacar que desde el principio se deben fijar las reglas que establecen el funcionamiento del sistema; y, en ocasiones, un cambio de condiciones puede requerir la creación de un nuevo sistema de inferencia difusa (imposibilidad para adaptar el sistema).

Los sistemas neuro-difusos permiten obviar las desventajas de los sistemas de inferencia difusa (por ejemplo, no ser capaces de aprender), al poder ajustar, por lo general, los parámetros del sistema de forma adaptativa. En este sentido, los sistemas neuro-difusos combinan las ventajas que ofrecen las redes neuronales con la de los sistemas de inferencia difusa.

5.3.6 APLICACIÓN EN LA PREDICCIÓN DE LA PRODUCCIÓN

Últimamente los modelos basados en sistemas de inferencia difusa han mostrado una aplicabilidad tan universal como la de los modelos basados en redes neuronales artificiales, ya que comparten con estas la capacidad de aproximación de funciones no lineales, y les aventajan en la posibilidad de que el diseñador pueda adaptar el modelo de predicción debido a su mayor sencillez conceptual.

La predicción de la producción eléctrica en instalaciones solares fotovoltaicas utilizando sistemas de inferencia difusa es similar a la realizada con redes neuronales. Las entradas corresponderán a las predicciones de un modelo atmosférico y a la representación del instante de dichas predicciones. Los modelos serán de Takagi-Sugeno de primer orden, dada la simplicidad y generalización que ofrecen. Además estos modelos pueden adaptar sus parámetros utilizando técnicas de modelos neuro-difusos.

En cuanto al método de partición del espacio de entrada, en principio se pueden usar cualquiera de los dos expuestos, es decir, la partición en rejilla y la partición por agrupamiento o clusterización. Cuando se use la partición en rejilla no se sobrepasará de los tres conjuntos difusos por entrada, para evitar un gran número de reglas, que precisarían a su vez de un gran número de datos de entrada para su construcción. Para

la partición del espacio de entrada por agrupamiento, la solución ideal será la utilización del algoritmo de agrupamiento substractivo, de tal forma que el número de clusters y reglas no sea elevado (inferior a 6). Tanto en el caso de partición en rejilla o por agrupamiento, pueden utilizarse técnicas neuro-difusas para la adaptación de los parámetros de los modelos y la reducción de los errores de predicción.

5.4 OTROS MODELOS

Existen muchos más modelos de predicción de series temporales, relacionados con las investigaciones vinculadas a la presente Tesis Doctoral, se ha creído conveniente describir brevemente algún otro de los tipos de modelos de predicción.

5.4.1 MODELO DE LOS *K* VECINOS MÁS PRÓXIMOS (*K-NN*)

El método de los *k* vecinos más próximos, *k-NN* (*k nearest neighbors*) [Fix89], es una técnica de predicción no lineal de amplia versatilidad y que permite realizar, entre otras, tareas de clasificación, estimación de densidades, aproximación de funciones y, la de mayor interés para las investigaciones presentes, la predicción de series temporales.

El objetivo principal de este algoritmo se centra en conocer el comportamiento futuro de los vecinos de un vector, con el fin de predecir el comportamiento de dicho vector.

Dicho algoritmo consta principalmente de los dos pasos descritos a continuación:

- Dado un nuevo vector, se buscan los *k* vectores más similares a él. Dichos vectores serán sus vecinos y su similitud se determinará calculando la distancia entre ellos, utilizando generalmente la distancia euclídea.
- Conociendo el valor de la variable objetivo en los *k* vecinos, se determina el valor de la variable objetivo del nuevo vector, es decir, el valor a predecir.

Por tanto, como método de predicción de series temporales, el *k-NN*, dado un conjunto de datos históricos, identifica los *k* registros pasados que sean más similares al del instante a pronosticar *y*, una vez determinados los *k* resgistros, combina los valores de la variable objetivo con el fin de calcular la predicción actual.

La secuencia del algoritmo se puede dividir en una serie de pasos que se detallan a continuación:

1. La serie temporal a analizar se divide en una serie de vectores de dimensión *d*, donde *d* es el número de variables de entrada a considerar. La expresión de dicho vector para un instante *i*, es la expresada a continuación:

$$Y_i = (x_1(i), x_2(i), \dots, x_d(i)) \quad (5.36)$$

2. Se calcula la distancia entre el vector correspondiente al instante de predicción, es decir el correspondiente al instante *t*, momento en que se realiza la predicción, con un horizonte de predicción *h*, Y_{t+h} , y todos los vectores Y_i , correspondientes a los vectores disponibles en los datos históricos. El cálculo de dichas distancias puede realizarse por diversos métodos, siendo muy utlizada la distancia euclídea o la de Mahalanobis. Una vez calculadas dichas distancias, se identifican los *k* vectores más cercanos a Y_{t+h} , que se denotan como $Y_{T1}, Y_{T2}, \dots, Y_{Tk}$.
3. Dados dichos *k* vectores más cercanos, es decir los *k* vecinos más próximos, la predicción se calcula como el promedio, generalmente ponderado, de los valores de la variable objetivo (salida), \hat{Y}_{Ti} , correspondiente a cada uno de los vectores seleccionados. Por ello, dicho cálculo se realiza tal y cómo se expresa en la ecuación (5.37).

$$\hat{Y}_{t+h} = \frac{\sum_{i=1}^k \omega_i \cdot \hat{Y}_{Ti}}{\sum_{i=1}^k \omega_i}, \quad (5.37)$$

Siendo,

ω_i : el peso que se le asigna al vecino i , de forma que $\omega_i \geq 0$ y $\sum_{i=1}^k \omega_i = 1$

Cabe destacar que si este peso es igual para los valores de todos los vecinos, o vectores seleccionados, entonces $\omega_i = 1/k \forall i$, se está realizando la media aritmética. Sin embargo, existen otras formas más sofisticadas de asignar dichos pesos consiguiendo que tengan un mayor peso los vectores más similares al actual. Una de ellas consiste en hacer que ω_i sea inversamente proporcional a la distancia entre el vector vecino y el actual.

5.4.2 MODELOS GRISES

Los modelos grises se basan en la teoría gris desarrollada por Deng [Deng82]. Una de las ventajas de los sistemas grises es su fácil aplicación ya que no requiere conocer la distribución de los parámetros y no requiere de modelos intermedios complejos.

Un sistema gris es un sistema que no es “blanco” (sistema de información completamente conocido) ni tampoco un sistema “negro” (sistema de información completamente desconocido). En realidad, la mayoría de procesos de interés en la predicción de generación eléctrica están en etapa gris debido a la información insuficiente e inexacta. Un “número gris” es un número cuyo valor exacto se desconoce, pero una serie o rango de números en la que el valor se encuentra es conocida. Sea X un conjunto cerrado y acotado de números reales. Un número gris, x^\pm , se define como un intervalo con límite menor conocido, x^- , y límite superior conocido, x^+ . La distribución de información desconocida para x:

$$x^\pm = [x^-, x^+] = [t \in X \mid x^- \leq t \leq x^+] \quad (5.38)$$

Con la secuencia no-negativa $x^{(0)} = \{x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(k)\}$, la teoría de sistemas o modelos grises usa un preprocesado de los datos en el que la secuencia $x^{(0)}(k)$ es acumulada:

$$x^{(1)}(k) = \sum_{m=1}^k x^{(0)}(m) \quad k (k = 1 \dots n) \quad (5.39)$$

De forma que se genera la siguiente serie:

$$x^{(1)}(k) = \{x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(k)\} \quad (5.40)$$

Para establecer las ecuaciones diferenciales de primer orden correspondientes a $x^{(1)}(k)$:

$$\frac{dx^{(1)}}{dt} + ax^{(1)} = u \quad (5.41)$$

Usando el método de mínimos cuadrados para obtener el valor de los parámetros a, u .

$$\hat{\mathbf{A}} = \begin{bmatrix} a \\ u \end{bmatrix} = (\mathbf{B}^T \mathbf{B})^{-1} (\mathbf{B}^T \mathbf{Y}_N) \quad (5.42)$$

$$\mathbf{B} = \begin{bmatrix} -\frac{1}{2}(x^{(1)}(1) + x^{(1)}(2)) & 1 \\ -\frac{1}{2}(x^{(1)}(2) + x^{(1)}(3)) & 1 \\ \dots & \dots \\ -\frac{1}{2}(x^{(1)}(n-1) + x^{(1)}(n)) & 1 \end{bmatrix} \quad (5.43)$$

$$\mathbf{Y}_N = \begin{bmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \dots \\ x^{(0)}(n) \end{bmatrix} \quad (5.44)$$

Donde, a es el parámetro de desarrollo para reflejar las tendencias de desarrollo de secuencia $x^{(1)}$, u es el parámetro de coordinación para reflejar la relación de cambio de los datos.

Si concretamos un modelo, la predicción gris mediante el modelo GM (1, 1) sobre $x^{(1)}$ es:

$$\hat{x}^{(1)}(k+1) = \left[x^{(0)}(1) - \frac{u}{a} \right] \cdot e^{-ak} + \frac{u}{a} \quad k = 0, 1, 2, \dots, n \quad (5.45)$$

Siendo el resultado de la previsión $\hat{x}^{(0)}$:

$$\hat{x}^{(0)}(k+1) = \hat{x}^{(1)}(k+1) - \hat{x}^{(1)}(k) \quad \hat{x}^{(0)}(1) = \hat{x}^{(0)}(1) \quad k = 1, 2, \dots, n-1 \quad (5.46)$$

5.4.3 MÁQUINAS DE VECTORES SOPORTE (SVMs)

Las máquinas de vectores soporte (*support vector machine*, SVM) son un conjunto de algoritmos de aprendizaje supervisado desarrollados por Cortes y Vapnik [Cortes95].

Estos métodos están propiamente relacionados con problemas de clasificación y regresión. Dado un conjunto de ejemplos de entrenamiento (de muestras) podemos etiquetar las clases y entrenar una SVM para construir un modelo que prediga la clase de una nueva muestra. Intuitivamente, una SVM es un modelo que representa a los puntos de muestra en el espacio, separando las clases por un espacio lo más amplio posible.

Cuando las nuevas muestras se ponen en correspondencia con dicho modelo, en función de su proximidad pueden ser clasificadas a una u otra clase.

Más formalmente, una SVM construye un hiperplano o conjunto de hiperplanos en un espacio de dimensionalidad muy alta (o incluso infinita) que puede ser utilizado en problemas de clasificación o regresión. Una buena separación entre las clases permitirá una clasificación correcta.

Dado un conjunto de puntos, subconjunto de un conjunto mayor (espacio), en el que cada uno de ellos pertenece a una de dos posibles categorías, un algoritmo basado en SVM construye un modelo capaz de predecir si un punto nuevo (cuya categoría desconocemos) pertenece a una categoría o a la otra. Como en la mayoría de los métodos de clasificación supervisada, los datos de entrada (los puntos) son vistos como un vector p -dimensional (una lista de p números).

La SVM busca un hiperplano que separe de forma óptima a los puntos de una clase de la de otra, que eventualmente han podido ser previamente proyectados a un espacio de dimensionalidad superior.

En ese concepto de "separación óptima" es donde reside la característica fundamental de las SVM: este tipo de algoritmos buscan el hiperplano que tenga la máxima distancia (margen) con los puntos que estén más cerca de él mismo. De esta forma, los puntos del vector que son etiquetados con una categoría estarán a un lado del hiperplano y los casos que se encuentren en la otra categoría estarán al otro lado.

En la literatura de los SVMs, se llama *atributo* a la variable predictora y *característica* a un atributo transformado que es usado para definir el hiperplano. La elección de la representación más adecuada del universo estudiado, se realiza mediante un proceso denominado selección de características.

Al vector formado por los puntos más cercanos al hiperplano se le llama *vector de soporte*.

Los modelos basados en SVMs están estrechamente relacionados con las redes neuronales. Usando una función kernel, resultan un método de entrenamiento alternativo para clasificadores polinomiales, funciones de base radial, perceptrón multicapa...

Idealmente, el modelo basado en SVM debería producir un hiperplano que separe completamente los datos del universo estudiado en dos categorías. Sin embargo, una separación perfecta no siempre es posible y, si lo es, el resultado del modelo no puede ser generalizado para otros datos (sobreajuste, *overfitting*).

Con el fin de permitir cierta flexibilidad, los SVM manejan un parámetro C que controla la compensación entre errores de entrenamiento y los márgenes rígidos, creando así un margen blando (soft margin) que permita algunos errores en la clasificación a la vez que los penaliza.

Se pueden crear diferentes modelos en función de los diferentes tipos de funciones kernel. Algunas de las funciones más utilizadas son la polinomial, la RBF y la sigmoidal ([Trafalis00] y [Zhang00]).

Una nueva versión de SVM para regresión fue propuesta en 1997 en [Drucker97], denominada SVR (*support vector regression machines*). La idea básica de SVR consiste en realizar un mapeo de los datos de entrenamiento $x \in X$, a un espacio de mayor dimensión F a través de un mapeo no lineal $\varphi : X \rightarrow F$, donde podemos realizar una regresión lineal.

5.4.4 MODELO DE DÍA CLARO (CIELO CLARO)

El modelo de día claro (*clear sky model*), es, generalmente, un modelo que estima la irradiancia global para un día claro (cielo no cubierto) para un instante dado. Chowdhury y Rahman [Chowdhury87] dividen la irradiancia global en un componente de día claro y otro componente relacionado con la cobertura de nubes:

$$G = G_{cs} \cdot \tau_c \quad (5.47)$$

Siendo:

G : irradiancia global (W/m^2)

G_{cs} : irradiancia de día claro (W/m^2)

τ_c : transmisividad de las nubes (otros autores la denotan como K_I [Monteiro13b])

La irradiancia de día claro se halla mediante la relación indicada a continuación en (5.48):

$$G_{cs} = I_0 \cdot \tau_a \quad (5.48)$$

Siendo:

I_0 : irradiancia extraterrestre (W/m^2), calculada por ecuaciones solares

τ_a : transmisividad de día claro

En el caso de los modelos de predicción de producción solar fotovoltaica se incorpora una nueva relación, equivalente a las anteriores, pero teniendo en cuenta la producción:

$$P = P_{cs} \cdot \tau \quad (5.49)$$

Siendo:

P : producción media fotovoltaica (W)

P_{cs} : producción equivalente a día claro (W/m^2)

τ : índice de atenuación (otros autores la denotan como K_P [Monteiro13b])

La normalización de la potencia o producción mediante el modelo de día claro es que la producción de día claro es más estacionaria y regular que la producción real. Por ello, se pueden aplicar incluso modelos básicos que asumen dicha estacionalidad [Madsen07].

Teniendo en cuenta todo lo anterior, el modelo de día claro se define mediante la siguiente relación:

$$P_{cs} = f_{\max}(x, y) \quad (5.50)$$

Siendo:

P_{cs} : producción equivalente a día claro (W/m^2)

x : día del año

y : hora del día

La función $f_{\max}(\cdot, \cdot)$ es considerada una función uniforme y puede ser estimada como un máximo local ([Koenker05] y [Monteiro13b]).

Existen diferentes métodos de estimación para las relaciones anteriores, en función de los autores y del modelo desarrollado.

Finalmente, queda patente que los cambios determinísticos de la potencia solar están causados principalmente por la relación geométrica existente entre la Tierra y el sol, que puede ser representada por la altura solar y el azimuth. Cabe destacar que, la estimación de las potencias de día claro en verano es mejor, puesto que su comportamiento es más estable y hay menor cobertura de nubes [Bacher09].

5.4.5 OTROS MODELOS

Además de los anteriores, nos encontramos con el modelo persistente (utilizado sobre todo para comparar la eficacia de los modelos de predicción cuando se desarrollan). Este modelo se basa en que la energía eléctrica generada para mañana a la hora actual, $E(t+k)$, es igual a la de la hora actual de ayer, $E(t)$.

Por otro lado, cabe destacar una variante de los sistemas neuro-difusos, el conocido como ANCFIS (*Adaptive Neuro Complex Fuzzy Inferential System*), que se basa en el ANFIS, pero en este caso, su función de pertenencia se encuentra en el plano complejo [Ramot02]. En otras palabras, cada función de pertenencia tendrá módulo y

fase. Los modelos ANCFIS han mostrado resultados prometedores en la predicción de series temporales [Chen11b] y han sido probados como un modelo aceptable para representar comportamientos “aproximadamente periódicos” [Dick05].

5.5 MODELOS HÍBRIDOS

Actualmente, los modelos existentes relacionados con la predicción de la energía generada por parques solares fotovoltaicos, necesitan disponer de valores de predicción para las variables meteorológicas, tipos de radiación, temperaturas...

Los modelos de predicción pueden ser clasificados tal y como se indica a continuación:

- **Modelos Físicos:** en los que podemos incluir los NWP ya explicados en el capítulo anterior.
- **Modelos estadísticos:** dentro de los cuales se encuentran los modelos explicados en el presente capítulos.

En la actualidad, existen modelos que combinan los dos anteriores, son los conocidos como **modelos híbridos**, cuyo objetivo es combinar las ventajas de ambos con el fin de obtener un modelo más preciso y fiable. Por esta razón, los modelos desarrollados en las investigaciones desarrolladas son principalmente de este tipo.

5.6 ASPECTOS A TENER EN CUENTA

Los modelos presentados a lo largo del presente capítulo se tratan de los más usados en la predicción de futuros valores para series temporales, por ello, su aplicación para la predicción de la producción eléctrica en parques solares fotovoltaicos es una muy buena opción. Dichos modelos han constituido uno de los elementos principales de los modelos de predicción desarrollados a lo largo de las investigaciones vinculadas a la presente Tesis Doctoral.

Cabe destacar que, antes de desarrollar cualquier modelo, habrá que tener en cuenta una serie de consideraciones que se destacan a continuación:

- **Detección, corrección y eliminación de outliers de la base de datos disponible:** la presencia de outliers tiene una influencia considerablemente negativa en la calidad de las previsiones realizadas por los modelos de predicción desarrollados. Los modelos más afectados por la presencia de outliers son los modelos basados en redes neuronales y los modelos ARIMA.
- **Clasificación de los datos en dos grupos principales:** la base de datos disponible deberá ser separada en dos grupos principales, uno general de entrenamiento (que podrá ser dividido en dos subgrupos como se especificará más adelante) y otro de test o prueba. El grupo de entrenamiento será el que se utilice para el desarrollo o construcción del modelo y el grupo de test será el utilizado para la evaluación de la eficacia del modelo.
- **Evitar sobreajuste (*overfitting*):** en el caso de las redes neuronales o de los modelos basados en sistemas neuro-difusos, el grupo general de entrenamiento deberá subdividirse en otros dos grupos: entrenamiento y validación cruzada. El grupo de entrenamiento será el que se utilice para ajustar los parámetros mientras que el grupo de validación cruzada se usará para evitar el sobreajuste. El procedimiento utilizado es el de interrumpir el proceso de entrenamiento si tras un número determinado de epochs, el error con los datos de validación cruzada no ha disminuido.

- **Penalización de la complejidad:** si se dispone de dos modelos del mismo tipo no sólo habrá que tener en cuenta su precisión en la predicción, si no que habrá que tener en cuenta también su complejidad. Para ello habrá que utilizar un criterio que penalice los modelos más complejos o con mayor número de parámetros, como puede ser el criterio de información de Akaike.

CAPÍTULO

6

DESARROLLO DE LOS MODELOS

Tal y como ya se ha comentado con anterioridad, el objetivo principal de las investigaciones vinculadas a la presente Tesis Doctoral es desarrollar una serie de modelos de predicción de la energía generada al día siguiente (hora a hora), por un parque solar fotovoltaico conectado a la red eléctrica. Además, también se desarrollan modelos para los dos y tres días siguientes.

Estos modelos deberán ser capaces de asegurar una elevada fiabilidad en sus predicciones.

Ya se ha comentado en los capítulos previos, que parte de modelos existentes en la actualidad no predicen la energía que se va a generar sino que hacen una predicción de la irradiancia, la cual posteriormente se tomaría como base para hacer un cálculo aproximado de la energía.

Por todo esto, parece interesante que el modelo a desarrollar prediga directamente la producción, ya que en los casos anteriores, al hacer un cálculo aproximado sobre una predicción, estamos propagando el error.

En este capítulo se van a presentar y describir los modelos desarrollados. A lo largo del presente capítulo se expondrán los diversos submodelos desarrollados hasta llegar al modelo definitivo para cada situación.

Además los modelos se clasifican en dos grupos principales, los que toman como punto de partida el modelo atmosférico MM5 y los basados en el modelo atmosférico WRF-NMM.

Previamente se ha comentado que una de las dificultades para el desarrollo de los modelos es la gran variabilidad de las condiciones meteorológicas, pero no es la única, sino que hay otras dificultades. Una de las más importantes es la obtención de datos de producción horarios de una instalación real, mediante los cuales sea factible desarrollar un modelo adecuado.

Con los modelos desarrollados se pretende que el día de mañana los productores dispongan de una herramienta adecuada en la que puedan confiar, permitiéndoles elaborar propuestas de venta para una posible participación en el mercado eléctrico, o programar el mantenimiento de sus instalaciones.

6.1 GENERALIDADES SOBRE EL DESARROLLO

En el presente apartado se presentan los fundamentos del desarrollo de los modelos de predicción. Se presenta tanto la estructura general de los modelos de predicción definitivos, como los flujoigramas de las tareas realizadas para llegar por fin a dichos modelos.

6.1.1 ESTRUCTURA GENERAL

Como ya se ha ido adelantando en los capítulos anteriores, el modelo que se va a desarrollar se trata de un modelo híbrido, es decir un modelo que será la suma de un modelo físico y un modelo estadístico. De este modo se busca combinar las ventajas de ambos con el fin de obtener un modelo más preciso y fiable.

El modelo físico es un modelo numérico (NWP), concretamente un modelo atmosférico local, el MM5 para los modelos desarrollados en las investigaciones iniciales vinculadas a la presente Tesis Doctoral, y el WRF para los modelos desarrollados en las

investigaciones finales. Gracias a estos modelos se obtienen las variables atmosféricas que forman parte de los datos de entrada de los modelos de predicción de series temporales. Además, del mismo modo, es necesaria la obtención de dichas variables para el desarrollo del modelo.

Como segundo integrante del modelo híbrido, nos valdremos de uno de los modelos para la predicción de series temporales descritos con anterioridad en el *Capítulo 5*, fijando el que mejores resultados consiga, de forma que, tendremos en cuenta tanto los modelos clásicos como los que se encuentran en el conocido ámbito del llamado “soft-computing”.



Figura 6. 1 Estructura General del Modelo

6.1.2 FLUJOGRAMA DEL DESARROLLO: MODELO MM5

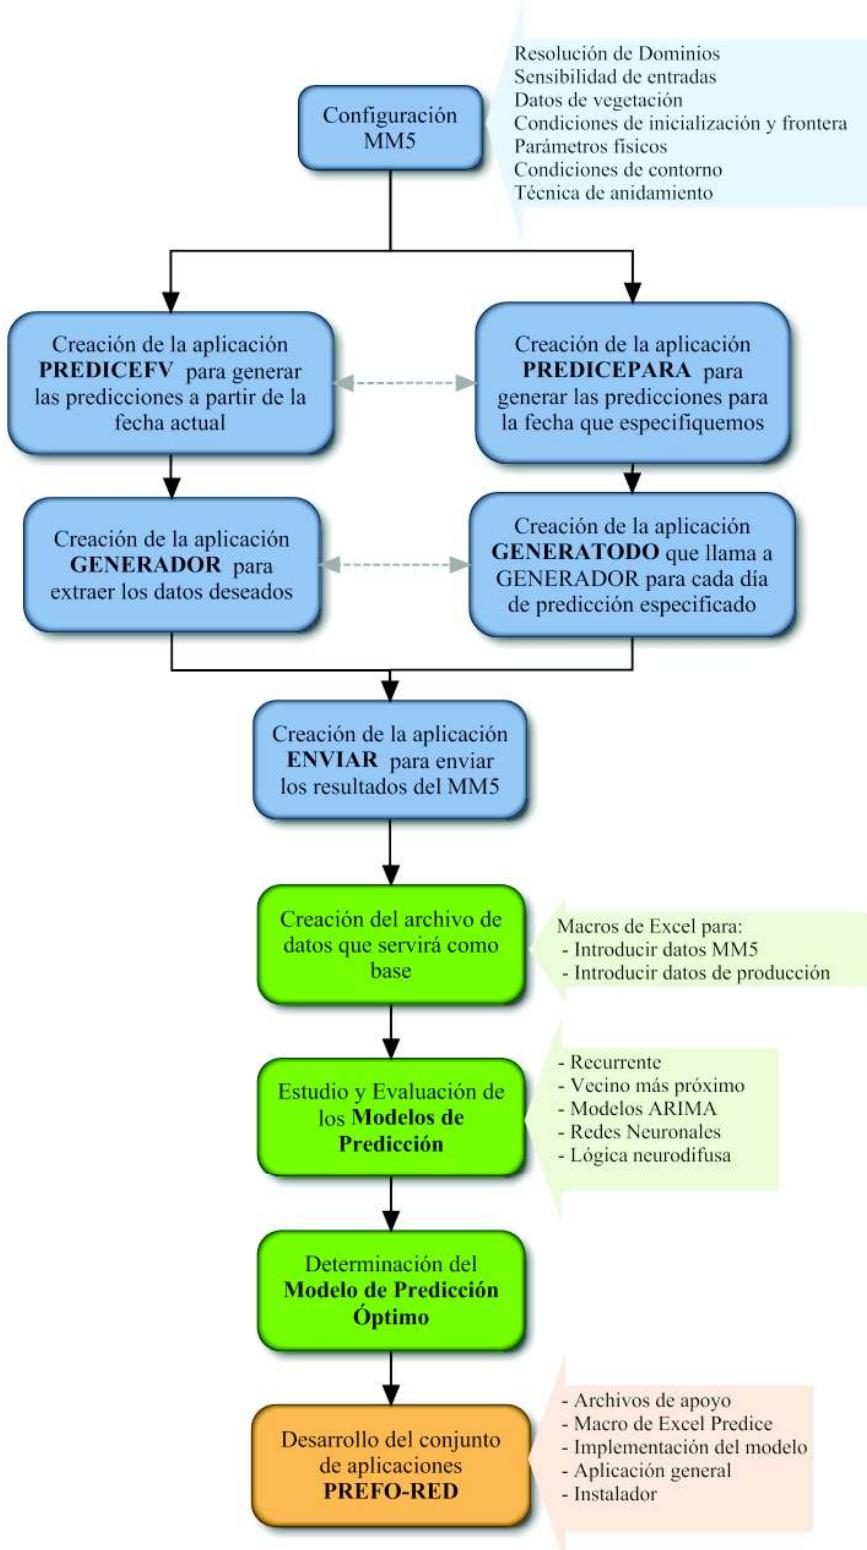


Figura 6. 2 Flujograma de tareas para desarrollar el Modelo de Predicción basado en MM5

6.1.3 FLUJOGRAMA DEL DESARROLLO: MODELO WRF



Figura 6. 3 Flujo de trabajo para desarrollar el Modelo de Predicción basado en WRF

6.2 DATOS DE PARTIDA: MODELOS BASADOS EN MM5

Para el desarrollo de los sistemas de predicción que toman como punto de partida el modelo atmosférico MM5, se utiliza el conjunto de datos que se va a describir en el presente apartado. Estos datos incluyen las predicciones de valores medios de los diferentes tipos de radiación y de la temperatura, obtenidas con el modelo MM5 para horizontes de predicción de 0.5 a 45 horas en intervalos de 15 minutos. Si bien es cierto, posteriormente, a la vista de los resultados de los primeros modelos desarrollados, se vio que los intervalos de 15 minutos eran demasiado pequeños y daban lugar a mayores gastos computacionales y mayores errores, por lo que se pasó a intervalos de una hora (siendo esta la resolución con la que se presentan generalmente las predicciones a más de 12 horas vista). Más adelante se explicará de forma detallada el tratamiento de los datos.

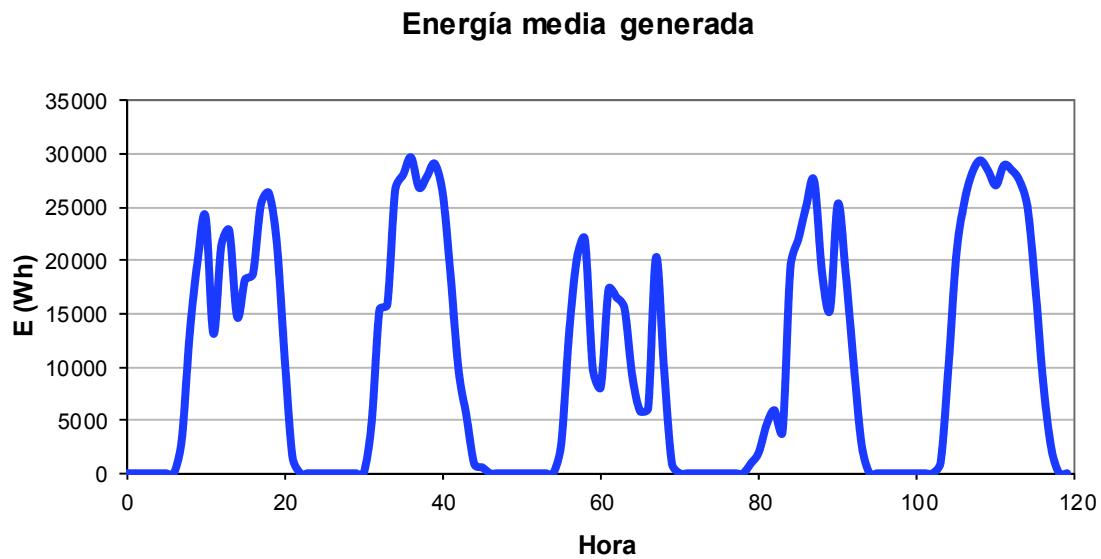


Figura 6. 4 Energía generada desde el 2 hasta el 6 de Junio de 2007 (Rincón de Soto)

Una característica especial de estos datos es la disponibilidad de la serie temporal de la energía generada por un grupo de placas solares fotovoltaicas ($P_{inst} = 36 \text{ kW}$) perteneciente al parque solar de Rincón de Soto (La Rioja). El parque solar está compuesto con paneles de diferentes tecnologías: fijos, con seguidor de un eje, y con seguidor de dos ejes. Sólo se dispone de los datos agregados de generación del conjunto. La serie temporal contiene los datos de 362 días (del 2 de Junio de 2007 al 27 de Mayo de 2008). La Figura 6. 4 representa la energía generada por dicho grupo para los primeros 5 días del intervalo considerado (del 2 al 6 de Junio de 2007).

6.2.1 SELECCIÓN Y NORMALIZACIÓN DE VARIABLES DE ENTRADA

La selección de las variables de entrada para un sistema de predicción de la producción eléctrica en un parque solar fotovoltaico es laboriosa. Resulta evidente que la incorporación de una variable explicativa con una elevada correlación con la variable a predecir puede mejorar significativamente el funcionamiento (mejora significativa de exactitud) del sistema de predicción. Por otra parte, la inclusión como variable de entrada en el sistema de predicción de una variable con muy baja correlación con la variable a predecir únicamente ralentizará el sistema de predicción, ya que éste debe procesar esa información suministrada por la variable de entrada aunque su contribución al valor de la salida (variable a predecir) sea muy pequeña. Así, aunque en la fase de diseño pueda parecer conveniente considerar todas las variables de entrada posibles, esta decisión no suele ser acertada.

Además, el hecho de considerar más variables explicativas que las estrictamente imprescindibles, provoca la necesidad de disponer una cantidad mayor de muestras en lo que se conoce como “curso de dimensionalidad”, lo que significa que para poder modelizar adecuadamente la predicción de la producción eléctrica, el número de datos disponibles debe crecer exponencialmente con el número de variables de entrada. Por esta razón, resulta importante tomar como entradas aquellas que realmente tienen una influencia notable en el valor de la salida del modelo de predicción.

Si no disponemos de antemano de conocimientos o nociones de la influencia de las posibles variables de entrada, podríamos intentar construir tantos modelos como fueran posibles, considerando en cada uno de ellos diferentes combinaciones de las posibles variables de entrada. De esta forma podríamos determinar empíricamente el modelo con la mejor combinación de entradas, siendo éste el que presentando un error de predicción menor, también ha requerido menor tiempo de ajuste o entrenamiento. Pero esto resulta un trabajo especialmente laborioso, de forma que hay que buscar otro modo de reducir el número de entradas.

En el presente caso, la selección inicial de las variables de entrada se realiza fundamentalmente por medio de la observación, y de los correspondientes estudios de sensibilidad, en el transcurso del desarrollo los modelos. Es suficiente con estos métodos, puesto que el número de variables de entrada no es muy elevado.

En el caso de los modelos de predicción creados sobre redes neuronales, la selección de variables final se realiza mediante una técnica algoritmos genéticos. Algunas de las razones que han conducido a elegir esta técnica son las siguientes:

- El desarrollo de modelos de predicción basados en redes neuronales artificiales requiere que se especifiquen desde el primer momento parámetros como el número de entradas, el número de neuronas por capa, los valores del factor de aprendizaje y del momento para las neuronas de cada capa, el número de unidades de retardo (para una red neuronal recurrente retardada en el tiempo), el número de componentes principales (para una red neuronal PCA), etc. Un adecuado sistema de optimización automática, basado en el uso de algoritmos genéticos, permite determinar una buena parte de las decisiones idóneas sobre la estructura óptima de una red neuronal.
- El procedimiento de selección de variables es automatizable: las operaciones de cruce y mutación permiten dicha selección.

De esta forma, la selección de las variables de entrada se realiza de forma automática, dejando que sea la evolución de las soluciones (modelos de predicción) la que conduzca a una selección óptima de éstas.

Una vez optimizado el modelo de predicción, puede realizarse un estudio de sensibilidad, lo que aún puede permitir eliminar alguna variable de entrada más de las consideradas (alguna variable con baja sensibilidad).

También se incluyen entre las posibles variables de entrada del modelo el día del año, d , y el momento u hora del día, h , correspondiente a cada predicción. Si bien es cierto que estas variables han sido normalizadas tal y como expresan las ecuaciones (6.1) y (6.2) para el día y las ecuaciones (6.3) y (6.4) para el momento o tiempo de predicción.

$$Dia_{seno} = \operatorname{seno}\left(d \cdot \frac{2\pi}{365}\right) \quad (6.1)$$

$$Dia_{\cos} = \operatorname{coseno}\left(d \cdot \frac{2\pi}{365}\right) \quad (6.2)$$

$$Tiempo_{\seno} = \operatorname{seno}\left(h \cdot \frac{2\pi}{24}\right) \quad (6.3)$$

$$Tiempo_{\cos} = \operatorname{seno}\left(h \cdot \frac{2\pi}{24}\right) \quad (6.4)$$

El resto de las posibles variables de entrada, son las variables atmosféricas obtenidas por medio del MM5 (los diferentes tipos de radiación y la temperatura a dos metros de altura). En la Tabla 6. 1 podemos ver todas estas variables.

Tabla 6. 1 Variables utilizadas (Modelos s/MM5)

Variable	Definición
Dia_{\seno}	Día correspondiente a la predicción (normalizado)
Dia_{\cos}	
$Tiempo_{\seno}$	Momento u hora correspondiente a la predicción (normalizado)
$Tiempo_{\cos}$	
$SHFLUX (W/m^2)$	"Surface Sensible Heat FLUX"
$LHFLUX (W/m^2)$	"Surface Latent Heat FLUX"
$SWDOWN (W/m^2)$	"ShortWave DOWNward radiation"
$LWDOWN (W/m^2)$	"LongWave DOWNward radiation"
$SWOUT (W/m^2)$	"Top OUTgoing ShortWave radiation"
$LWOUT (W/m^2)$	"Top OUTgoing LongWave radiation"
$Temperatura(K)$	Temperatura a 2 m de altura

Cabe destacar que se utilizan las variables correspondientes a las predicciones obtenidas con el modelo MM5 no sólo para el instante t , sino también para los instantes $t - 1$ y $t + 1$.

6.2.2 CLASIFICACIÓN DE DATOS PARA EL DESARROLLO

Para el desarrollo de los modelos de predicción, los datos de los 362 días (8688 registros de una hora de duración) se dividen en tres grupos, entrenamiento, validación cruzada y testeo. El grupo de entrenamiento engloba el 60 % de los datos, el grupo de validación un 20 % de los datos y el grupo de testeo el 20 % restante.

Como ya se verá con más detalle, va a haber dos tipos de división o clasificación de los datos:

- **Tipo A:**

- Entrenamiento: el primer 60 % de los datos de cada mes.
- Validación: el siguiente 20% de los datos de cada mes.
- Testeo: el 20% restante de los datos de cada mes.

- **Tipo B:**

- Entrenamiento: el primer 60 % de todo el intervalo de los datos.
- Validación: el siguiente 20% de todo el intervalo de los datos.
- Testeo: el 20% restante de todo el intervalo de los datos.

Cuando hablamos de los diferentes modelos desarrollados, ya se especificará el tipo de división utilizado. En el caso de modelos ARIMA, o de redes neuronales recurrentes, es obvio que el único tipo de clasificación válido es el “Tipo B”, ya que en estos modelos los datos de entrenamiento deben estar ordenados (ser sucesivos).

Cuando se muestren los errores obtenidos con los diferentes modelos se especificarán para su correspondiente grupo de testeo, aunque para comparar modelos con diferente división de datos (tipo A o B) se incluirá también el error de los datos de testeo comunes de ambos tipos de división (aproximadamente un 5 % del total de los datos).

La Tabla 6. 2 muestra las características estadísticas de cada uno los grupos del tipo de división A referidas a la energía generada (unidades Wh), y la Tabla 6. 3 las correspondientes a los grupos del tipo de división B.

El “espaciamiento” temporal entre datos es de una hora, esto es, el intervalo entre dato y dato de las series temporales es 60 minutos.

Tabla 6. 2 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos (División tipo A)

	Entrenamiento	Validación	Testeo
Media (Wh)	7197,43	6689,50	7032,20
Mediana (Wh)	134	97,50	117
Moda (Wh)	0	0	0
Desviación estándar (Wh)	9919,70	9390,46	9792,94
Min (Wh)	0	0	0
Max (Wh)	31007	30745	30889
Número de horas	5160	1800	1728

Tabla 6. 3 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos (División tipo B)

	Entrenamiento	Validación	Testeo
Media (Wh)	7756,38	4345,52	7674,62
Mediana (Wh)	254	0	1129,50
Moda (Wh)	0	0	0
Desviación estándar (Wh)	10259,35	7314,06	10030,65
Min (Wh)	0	0	0
Max (Wh)	30663	27285	31007
Número de horas	5212	1738	1738

Las predicciones del modelo atmosférico disponibles en el conjunto de datos se refieren a predicciones realizadas con el modelo atmosférico MM5. Estas predicciones corresponden a los valores de las variables meteorológicas de los diferentes tipos de radiación y a los de temperatura, todos para un punto situado en el centro del parque solar. Se dispone de predicciones realizadas todos los días del año, cubriendo, cada una ellas, más de dos días completos (desde las 6:00 UTM del primer día, hasta las 4:00 UTM del tercer día) con valores de predicción para cada 15 minutos. Aunque tal y como se explicará más adelante, finalmente sólo se han utilizado las predicción para el 2º día (horizonte de predicción 16-40 h en horario de verano y 17-41 h en horario de invierno), debido a que es el objetivo principal de las investigaciones desarrolladas.

La disponibilidad, dentro de este conjunto de datos fiables, de predicciones de un modelo atmosférico con el horizonte de predicción comentado, posibilita el desarrollo de modelos de predicción de la energía eléctrica generada por el grupo de placas del parque solar, para el día siguiente al momento de la predicción.

6.2.3 FILTRADO DE DATOS

Para desarrollar los modelos en ciertos casos se realizará un filtrado de datos para optimizar la eficacia de dichos modelos. Concretamente se trata de una regla lógica, que determinará que el valor de la energía fotovoltaica producida será nula cuando no haya, o su valor sea inapreciable, radiación solar en la superficie terrestre (*SWDOWN*).

6.3 DATOS DE PARTIDA: MODELOS BASADOS EN WRF

Para el desarrollo de los sistemas de predicción que toman como punto de partida el modelo atmosférico WRF-NMM, se utiliza el conjunto de datos que se va a describir en el presente apartado. Estos datos incluyen las predicciones de valores medios de los diferentes tipos de radiación, temperatura, humedad, cobertura de nubes y velocidad del viento obtenidas con el modelo WRF-NMM para horizontes de predicción de 0,5 a 90 horas en intervalos de 30 minutos. Si bien es cierto, posteriormente, a la vista de los resultados de los primeros modelos desarrollados se vio que los intervalos de 30 minutos también eran demasiado pequeños y daban lugar a mayores gastos computacionales y mayores errores, por lo que se pasó a intervalos de una hora (siendo esta la resolución con la que se presentan generalmente las predicciones a más de 12 horas vista). Más adelante se explicará de forma detallada el tratamiento de los datos.

Una característica especial de estos datos es la disponibilidad de la serie temporal de la energía generada por los paneles solares fotovoltaicos ($P_{inst} = 2 \text{ MW}$) con seguidores a 2 ejes que conforman el parque solar de Autol (La Rioja). La serie temporal contiene los datos de 881 días (del 1 de Noviembre de 2008 al 31 de Marzo de 2011). La Figura 6. 5 representa la energía generada por dicho parque para los mismos 5 días que los mostrados en el apartado anterior (datos para el modelo basado en MM5), pero para un año posterior (del 2 al 6 de Junio de 2009).

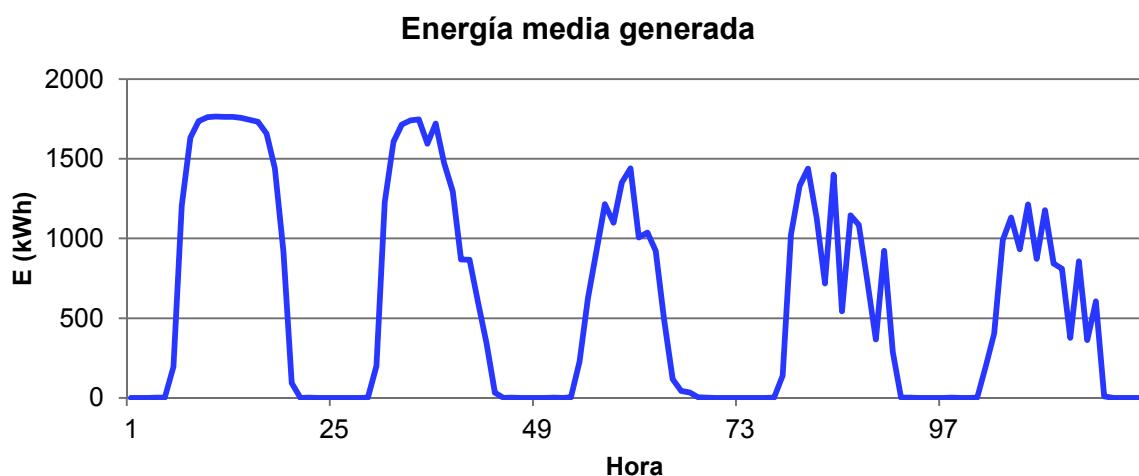


Figura 6. 5 Energía generada desde el 2 hasta el 6 de Junio de 2009 (Autol)

6.3.1 SELECCIÓN Y NORMALIZACIÓN DE VARIABLES DE ENTRADA

En este caso se ha seguido la misma línea que para los modelos basados en MM5, ya descrita en el apartado 6.2.1.

De nuevo se incluyen entre las posibles variables de entrada del modelo el día del año, d , y el momento u hora del día, h , correspondiente a cada predicción, normalizadas tal y como expresan las ecuaciones (6.1) y (6.2) para el día y las ecuaciones (6.3) y (6.4) para el momento o instante correspondiente a la predicción.

El resto de las posibles variables de entrada, son las variables atmosféricas obtenidas por medio del WRF-NMM (radiación, temperatura, humedad, cobertura de nubes y velocidad del viento). En la Tabla 6. 4 podemos ver todas estas variables.

Tabla 6. 4 Variables utilizadas inicialmente (Modelos s/WRF)

Variable	Definición
Dia_{seno}	Día correspondiente a la predicción (normalizado)
Dia_{cos}	
$Tiempo_{seno}$	Momento u hora correspondiente a la predicción (normalizado)
$Tiempo_{cos}$	
$THS (K)$	Temperatura a 2 m de altura
QS	Humedad relativa
$CFRACH$	Coeficiente de cobertura de nubes altas
$CFRACM$	Coeficiente de cobertura de nubes medias
$CFRACL$	Coeficiente de cobertura de nubes bajas
$RSWIN (W/m^2)$	Radiación superficial
$RSWINC (W/m^2)$	Radiación superficial correspondiente a día claro
$VVTO (m/s)$	Velocidad del viento

COSVTO	Coseno de la dirección del viento
SENVTO	Seno de la dirección del viento

Cabe destacar que se utilizan las variables correspondientes a las predicciones obtenidas con el modelo WRF-NMM no sólo para el instante t , sino también para los instantes $t - 1$ y $t + 1$.

Es importante reseñar que a esas variables utilizadas para el desarrollo inicial de modelos (1^a fase) se le añadirán posteriormente una serie de estadísticos tal y como se especifica posteriormente en el apartado 6.3.3, para el desarrollo de los modelos de la 2^a fase que darán lugar a los definitivos.

6.3.2 CLASIFICACIÓN DE DATOS PARA EL DESARROLLO

Para el desarrollo de los modelos de predicción, los datos de los 881 días (21142 registros horarios) se dividen en tres grupos, entrenamiento, validación cruzada y testeo. El grupo de entrenamiento engloba el 60 % de los datos, el grupo de validación un 20 % de los datos y el grupo de testeo el 20 % restante.

Antes de pasar a detallar la clasificación de los datos es preciso indicar que el desarrollo de modelos se ha dividido en dos fases. En la primera fase se ha tenido en cuenta toda la serie temporal completa, mientras que en la segunda fase la serie temporal se ha dividido en otras tres series en función del tipo de día (día claro, nublado o muy nublado/lluvioso).

Para los modelos desarrollados se ha seguido la clasificación que se va a especificar a continuación:

- **1^a Fase :**
 - Primer 80% de los datos de la serie: cada 4 días consecutivos (3 días Entrenamiento – 1 día Validación).

- Testeo: el 20% restante de todo el intervalo de los datos.
- **2^a Fase: para cada subgrupo se sigue el mismo criterio de la 1^a Fase**
 - Primer 80% de los datos de cada subgrupo (s/ tipo de día): cada 4 días consecutivos (3 días Entrenamiento – 1 día Validación).
 - Testeo: el 20% restante del intervalo de los datos correspondiente a cada subgrupo.

La Tabla 6. 5 muestra las características estadísticas de cada uno los grupos de la primera fase, referidas a la energía generada (kWh), y la

Tabla 6. 6, Tabla 6. 7 y Tabla 6. 8 las correspondientes a los grupos para cada uno de los subgrupos de la 2^a fase.

El “espaciamiento” temporal entre datos es de una hora, esto es, el intervalo entre dato y dato de las series temporales es 60 minutos.

Tabla 6. 5 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos (1^a Fase)

	Entrenamiento	Validación	Testeo
Media (kWh)	432,04	464,24	321,03
Mediana (kWh)	8	10	1
Moda (kWh)	0	0	0
Desviación estándar (kWh)	613,85	635,84	548,89
Min (kWh)	0	0	0
Max (kWh)	1826	1816	1816
Número de horas	12551	4224	4366

Tabla 6. 6 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos para día claro (2^a Fase)

	Entrenamiento	Validación	Testeo
Media (kWh)	625,37	629,50	519,31
Mediana (kWh)	57,50	58,50	1
Moda (kWh)	0	0	0
Desviación estándar (kWh)	727,70	733,57	707,56
Min (kWh)	0	0	0
Max (kWh)	1826	1815	1813
Número de horas	5856	1920	1942

Tabla 6. 7 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos para día nublado (2^a Fase)

	Entrenamiento	Validación	Testeo
Media (kWh)	344,52	347,67	285,78
Mediana (kWh)	8	8	1
Moda (kWh)	0	0	0
Desviación estándar (kWh)	483,108	489,81	463,17
Min (kWh)	0	0	0
Max (kWh)	1803	1782	1816
Número de horas	4584	1488	1512

Tabla 6. 8 Características de la energía generada de los tres grupos de datos para el desarrollo de los modelos para día muy nublado o lluvioso (2^a Fase)

	Entrenamiento	Validación	Testeo
Media (kWh)	100,63	98,42	85,19
Mediana (kWh)	0	0	1
Moda (kWh)	0	0	0
Desviación estándar (kWh)	199,67	172,69	161,65
Min (kWh)	0	0	0
Max (kWh)	1778	978	904
Número de horas	2303	744	768

Las predicciones del modelo atmosférico disponibles en el conjunto de datos se refieren a predicciones realizadas con el modelo atmosférico WRF-NMM. Estas predicciones corresponden a los valores de las variables meteorológicas de radiación, temperatura, humedad, cobertura de nubes, dirección y velocidad del viento, todos para el punto de la rejilla más cercano al parque solar. Se dispone de predicciones realizadas todos los días del año, cubriendo, cada una ellas, más de cuatro días completos (desde las 6:00 UTM del primer día, hasta las 4:00 UTM del quinto día) con valores de predicción para cada 30 minutos. Aunque tal y como se explicará más adelante, finalmente sólo se han utilizado las predicción para el 2º día, 24h, (horizonte de predicción real 16-40 h en horario de verano y 17-41 h en horario de invierno), que es el objetivo principal de las investigaciones desarrolladas, para el 3º día, 48h, (horizonte de predicción real 40-64 h en horario de verano y 41-65 h en horario de invierno) y el 4º día, 72h, (horizonte de predicción real 64-88 h en horario de verano y 65-89 h en horario de invierno), objetivos secundarios.

La disponibilidad, dentro de este conjunto de datos fiables, de predicciones de un modelo atmosférico con el horizonte de predicción comentado, posibilita el desarrollo de modelos de predicción de la energía eléctrica generada por el grupo de placas del parque solar, para el día siguiente al momento de la predicción y para los dos días posteriores.

6.3.3 INCORPORACIÓN DE DATOS ESTADÍSTICOS COMO NUEVAS ENTRADAS

Tras el desarrollo de los modelos de predicción de la primera fase se decide no sólo clasificar los datos por el tipo de día, sino que además se introducen nuevas variables de entrada, concretamente una serie de datos estadísticos cuyo cálculo es detallado a continuación:

SUNSHINE

Esta variable especifica el nº de horas de sol que se dan el día correspondiente a la predicción. Por ello es constante durante todo el día.

RADMEDIA

Esta variable expresa el valor medio, en W/m^2 , de la radiación prevista presente durante las horas de sol el día correspondiente a la predicción. Por ello su cálculo se realiza mediante la siguiente expresión:

$$RADMEDIA = \frac{\sum_{0}^{23} RSWIN}{SUNSHINE} \quad (6.5)$$

A partir de la expresión anterior queda patente que es constante durante todo el día.

I0CORR

Esta variable expresa el valor corregido, en W/m^2 , de la radiación extraterrestre correspondiente a cada instante de predicción. El cálculo de la radiación extraterrestre se realiza mediante la siguiente expresión:

$$I_0 = I_{SC} \cdot \left(1 + 0,33 \cdot \cos\left(\frac{360^\circ \cdot d}{365}\right) \right) \cdot (\sin\delta \cdot \sin\phi + \cos\delta \cdot \cos\phi \cdot \cos\omega) \quad (6.6)$$

Siendo:

I_{SC} : constante solar (1367 W/m^2)

d : día del año

δ : declinación solar, calculada mediante la ecuación (6.7)

ϕ : latitud correspondiente a la localización del parque solar fotovoltaico

ω : ángulo horario, calculado mediante la ecuación (6.8)

La declinación solar, δ , se obtiene mediante la siguiente expresión:

$$\delta = 23,45^\circ \cdot \sin\left(360^\circ \cdot \frac{284 + d}{365}\right) \quad (6.7)$$

El ángulo horario en grados, ω , se obtiene mediante la siguiente expresión:

$$\omega = 15 \cdot (h_s - 12) \quad (6.8)$$

Siendo:

h_s : hora solar verdadera, calculado mediante la ecuación (6.9)

$$h_s = H_{UTC} + ET - \frac{LONG}{15} \quad (6.9)$$

Siendo:

H_{UTC} : hora UTC

ET : corrección correspondiente a la “ecuación del tiempo” [Rabl85], calculada mediante la ecuación (6.10)

$LONG$: longitud correspondiente a la localización del parque solar fotovoltaico

La corrección de la ecuación del tiempo, ET , se obtiene mediante la siguiente expresión:

$$ET = \frac{9,87 \cdot \sin(2\beta) - 7,53 \cdot \cos(\beta) - 1,5 \cdot \sin(\beta)}{60} \quad (6.10)$$

Calculándose β mediante la siguiente ecuación:

$$\beta = \frac{360^\circ \cdot (d - 81)}{364} \quad (6.11)$$

Mediante la expresión 6.6, durante las horas en las que no haya radiación solar, es decir, entre el anochecer y el amanecer, el valor obtenido será negativo. Por ello se corrige mediante una función lógica para que en dichas horas su valor sea cero.

Idb-Ida

El objetivo de esta variable es permitir la detección de cambios bruscos en las condiciones meteorológicas. Para detallar su cálculo es preciso definir, en primer lugar, la variable I_d , que es la diferencia entre la radiación extraterrestre y la radiación en la superficie terrestre, tal y como se indica en la ecuación (6.12).

$$I_d = I0CORR - RSWIN \quad (6.12)$$

De forma que la variable $Idb-Ida$, utilizada como entrada en los modelos, corresponde a la diferencia entre las I_d del instante de la predicción y del anterior:

$$Idb - Ida = I_{dt} - I_{dt-1} \quad (6.13)$$

$Idb-Ida\ maxd$

Es el valor máximo que presenta la variable anterior durante todo el día considerado. Por ello es constante durante todo el día.

$(I0N-RADN)^2$

El objetivo de esta variable es permitir la detección de cambios muy bruscos en las condiciones meteorológicas. Su valor corresponde a la diferencia entre la radiación prevista en la superficie terrestre y la extraterrestre pero normalizadas en forma de %. Su método de cálculo aparece en la ecuación (6.14):

$$(I0N - RADN)^2 = (I0CORRN - RSWINN)^2 \quad (6.14)$$

Siendo:

$$I0CORRN = \frac{I0CORR}{\max\{I0CORR\}} \quad (6.15)$$

$$RSWINN = \frac{RSWIN}{\max\{RSWIN\}} \quad (6.16)$$

NDD

A partir de la variable descrita en el punto anterior, $(I_{ON}-RADN)^2$, se puede obtener NDD , obteniendo su valor medio diario y calculando su raíz cuadrada, tal y como muestra la ecuación (6.17).

$$NDD = \sqrt{\frac{1}{24} \cdot \sum_0^{23} (I_{ON} - RADN)^2} \quad (6.17)$$

El valor de esta variable permite intuir comportamientos irregulares en la producción fotovoltaica.

SIMESTACION

Teniendo en cuenta la semejanza entre distintos meses del año, se define esta variable como similaridad de estación, con el fin de que el modelo de predicción pueda tenerla en cuenta. Su valor se obtiene a partir de la ecuación (6.18):

$$SIMESTACION = \begin{cases} 1 - \frac{d}{365} & d \leq 183 \\ 1 - \frac{365-d}{365} & d > 183 \end{cases} \quad (6.18)$$

ALTOSOLAR (γ_s)

Es interesante considerar como variables de entrada ciertas coordenadas solares. Por un lado nos encontramos con la altura solar, γ_s , cuyo valor se obtiene mediante la siguiente ecuación:

$$\gamma_s = \arcsen(\sen\delta \cdot \sen\phi + \cos\delta \cdot \cos\phi \cdot \cos\omega) \quad (6.19)$$

AZIMUT (ψ_S)

Otra de las coordenadas solares a considerar es el azimut, ψ_S , cuyo valor se obtiene mediante la siguiente ecuación:

$$\psi_S = \arccos\left(\frac{\sin\gamma_S \cdot \sin\phi - \cos\gamma_S \cdot \cos\phi}{\cos\gamma_S \cdot \cos\phi}\right) \quad (6.20)$$

TEMPMEDIA

Es el valor medio de la temperatura prevista, en K, durante todo el día considerado.

6.3.4 FILTRADO DE DATOS

Para desarrollar los modelos en ciertos casos se realizará un filtrado de datos para optimizar la eficacia de dichos modelos. Concretamente se trata de una regla lógica, que determinará que el valor de la energía fotovoltaica producida será nula cuando no haya, o su valor sea inapreciable, radiación solar en la superficie terrestre (*RSWIN*).

6.4 MODELO MM5

Tal y como se ha presentado y explicado con anterioridad, la herramienta inicial de los modelos de predicción correspondientes a las investigaciones iniciales vinculadas a la presente Tesis Doctoral, está constituida por el modelo MM5. Este modelo, cabe recordar, que se trata de un modelo de predicción meteorológica de meso-escala, desarrollado por PSU/NCAR (*Pennsylvania University and National Center for Atmospheric Research*), de área limitada, no hidrostático, el cual tiene un diseño de coordenadas sigma, las cuales están diseñadas para seguir el perfil del terreno en superficie.

De las diferentes opciones disponibles se eligió este modelo de predicción numérica meteorológica porque según los estudios realizados, este era uno de los modelos más utilizados en aplicaciones científicas, además de incluir todos los avances realizados en modelización meteorológica en el momento en el que comencé con el desarrollo de modelos de predicción para instalaciones fotovoltaicas. Además, se tuvo en cuenta que era un modelo de libre distribución.

En este apartado no se va a explicar con más detalle el funcionamiento del MM5 ya que se ha hecho con anterioridad.

La herramienta de simulación MM5 tiene una serie de parámetros configurables que ayudan a la mejora de los resultados [Dudhia05]. La modificación de los valores de estos parámetros contribuirá a una mejora o por el contrario empeorará las simulaciones obtenidas.

Para determinar la sensibilidad del modelo MM5 me he servido de las pruebas realizadas en las primeras etapas de desarrollo de esta Tesis doctoral, además se han realizado una serie de estudios estadísticos a partir de los cuáles se han obtenido las correspondientes conclusiones.

Gracias al conocimiento aproximado de la sensibilidad del modelo se ha configurado el MM5 para realizar todas las predicciones necesarias para el desarrollo del modelo de predicción.

Además, se han programado una serie de aplicaciones para automatizar la predicción de las variables deseadas y su almacenamiento.

6.4.1 CONFIGURACIÓN DEL MM5

Tras investigar y estudiar la sensibilidad para los parámetros del modelo se han seleccionado estos para los valores más adecuados para el propósito general de las investigaciones. A continuación se muestran los parámetros escogidos.

DEFINICIÓN DE DOMINIOS

Teniendo en cuenta que el objetivo perseguido es la previsión de la energía en parques solares fotovoltaicos, en los cuáles la orografía característica no suele ser compleja utilizamos, haciendo caso a estudios de ciertos autores ([McQueen95], [Salvador99] y [Stenger00]), una malla de 3 km x 3 km.

Además, tras observar los estudios estadísticos, se observa una mejora en las predicciones para un Dominio Madre que cubre España con parte de Europa y África.

Concretamente, se han seleccionado 3 dominios, el primero D1 cubre España con parte de Europa y África, D2 toda la península ibérica y D3 La Rioja.

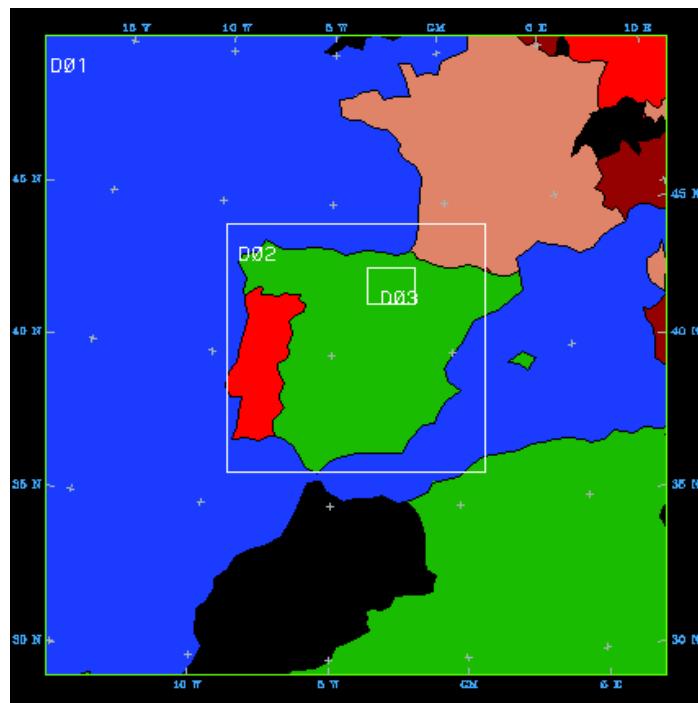


Figura 6. 6 Disposición de los Dominios

Tabla 6. 9 Información de los dominios escogidos

Dominio	Numero de celdas	Tamaño de celdas	Posición respecto dominio madre
D1	86x80	27 km	1,1
D2	100x100	9 km	28,24
D3	43x55	3 km	68,55
Latitud central del dominio madre 40.0°N			
Longitud central de dominio madre 4° O			
Proyección Lambert-conformal			

DATOS DE ENTRADA (CARACTERIZACIÓN DEL TERRENO)

DATOS DE ALTIMETRÍA

Los datos de altimetría del terreno se han obtenido de la base de datos del USGS (*U.S Geological Survey*) que se muestran en la siguiente tabla:

Tabla 6. 10 Archivos de datos de altimetría del terreno utilizados

Resolución	Fuente	Cobertura	Tamaño archivo	Nombre archivo
1 grado (111Km)	USGS	Global	126K	DEM_60M_GLOBAL
30 min (55Km)	USGS	Global	506K	DEM_30M_GLOBAL
10 min (18,5Km)	USGS	Global	4.4M	DEM_10M_GLOBAL
5 min (9,25Km)	USGS	Global	17.8M	DEM_05M_GLOBAL
2 min (3,70Km)	USGS	Global	111.2M	DEM_02M_GLOBAL
30 seg (0,925Km)	USGS GTOPO30	Ver Figura 6. 7A	54.9M	W020N90.DEM
		Ver Figura 6. 7B	54.9M	W020N40.DEM

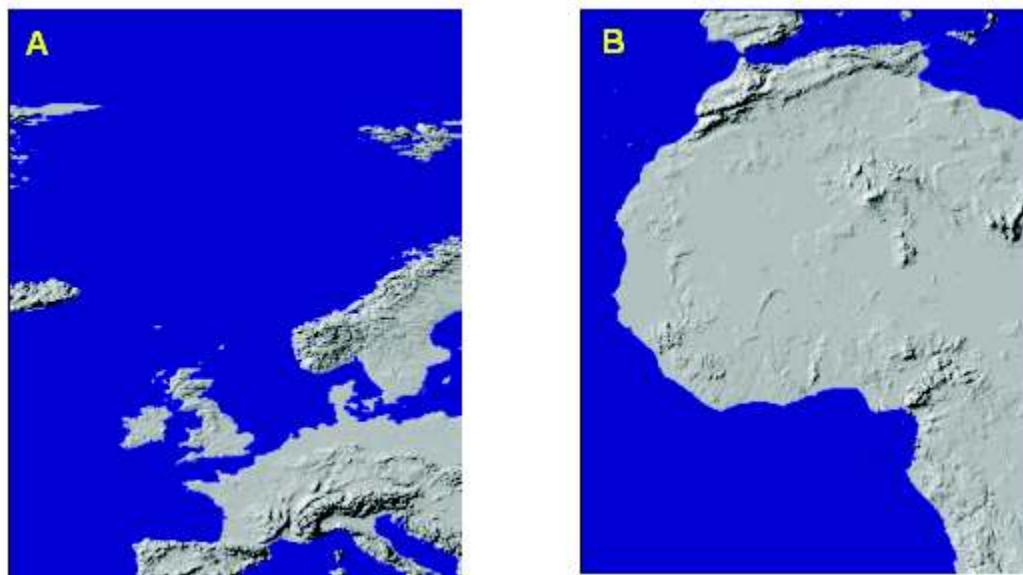


Figura 6. 7 Zona de los datos de altimetría (A: W020N90.DEM y B: W020N40.DEM)

USO DEL SUELO

Los datos de usos del suelo se han obtenido de la base de datos de la NCAR (*National Center Atmospheric Research*) con 13 categorías diferentes de usos para tres resoluciones de 1°, 30min y 10min.

Tabla 6. 11 Archivos de usos del suelo utilizados

Resolución	Fuente	Cobertura	Tamaño archivo	Nombre archivo
1 grado (111Km)	NCAR	Global	822.7K	LANDUSE.60
30 min (55Km)	NCAR	Global	3.2M	LANDUSE.30
10 min (18,5Km)	NCAR	Global	28.9M	LANDUSE.10

Tabla 6. 12 Categorías de usos del suelo de la NCAR

Nº Identif.	Descripción	Albedo (%)		Humedad (%)		Emisividad (% - 9μm)		Rugosidad (cm)		Inercia termal (cal cm ⁻² K ⁻¹ s ^{-1/2})	
		Ver.	Inv.	Ver.	Inv.	Ver.	Inv.	Ver.	Inv.	Ver.	Inv.
1	Urbano	18	18	5	10	88	88	50	50	0,03	0,03
2	Agrícola	17	23	30	60	92	92	15	5	0,04	0,04
3	Prado	19	23	15	30	92	92	12	10	0,03	0,04
4	Bosque Cáduco	16	17	30	60	93	93	50	50	0,04	0,05
5	Bosque coníferas	12	12	30	60	95	95	50	50	0,04	0,05
6	Bosque mixto	14	14	35	70	95	95	40	40	0,05	0,06
7	Aqua	8	8	100	100	98	98	0,01	0,01	0,06	0,06
8	Pantano	14	14	50	75	95	95	20	20	0,06	0,06
9	Desierto	25	25	2	5	85	85	10	10	0,02	0,02
10	Tundra	15	70	50	90	92	92	10	10	0,05	0,05
11	Hielo permanente	80	82	95	95	95	95	0,01	0,01	0,05	0,05
12	Bosque Tropical	12	12	50	50	95	95	50	50	0,05	0,05
13	Sabana	20	20	15	15	92	92	15	15	0,03	0,03

DATOS DE VEGETACIÓN

Los datos de vegetación utilizados son de la USGS disponibles con una resolución de 25 categorías:

Tabla 6. 13 Archivos de vegetación

Resolución	Fuente	Cobertura	Tamaño archivo	Nombre archivo
1 grado (111Km)	USGS	Global	1.5M	VEG-USGS.60
30 min (55Km)	USGS	Global	6.2M	VEG-USGS.30
10 min (18,5Km)	USGS	Global	55.6M	VEG-USGS.10
5 min (9,25Km)	USGS	Global	222.5M	VEG-USGS.05
2 min (3,70Km)	USGS	Global	1.4G	VEG-USGS.02
30 seg (0,925Km)	USGS	Global	889.8M	VEG-USGS.30s

Tabla 6. 14 Categorías de vegetación de USGS

Nº Identif.	Descripción	Albedo (%)		Humedad (%)		Emisividad (% - 9μm)		Rugosidad (cm)		Inercia termal (cal cm ⁻² K ⁻¹ s ^{-1/2})	
		Ver.	Inv.	Ver.	Inv.	Ver.	Inv.	Ver.	Inv.	Ver.	Inv.
1	<i>Urban</i>	15	15	10	10	88	88	80	80	0,03	0,03
2	<i>Dry Crop. Past.</i>	17	23	30	60	98,5	92	15	5	0,04	0,04
3	<i>Irrg. Crop. Past.</i>	18	23	50	50	98,5	92	15	5	0,04	0,04
4	<i>Mix Dry/Irrg.C.P.</i>	18	23	25	50	98,5	92	15	5	0,04	0,04
5	<i>C.Grs. Mosaic</i>	18	23	25	40	99	92	14	5	0,04	0,04
6	<i>C.Wood Mosaic</i>	16	20	35	60	98,5	93	20	20	0,04	0,04
7	<i>Grassland</i>	19	23	15	30	98,5	92	12	10	0,03	0,04
8	<i>Shrubland</i>	22	25	10	20	88	88	10	10	0,03	0,04
9	<i>Mix Shrb./Grs.</i>	20	24	15	25	90	90	11	10	0,03	0,04
10	<i>Savanna</i>	20	20	15	15	92	92	15	15	0,03	0,03
11	<i>Dec.Broadlf.</i>	16	17	30	60	93	93	50	50	0,04	0,05
12	<i>Dec.Needlf.</i>	14	15	30	60	94	93	50	50	0,04	0,05
13	<i>Evergrn.Broadlf.</i>	12	12	50	50	95	95	50	50	0,05	0,05
14	<i>Evergrn.Needlf.</i>	12	12	30	60	95	95	50	50	0,04	0,05
15	<i>Mixed Forest</i>	13	14	30	60	94	94	50	50	0,04	0,06
16	<i>Water Bodies</i>	8	8	100	100	98	98	0,01	0,01	0,06	0,06
17	<i>Herb. Wetland</i>	14	14	60	75	95	95	20	20	0,06	0,06
18	<i>Wooded Wetland</i>	14	14	35	70	95	95	40	40	0,05	0,06
19	<i>Bar. Sparse Veg.</i>	25	25	2	5	85	85	10	10	0,02	0,02
20	<i>Herb. Tundra</i>	15	60	50	90	92	92	10	10	0,05	0,05
21	<i>Wooden Tundra</i>	15	50	50	90	93	93	30	30	0,05	0,05
22	<i>Mixed Tundra</i>	15	55	50	90	92	92	15	15	0,05	0,05
23	<i>Bare Gr. Tundra</i>	25	70	2	95	85	95	10	5	0,02	0,05
24	<i>Snow/Ice</i>	55	70	95	95	95	95	5	5	0,05	0,05

DATOS DE TIERRA INUNDADA

Igual que los anteriores, los datos sobre las zonas de tierra inundadas por agua han sido obtenidos de la base de datos de *USGS Vegetation* para las siguientes resoluciones:

Tabla 6. 15 Archivos de zonas de tierra inundada

Resolución	Fuente	Cobertura	Tamaño archivo	Nombre archivo
1 grado (111Km)	USGS Vegetation	Global	63,3K	LWMASK-USGS.60
30 min (55Km)	USGS Vegetation	Global	253,1K	LWMASK -USGS.30
10 min (18,5Km)	USGS Vegetation	Global	2,2M	LWMASK -USGS.10
5 min (9,25Km)	USGS Vegetation	Global	8,9M	LWMASK -USGS.05
2 min (3,70Km)	USGS Vegetation	Global	55,6G	LWMASK -USGS.02
30 seg (0,925Km)	USGS Vegetation	Global	889.9M	LWMASK -USGS.30s

CATEGORÍAS DE SUELO

17 categorías del suelo han sido utilizadas obtenidas de la FAO (*Food and Agriculture Organization*) y la STATSGO (*U.S. General Soil Map*) para una resolución única de 30 segundos.

Tabla 6. 16 Categorías de Suelo

Resolución	Fuente	Cobertura	Tamaño archivo	Nombre archivo
1 grado (111Km)	FAO+STATSGO	Global	-	-
30 min (55Km)	FAO+STATSGO	Global	-	-
10 min (18,5Km)	FAO+STATSGO	Global	-	-
5 min (9,25Km)	FAO+STATSGO	Global	-	-
2 min (3,70Km)	FAO+STATSGO	Global	-	-
30 seg (0,925Km)	FAO+STATSGO	Global	889.9M	SOILCAT.30s

Tabla 6. 17 Categorías del suelo de la FAO+STATSGO

Nº Identif.	Descripción	Humedad Máx.	Humedad Ref. Suelo	Punto límite Humedad Suelo	Límite Humedad Aire seco	Saturación Suelo		Parámetro B	Saturación Suelo	
						Potencial	Conduct. (10 ⁻⁶)		Difusiv. (10 ⁻⁶)	Dif. Cond. Coef.
1	Sand	0,339	0,236	0,010	0,010	0,069	1,07	2,79	0,608	-0,472
2	Loamy Sand	0,421	0,283	0,028	0,028	0,036	14,10	4,26	5,14	-1,044
3	Sandy Loam	0,434	0,312	0,047	0,047	0,141	5,23	4,74	8,05	-0,569
4	Silt Loam	0,476	0,360	0,084	0,084	0,759	2,81	5,33	23,90	0,162
5	Silt	0,476	0,360	0,084	0,084	0,759	2,81	5,33	23,90	0,162
6	Loam	0,439	0,329	0,066	0,066	0,355	3,38	5,25	14,30	-0,327
7	Sandy Clay Loam	0,404	0,314	0,067	0,067	0,135	4,45	6,66	9,90	-1,491
8	Silty Clay Loam	0,464	0,387	0,120	0,120	0,617	2,04	8,72	23,70	-1,118
9	Clay Loam	0,465	0,382	0,103	0,103	0,263	2,45	8,17	11,30	-1,297
10	Sandy Clay	0,406	0,338	0,100	0,100	0,098	7,22	10,73	18,70	-3,209
11	Silty Clay	0,468	0,404	0,126	0,126	0,324	1,34	10,39	9,64	-1,916
12	Clay	0,468	0,412	0,138	0,138	0,468	0,97	11,55	11,20	-2,138
13	Organic Mat.	0,439	0,329	0,066	0,066	0,355	3,38	5,25	14,30	-0,327
14	Water	1,000	0,000	0,000	0,000	0,000	0,00	0,00	0,00	0,000
15	Bedrock	0,200	0,108	0,006	0,006	0,069	141,00	2,79	136,00	-1,111
16	Other	0,421	0,283	0,028	0,028	0,036	14,10	4,26	5,14	-1,044

CONDICIONES DE INICIALIZACIÓN Y FRONTERA

Los modelos de área limitada necesitan información de inicialización y condiciones de frontera durante la ejecución de la simulación para poderse ejecutar satisfactoriamente. Esta información la obtienen a partir de los resultados de un modelo de escala superior, que usualmente son modelos globales.

Los datos que se han utilizado para las simulaciones han sido los análisis del modelo global GFS (*Global Forecasting Systems*), que es una actualización de un primer modelo desarrollado para usos de aviación (*Aviation model, AVN*). El modelo GFS proporciona información de la temperatura, presión, humedad, componentes de la velocidad del viento para los niveles de presión estándar. La resolución espacial de estos datos es de 1° (aproximadamente 100 km para las latitudes de trabajo), y se actualizan con una frecuencia de 6 horas (a las 0, 6, 12 y 18 horas UTM). Los datos del ciclo de las 0 horas UTM están disponibles todos los días a partir de las 6 a.m. en los servidores del NCEP con datos desde las 0 hasta 180 horas en intervalos de 3 en 3 horas. Los ficheros tienen la denominación *gfs.t00z.pgrbfXXX*, donde las XXX corresponden a la hora de la predicción. Dado que se van a realizar predicciones con un horizonte de hasta 45 horas solo serán necesarios los siguientes archivos:

Tabla 6. 18 Lista de archivos del gfs model utilizados para el MM5

<i>gfs.t00z.pgrbf00</i>	<i>gfs.t00z.pgrbf18</i>	<i>gfs.t00z.pgrbf36</i>
<i>gfs.t00z.pgrbf03</i>	<i>gfs.t00z.pgrbf21</i>	<i>gfs.t00z.pgrbf39</i>
<i>gfs.t00z.pgrbf06</i>	<i>gfs.t00z.pgrbf24</i>	<i>gfs.t00z.pgrbf42</i>
<i>gfs.t00z.pgrbf09</i>	<i>gfs.t00z.pgrbf27</i>	<i>gfs.t00z.pgrbf45</i>
<i>gfs.t00z.pgrbf12</i>	<i>gfs.t00z.pgrbf30</i>	
<i>gfs.t00z.pgrbf15</i>	<i>gfs.t00z.pgrbf33</i>	

Como ya se ha explicado en el apartado de la descripción del modelo MM5, este dispone de la capacidad de asimilar datos de observaciones meteorológicas durante el

avance de la simulación. Esta técnica se denomina asimilación de datos en cuatro dimensiones (FDDA, *four dimensional data assimilation*). La técnica que utiliza es la relajación Newtoniana o técnica *nudging* [Stauffer90]. Su finalidad es la de mejorar los resultados del modelo mesoscalar introduciendo una variable ficticia en las ecuaciones primitivas que hace tender los resultados del modelo a las observaciones que se le introducen. MMMD/NCAR (2001) recomiendan no aplicar esta técnica para estudios científicos y pronósticos meteorológicos, ya que, se introducen términos no físicos dentro de las ecuaciones primitivas. Para las simulaciones realizadas en los trabajos descritos en esta Tesis, se ha decidido no realizar asimilación de datos.

Así, el modelo se ejecuta a partir de la información aportada por los análisis del modelo global GFS. Las primeras seis horas de simulación no se utilizarán para la producción de valores de predicción de variables meteorológicas, ya que es el período de estabilización numérica recomendado en ejecuciones tipo *cold start* (sin un período inicial de asimilación de datos meteorológicos). Además, esas primeras 6 horas no entran dentro del horizonte de predicción.

PARÁMETROS FÍSICOS

Las parametrizaciones físicas del modelo MM5 que se han seleccionado tras un procedimiento de prueba y error son:

Tabla 6. 19 Parametrizaciones físicas

Dominio	Capa fronteriza <i>IBLTYP</i>	Cumulo <i>ICUPA</i>	Humedad <i>IMPHYS</i>	Radiación <i>FRAD</i>	Suelo <i>ISOIL</i>
D1	MRF 4	Grell 3	Simple Ice 4	Cloud 2	Multi soil 1
D2	MRF 4	Grell 3	Simple Ice 4	Cloud 2	Multi soil 1
D3	MRF 4	None 1	Simple Ice 4	Cloud 2	Multi soil 1

Entre ellos por ejemplo cabe destacar el tipo de cálculo de la radiación (*FRAD*), por su importancia en la presente Tesis.

1. NONE: cálculo de radiación sin nubosidad.
2. CLOUD: cálculo de la radiación teniendo en cuenta la nubosidad.

3. RRTM: cálculo de la radiación con nubosidad compleja.

Se ha elegido el tipo CLOUD porque existe una mejora en los resultados usando la opción CLOUD con respecto a los obtenidos con la opción NONE.

Con la opción RRTM, que es una derivación de la opción CLOUD, no he observado mejora en las predicciones con respecto a la opción anterior y dado que precisa un mayor tiempo de ejecución, opté por no utilizarla.

CONDICIONES DE CONTORNO

Tabla 6. 20 Condiciones de Contorno

<i>Dominio</i>	<i>Laterales IBOUDY</i>	<i>Superiores IFUPR</i>
D1	<i>Relaxation/inflow-outflow 3</i>	<i>Upper radiative condicion 0</i>
D2	<i>Time-dependt/Nest 2</i>	<i>Upper radiative condicion 0</i>
D3	<i>Time-dependt/Nest 2</i>	<i>Upper radiative condicion 0</i>

TÉCNICA DE ANIDAMIENTO

La técnica de anidamiento utilizada será la **unidireccional (one-way)** teniendo en cuenta sobre todo que requiere un consumo computacional menor. Es decir, se resuelve la física del dominio madre en primer lugar y la información obtenida se transmite a los dominios interiores para resolver la física en estos dominios de mayor resolución.

6.4.2 PROGRAMA DE EJECUCIÓN AUTOMÁTICA: PREDICEFV

Teniendo en cuenta que para conseguir las predicciones, hay que ejecutar de manera secuencial los subprogramas que componen el MM5, configurándolos uno a uno para cada día de simulación, se decidió desarrollar la aplicación PREDICEFV que permite ejecutar el MM5 de manera directa todos los días.

El código fue escrito en lenguaje C, utilizando el compilador interno del mismo que incorporan los sistemas operativos Linux.

Este programa incluye otras dos aplicaciones GENERADOR y ENVIAR cuya función se detalla más adelante.

A continuación, en la Figura 6. 8, podemos ver un flujograma que resume el funcionamiento del mismo.

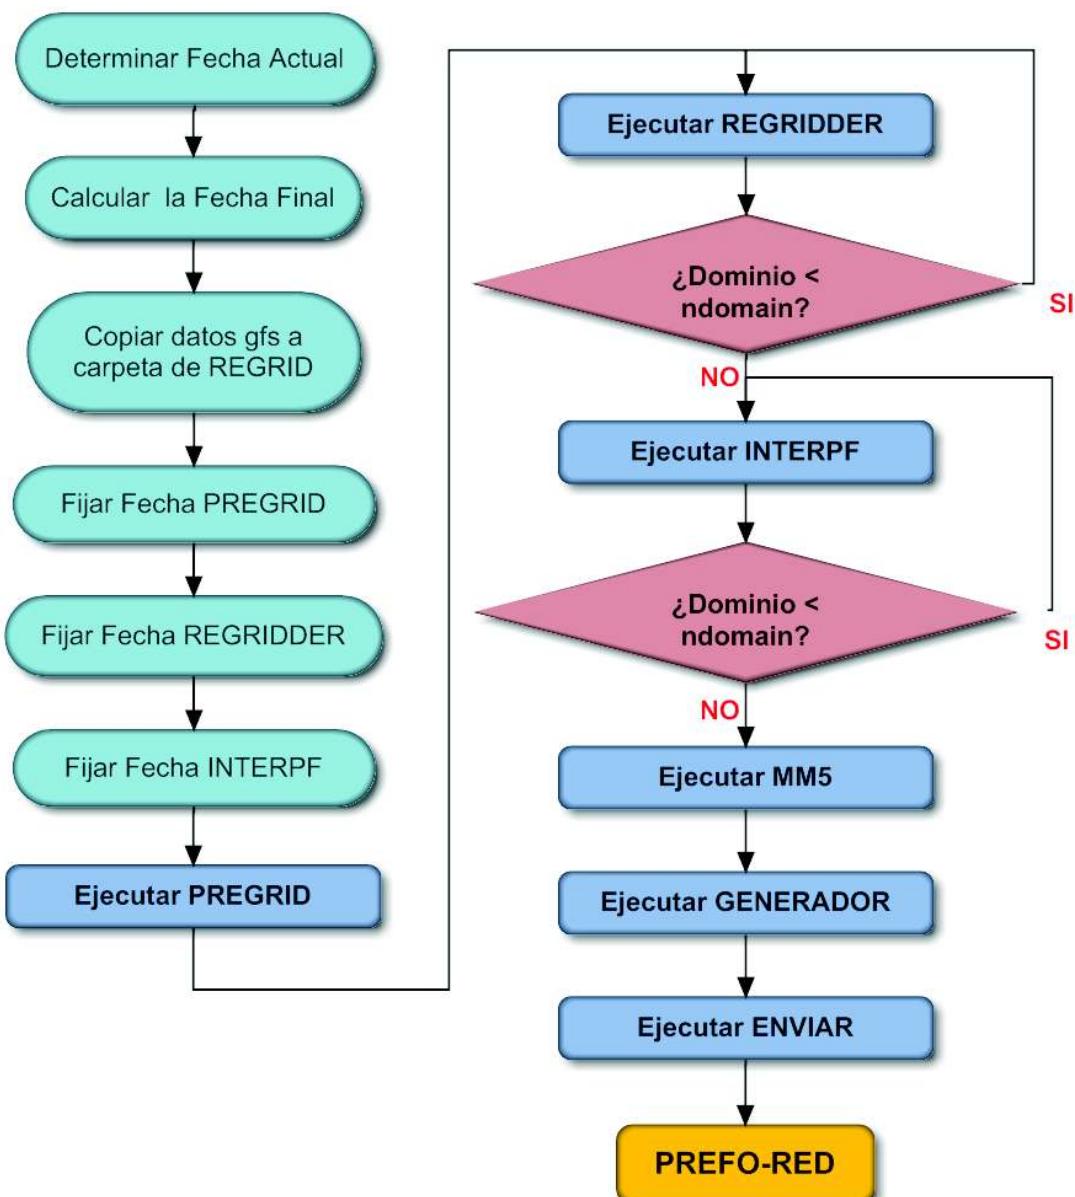


Figura 6. 8 Flujograma de funcionamiento de PREDICEFV

A/ GENERADOR

El objetivo de esta aplicación es tomar del archivo MMOUT_DOMAIN3, únicamente las predicciones correspondientes al parque solar fotovoltaico objeto de estudio, y además sólo siete variables (los diferentes tipos de radiación y la temperatura a 2 m de altura).

Para ello la aplicación accede al archivo MMOUT_DOMAIN3, lee las variables y va escribiendo en otro archivo, el cuál cuando termine la ejecución del bucle contendrá los datos necesarios para introducirlos en el conjunto de entradas del modelo de predicción y que éste pueda realizar las predicciones energéticas.

Finalmente obtenemos un archivo de texto delimitado por tabulaciones (de 57 kbytes) que contiene únicamente las variables comentadas para la localización del parque solar fotovoltaico.

B/ ENVIAR

El único fin de esta sencilla aplicación es enviar el archivo de predicciones, vía ftp, al disco duro en red para que posteriormente pueda ser descargado desde el PC que disponga del modelo de predicción.

Podría modificarse fácilmente, para acceder a otro servidor ftp cualquiera.

6.5 CONFIGURACIÓN DEL MODELO WRF-NMM

Tal y como se ha presentado y explicado con anterioridad, la parte inicial de los modelos de predicción correspondientes a las investigaciones finales vinculadas a la presente Tesis Doctoral, está constituida por el modelo WRF (*Weather Research and Forecasting Model*), otro de los modelos más utilizados en aplicaciones científicas, y que incluye todos los avances realizados hasta el momento en modelización meteorológica. Concretamente se va a usar el WRF-NMM (*Nonhydrostatic Mesoscale Model*).

Este modelo, cabe recordar, que se trata de un modelo de predicción meteorológica de meso-escala, desarrollado por NOAA/NCEP (*National Oceanic and Atmospheric Administration / National Centers for Environmental Prediction*), de área limitada, no hidrostático, pero con una opción hidrostática ([Janjic01], [Janjic03a], [Janjic03b]). Además tiene un diseño de coordenadas sigma, las cuales están diseñadas para seguir el perfil del terreno en superficie. El modelo WRF es una actualización del modelo MM5 y comparte con él muchos de los parámetros configurables.

Teniendo en cuenta todos los parámetros configurados en el MM5 con anterioridad y siguiendo la guía de usuario del WRF-NMM, [Janjic14], se ha configurado el WRF-NMM para realizar todas las predicciones necesarias para el desarrollo del modelo de predicción.

Por ello se han tenido en cuenta los parámetros escogidos para la configuración del MM5 en cuanto a definición de Dominios y caracterización del terreno. Es interesante destacar un par de puntos:

1. En cuanto a la definición de dominios se ha seguido la misma línea que el MM5, pero es interesante destacar que con el WRF-NMM, disponemos de dos opciones para definir los dominios. Además de poder introducir las coordenadas que delimitan los dominios editando el fichero directamente, el WRF dispone de una herramienta denominada *WRF Domain Wizard*, que nos permite definir los dominios de forma gráfica y mediante diversos menús muy intuitivos. A continuación en la Figura 6. 9, podemos ver un ejemplo de ello.

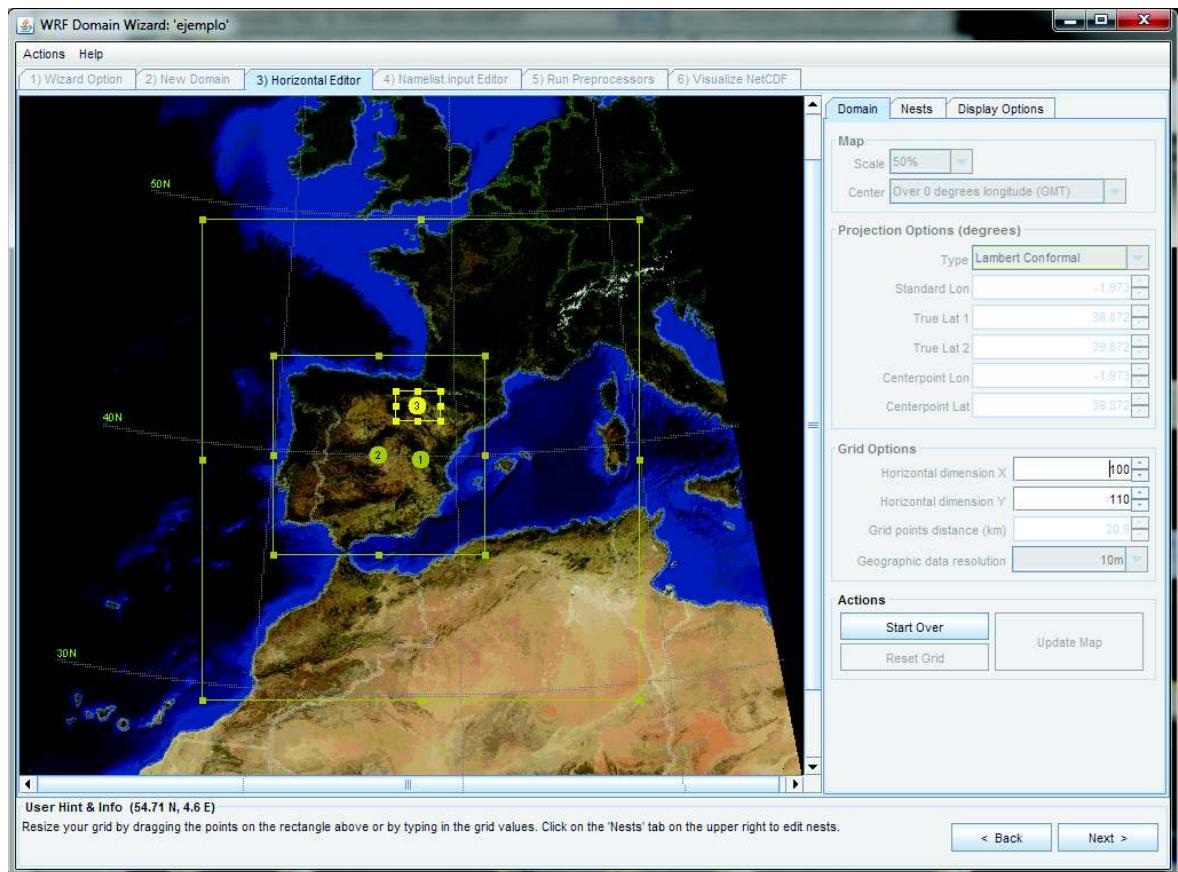


Figura 6. 9 Definición de dominios mediante WRF Domain Wizard

2. De nuevo, en lo referente a las condiciones de inicialización y frontera, los datos que se han utilizado para las simulaciones han sido los análisis del modelo global GFS, pero en este caso, dado que se van a realizar predicciones que puede llegar a los 3 días siguientes serán necesarios más archivos que en el caso del MM5. En este caso irán desde el *gfs.t00z.pgrbf00* hasta el *gfs.t00z.pgrbf90*.

6.6 MODELOS DESARROLLADOS BASADOS EN MM5

Los modelos de predicción de series temporales que se analizan para el desarrollo del sistema de predicción incluyen el clásico modelo persistente, un modelo de la familia ARIMA, un modelo *k-NN* (*k* vecinos más próximos), modelos basados en redes neuronales artificiales, y modelos basados en sistemas de inferencia neurodifusa.

A continuación se muestra un flujograma, Figura 6. 10, que muestra el proceso de desarrollo y evaluación de los modelos:



Figura 6. 10 Flujograma de desarrollo de los Modelos de Predicción

A continuación se van a describir brevemente los diferentes modelos de predicción desarrollados y analizados.

6.6.1 MODELOS CLÁSICOS Y OTROS

- **Modelo persistente:** el valor de predicción de la energía generada para la hora x de mañana es igual a la generada a la hora x de ayer.
- **Modelo ARIMA:** con la metodología Box-Jenkins se determinó el modelo ARIMA que mejores predicciones ofrecía y tras las conclusiones y observaciones iniciales se desarrolló un segundo modelo con mejores resultados (se explica con mayor detalle en el capítulo 7). Para el ajuste del modelo se utilizaron los datos de los grupos de entrenamiento y de validación.
- **Modelo de los k vecinos más próximos (k -NN: *k -nearest neighbor model*):** el modelo k -NN se basa en el principio de que cuando se reproducen las situaciones, también se reproducen los resultados. En el presente caso, la situación se representa mediante un vector característico que contiene los valores de predicción de las variables atmosféricas (y_1 a y_n), para la localización del parque solar fotovoltaico, obtenidas mediante el modelo MM5. Este vector se asocia con cada instante de tiempo del pasado. Por ejemplo, el vector característico para el instante i es expresado en la ecuación (6.21), donde los elementos representan los valores previstos para las variables atmosféricas disponibles en el instante i .

$$Y_i = (y_{1i}, y_{2i}, \dots, y_{ni})^T \quad (6.21)$$

Para cada Y_i , hay asociado un valor medido de producción de energía eléctrica en el mismo instante de tiempo (producción energética fotovoltaica para el instante i). De esta forma el histórico de datos disponible puede ser clasificado en pares de vectores Y_i y de escalares de energía producida, E_i , como: (Y_i, E_i) para $i = 1, 2, \dots, t$ siendo t el instante actual [Devroye94].

El par (Y_i, E_i) constituye un registro histórico. Al aplicarlo, el modelo k -NN, busca los registros históricos con los vectores característicos más próximos (a los que denomina vecinos más próximos).

En el presente caso, para las predicciones, se escogen los vecinos más próximos, de entre los correspondientes vectores característicos, como aquellos con la menor distancia (euclídea o de Mahalanobis), entre el vector característico actual y los anteriores. Por ejemplo, en la predicción de la producción fotovoltaica de energía para el instante $t + k$ (siendo k el horizonte de predicción) el vector característico está compuesto por los valores predichos para las variables atmosféricas en el instante $t + k$. De esta forma, el valor de energía producida se calcula como el valor medio, ponderado (en función de su cercanía euclídea) o no, de la producción correspondiente a los vecinos más próximos seleccionados.

6.6.2 MODELOS BASADOS EN REDES NEURONALES ARTIFICIALES

RED NEURONAL PERCEPTRÓN MULTICAPA (MLP) (*cuatro submodelos*):

Se escoge una red neuronal MLP con dos capas ocultas. La estructura de esta red neuronal es la reflejada en la Figura 6. 11, en la que las capas a la izquierda y derecha de la figura corresponden a la capa de entradas y a la capa de salidas, respectivamente. Las capas ocultas son las dos capas intermedias. Cada capa sólo está unida (conexiones entre neuronas) a la capa precedente y a la capa que le sigue (si existen). En función de la división de los datos (tipo A o B, ya comentados con anterioridad) y posteriormente tras un filtrado de datos (no aplicable a redes neuronales recurrentes), que ya ha sido comentado, se han desarrollado los siguientes submodelos:

- MLP 1A: División de datos tipo A, sin filtrado.
- MLP 1B: División de datos tipo B, sin filtrado.

- MLP 2A: División de datos tipo A, con filtrado.
- MLP 2B: División de datos tipo B, con filtrado.

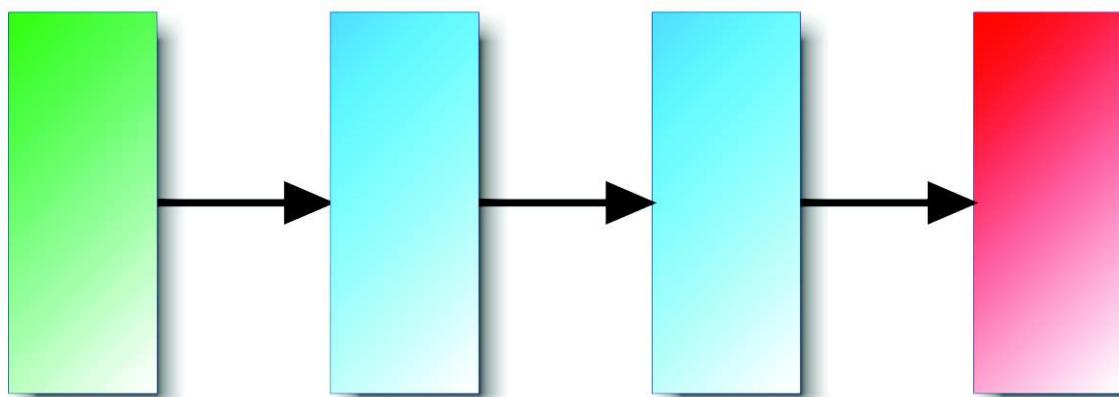


Figura 6. 11 Estructura de la red neuronal MLP de dos capas ocultas

RED NEURONAL MULTICAPA GENERALIZADA (FFBP) (*dos submodelos*):

Se escoge una red neuronal FFBP también con dos capas ocultas. La red neuronal unidireccional multicapa generalizada, FFBP, comparte las características de la red neuronal MLP, ya que está formada por capas de neuronas con conexiones unidireccionales (de entradas a salidas), pero a diferencia de la red neuronal MLP permite que haya conexiones entre neuronas de capas no consecutivas. Así, para el caso de una red neuronal FFBP con una sola capa oculta, las neuronas de la capa de entradas también se conectan a las neuronas de la capa de salidas, tal como muestra la Figura 6. 12.

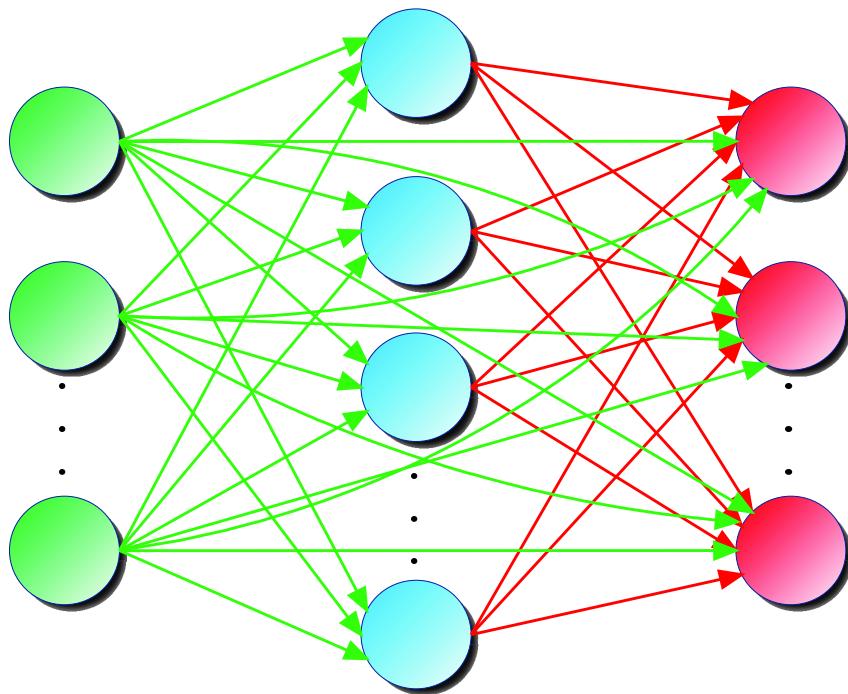


Figura 6. 12 Red neuronal unidireccional multicapa generalizada, FFBP, con una capa oculta

Para el caso de una red neuronal FFBP con dos capas ocultas, las neuronas de la capa de entradas se conectan a las dos capas ocultas y a la capa de salidas; las neuronas de la primera capa oculta se conectan a la segunda capa oculta y a la capa de salidas; y las neuronas de la segunda capa oculta se conectan solamente a la capa de salidas (ver Figura 6. 13).

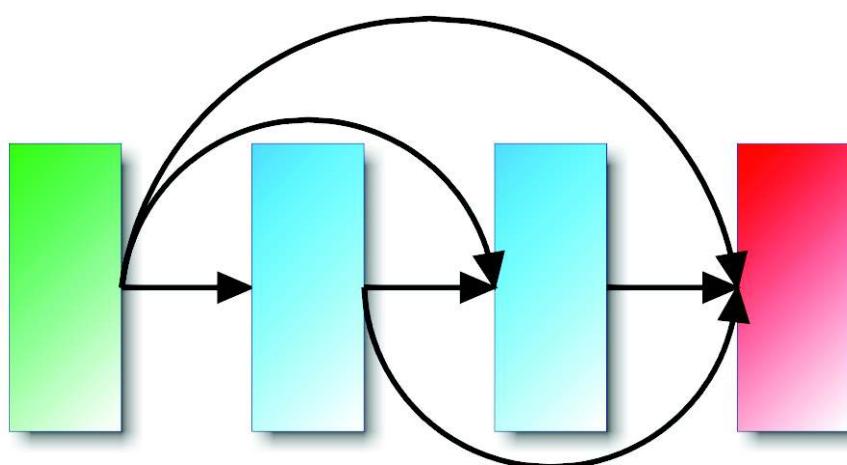


Figura 6. 13 Estructura de la red neuronal FFBPP de dos capas ocultas

De nuevo se han desarrollado distintos submodelos, en este caso dos:

- FFBP 1B: División de datos tipo B, sin filtrado.
- FFBP 2A: División de datos tipo A, con filtrado.

La ventaja de la red neuronal FFBP sobre la red neuronal MLP es que, para una misma estructura (capas y neuronas), necesita menos tiempo en el entrenamiento al adaptarse más rápidamente los pesos de las conexiones de las neuronas de las primeras capas de la red.

RED NEURONAL MODULAR (MNN) (*dos submodelos*):

La red neuronal modular constituye otra variante sobre la red neuronal MLP. Este tipo de red neuronal se compone de varias redes neuronales multicapa en paralelo (sub-redes neuronales), por lo tanto, podemos decir que comparten la capa de entradas y la capa de salidas, pero las capas ocultas son independientes. El valor del vector de salidas de la red neuronal modular se obtiene por combinación lineal de los valores de los vectores de salidas de las sub-redes neuronales.

En el entrenamiento, cada sub-red neuronal puede dedicarse a ajustar los valores de su vector de salidas para un conjunto de valores del vector de entradas, lo que mejora el funcionamiento de la red neuronal en su totalidad. Por otro lado, suponiendo un número total de neuronas igual, el entrenamiento de una red neuronal modular es más rápido que el de una red neuronal MLP, ya que el número de conexiones entre neuronas es menor para la red neuronal modular (al no existir conexiones entre neuronas de sub-redes neuronales distintas).

Pueden implementarse diferentes redes neuronales modulares haciendo que cada sub-red neuronal sea MLP o FFBP. Aunque hay que tener en cuenta, como se ha comentado, que no se permiten conexiones de las neuronas de una sub-red neuronal a las de otra.

Se escoge una red neuronal modular con una estructura igual a la reflejada en la Figura 6. 14, es decir, con dos pares de capas ocultas. Cada una de las dos redes en paralelo tiene dos capas ocultas. En ambas redes cada capa está conectada a la anterior y a la posterior. Adicionalmente, las primeras capas ocultas de ambas redes están unidas a la capa de salidas, al igual que la capa de entradas. Esta configuración permite la especialización de ambas redes con un grupo particular de datos del conjunto de entrenamiento, permitiendo, en muchos casos, mejores resultados que los obtenidos con las redes neuronales MLP. La conexión entre capas no significa que todas las neuronas de cada capa estén unidas entre sí. Los dos submodelos desarrollados son:

- MNN 1B: División de datos tipo B, sin filtrado.
- MNN 2A: División de datos tipo A, con filtrado.

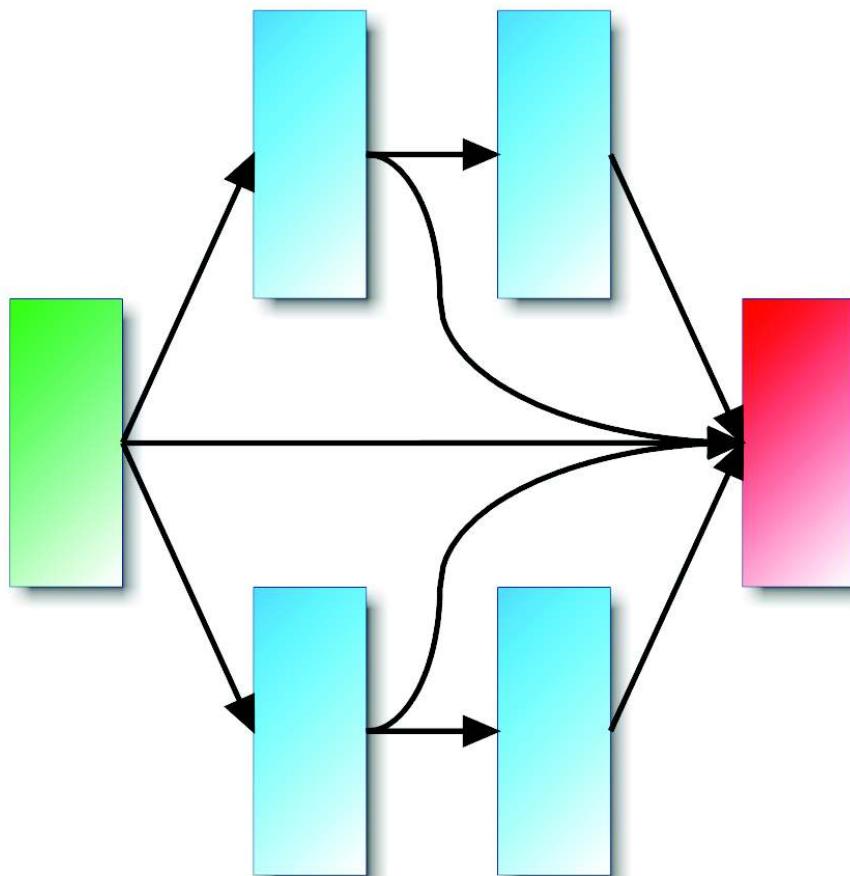


Figura 6. 14 Estructura de la red neuronal MNN de dos capas ocultas

RED NEURONAL CON ANÁLISIS DE COMPONENTES PRINCIPALES (PCA) (*tres submodelos*):

A la hora de procesar información podemos encontrarnos con un conjunto de entradas de alta dimensión (gran número de variables de entrada), por ello en muchas ocasiones se hace necesario determinar o extraer las características principales y propias de dichas entradas.

Uno de los ejemplos que más se utiliza para explicar esto es el procesado de una imagen, ya sea atendiendo al nº de colores (si tenemos un ícono o una caricatura basta con 256 colores, formato *.gif*, en vez de 16-32 millones de colores, formato *.bmp* o *.jpg*) o a la resolución (en una imagen de 4x4 cm es más que suficiente con una resolución de 250x250 pixel en vez de 5 Megapíxel).

Una de las técnicas propuestas para la extracción genérica de esas características es el análisis de componentes principales, PCA, técnica estadística que trata de encontrar las componentes principales de una población o conjunto de datos.

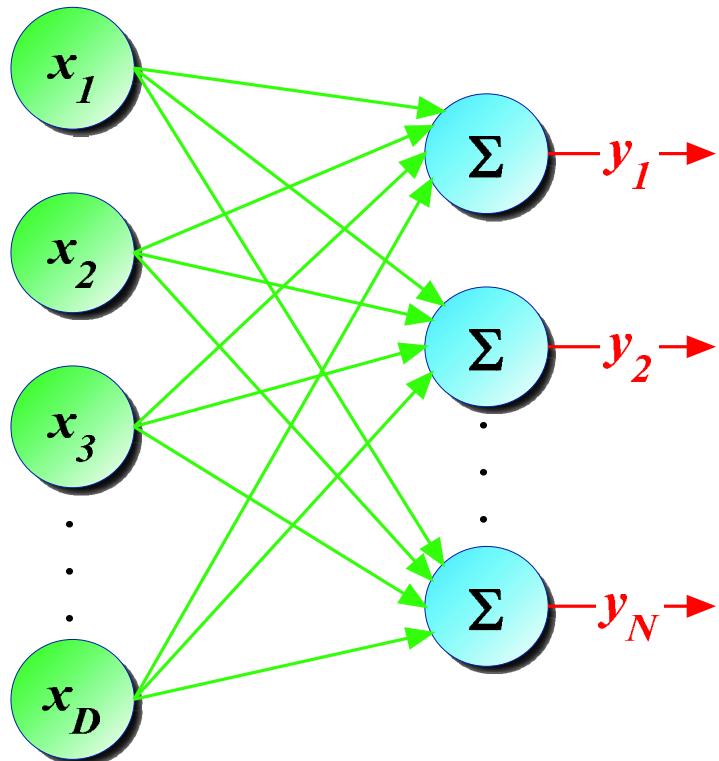


Figura 6. 15 Principio de red neuronal PCA

Las redes neuronales con análisis de componentes principales (en lo sucesivo redes neuronales PCA) realizan esa reducción de la dimensión del espacio de entrada (reducción de la dimensión del vector de entradas) mediante la proyección de la información de D neuronas de entrada sobre N neuronas de una capa oculta, tal como muestra la Figura 6. 15. La capa de neuronas ocultas, representadas en color azul, tendrá como vector de salidas las N primeras componentes principales correspondientes a las D variables de entrada. El valor del vector de salidas se calcula por combinación lineal, es decir, sin función de activación.

La ventaja de las redes neuronales PCA sobre las redes neuronales MLP es que están menos afectadas por el problema conocido como “curso de dimensionalidad” [Härdle90].

La red neuronal PCA escogida consta de dos capas ocultas para el aprendizaje supervisado. El número de componentes principales se escoge por el proceso de optimización. Para el aprendizaje no supervisado el número de epochs máximo es de 800, con la posibilidad de que sea menor el número de epochs del entrenamiento no supervisado si el cambio en todos los pesos de las conexiones de las neuronas de la capa de neuronas oculta es menor a 0,0001. Los submodelos desarrollados son:

- PCA 1B: División de datos tipo B, sin filtrado y reducción del espacio de entrada aplicando la regla de Oja [Oja89].
- PCA 2AOja: División de datos tipo A, con filtrado y reducción del espacio de entrada aplicando la regla de Oja.
- PCA 2ASanger: División de datos tipo A, con filtrado y reducción del espacio de entrada aplicando el método de Sanger [Sanger89].

RED NEURONAL DE FUNCIÓN DE BASE RADIAL (RBF) (*dos submodelos*):

Se escoge una red neuronal híbrida compuesta por una red neuronal RBF seguida por una red neuronal MLP con dos capas ocultas. La red con neuronas de función de base radial actúa como la capa de entradas de la red neuronal MLP. Ambas redes neuronales se entranan separadamente: la red neuronal RBF se entrena con aprendizaje

no supervisado con un máximo de 800 epochs, con la posibilidad de que sea menor el número de epochs del entrenamiento no supervisado si el cambio en todos los pesos de las conexiones de las neuronas de la capa de neuronas de función de base radial es menor a 0,0001. La red neuronal MLP se entrena, posteriormente, con aprendizaje supervisado con un máximo de 3000 epochs.

Los dos submodelos desarrollados son:

- RBF 1B: División de datos tipo B, sin filtrado.
- RBF 2A: División de datos tipo A, con filtrado.

RED NEURONAL HÍBRIDA CON MAPA AUTO-ORGANIZADO (SOM) (*tres submodelos*):

Los mapas auto-organizados (SOM) son redes neuronales en cuyo entrenamiento de nuevo aparece el aprendizaje no supervisado. Este tipo de red se denomina así porque se “auto-organiza”, ya que durante el entrenamiento no se le suministra el valor del vector de salidas esperado y la red debe procesar los datos de entrada de forma autónoma.

Los mapas auto-organizados realizan una transformación de un espacio de entrada continuo, y con dimensión arbitraria, a un espacio discreto de una o dos dimensiones (mapa), manteniendo las propiedades topológicas de la entrada. Esto se realiza por reconocimiento, en los valores del vector de entradas, de unas características o patrones que son representadas después en el plano como un mapa de dichas características o patrones.

La Figura 6. 16 representa la estructura de una red neuronal SOM. Un total de D neuronas de entrada (en color verde) se conectan a las neuronas de la capa de salidas del mapa auto-organizado (en este caso una estructura de 4x2 neuronas).

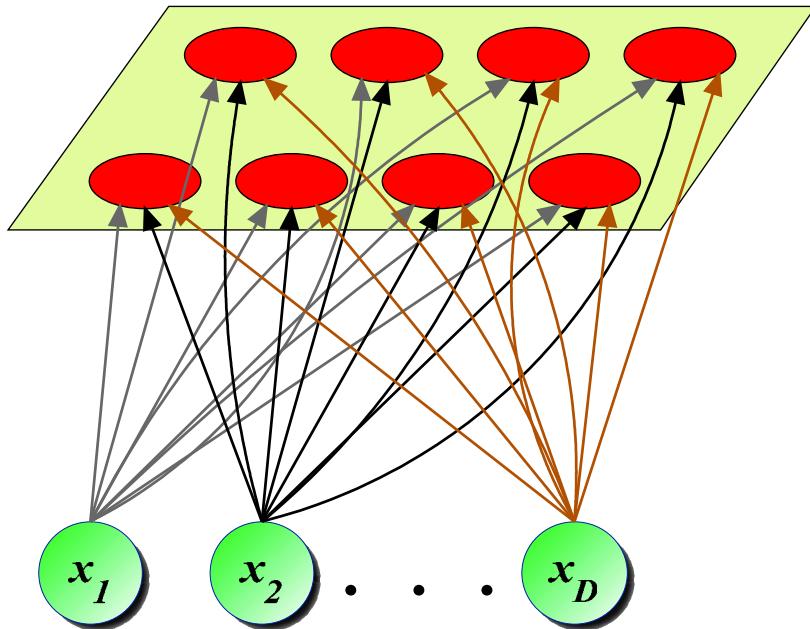


Figura 6. 16 Mapa auto-organizado (SOM)

El objetivo de una red neuronal SOM es clasificar los valores del vector de entradas en grupos de características similares, de tal forma que los valores del vector de entradas del mismo grupo activarán siempre las mismas neuronas de la capa de salidas del mapa auto-organizado. De ahí su principal aplicación como clasificador, o sistema para agrupamiento o clusterización de datos.

Para el entrenamiento de una red neuronal SOM se utiliza el método de aprendizaje no supervisado de Kohonen [Kohonen95].

El mapa auto-organizado desarrollado se limita a una estructura 4x4 en dos de los submodelos y a una 7x7 en el otro. Este mapa auto-organizado sirve de capa de entradas a una red neuronal MLP con dos capas ocultas. Para el aprendizaje no supervisado el número de epochs máximo fue de 800, con la posibilidad de interrupción anticipada de este aprendizaje si el cambio en todos los pesos de las conexiones del mapa auto-organizado era menor a 0,0001. Los submodelos desarrollados son:

- SOM 1B4: División de datos tipo B, sin filtrado y estructura 4x4.
- SOM 2A4: División de datos tipo A, con filtrado y estructura 4x4.
- SOM 2A7: División de datos tipo A, con filtrado y estructura 7x7.

RED NEURONAL DE ELMAN (*un submodelo*):

Las redes neuronales de Elman [Elman90] son un tipo de redes recurrentes, que el propio Elman describió como “redes recurrentes simples”. Se trata de un tipo de red neuronal muy similar a la MLP pero con una capa oculta adicional, conocida como capa de contexto. Esta capa extrae información temporal de los datos copiando el contenido de una capa oculta en la capa de neuronas de contexto. La capa de neuronas de contexto tiene como entradas sus propias salidas y las salidas de las neuronas de la capa oculta. La capa oculta tiene como entradas las neuronas de la capa de entradas y las neuronas de la capa de contexto. Las salidas de las neuronas de la capa oculta son las entradas de la capa de salida.

La Figura 6. 17 muestra una red neuronal de Elman con una capa oculta: en color verde se representan las neuronas de la capa de entrada, en color rojo las neuronas de la capa de salida, en color azul las neuronas de la capa oculta y en color amarillo las neuronas de contexto.

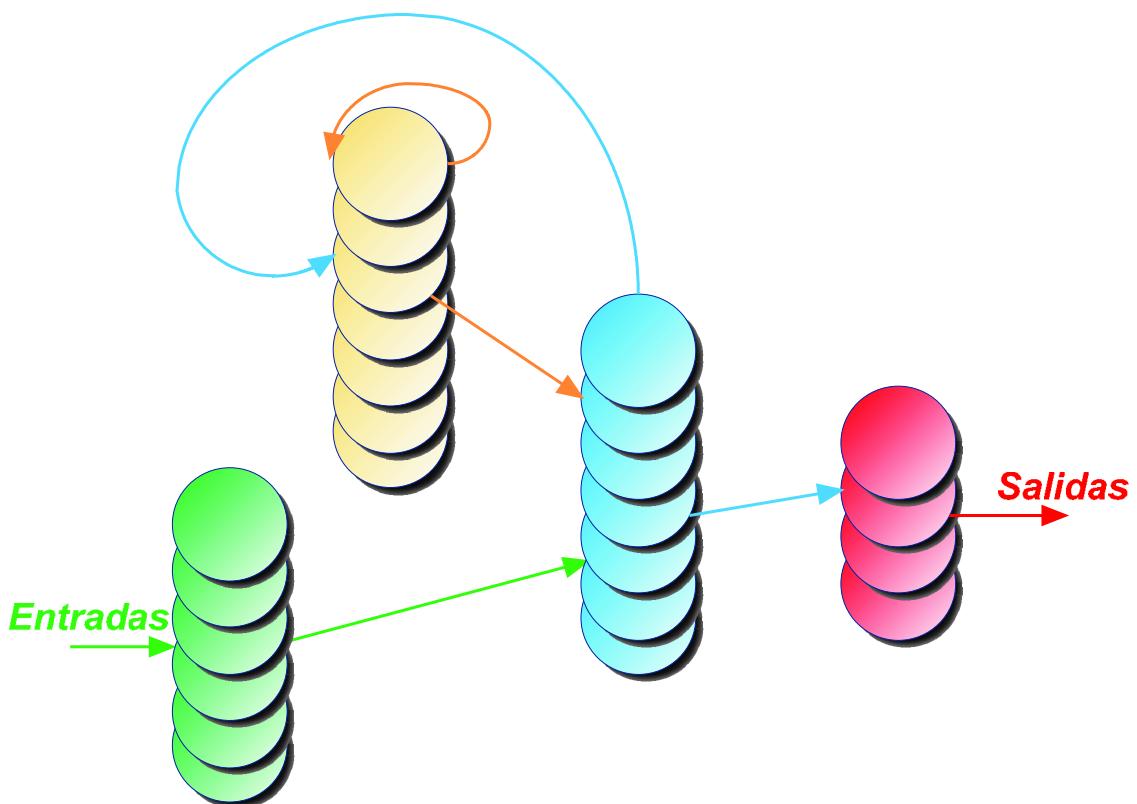


Figura 6. 17 Red neuronal Recurrente de Elman

La ventaja de este tipo de red neuronal se centra en que sus salidas no dependen del valor del vector de entradas en un instante determinado, sino también de los valores del vector de entradas previos, representando relaciones temporales que una red neuronal MLP no podría recoger (a no ser que estos valores se incluyan en el vector de entradas tal y como se ha hecho en la presente investigación con el instante anterior y posterior).

Se escoge una red neuronal de Elman con dos capas ocultas. La capa de neuronas de contexto copia el contenido de la segunda capa oculta y las salidas de esta capa de neuronas de contexto actúan como entradas adicionales de la primera capa oculta. La Figura 6. 18 muestra la estructura de la red neuronal de Elman con las dos capas ocultas. Las capas a la izquierda y derecha son las capas de entradas y salidas, respectivamente; la superior es la capa de neuronas de contexto. El submodelo desarrollado se denomina Elman1B.

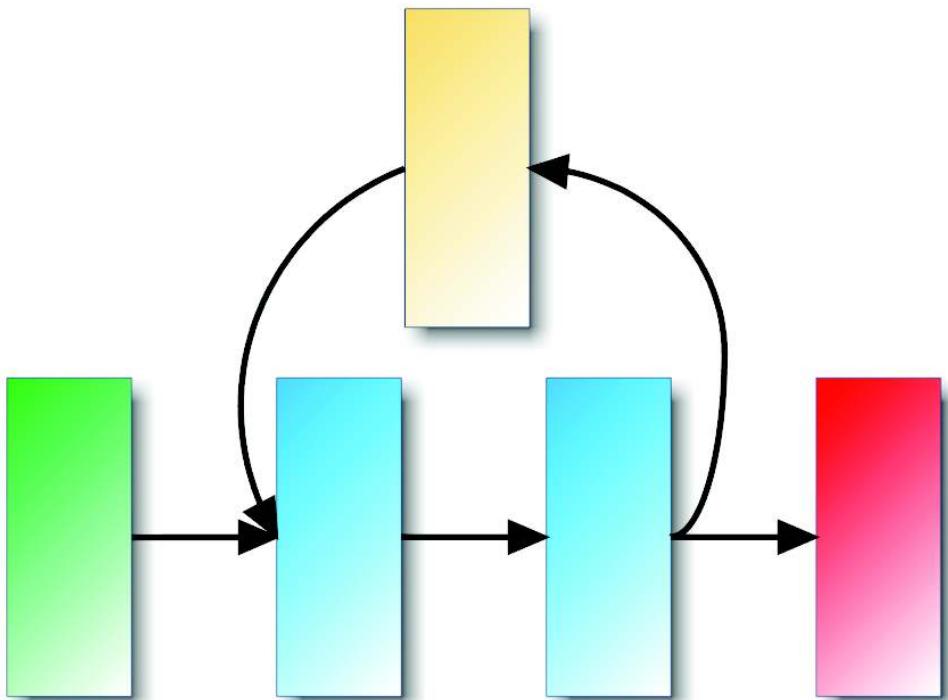


Figura 6. 18 Estructura de la red neuronal Elman de dos capas ocultas

RED NEURONAL RETARDADA EN EL TIEMPO (*seis submodelos*):

En este tipo de redes neuronales recurrentes se establecen conexiones entre neuronas de una misma capa [Principe00]. Se puede distinguir entre redes neuronales retardadas en el tiempo focalizadas y no focalizadas. Una red neuronal retardada en el tiempo focalizada es aquella en la que las conexiones entre neuronas de la misma capa se producen en la capa de entradas. En cambio, en las redes no focalizadas las conexiones entre neuronas de la misma capa se producen en la capa de entradas y en las capas ocultas.

La Figura 6. 19 representa una red neuronal retardada en el tiempo focalizada. Este tipo de red se conoce como TDNN focalizada (*Time Delay Neural Network*). En dicha figura está representada una red neuronal TDNN focalizada con tres neuronas “de entrada” en la capa de entradas (de color verde), es decir, con tres entradas. Hay una capa oculta (color azul) y una capa de salidas (color rojo). Pero lo específico de la red neuronal TDNN focalizada es que la capa de entradas cuenta con varias neuronas más que las entradas de la red neuronal: el número de neuronas en la capa de entradas es un múltiplo de las entradas de la red. En la Figura 6. 19 se ha representado una red neuronal con tres entradas, pero la capa de entradas presenta nueve neuronas (tres grupos de tres neuronas). El primer grupo de tres neuronas recibe el valor de las entradas de la red, el segundo grupo de tres neuronas de la capa de entradas almacena el valor previo del vector de entradas de la red neuronal y el tercer grupo de tres neuronas almacena los valores previos de las neuronas del segundo grupo (por tanto, el valor del vector de entradas de la red neuronal con una antigüedad de dos unidades de tiempo). Los grupos se conectan a su antecesor por medio de unidades de retardo, z^{-1} . Así, la red TDNN, y en general las redes neuronales retardadas en el tiempo, cuentan con una estructura que le permite mantener una memoria de la actividad de las neuronas de la red con valores previos del vector de entradas.

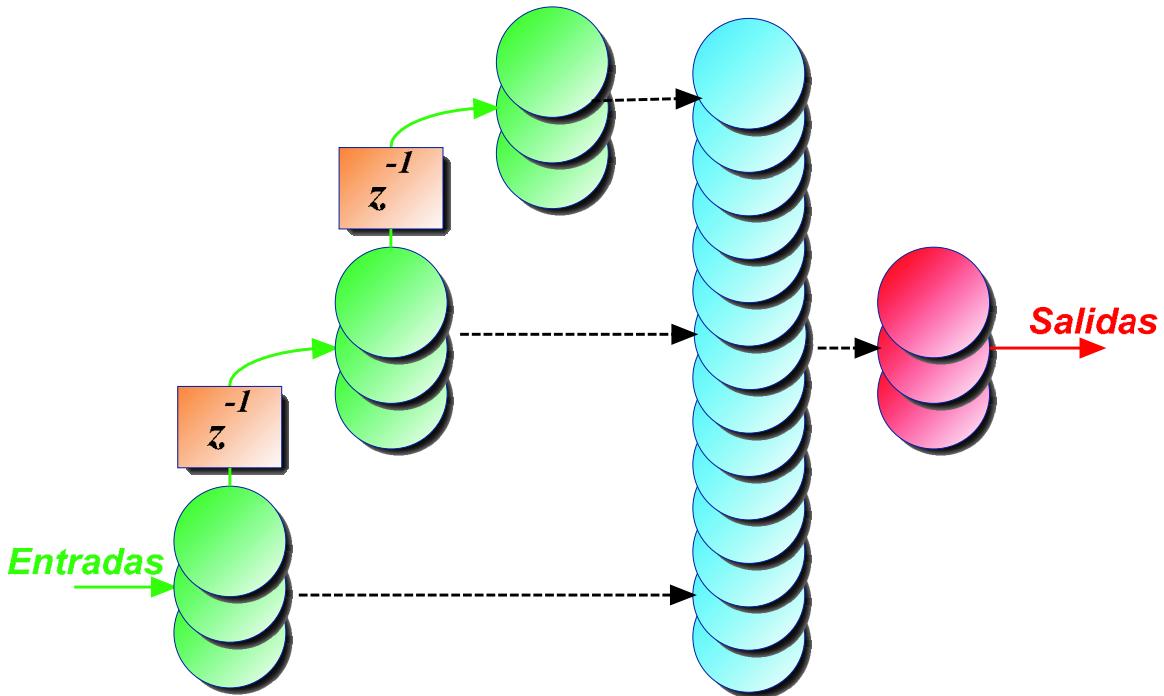


Figura 6. 19 Red neuronal TDNN focalizada

Además de la red neuronal TDNN existen otras configuraciones (Gamma [deVries92] y Laguerre [Back96]) para las redes neuronales retardadas en el tiempo, según sea la estructura asociada a las neuronas que implementan la memoria de la red neuronal.

De forma que se desarrollan 3 tipos de redes neuronales retardadas en el tiempo. Concretamente se desarrollan redes neuronales retardadas en el tiempo del tipo TDNN, del tipo Gamma y del tipo Laguerre. Todas las redes neuronales tienen dos capas ocultas y el proceso de optimización puede escoger el número de unidades de retardo de cada red.

Los submodelos desarrollados son:

- GAMMA F: Tipo Gamma focalizada (sólo unidades de retardo en la capa de entradas).
- GAMMA NF: Tipo Gamma no focalizada (unidades de retardo en todas las capas, excepto la de salidas).

- LAGUERRE F: Tipo Laguerre focalizada.
- LAGUERRE NF: Tipo Laguerre no focalizada.
- TDNN F: Tipo TDNN focalizada
- TDNN NF: Tipo TDNN no focalizada.

CARACTERÍSTICAS COMUNES A TODOS LOS MODELOS DE REDES NEURONALES:

Todos los modelos de redes neuronales desarrollados presentan una serie de características comunes, las cuales se indican a continuación:

- Todas las redes neuronales desarrolladas cuentan con dos capas ocultas. Se toma esta decisión al considerar que el problema de predicción abordado es considerablemente complejo.
- La segunda característica común, hace referencia a la optimización de los modelos de predicción, ya que, tal y como se ha comentado con anterioridad, todos los modelos basados en redes neuronales son optimizados en un proceso controlado por un algoritmo genético. El número de generaciones se fija en 50, y a su vez, el número de individuos por generación también se establece en 50. La selección de individuos para la siguiente generación se realiza por ruleta ordenada por rango. La probabilidad de cruce se establece en un 90% y la de mutación en un 1%. La función de activación para todas las neuronas es la tangente hiperbólica. Para evitar el sobre-entrenamiento nos servimos del grupo de validación. La no disminución del error con los datos del grupo de validación tras 50 epochs en el proceso de entrenamiento lo interrumpe, dejando la red neuronal con los valores de los parámetros (pesos de las conexiones) que proporcionan el menor error con los datos del grupo de validación. El límite máximo de epochs se fija en 3000 para aprendizaje supervisado y 800 para aprendizaje no supervisado (en caso de que la red neuronal disponga de este tipo de aprendizaje).

6.6.3 MODELOS BASADOS EN INFERENCIA NEURODIFUSA

Se desarrollan tres tipos de sistemas de inferencia neurodifusa (ANFIS), los tres con partición del espacio de entrada por agrupamiento sustractivo. Se utilizan los datos de los grupos de entrenamiento y validación en el desarrollo de los modelos.

Se crean numerosos submodelos modificando los diferentes parámetros que definen el modelo ANFIS.

Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- ANFIS 1B: División de datos tipo B, sin filtrado.
- ANFIS 2A: División de datos tipo A, con filtrado.
- ANFIS 2B: División de datos tipo B, con filtrado.

6.7 MODELOS DESARROLLADOS BASADOS EN WRF

Los modelos de predicción de series temporales que se analizan para el desarrollo del sistema de predicción incluyen el clásico modelo persistente, sólo para poder evaluar la eficiencia de los modelos desarrollados, modelos basados en redes neuronales artificiales y modelos basados en sistemas de inferencia neurodifusa. En este caso se han desechado otros modelos como los ARIMA o k -NN, teniendo en cuenta los resultados obtenidos para los modelos de predicción basados en MM5, desarrollados en las investigaciones iniciales vinculadas a la presente Tesis Doctoral.

En este caso, el desarrollo de los modelos cuyas variables atmosféricas, entradas, han sido obtenidas a partir del WRF-NMM, se ha dividido en dos fases y en una etapa final de optimización.

- **1^a Fase:** se desarrollan modelos basados en redes neuronales artificiales y basados en sistemas de inferencia neurodifusa, además del modelo persistente para evaluar la adecuación de los anteriores. Para el desarrollo de estos modelos se toma toda la serie temporal disponible, una para cada horizonte de predicción, ya descrita en el apartado 6.3 *Datos de partida: Modelos basados en WRF*.
- **2^a Fase:** en este caso se desarrollan únicamente modelos basados en redes neuronales. Pero en este caso para entrenar los modelos no se tiene en cuenta toda la serie temporal completa, sino que esta se subdivide en otras tres en función del tipo de día (claro, nublado o muy nublado / lluvioso) según los pronósticos meteorológicos locales.
- **Combinación de modelos:** se crea un modelo promedio entre las mejores redes neuronales para cada situación, se filtra y se realiza un ajuste estadístico.

A continuación se muestran dos flujogramas, Figura 6. 20 y Figura 6. 21, que muestran el proceso de desarrollo y evaluación de los modelos para la 1^a y la 2^a fase respectivamente.

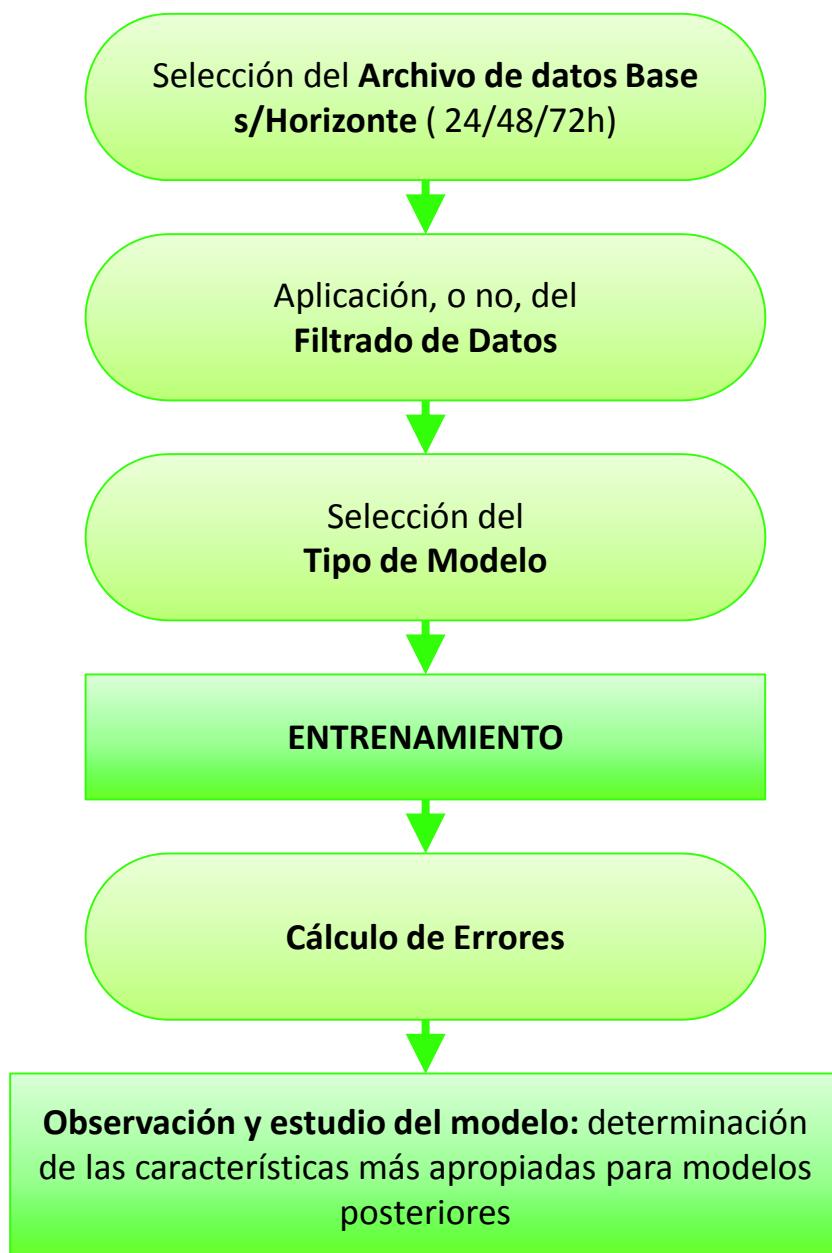


Figura 6. 20 Flujograma de desarrollo de los Modelos de Predicción 1ª Fase



Figura 6. 21 Flujograma de desarrollo de los Modelos de Predicción 2ª Fase

6.7.1 MODELOS DESARROLLADOS EN LA 1^a FASE

A continuación se van a describir brevemente los diferentes modelos de predicción desarrollados y analizados en la primera fase.

Teniendo en cuenta los resultados obtenidos para los modelos de predicción basados en MM5, también se ha aplicado el filtrado de datos en estos modelos.

6.7.1.1 MODELOS PERSISTENTES

El punto de partida para la evaluación de los modelos de predicción lo constituye el resultado obtenido con el modelo persistente. En este caso, se desarrollarán tres modelos persistentes, uno para cada horizonte de predicción:

1. La producción, la energía generada, para la hora x de mañana es igual a la producción a la hora x de ayer.
2. La producción para la hora x dentro de dos días es igual a la producción a la hora x de ayer.
3. La producción para la hora x dentro de tres días es igual a la producción a la hora x de ayer.

6.7.1.2 MODELOS BASADOS EN REDES NEURONALES ARTIFICIALES

RED NEURONAL PERCEPTRÓN MULTICAPA (MLP):

Se escoge una red neuronal MLP con dos capas ocultas. La estructura de esta red neuronal ya se ha visto con anterioridad, en la Figura 6. 11. En función de los horizontes de predicción (ya comentados con anterioridad) y posteriormente tras un filtrado de datos (también comentado), se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- MLP124: Horizonte de predicción día siguiente, sin filtrado.
- MLP224: Horizonte de predicción día siguiente, con filtrado.
- MLP148: Horizonte de predicción dentro de 2 días, sin filtrado.
- MLP248: Horizonte de predicción dentro de 2 días, con filtrado.
- MLP172: Horizonte de predicción dentro de 3 días, sin filtrado.
- MLP272: Horizonte de predicción dentro de 3 días, con filtrado.

RED NEURONAL MULTICAPA GENERALIZADA (FFBP):

Se escoge una red neuronal FFBP con dos capas ocultas. La estructura de esta red neuronal ya se ha visto con anterioridad, en la Figura 6. 13. En función de los horizontes de predicción (ya comentados con anterioridad) y posteriormente tras un filtrado de datos (también comentado), se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- FFBP124: Horizonte de predicción día siguiente, sin filtrado.
- FFBP224: Horizonte de predicción día siguiente, con filtrado.
- FFBP148: Horizonte de predicción dentro de 2 días, sin filtrado.
- FFBP248: Horizonte de predicción dentro de 2 días, con filtrado.
- FFBP172: Horizonte de predicción dentro de 3 días, sin filtrado.
- FFBP272: Horizonte de predicción dentro de 3 días, con filtrado.

RED NEURONAL MODULAR (MNN):

Se escoge una red neuronal modular con una estructura con dos pares de capas ocultas. Esta configuración permite la especialización de ambas redes con un grupo particular de datos del conjunto de entrenamiento, permitiendo, en algunos casos, mejores resultados que los obtenidos con las redes neuronales MLP. La conexión entre capas no significa que todas las neuronas de cada capa estén unidas entre sí. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- MNN124: Horizonte de predicción día siguiente, sin filtrado.
- MNN224: Horizonte de predicción día siguiente, con filtrado.
- MNN148: Horizonte de predicción dentro de 2 días, sin filtrado.
- MNN248: Horizonte de predicción dentro de 2 días, con filtrado.
- MNN172: Horizonte de predicción dentro de 3 días, sin filtrado.
- MNN272: Horizonte de predicción dentro de 3 días, con filtrado.

RED NEURONAL CON ANÁLISIS DE COMPONENTES PRINCIPALES (PCA):

La red neuronal PCA escogida consta de dos capas ocultas para el aprendizaje supervisado. El número de componentes principales se escoge por el proceso de optimización. Para el aprendizaje no supervisado el número de epochs máximo es de 800, con la posibilidad de que sea menor el número de epochs del entrenamiento no supervisado si el cambio en todos los pesos de las conexiones de las neuronas de la capa de neuronas de componentes principales es menor a 0,0001. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- PCA124O: Horizonte de predicción día siguiente, sin filtrado y reducción del espacio de entrada aplicando la regla de Oja.
- PCA224O: Horizonte de predicción día siguiente, con filtrado y reducción del espacio de entrada aplicando la regla de Oja.

- PCA148O: Horizonte de predicción dentro de 2 días, sin filtrado y reducción del espacio de entrada aplicando la regla de Oja.
- PCA248O: Horizonte de predicción dentro de 2 días, con filtrado y reducción del espacio de entrada aplicando la regla de Oja.
- PCA172O: Horizonte de predicción dentro de 3 días, sin filtrado y reducción del espacio de entrada aplicando la regla de Oja.
- PCA272O: Horizonte de predicción dentro de 3 días, con filtrado y reducción del espacio de entrada aplicando la regla de Oja.

RED NEURONAL DE FUNCIÓN DE BASE RADIAL (RBF):

Se escoge una red neuronal híbrida compuesta por una red neuronal RBF seguida por una red neuronal MLP con dos capas ocultas. La red con una capa de neuronas con función de activación de base radial actúa como la capa de entradas de la red neuronal MLP. Ambas redes neuronales se entrena separadamente: la red neuronal RBF se entrena con aprendizaje no supervisado con un máximo de 800 epochs, con la posibilidad de que sea menor el número de epochs del entrenamiento no supervisado si el cambio en todos los pesos de las conexiones de las neuronas de la capa de neuronas de función de base radial es menor a 0,0001. La red neuronal MLP se entrena, posteriormente, con aprendizaje supervisado con un máximo de 3000 epochs. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- RBF124: Horizonte de predicción día siguiente, sin filtrado.
- RBF224: Horizonte de predicción día siguiente, con filtrado.
- RBF148: Horizonte de predicción dentro de 2 días, sin filtrado.
- RBF248: Horizonte de predicción dentro de 2 días, con filtrado.
- RBF172: Horizonte de predicción dentro de 3 días, sin filtrado.
- RBF272: Horizonte de predicción dentro de 3 días, con filtrado.

RED NEURONAL HÍBRIDA CON MAPA AUTO-ORGANIZADO (SOM):

El mapa auto-organizado desarrollado se limita a una estructura 4x4 en seis de los submodelos y a una 7x7 en los otros tres. Este mapa auto-organizado sirve de capa de entradas a una red neuronal MLP con dos capas ocultas. Para el aprendizaje no supervisado el número de epochs máximo fue de 800, con la posibilidad de interrupción anticipada de este aprendizaje si el cambio en todos los pesos de las conexiones del mapa auto-organizado era menor a 0,0001. Los submodelos desarrollados son:

- SOM124: Horizonte de predicción día siguiente, sin filtrado y estructura 4x4.
- SOM224: Horizonte de predicción día siguiente, con filtrado y estructura 4x4.
- SOM2247X7: Horizonte de predicción día siguiente, con filtrado y estructura 7x7.
- SOM148: Horizonte de predicción dentro de 2 días, sin filtrado y estructura 4x4.
- SOM248: Horizonte de predicción dentro de 2 días, con filtrado y estructura 4x4.
- SOM2487X7: Horizonte de predicción de 2 días, con filtrado y estructura 7x7.
- SOM172: Horizonte de predicción dentro de 3 días, sin filtrado y estructura 4x4.
- SOM272: Horizonte de predicción dentro de 3 días, con filtrado y estructura 4x4.
- SOM2727X7: Horizonte de predicción de 3 días, con filtrado y estructura 7x7.

RED NEURONAL DE ELMAN:

Se escoge una red neuronal de Elman con dos capas ocultas. La capa de neuronas de contexto copia el contenido de la segunda capa oculta y las salidas de esta capa de neuronas de contexto actúan como entradas adicionales de la primera capa oculta. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- ELMAN124: Horizonte de predicción día siguiente, sin filtrado.

- ELMAN224: Horizonte de predicción día siguiente, con filtrado.
- ELMAN148: Horizonte de predicción dentro de 2 días, sin filtrado.
- ELMAN248: Horizonte de predicción dentro de 2 días, con filtrado.
- ELMAN172: Horizonte de predicción dentro de 3 días, sin filtrado.
- ELMAN272: Horizonte de predicción dentro de 3 días, con filtrado.

CARACTERÍSTICAS COMUNES A TODOS LOS MODELOS DE REDES NEURONALES:

Todos los modelos de redes neuronales desarrollados presentan una serie de características comunes, las cuales se indican a continuación. Por un lado se ha comentado que para cada tipo de red neuronal se han seleccionado entre todos los modelos desarrollados los mejores, concretamente se han elegido aquellos con menor *RMSE* medio (ponderado entre los datos de entrenamiento y validación).

El resto de características son idénticas a las comentadas con anterioridad en el apartado 6.6.2., excepto que ahora el límite máximo de epochs se fija en 3000 para aprendizaje supervisado y 800 para aprendizaje no supervisado (en caso de que la red neuronal disponga de este tipo de aprendizaje).

6.7.1.3 MODELOS BASADOS EN INFERENCIA NEURODIFUSA

Se desarrollan numerosos tipos de sistemas de inferencia neurodifusa (ANFIS), todos con partición del espacio de entrada por agrupamiento sustractivo. Se utilizan los datos de los grupos de entrenamiento y validación en el desarrollo de los modelos.

Se crean numerosos submodelos modificando lo diferentes parámetros que definen el modelo ANFIS, dando lugar a un número de reglas diferente.

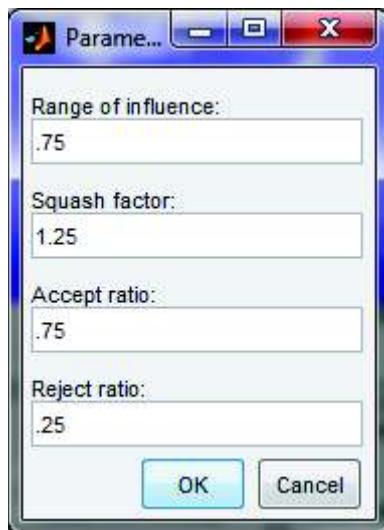


Figura 6. 22 Definición de parámetros modelo ANFIS (ejemplo)

Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los mejores:

- ANFIS124: Horizonte de predicción día siguiente, sin filtrado.
- ANFIS224: Horizonte de predicción día siguiente, con filtrado.
- ANFIS148: Horizonte de predicción dentro de 2 días, sin filtrado.
- ANFIS248: Horizonte de predicción dentro de 2 días, con filtrado.
- ANFIS172: Horizonte de predicción dentro de 3 días, sin filtrado.
- ANFIS272: Horizonte de predicción dentro de 3 días, con filtrado.

6.7.2 MODELOS DESARROLLADOS EN LA 2^a FASE

Gracias a la experiencia adquirida mediante el desarrollo de los modelos especificados en el punto anterior, se pasa a aplicar el filtrado de datos tras entrenar el modelo para optimizar los resultados.

La característica principal de los modelos de predicción desarrollados en esta fase es la clasificación de datos en función del tipo de día.

Cada una de las series temporales disponibles para cada horizonte se divide en tres categorías a partir de los pronósticos meteorológicos locales disponibles:

- Día Claro: 
- Nublado: 
- Muy Nublado / Lluvioso: 

De esta forma dispondremos de nueve series temporales diferentes para entrenar los diferentes modelos desarrollados.

Además, para estos modelos se incorporan como nuevas variables de entrada las especificadas en el apartado 6.3.3 *Incorporación de datos estadísticos como nuevas entradas*.

En este caso un modelo completo para un horizonte de predicción englobaría los 3 submodelos (una para cada tipo de día) de dicho horizonte.

En el próximo apartado se describirá el proceso de obtención de los modelos de predicción definitivos. Para ello se optimizarán los mejores modelos de los desarrollados en esta segunda fase.

A continuación se van a describir brevemente los diferentes modelos de predicción desarrollados y analizados en la segunda fase.

RED NEURONAL PERCEPTRÓN MULTICAPA (MLP):

Se escoge una red neuronal MLP con dos capas ocultas. En función de los horizontes de predicción y del tipo de día, que ya ha sido comentado, se han desarrollado numerosos submodelos, de los cuales se han seleccionado los de menor *RMSE* medio ponderado:

- MLPD124: Horizonte de predicción día siguiente, para día claro.
- MLPD224: Horizonte de predicción día siguiente, para día nublado.
- MLPD324: Horizonte de predicción día siguiente, para día muy nublado o lluvioso.
- MLPD148: Horizonte de predicción dentro de 2 días, para día claro.
- MLPD248: Horizonte de predicción dentro de 2 días, para día nublado.
- MLPD348: Horizonte de predicción dentro de 2 días, para día muy nublado o lluvioso.
- MLPD172: Horizonte de predicción dentro de 3 días, para día claro.
- MLPD272: Horizonte de predicción dentro de 3 días, para día nublado.
- MLPD372: Horizonte de predicción dentro de 3 días, para día muy nublado o lluvioso.

RED NEURONAL MULTICAPA GENERALIZADA (FFBP):

Se escoge una red neuronal FFBP con dos capas ocultas. En función de los horizontes de predicción y según el tipo de día, se han desarrollado numerosos submodelos, de los cuales se han seleccionado los de menor *RMSE* medio ponderado:

- FFBPD124: Horizonte de predicción día siguiente, para día claro.
- FFBPD224: Horizonte de predicción día siguiente, para día nublado.

- FFBPD324: Horizonte de predicción día siguiente, para día muy nublado o lluvioso.
- FFBPD148: Horizonte de predicción dentro de 2 días, para día claro.
- FFBPD248: Horizonte de predicción dentro de 2 días, para día nublado.
- FFBPD348: Horizonte de predicción dentro de 2 días, para día muy nublado o lluvioso.
- FFBPD172: Horizonte de predicción dentro de 3 días, para día claro.
- FFBPD272: Horizonte de predicción dentro de 3 días, para día nublado.
- FFBPD372: Horizonte de predicción dentro de 3 días, para día muy nublado o lluvioso.

RED NEURONAL MODULAR (MNN):

Se escoge una red neuronal modular con una estructura con dos pares de capas ocultas. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los de menor *RMSE* medio ponderado:

- MNND124: Horizonte de predicción día siguiente, para día claro.
- MNND224: Horizonte de predicción día siguiente, para día nublado.
- MNND324: Horizonte de predicción día siguiente, para día muy nublado o lluvioso.
- MNND148: Horizonte de predicción dentro de 2 días, para día claro.
- MNND248: Horizonte de predicción dentro de 2 días, para día nublado.
- MNND348: Horizonte de predicción dentro de 2 días, para día muy nublado o lluvioso.
- MNND172: Horizonte de predicción dentro de 3 días, para día claro.

- MNND272: Horizonte de predicción dentro de 3 días, para día nublado.
- MNND372: Horizonte de predicción dentro de 3 días, para día muy nublado o lluvioso.

RED NEURONAL CON ANÁLISIS DE COMPONENTES PRINCIPALES (PCA):

La red neuronal PCA escogida consta de dos capas ocultas para el aprendizaje supervisado. El número de componentes principales se escoge por el proceso de optimización. Para el aprendizaje no supervisado el número de epochs máximo es de 1000, con la posibilidad de que sea menor el número de epochs del entrenamiento no supervisado si el cambio en todos los pesos de las conexiones de las neuronas de la capa de neuronas de componentes principales es menor a 0,0001. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los de menor *RMSE* medio ponderado:

- PCAD124: Horizonte de predicción día siguiente, para día claro y reducción del espacio de entrada aplicando la regla de Sanger.
- PCAD124O: Horizonte de predicción día siguiente, para día claro y reducción del espacio de entrada aplicando la regla de Oja.
- PCAD224: Horizonte de predicción día siguiente, para día nublado (Sanger).
- PCAD324: Horizonte de predicción día siguiente, para día muy nublado o lluvioso (Sanger).
- PCAD148: Horizonte de predicción dentro de 2 días, para día claro (Sanger).
- PCAD248: Horizonte de predicción dentro de 2 días, para día nublado (Sanger).
- PCAD348: Horizonte de predicción dentro de 2 días, para día muy nublado o lluvioso (Sanger).
- PCAD172: Horizonte de predicción dentro de 3 días, para día claro (Sanger).

- PCAD272: Horizonte de predicción dentro de 3 días, para día nublado (Sanger).
- PCAD372: Horizonte de predicción dentro de 3 días, para día muy nublado o lluvioso (Sanger).

RED NEURONAL DE FUNCIÓN DE BASE RADIAL (RBF):

Se escoge una red neuronal híbrida compuesta por una red neuronal RBF seguida por una red neuronal MLP con dos capas ocultas. La capa de neuronas de función de base radial actúa como la capa de entradas de la red neuronal MLP. Ambas redes neuronales se entranan separadamente: la red neuronal RBF se entrena con aprendizaje no supervisado con un máximo de 1000 epochs, con la posibilidad de que sea menor el número de epochs del entrenamiento no supervisado si el cambio en todos los pesos de las conexiones de las neuronas de la capa de neuronas de función de base radial es menor a 0,0001. La red neuronal MLP se entrena, posteriormente, con aprendizaje supervisado con un máximo de 10000 epochs. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los de menor *RMSE* medio ponderado:

- RBFD124: Horizonte de predicción día siguiente, para día claro.
- RBFD224: Horizonte de predicción día siguiente, para día nublado.
- RBFD324: Horizonte de predicción día siguiente, para día muy nublado o lluvioso.
- RBFD148: Horizonte de predicción dentro de 2 días, para día claro.
- RBFD248: Horizonte de predicción dentro de 2 días, para día nublado.
- RBFD348: Horizonte de predicción dentro de 2 días, para día muy nublado o lluvioso.
- RBFD172: Horizonte de predicción dentro de 3 días, para día claro.
- RBFD272: Horizonte de predicción dentro de 3 días, para día nublado.
- RBFD372: Horizonte de predicción dentro de 3 días, para día muy nublado o lluvioso.

RED NEURONAL HÍBRIDA CON MAPA AUTO-ORGANIZADO (SOM):

El mapa auto-organizado desarrollado se limita a una estructura 4x4 en todos los submodelos destacados (otras estructuras resultan menos adecuadas). Este mapa auto-organizado sirve de capa de entradas a una red neuronal MLP con dos capas ocultas. Para el aprendizaje no supervisado el número de epochs máximo fue de 1000, con la posibilidad de interrupción anticipada de este aprendizaje si el cambio en todos los pesos de las conexiones del mapa auto-organizado era menor a 0,0001. Los submodelos desarrollados son:

- SOMD124: Horizonte de predicción día siguiente, para día claro.
- SOMD224: Horizonte de predicción día siguiente, para día nublado.
- SOMD324: Horizonte de predicción día siguiente, para día muy nublado o lluvioso.
- SOMD148: Horizonte de predicción dentro de 2 días, para día claro.
- SOMD248: Horizonte de predicción dentro de 2 días, para día nublado.
- SOMD348: Horizonte de predicción dentro de 2 días, para día muy nublado o lluvioso.
- SOMD172: Horizonte de predicción dentro de 3 días, para día claro.
- SOMD272: Horizonte de predicción dentro de 3 días, para día nublado.
- SOMD372: Horizonte de predicción dentro de 3 días, para día muy nublado o lluvioso.

RED NEURONAL DE ELMAN:

Se escoge una red neuronal de Elman con dos capas ocultas. La capa de neuronas de contexto copia el contenido de la segunda capa oculta y las salidas de esta capa de neuronas de contexto actúan como entradas adicionales de la primera capa

oculta. Se han desarrollado numerosos submodelos, de los cuales se han seleccionado los de menor *RMSE* medio ponderado:

- ELMAND124: Horizonte de predicción día siguiente, para día claro.
- ELMAND224: Horizonte de predicción día siguiente, para día nublado.
- ELMAND324: Horizonte de predicción día siguiente, para día muy nublado o lluvioso.
- ELMAND148: Horizonte de predicción dentro de 2 días, para día claro.
- ELMAND248: Horizonte de predicción dentro de 2 días, para día nublado.
- ELMAND348: Horizonte de predicción dentro de 2 días, para día muy nublado o lluvioso.
- ELMAND172: Horizonte de predicción dentro de 3 días, para día claro.
- ELMAND272: Horizonte de predicción dentro de 3 días, para día nublado.
- ELMAND372: Horizonte de predicción dentro de 3 días, para día muy nublado o lluvioso.

CARACTERÍSTICAS COMUNES A TODOS LOS MODELOS DE REDES NEURONALES:

Todos los modelos de redes neuronales desarrollados presentan una serie de características comunes, que son las mismas que las especificadas en el apartado anterior con la excepción de que el límite máximo de epochs se fija en 10000 para aprendizaje supervisado y 1000 para aprendizaje no supervisado (en caso de que la red neuronal disponga de este tipo de aprendizaje).

6.7.3 COMBINACIÓN DE MODELOS

Con el fin de obtener los modelos definitivos para cada horizonte de predicción, es decir, los modelos cuyas predicciones cometan el menor error posible, se realiza una combinación de los modelos descritos en el apartado anterior. Con esta combinación de modelos pretendemos hacer que el valor final de predicción corresponda a una función de los valores de predicción obtenidos con varios modelos, no solo con uno.

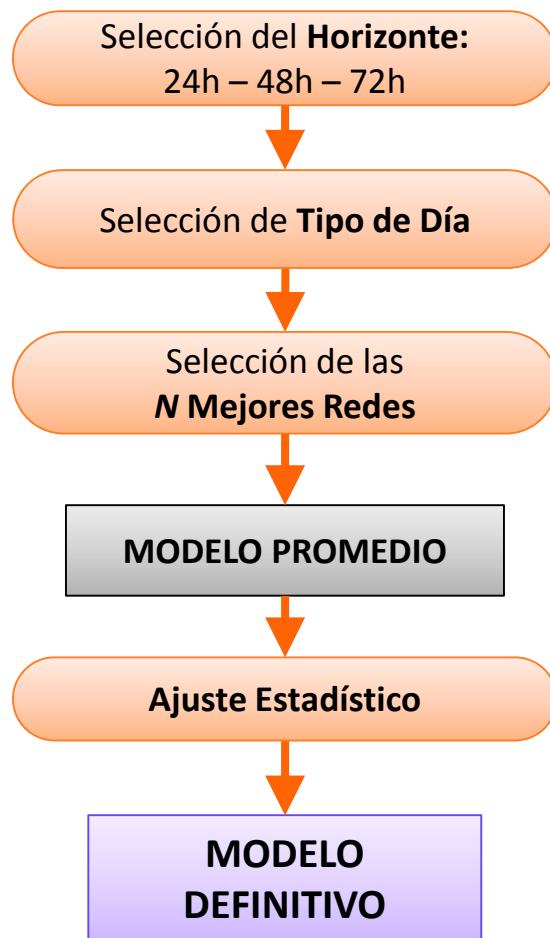


Figura 6. 23 Flujograma del proceso de combinación final

Para ello teniendo en cuenta el horizonte de predicción y el tipo de día, se seleccionan las N mejores redes, es decir, aquellas con menor RMSE medio (ponderado entre los datos de entrenamiento y validación), y se obtiene como resultado final de la predicción el valor promedio de sus salidas.

Esto se basa en la suposición de que varios expertos, de forma consensuada, pueden llegar a un mejor pronóstico que el mejor de los expertos en solitario [Seni10].

Tras esto se aplica el filtrado de datos ya comentado con anterioridad, con el fin de afinar las predicciones finales.

Este proceso de optimización final para desarrollar los modelos más eficientes se describe esquemáticamente en el flujoGRAMA de la Figura 6. 23.

CAPÍTULO

7

EVALUACIÓN DE LOS MODELOS

Para comprobar que los modelos de predicción de energía solar fotovoltaica son adecuados, es preciso evaluarlos, analizar sus resultados. A partir de estos resultados, se analiza su adecuación comparándolos con los de otros modelos de predicción. En este capítulo se presentan los resultados obtenidos para todos los modelos desarrollados (descritos en el capítulo anterior), así como sus comparaciones y particularidades.

El horizonte temporal de la predicción se centra sobre todo en las 24 horas del día siguiente en intervalos de 1 hora. Aunque tal y como se ha comentado con anterioridad, en el caso de los modelos que utilizan como modelo atmosférico el WRF-NMM, también se han desarrollado modelos de predicción a dos y tres días vista.

De todos los modelos desarrollados, en cada grupo, se va a seleccionar el modelo de predicción más adecuado, es decir, el que presente mejores resultados computacionales (error mínimo y menor complejidad).

Cómo ya se ha comentado anteriormente para el testeo de los modelos que toman como punto de partida el MM5 disponemos de las predicciones del modelo atmosférico que cubren la totalidad de un año, lo que permite utilizarlas en el desarrollo de modelos de predicción que requieran proceso de aprendizaje, como el caso de los modelos basados en redes neuronales. Para los basados en WRF-NMM, la serie temporal engloba 881 días.

En cuanto a los indicadores estadísticos que se van a utilizar para realizar la evaluación de los diferentes modelos de predicción desarrollados, cabe destacar que ya han sido explicados en detalle al inicio del *Capítulo 3: Estado del Arte*. Pese a ello cabe reseñar algún aspecto y recordar algún punto.

La adecuación de los modelos no será evaluada con los datos utilizados en su ajuste, sino con otro conjunto de valores (valores de testeo) de las variables explicativas. Esta prueba permitirá la comparación de los resultados (valores de predicción) entre diferentes modelos y la selección del modelo que arroje los menores errores de predicción.

Los criterios que más se van a utilizar para comparar la adecuación de los modelos, son el *MAE* y el *RMSE* referidos a la máxima potencia que el parque fotovoltaico puede producir (potencia instalada), es decir, normalizados. Así el indicador *MAE* normalizado se obtiene mediante la ecuación (3.8), y el indicador *RMSE* normalizado según la ecuación (3.9), siendo P_{inst} la potencia instalada del parque solar.

Además en algunos casos se va a cuantificar la mejora en el error de predicción que presenta un modelo con respecto a otro, que se toma como referencia, mediante la comparación relativa entre los valores de alguno de los indicadores de error, se define dicha mejora mediante la ecuación (3.10).

7.1 RESULTADOS GENERALES: MODELOS BASADOS EN MM5

En este apartado se van a presentar de forma resumida los resultados obtenidos por los modelos de predicción desarrollados en las investigaciones iniciales vinculadas a la presente Tesis Doctoral, es decir, los que utilizan como modelo atmosférico el MM5.

Tras el proceso de ajuste o entrenamiento de los modelos, y la aplicación de los mismos en la predicción de la energía generada a intervalos de una hora, se obtuvieron los resultados que se van a pormenorizar en los próximos párrafos.

El modelo persistente se aplicó directamente sobre los datos del grupo de testeо.

El modelo ARIMA se diseñó a partir de los datos de la energía generada, correspondientes a los grupos de entrenamiento y validación. Se diseñaron 6 modelos, incluyendo modelos auto-regresivos puros (con órdenes de 1 a 3) y modelos auto-regresivos de media móvil (el de mayor orden fue el modelo *ARMA(2, 2)*) sin considerar la estacionalidad; y además, se construyeron otros 6 modelos similares considerando la estacionalidad (con periodo de estacionalidad de 24 muestras, es decir, 24 horas). Una vez diseñados y evaluados los 12 modelos, se escogió aquél que proporcionaba un valor menor del error *RMSE* con los datos utilizados en el ajuste del modelo (coincidía en ser también el modelo con menor valor del criterio de información de *Akaike (AIC)*, y las gráficas de auto-correlación y auto-correlación parcial también sugerían que el modelo de predicción debería tener su misma estructura). Este modelo fue el *ARIMA (3, 0, 2)(1, 0, 0)₂₄*. Desarrollando la ecuación (7.1) obtenemos la ecuación (7.3) que proporciona el valor de predicción:

$$\phi_3(B)\Phi_1(B^{24})X_t = \phi_0 + \theta_2(B)e_t \quad (7.1)$$

$$(1 - \phi_1B - \phi_2B^2 - \phi_3B^3) \cdot (1 - \Phi_1B^{24})X_t = \phi_0 + \theta_2(B)e_t \quad (7.2)$$

Operando obtenemos:

$$E_t = \phi'_0 + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \phi_3 X_{t-3} + \Phi_1 X_{t-24} - \phi_1 \Phi_1 X_{t-25} - \phi_2 \Phi_1 X_{t-26} - \phi_3 \Phi_1 X_{t-27} - \theta_1 e_{t-1} - \theta_2 e_{t-2} \quad (7.3)$$

Siendo:

$$X_{t-i} = E_{t-i} - \phi'_0 \quad (7.4)$$

E_t : energía generada en el instante t

E_{t-i} : energía generada en el instante $t - i$

e_{t-i} : error en la predicción de la energía generada para el instante $t - i$

Los valores de los coeficientes se expresan a continuación en la Tabla 7. 1:

Tabla 7. 1 Coeficientes del modelo ARIMA (3, 0, 2)(1, 0, 0)₂₄

Coeficiente	Valor
ϕ'_0	6922
θ_1	-0,2361
θ_2	0,73745
ϕ_1	0,74889
ϕ_2	0,86583
ϕ_3	-0,75119
Φ_1	0,51138

La ecuación (7.3) permite la predicción de la energía generada para la siguiente hora (con horizonte de predicción de 1 hora). Para la predicción con horizontes mayores, sólo hay que aplicar de forma iterativa la ecuación anterior, obteniendo sucesivamente las predicciones para horizontes “intermedios” hasta alcanzar el horizonte deseado. Hay términos que a medida que crece el horizonte de predicción van desapareciendo, para predicción a 2 horas desaparece el término de error e_{t-1} , y para la predicción a 3 horas ya desaparece e_{t-2} . Además a medida que se aumenta el horizonte de predicción los valores de E_{t-i} , pasan a ser sustituidos por predicciones de horizontes anteriores.

En la Figura 7. 1 se representa el error *RMSE* (calculado para el grupo de testeo de la División de datos tipo B) en función del horizonte de predicción para el modelo ARIMA desarrollado:

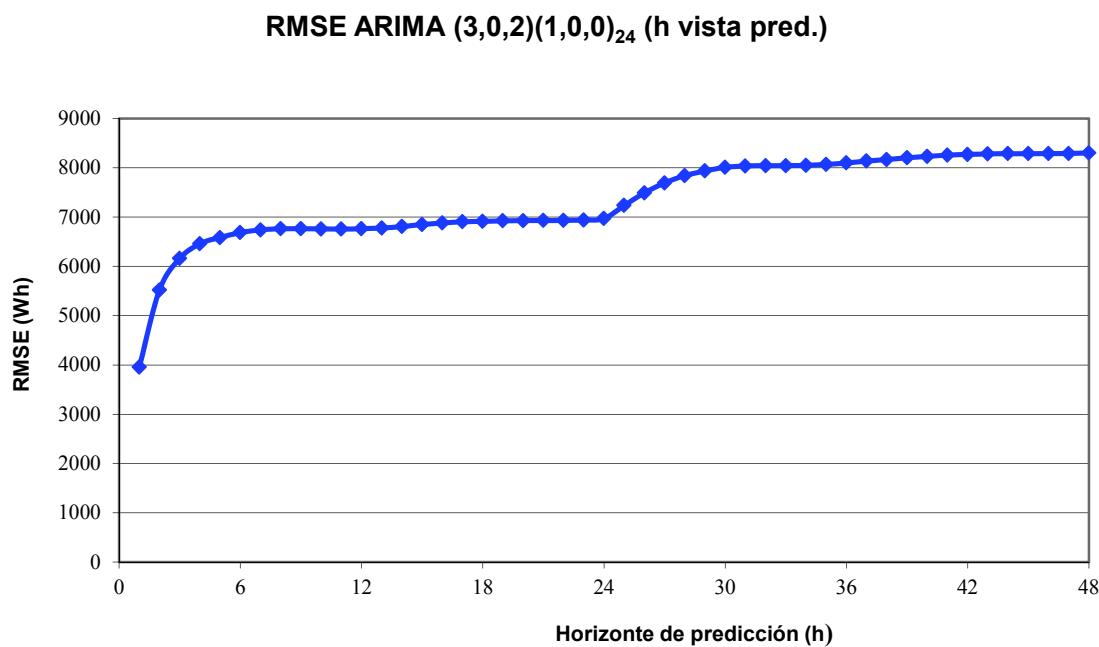


Figura 7. 1 Representación gráfica del error RMSE en función del horizonte de predicción del ARIMA (3,0,2)(1,0,0)₂₄

Para comparar los errores obtenidos con el ARIMA (3, 0, 2)(1, 0, 0)₂₄ con el resto de modelos, se tomará la media del error para el horizonte de predicción 16-41 h, que corresponde a todo el día siguiente, considerando tanto horario de verano como horario de invierno).

Tras comparar los resultados del modelo ARIMA anterior con el persistente, se observó que los resultados eran peores, lo cual era plausible ya que, la presencia de incertidumbre en dicho modelo era considerable. Por esta razón se desarrollaron otra serie de modelos ARIMA teniendo en cuenta básicamente la estacionalidad. De todos ellos se escogió el mejor modelo siendo un ARIMA (1,0,1)₂₄, que se desarrolló utilizando exclusivamente los datos de la serie temporal correspondiente al día anterior considerando únicamente la estacionalidad.

En cuanto al modelo del vecino más próximo, se ha realizado tomando de uno a diez vecinos, es decir como mínimo tomando el registro anterior más aproximado o similar (en término euclídeos) y como máximo la media (aritmética o ponderada) de los diez registros más aproximados.

A continuación, en la Figura 7. 2, se muestra el gráfico con los errores *RMSE* obtenidos para este tipo de modelo tomando de uno a diez vecinos, y para ambos tipos de media (aritmética o ponderada según la inversa de la distancia). Para comparar los errores obtenidos con el modelo del vecino más próximo con el resto de modelos, se tomará el error correspondiente a 10 vecinos para la media ponderada (por ser el menor).

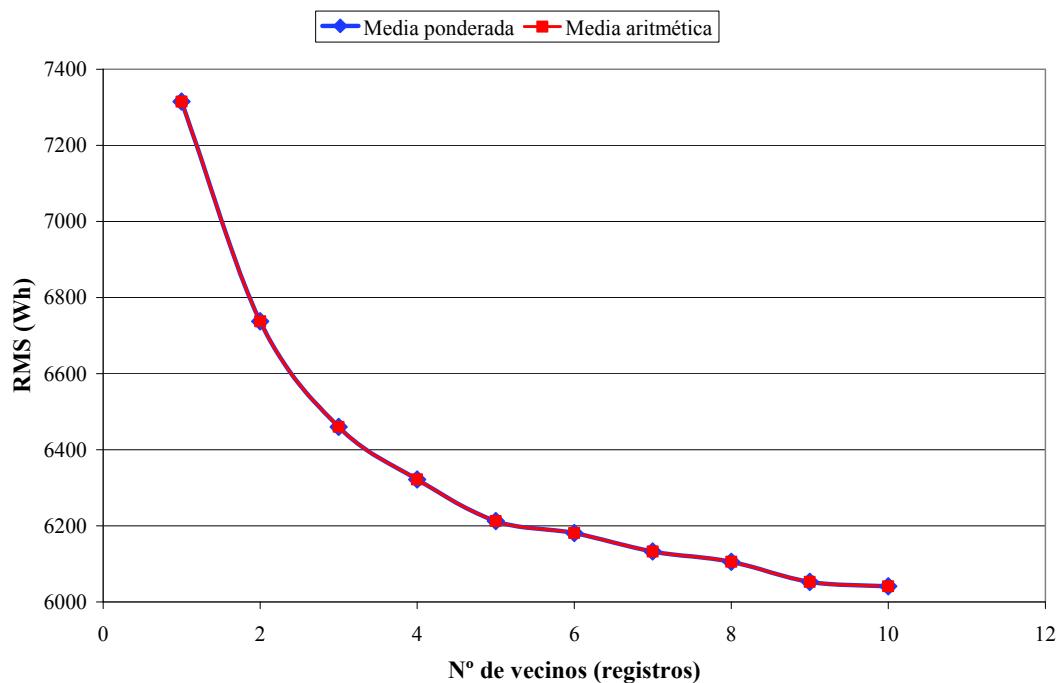


Figura 7. 2 Representación gráfica del error *RMSE* en función del nº de vecinos del modelo del vecino más próximo

En cuanto al desarrollo de los modelos basados en los sistemas de inferencia neurodifusa, además de lo comentado con anterioridad, es de destacar que en todos los casos la partición del espacio de entrada por agrupamiento sustractivo se realizó de forma que quedasen 5 reglas (*mfs*) para aplicar.

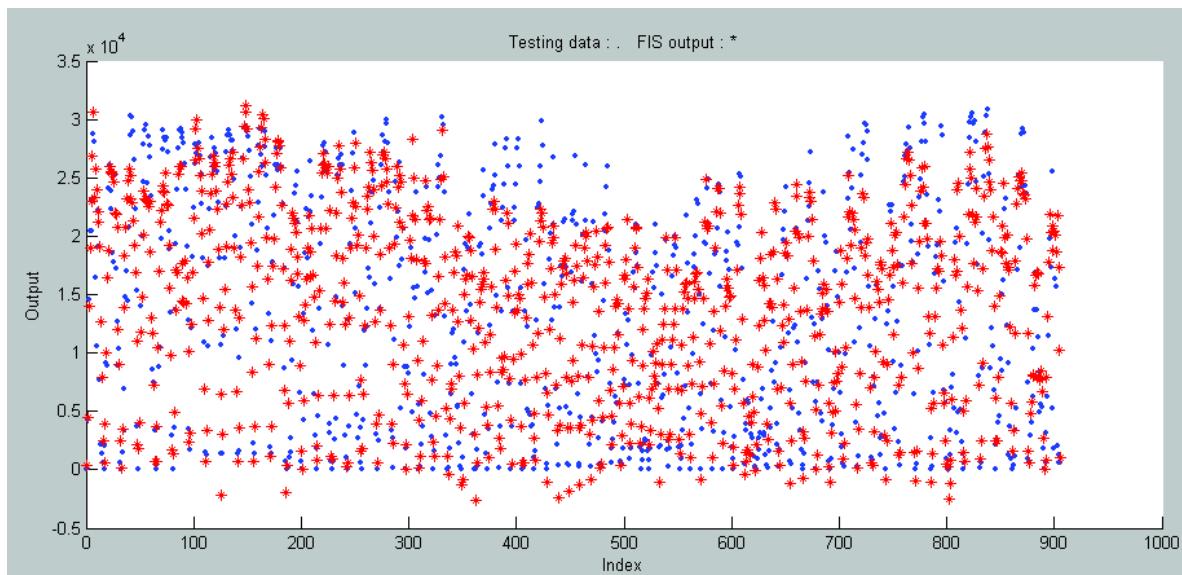


Figura 7. 3 Representación gráfica del grupo de testeo frente a sus predicciones (ANFIS 2A)

En la Figura 7. 3 podemos ver representados de forma gráfica los puntos correspondientes a los valores del grupo de testeo (en azul) y los correspondientes a sus predicciones (en rojo) del modelo ANFIS 2A (el cuál, como veremos más adelante, es el modelo de inferencia difusa con el que se han obtenido menores errores).

En el desarrollo de los modelos basados en redes neuronales artificiales se permitió que el proceso de optimización (con algoritmo genético) pudiera elegir las variables de entrada de las redes neuronales. Para el diseño de cada red neuronal, era posible escoger entre diversas variables de entrada. Dichas variables podían ser las indicadas a continuación.

- Día de la predicción (normalizado a las variables Dia_{seno} y Dia_{cos}).
- Hora de la predicción (normalizado a las variables $Tiempo_{seno}$ y $Tiempo_{cos}$).
- Predicciones de los diferentes tipos de radiación a partir del modelo MM5
- Predicciones de la temperatura a partir del modelo MM5

Inicialmente se estudiaron los siguientes modelos:

- MLP 1B
- FFBP 1B
- MNN 1B
- ELMAN 1B
- PCA 1B
- RBF 1B
- SOM 1B4
- GAMMA F
- LAGUERRE F
- TDNN F

Tabla 7. 2 Resultados iniciales con redes neuronales

Modelo	RMSE	
	(Wh)	(%)
MLP 1B	5522,35	15,34
FFBP 1B	5350,87	14,86
MNN 1B	5341,96	14,84
Elman 1B	4964,37	13,79
PCA 1B	5198,74	14,44
RBF 1B	5442,78	15,12
SOM 1B4	5501,52	15,28
GAMMA F	4897,96	13,61
LAGUERRE F	5401,04	15,00
TDNN F	5315,29	14,76

De los resultados obtenidos (ver Tabla 7. 2) se dedujo que había cierta recurrencia, puesto que el *GAMMA F*, tenía el menor error. Por esta razón a partir de este momento se decidió incluir en los modelos no recurrentes desarrollados las variables correspondientes a las predicciones obtenidas con el modelo MM5 no sólo para el instante t , sino también para los instantes $t - 1$ y $t + 1$, con el fin de mejorar los resultados.

Tras esto se desarrollaron estos modelos:

- MLP 1A
- GAMMA NF
- LAGUERRE NF
- TDNN NF

Tras realizar tantos trabajos con los datos, se observó que la energía generada era nula cuando la variable *SWOUT* era también nula, por lo que se realizó lo que se ha denominado anteriormente como filtrado de los datos. Se omitieron estos datos del proceso de entrenamiento, con el propósito de que la red neuronal se centrase en el resto de datos (ya que los momentos de energía nula quedaban determinados por la variable *SWOUT*).

Así se desarrollaron los modelos que aparecen a continuación, obviamente todos ellos eran redes neuronales no recurrentes, ya que las recurrentes no pueden usarse debido a la falta de datos intermedios.

- MLP 2A
- MLP 2B
- FFBP 2A

- MNN 2A
- PCA 2AOja
- PCA 2ASanger
- RBF 2A
- SOM 2A4
- SOM2A7

Con el fin de visualizar los resultados de los modelos desarrollados disponemos de la Tabla 7. 3, donde se representan los errores RMSE en la predicción de la energía generada para el grupo de testeo propio del modelo y para el grupo de testeo común entre la división de datos tipo A y B (ya explicado con anterioridad). Es decir, para comparar modelos que tengan el mismo tipo de división de datos nos fijaremos en el $RMSE_{Propio}$ y para comparar modelos con distinto tipo de división de datos (uno tipo A con otro tipo B) nos fijaremos en el error $RMSE_{Común}$.

Tabla 7. 3 Errores RMSE para los modelos de predicción desarrollados

Modelo	RMSE _{Propio}		RMSE _{Común}	
	(Wh)	(%)	(Wh)	(%)
Persistente	7530,91	20,92		
ARIMA(3,0,2)(1,0,0) ₂₄	7609,12	21,14		
ARIMA (1,0,1) ₂₄	6249,30	17,36		
Vecino más próximo	6041,25	16,78		
MLP 1A	4255,19	11,82	4967,25	13,80
MLP 1B	5522,35	15,34	5452,58	15,15
MLP 2A	4243,01	11,79	4740,19	13,17
MLP 2B	4999,16	13,89	5008,43	13,91
FFBP 1B	5350,87	14,86	5065,47	14,07
FFBP 2A	4419,71	12,28	4833,94	13,43
MNN 1B	5341,96	14,84	5523,97	15,34
MNN 2A	4377,83	12,16	4903,67	13,62

Elman 1B	4964,37	13,79		
PCA 1B	5198,74	14,44	5395,56	14,99
PCA 2AOja	4355,08	12,10	4761,10	13,23
PCA 2ASanger	4384,99	12,18	4836,60	13,44
RBF 1B	5442,78	15,12	5648,83	15,69
RBF 2A	4429,43	12,30	4960,24	13,78
SOM 1B4	5501,52	15,28	5452,46	15,15
SOM 2A4	4364,22	12,12	4955,36	13,76
SOM 2A7	4485,65	12,46	4945,36	13,74
GAMMA F	4897,96	13,61		
GAMMA NF	5476,05	15,21		
LAGUERRE F	5401,04	15,00		
LAGUERRE NF	5086,82	14,13		
TDNN F	5315,29	14,76		
TDNN NF	5362,77	14,90		
ANFIS 1B	5466,15	15,18		
ANFIS 2A	4375,21	12,15	4872,24	13,53
ANFIS 2B	5072,34	14,09		

De todos los modelos tipo A destacamos los dos modelos con menor RMSE_{Propio}, y además los dos mejores entre los modelos tipo B (con su RMSE_{Propio}) y los tipo A (con su RMSE_{Común}).

De forma que queda claro que de todos los modelos de predicción desarrollados el modelo más adecuado para la predicción de la energía eléctrica generada por parques solares fotovoltaicos es el **MLP 2A**.

7.2 ANÁLISIS DETALLADO DEL MODELO ÓPTIMO BASADO EN MM5

Las características de la red neuronal MLP del modelo que da los mejores resultados (de los modelos que toman como punto de partida el modelo MM5), denominado **MLP 2A**, en la predicción son las indicadas a continuación:

- Entradas utilizadas: 15 de las 23 variables de entrada posibles, concretamente:
 - $Tiempo_{seno}$
 - $Tiempo_{cos}$
 - $SHFLUX\ t-1\ (W/m^2)$
 - $LWDOWN\ t-1\ (W/m^2)$
 - $LWOUT\ t-1\ (W/m^2)$
 - $LHFLUX\ (W/m^2)$
 - $SWOUT\ (W/m^2)$
 - $LWOUT\ (W/m^2)$
 - $Temperatura(K)$
 - $LHFLUX\ t+1\ (W/m^2)$
 - $SWDOWN\ t+1\ (W/m^2)$
 - $LWDOWN\ t+1\ (W/m^2)$
 - $SWOUT\ t+1\ (W/m^2)$
 - $LWOUT\ t+1\ (W/m^2)$
 - $Temperatura\ t+1\ (K)$
- 7 neuronas en la primera capa oculta y 7 neuronas en la segunda capa oculta.

En la Figura 7. 4, podemos ver el gráfico de sensibilidad, en el que podemos ver la importancia de cada entrada en el valor de la energía.

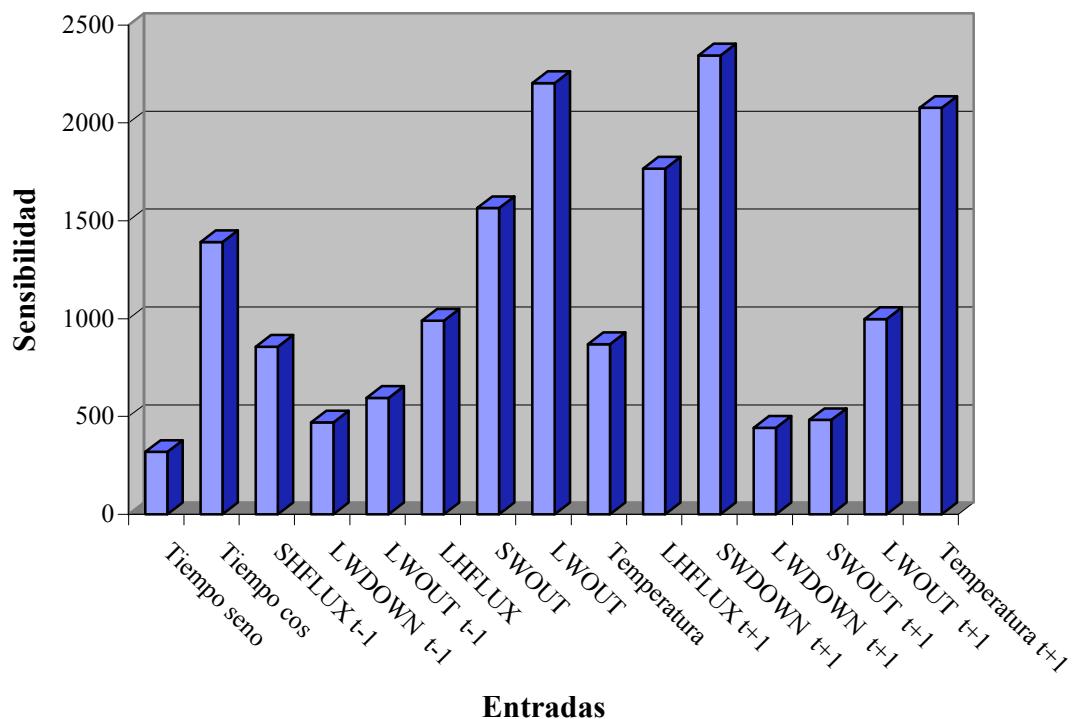


Figura 7. 4 Gráfico de sensibilidad de las variables de entrada (MLP 2A)

Además, centrándonos con mayor detalle en el modelo *MLP 2A* desarrollado, podemos observar lo siguiente en cuanto a su error absoluto medio (*MAE*) y al error real medio (*ME*):

Tabla 7. 4 Errores *MAE* y *ME* para el modelo de predicción *MLP 2A*

MAE_{Propio}		MAE_{Común}		ME_{Propio}		ME_{Común}	
(Wh)	(%)	(Wh)	(%)	(Wh)	(%)	(Wh)	(%)
2308,27	6,41	2524,28	7,01	99,54	0,28	-42,77	-0,12

De forma que podemos observar que el error absoluto medio oscila entre el 6,41 – 7,01 %, y el error real cometido a lo largo de todo el período de testeo ha sido inferior al

0,28 %, lo cual quiere decir, que la suma de la energía predicha a lo largo de todo el período y la energía real producida se diferenciará muy poco, concretamente:

Tabla 7. 5 Diferencia entre la energía total real y predicha para el grupo de testeo propio

E _{TReal} (Wh)	E _{TPredicha} (Wh)	Error (%)
12142112	11970986,21	1,41

Tabla 7. 6 Diferencia entre la energía total real y predicha para el grupo de testeo común

E _{TReal} (Wh)	E _{TPredicha} (Wh)	Error (%)
2849201	2866973,48	0,62

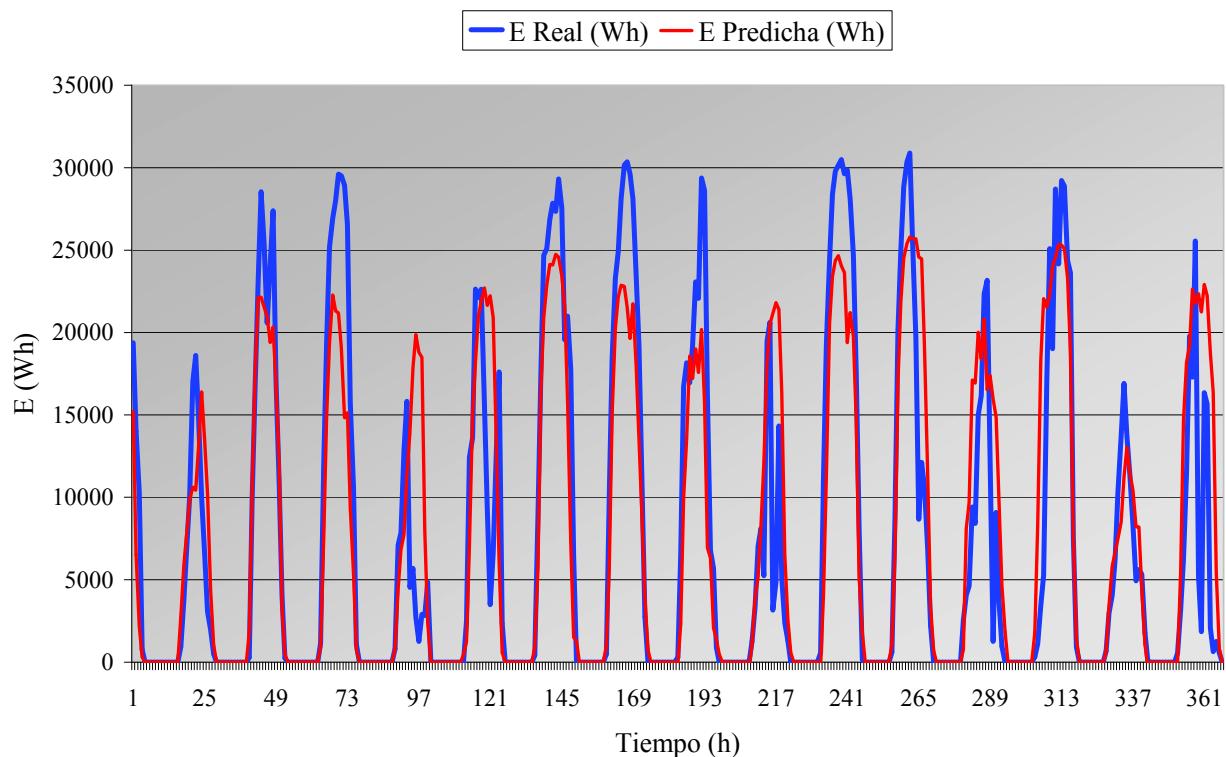


Figura 7. 5 Gráfico de comparación entre la energía real generada y la predicha

Teniendo en cuenta que los resultados para el grupo de testeo común son algo peores, se presenta en la Figura 7. 5, un gráfico de comparación entre la energía predicha y la real generada para todo el grupo de testeo común.

7.3 RESULTADOS GENERALES: MODELOS BASADOS EN WRF

En este apartado se van a presentar de forma resumida los resultados obtenidos por los modelos de predicción desarrollados en las investigaciones finales vinculadas a la presente Tesis Doctoral, es decir, los que utilizan como modelo atmosférico el WRF-NMM.

Tras el proceso de ajuste o entrenamiento de los modelos, y la aplicación de los mismos en la predicción de la energía generada a intervalos de una hora, se obtuvieron los resultados que se van a pormenorizar en los próximos subapartados.

7.3.1 MODELOS DESARROLLADOS EN LA 1^a FASE

El **modelo persistente** se aplicó directamente sobre los datos del grupo de testeo. Concretamente, hay tres modelos persistentes, uno para cada horizonte de predicción:

1. La producción, la energía generada, para la hora x de mañana es igual a la producción a la hora x de ayer.
2. La producción para la hora x dentro de dos días es igual a la producción a la hora x de ayer.
3. La producción para la hora x dentro de tres días es igual a la producción a la hora x de ayer.

En cuanto al desarrollo de los **modelos** basados en los sistemas de **inferencia neurodifusa**, además de lo comentado con anterioridad es de destacar que en todos los casos, la partición del espacio de entrada por agrupamiento sustractivo se realizó de forma que quedasen de 5 a 6 reglas (*mfs*) para aplicar.

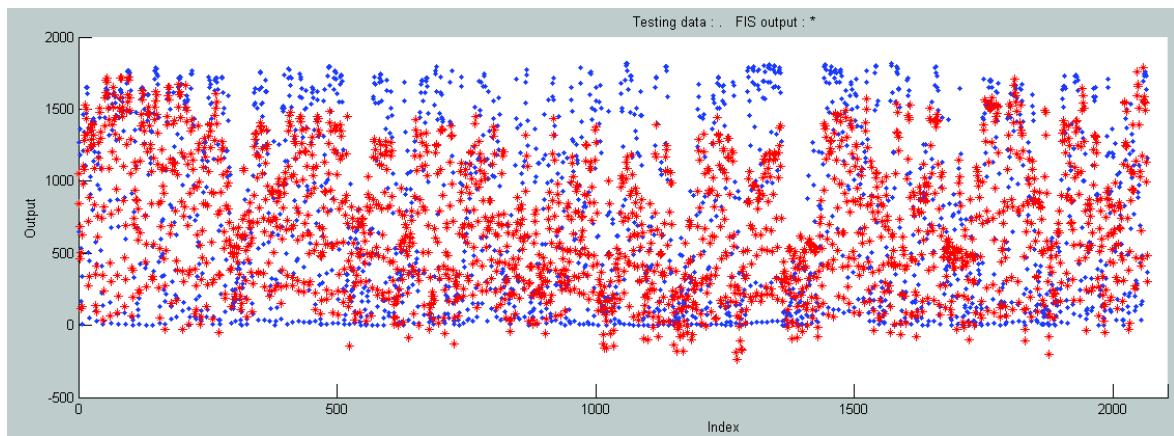


Figura 7. 6 Representación gráfica del grupo de testeo frente a sus predicciones (ANFIS224)

En la Figura 7. 6 podemos ver representados de forma gráfica los puntos correspondientes a los valores del grupo de testeo (en azul) y los correspondientes a sus predicciones (en rojo) del modelo ANFIS224 (el modelo de inferencia difusa con el que se han obtenido menores errores en la predicción de la producción para el día siguiente).

En el desarrollo de los **modelos** basados en **redes neuronales** artificiales se permitió que el proceso de optimización (con algoritmo genético) pudiera elegir las variables de entrada de las redes neuronales. Para el diseño de cada red neuronal, era posible escoger entre diversas variables de entrada. Dichas variables podían ser las indicadas a continuación.

- Día de la predicción (normalizado a las variables Dia_{seno} y Dia_{cos}).
- Hora de la predicción (normalizado a las variables $Tiempo_{seno}$ y $Tiempo_{cos}$).
- Predicciones de radiación en la superficie terrestre (real y día claro) a partir del modelo WRF-NMM
- Predicciones de la humedad relativa a partir del modelo WRF-NMM
- Predicciones de la cobertura de nubes (baja, media, alta) a partir del modelo WRF-NMM
- Predicciones de la velocidad y dirección del viento a partir del modelo WRF-NMM
- Predicciones de la temperatura a partir del modelo WRF-NMM

Inicialmente se estudiaron los siguientes modelos:

- MLP124 – MLP148 – MLP172
- FFBP124 – FFBP148 – FFBP172
- MNN124 – MNN148 – MNN172
- PCA124O – PCA148O – PCA172O
- RBF124 – RBF148 – RBF172
- SOM124 – SOM148 – SOM172
- ELMAN124 – ELMAN148 – ELMAN172

Al igual que ocurría con los modelos basados en MM5, se observó que la energía generada era nula cuando la variable *RSWIN* era también nula, por lo que se realizó lo que se ha denominado anteriormente como filtrado de los datos. Se omitieron estos datos del proceso de entrenamiento, con el propósito de que la red neuronal se centrase en el resto de datos (ya que los momentos de energía nula quedaban determinados por la variable *RSWIN*). Así se desarrollaron los modelos que aparecen a continuación, aplicando el filtrado de datos.

- MLP224 – MLP248 – MLP272
- FFBP224 – FFBP248 – FFBP272
- MNN224 – MNN248 – MNN272
- PCA224O – PCA248O – PCA272O
- RBF224 – RBF248 – RBF272
- SOM224 – SOM248 – SOM272 – SOM2247X7 – SOM2487X7 – SOM2727X7
- ELMAN224 – ELMAN248 – ELMAN272

Con el fin de visualizar los resultados de los modelos desarrollados disponemos de las tres tablas adjuntadas a continuación (una para cada horizonte), donde se representan los errores RMSE en la predicción de la energía generada para el grupo de testeo.

Tabla 7. 7 Resultados de los modelos de la 1^a Fase (Horizonte 1 día)

Modelo	RMSE	
	(kWh)	(%)
PERSISTENTE24	421,721	21,09
ANFIS124	296,113	14,81
ANFIS224	277,704	13,89
MLP124	267,769	13,39
MLP224	265,592	13,28
FFBP124	281,896	14,09
FFBP224	276,294	13,81
MNN124	273,909	13,70
MNN224	275,091	13,75
PCA124O	262,365	13,12
PCA224O	285,105	14,26
RBF124	281,674	14,08
RBF224	271,823	13,59
SOM124	320,967	16,05
SOM224	303,898	15,91
SOM2247X7	291,610	14,58
ELMAN124	296,044	14,80
ELMAN224	269,735	13,49

Tabla 7. 8 Resultados de los modelos de la 1^a Fase (Horizonte 2 días)

Modelo	RMSE	
	(kWh)	(%)
PERSISTENTE48	446,496	22,32
ANFIS148	306,221	15,31
ANFIS248	296,496	14,82
MLP148	290,139	14,51
MLP248	290,583	14,53
FFBP148	299,501	14,98
FFBP248	295,455	14,77
MNN148	295,861	14,79
MNN248	289,308	14,47
PCA148O	285,024	14,25
PCA248O	293,820	14,69
RBF148	314,08	15,70
RBF248	305,838	15,29
SOM148	321,631	16,08
SOM248	323,640	16,18
SOM2487X7	301,995	15,10
ELMAN148	281,035	14,05
ELMAN248	284,477	14,22

Tabla 7. 9 Resultados de los modelos de la 1^a Fase (Horizonte 3 días)

Modelo	RMSE	
	(kWh)	(%)
PERSISTENTE72	475,039	23,75
ANFIS172	322,225	16,11
ANFIS272	307,632	15,38
MLP172	298,11	14,91
MLP272	296,900	14,84
FFBP172	301,125	15,06
FFBP272	299,694	14,98
MNN172	307,047	15,35
MNN272	297,571	14,88
PCA172O	306,446	15,32
PCA272O	302,219	15,11
RBF172	319,558	15,98
RBF272	314,771	15,74
SOM172	334,252	16,71
SOM272	341,117	17,06
SOM2727X7	321,592	16,08
ELMAN172	307,083	15,35
ELMAN272	299,648	14,98

Para cada horizonte de predicción se destacan los dos modelos sin aplicar el filtrado de datos y los dos modelos con filtrado que obtienen menor *RMSE*. El mejor de cada horizonte aparece más destacado que el resto.

De forma que queda claro que de todos los modelos de predicción desarrollados para cada horizonte en esta primera fase, los modelos más adecuados para la predicción de la energía eléctrica generada en el parque solar fotovoltaico son **PCA124O** (1 día vista), **ELMAN148** (2 días vista) y **MLP272** (3 días vista).

7.3.2 MODELOS DESARROLLADOS EN LA 2^a FASE

A partir de los resultados obtenidos mediante los modelos desarrollados en la 1^a fase de esta etapa final de las investigaciones vinculadas a la Tesis, queda patente que la aplicación del filtrado de datos antes del entrenamiento, en este caso, no obtiene mejores resultados que si el filtrado se aplica después, una vez el modelo obtiene sus valores de salida. Por ello en este caso, el filtrado se aplica con posterioridad.

Además, cabe recordar que en esta segunda fase se van a incorporar como entradas una serie de estadísticos nuevos:

- SUNSHINE: nº de horas de sol.
- RADMEDIA: radiación media predicha para el día horizonte.
- I0CORR: radiación extraterrestre para el día horizonte.
- Idb-Ida: incremento de diferencia entre radiaciones (cambios bruscos en las condiciones meteorológicas).
- Idb-Ida maxd: Máximo diario del incremento de diferencia entre radiaciones.
- (I0N-RADN)²: diferencia cuadrada entre radiaciones normalizadas (cambios muy bruscos en las condiciones meteorológicas).
- NDD: variable que permite intuir comportamientos irregulares en la producción fotovoltaica.
- SIMESTACION: similaridad de estación.
- ALTSOLAR (γ_S): altura solar.
- AZIMUT (ψ_S): azimut.
- TEMPMEDIA: temperatura media diaria.

Por otro lado, la característica principal de los modelos de predicción desarrollados en esta fase es la clasificación de datos en función del tipo de día.

Cada una de las series temporales disponibles para cada horizonte se divide en tres categorías a partir de los pronósticos meteorológicos locales disponibles:

- Día Claro: 
- Nublado: 
- Muy Nublado / Lluvioso: 

De forma que los modelos desarrollados durante esta fase son los que se indican a continuación:

- MLPD124 – MLPD224 – MLPD324
- MLPD148 – MLPD248 – MLPD348
- MLPD172 – MLPD272 – MLPD372
- FFBPD124 – FFBPD224 – FFBPD324
- FFBPD148 – FFBPD248 – FFBPD348
- FFBPD172 – FFBPD272 – FFBPD372
- MNND124 – MNND224 – MNND324
- MNND148 – MNND248 – MNND348
- MNND172 – MNND272 – MNND372
- PCAD124 – PCAD124O – PCAD224 – PCAD324
- PCAD148 – PCAD248 – PCAD348
- PCAD172 – PCAD272 – PCAD372

- RBFD124 – RBFD224 – RBFD324
- RBFD148 – RBFD248 – RBFD348
- RBFD172 – RBFD272 – RBFD372
- SOMD124 – SOMD224 – SOMD324
- SOMD148 – SOMD248 – SOMD348
- SOMD172 – SOMD272 – SOMD372
- ELMAND124 – ELMAND224 – ELMAND324
- ELMAND148 – ELMAND248 – ELMAND348
- ELMAND172 – ELMAND272 – ELMAND372

Con el fin de visualizar los resultados de los modelos desarrollados disponemos de las nueve tablas adjuntadas a continuación (una para cada horizonte y tipo de día), donde se representan los errores RMSE en la predicción de la energía generada para el grupo de testeo.

Tabla 7. 10 Resultados de los modelos de la 2^a Fase (Horizonte 1 día – Día Claro)

Modelo	RMSE	
	(kWh)	(%)
MLPD124	208,086	10,40
FFBPD124	223,190	11,16
MNND124	211,909	10,60
PCAD124	205,27	10,26
PCAD124O	233,932	11,70
RBFD124	192,291	9,61
SOMD124	225,587	11,28
ELMAND124	221,096	11,05

Tabla 7. 11 Resultados de los modelos de la 2^a Fase (Horizonte 1 día – Día Nublado)

Modelo	RMSE	
	(kWh)	(%)
MLPD224	243,366	12,17
FFBPD224	250,427	12,52
MNND224	250,526	12,53
PCAD224	252,974	12,65
Rbfd224	254,16	12,71
SOMD224	271,001	13,55
ELMAND224	250,666	12,53

Tabla 7. 12 Resultados de los modelos de la 2^a Fase (Horizonte 1 día – Día Muy Nublado/lluvioso)

Modelo	RMSE	
	(kWh)	(%)
MLPD324	111,798	5,59
FFBPD324	121,120	6,06
MNND324	115,121	5,76
PCAD324	122,821	6,14
Rbfd324	103,997	5,20
SOMD324	116,236	5,81
ELMAND324	114,374	5,72

Tabla 7. 13 Resultados de los modelos de la 2^a Fase (Horizonte 2 días – Día Claro)

Modelo	RMSE	
	(kWh)	(%)
MLPD148	234,782	11,74
FFBPD148	236,123	11,81
MNND148	228,575	11,43
PCAD148	222,418	11,12
RBFD148	196,505	9,83
SOMD148	243,112	12,16
ELMAND148	259,103	12,96

Tabla 7. 14 Resultados de los modelos de la 2^a Fase (Horizonte 2 días – Día Nublado)

Modelo	RMSE	
	(kWh)	(%)
MLPD248	259,416	12,97
FFBPD248	268,345	13,42
MNND248	263,669	13,18
PCAD248	270,741	13,54
RBFD248	262,393	13,12
SOMD248	271,222	13,56
ELMAND248	279,770	13,99

Tabla 7. 15 Resultados de los modelos de la 2^a Fase (Horizonte 2 días–Día Muy Nublado/lluvioso)

Modelo	RMSE	
	(kWh)	(%)
MLPD348	110,846	5,54
FFBPD348	118,555	5,93
MNND348	123,577	6,18

PCAD348	108,004	5,40
Rbfd348	104,644	5,23
SOMD348	121,111	6,06
ELMAND348	113,514	5,68

Tabla 7. 16 Resultados de los modelos de la 2^a Fase (Horizonte 3 días – Día Claro)

Modelo	RMSE	
	(kWh)	(%)
MLPD172	228,036	11,40
FFBPD172	227,191	11,36
MNND172	226,917	11,35
PCAD172	224,213	11,21
Rbfd172	209,413	10,47
SOMD172	235,522	11,78
ELMAND172	237,242	11,86

Tabla 7. 17 Resultados de los modelos de la 2^a Fase (Horizonte 3 días – Día Nublado)

Modelo	RMSE	
	(kWh)	(%)
MLPD272	260,012	13,00
FFBPD272	267,882	13,39
MNND272	265,251	13,26
PCAD272	276,784	13,84
Rbfd272	264,635	13,23
SOMD272	277,717	13,89
ELMAND272	265,839	13,29

Tabla 7. 18 Resultados de los modelos de la 2^a Fase (Horizonte 3 días–Día Muy Nublado/lluvioso)

Modelo	RMSE	
	(kWh)	(%)
MLPD372	114,420	5,72
FFBPD372	118,887	5,94
MNND372	116,481	5,82
PCAD372	112,712	5,64
RBFD372	108,574	5,43
SOMD372	121,121	6,06
ELMAND372	111,935	5,60

Para cada horizonte de predicción y tipo de día se destaca el modelo que obtiene el menor *RMSE*, es decir, el más eficiente.

Teniendo en cuenta todos los resultados expuestos en las tablas anteriores y considerando el tanto por ciento que cada tipo de día representa en el global del grupo de test de cada horizonte, en las siguientes tres tablas se recoge para cada horizonte cuál sería el modelo general y su *RMSE_{Global}*.

Tabla 7. 19 Resultados globales del Modelo24H de la 2^a Fase

Tipo de Día	Modelo	% del G.Test	RMSE	
			(kWh)	(%)
Claro	RBFD124	49,66	192,291	9,61
Nublado	MLPD224	35,42	243,366	12,17
Muy nublado lluvioso	RBFD324	14,92	103,977	5,20
General	GLOBAL	100%	197,211	9,86

Tabla 7. 20 Resultados globales del Modelo48H de la 2^a Fase

Tipo de Día	Modelo	% del G.Test	RMSE	
			(kWh)	(%)
Claro	RBFD148	46,00	196,505	9,83
Nublado	MLPD248	35,81	259,416	12,97
Muy nublado lluvioso	RBFD348	18,19	104,644	5,23
General	GLOBAL	100%	202,325	10,12

Tabla 7. 21 Resultados globales del Modelo72H de la 2^a Fase

Tipo de Día	Modelo	% del G.Test	RMSE	
			(kWh)	(%)
Claro	RBFD172	46,00	209,413	10,47
Nublado	MLPD272	35,81	260,012	13,00
Muy nublado lluvioso	RBFD372	18,19	108,574	5,43
General	GLOBAL	100%	209,191	10,46

A raíz de los resultados anteriores vemos que para todos los horizontes de predicción tenidos en cuenta se utilizará una red neuronal RBF cuando los días sean claros, una MLP para los días nublados y otra RBF cuando los días sean muy nublados o lluviosos.

De forma que, teniendo en cuenta el horizonte de predicción, el esquema que representa los modelos globales desarrollados en esta fase puede verse a continuación en la Figura 7. 7.

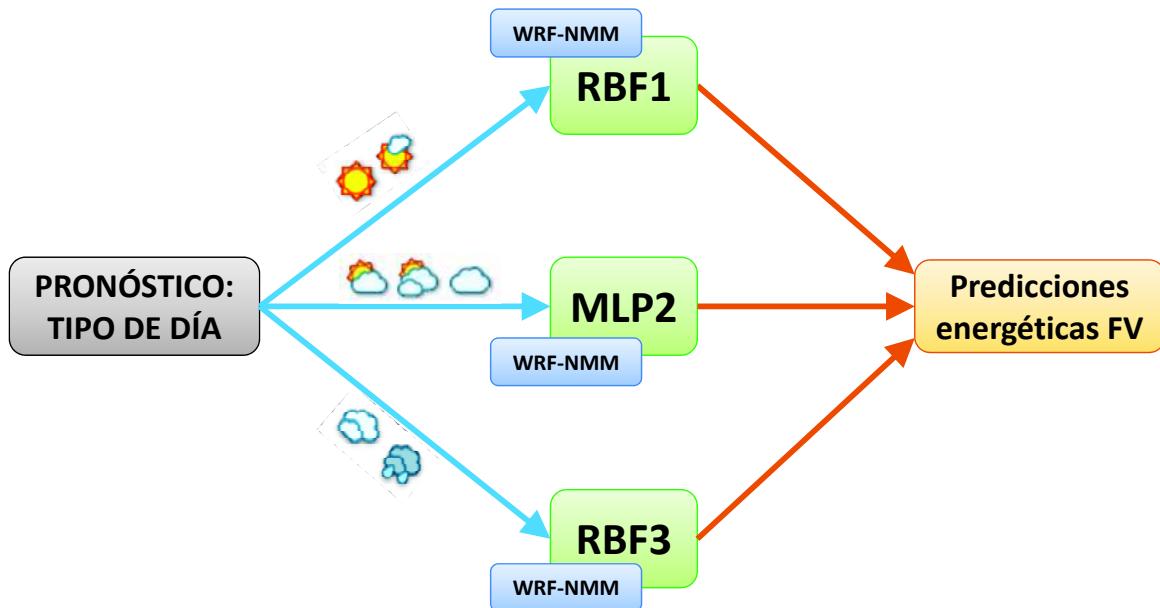


Figura 7. 7 Estructura de los modelos globales desarrollados en la 2^a fase

7.3.3 COMBINACIÓN DE MODELOS

Llegados a este punto, se van a crear los modelos de predicción definitivos para cada horizonte de predicción, es decir, los modelos cuyas predicciones cometan el menor error posible. Para ello se realiza una combinación de los modelos del apartado anterior.

Por tanto, teniendo en cuenta el horizonte de predicción y el tipo de día, se seleccionan las mejores redes, es decir, aquellas con menor *RMSE* medio (ponderado entre los datos de entrenamiento y validación), y se obtiene como resultado final de la predicción el valor promedio de sus salidas. Cabe destacar que se han hecho numerosas pruebas y se ha determinado que el número óptimo de redes a promediar para obtener los mejores resultados es de **5**.

Tras esto, aplicamos el filtrado de datos (comentado con anterioridad), con el fin de afinar las predicciones finales.

A continuación, en las siguientes nueve tablas, se muestra para cada horizonte y tipo de día las **5** mejores redes neuronales, con su *RMSE* correspondiente.

Tabla 7. 22 Mejores redes neuronales (Horizonte 1 día – Día Claro)

Modelo	RMSE	
	(kWh)	(%)
RBFD124_1	192,291	9,61
RBFD124_2	192,718	9,64
RBFD124_3	193,330	9,67
RBFD124_4	195,251	9,76
RBFD124_5	197,993	9,90

Tabla 7. 23 Mejores redes neuronales (Horizonte 1 día – Día Nublado)

Modelo	RMSE	
	(kWh)	(%)
MLPD224_1	243,366	12,17
MLPD224_2	246,751	12,33
MLPD224_3	244,807	12,24
MLPD224_4	244,911	12,25
MLPD224_5	245,304	12,27

Tabla 7. 24 Mejores redes neuronales (Horizonte 1 día – Día Muy nublado / lluvioso)

Modelo	RMSE	
	(kWh)	(%)
RBFD324_1	103,977	5,20
RBFD324_2	106,090	5,30
RBFD324_3	106,704	5,34
RBFD324_4	107,054	5,35
RBFD324_5	107,440	5,37

Tabla 7. 25 Mejores redes neuronales (Horizonte 2 días – Día Claro)

Modelo	RMSE	
	(kWh)	(%)
RBFD148_1	196,505	9,83
RBFD148_2	198,106	9,91
RBFD148_3	200,171	10,01
RBFD148_4	200,334	10,02
RBFD148_5	206,696	10,33

Tabla 7. 26 Mejores redes neuronales (Horizonte 2 días – Día Nublado)

Modelo	RMSE	
	(kWh)	(%)
MLPD248_1	259,416	12,97
MLPD248_2	259,482	12,97
MLPD248_3	259,726	12,99
MLPD248_4	261,781	13,09
MLPD248_5	262,937	13,15

Tabla 7. 27 Mejores redes neuronales (Horizonte 2 días – Día Muy nublado / lluvioso)

Modelo	RMSE	
	(kWh)	(%)
RBFD348_1	104,644	5,23
RBFD348_2	105,581	5,28
RBFD348_3	105,678	5,28
RBFD348_4	105,937	5,30
RBFD348_5	106,941	5,35

Tabla 7. 28 Mejores redes neuronales (Horizonte 3 días – Día Claro)

Modelo	RMSE	
	(kWh)	(%)
RBFD172_1	209,413	10,47
RBFD172_2	212,579	10,63
RBFD172_3	213,267	10,66
RBFD172_4	213,614	10,68
RBFD172_5	216,411	10,82

Tabla 7. 29 Mejores redes neuronales (Horizonte 3 días – Día Nublado)

Modelo	RMSE	
	(kWh)	(%)
MLPD272_1	260,012	13,00
MLPD272_2	260,055	13,00
MLPD272_3	262,894	13,14
MLPD272_4	263,022	13,15
MLPD272_5	264,215	13,21

Tabla 7. 30 Mejores redes neuronales (Horizonte 3 días – Día Muy nublado / lluvioso)

Modelo	RMSE	
	(kWh)	(%)
RBFD372_1	108,574	5,43
RBFD372_2	109,241	5,46
RBFD372_3	111,098	5,55
RBFD372_4	109,794	5,49
RBFD372_5	112,069	5,60

Creando los modelos promedio correspondientes a las las tablas anteriores y considerando el tanto por ciento que cada tipo de día representa en el global del grupo de test de cada horizonte, en las siguientes tres tablas se recoge para cada horizonte cuál sería el modelo optimizado realizando el filtrado de datos, y su $RMSE_{Global}$.

Tabla 7. 31 Resultados globales del ModeloDefinitivo24H

Tipo de Día	Modelo	% del G.Test	RMSE	
			(kWh)	(%)
Claro	RBFD124DEF	49,66	184,631	9,23
Nublado	MLPD224DEF	35,42	240,921	12,05
Muy nublado lluvioso	RBFD324DEF	14,92	103,687	5,18
General	GLOBAL	100%	192,497	9,62

Tabla 7. 32 Resultados globales del ModeloDefinitivo48H

Tipo de Día	Modelo	% del G.Test	RMSE	
			(kWh)	(%)
Claro	RBFD148DEF	46,00	192,547	9,63
Nublado	MLPD248DEF	35,81	258,344	12,92
Muy nublado lluvioso	RBFD348DEF	18,19	104,553	5,23
General	GLOBAL	100%	200,104	10,01

Tabla 7. 33 Resultados globales del ModeloDefinitivo72H

Tipo de Día	Modelo	% del G.Test	RMSE	
			(kWh)	(%)
Claro	RBFD172DEF	46,00	206,75	10,34
Nublado	MLPD272DEF	35,81	258,879	12,94
Muy nublado lluvioso	RBFD372DEF	18,19	108,166	5,41
General	GLOBAL	100%	207,486	10,37

7.4 ANÁLISIS DETALLADO DE LOS MODELOS ÓPTIMOS BASADOS EN WRF

En este apartado se van a analizar con más detalle los resultados que se obtienen mediante los tres modelos definitivos desarrollados (uno para cada horizonte de predicción): ModeloDefinitivo24H, ModeloDefinitivo48H y ModeloDefinitivo72H.

De forma general, únicamente varía el horizonte de predicción, en la Figura 7. 8, se puede ver la estructura de los tres modelos definitivos desarrollados

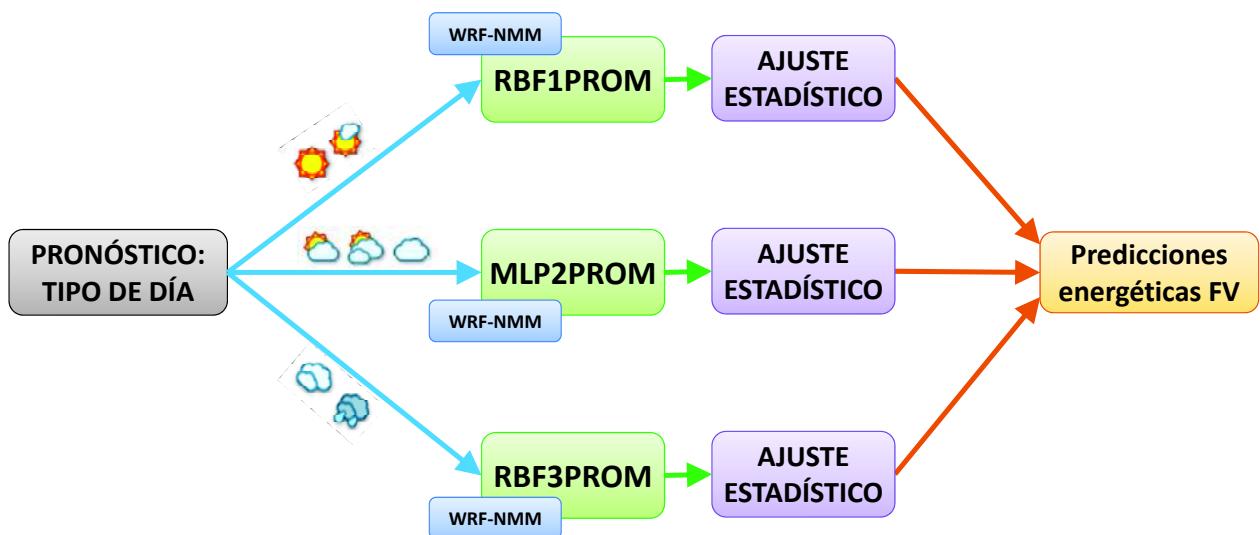


Figura 7. 8 Estructura de los Modelos Definitivos

7.4.1 MODELODEFINITIVO24H

Centrándonos con mayor detalle en el ModeloDefinitivo24H desarrollado, podemos observar lo siguiente en cuanto a su error absoluto medio (*MAE*) y al error real medio (*ME*):

Tabla 7. 34 Errores *MAE* y *ME* para el *ModeloDefinitivo24H*

MAE		ME	
(kWh)	(%)	(kWh)	(%)
97,767	4,89	-22,454	-1,12

De forma que podemos observar que el error absoluto medio se encuentra en torno al 4,89%, y el error real medio cometido a lo largo de todo el período de testeo ha sido inferior al -1,12%.

Además, puesto que el desarrollo de este modelo, debido a su horizonte de predicción, es el objetivo principal de las investigaciones vinculadas a la Tesis Doctoral se pasa a calcular la mejora que supone respecto a otros modelos. Concretamente se va a evaluar la mejora que supone respecto al modelo persistente, al MLP 2A (el más eficiente de los basados en MM5, desarrollado en las investigaciones iniciales), al PCA124O (el más eficiente de los desarrollados en la 1^a fase para el día siguiente), el Modelo24H (desarrollado en la 2^a fase) y de los modelos similares descritos en el *Capítulo 3 – Estado del Arte*, los más eficientes ([Bacher09], [DaSilva11], [Ciabattoni12b] y [Yona13]).

En la tabla Tabla 7. 35 aparecen las mejoras respecto a todos los modelos comentados en el párrafo anterior excepto del correspondiente a [Yona13], ya que en su caso el error que proporcionan es el *MAE*. Por tanto la mejora respecto a este modelo se calcula mediante la comparación del *MAE*. Su resultado puede verse en la Tabla 7. 36.

Tabla 7. 35 Mejoras del ModeloDefinitivo24H

Modelo Ref.	Horizonte	RMSE (%)	Mejora _{ref,RMSE} (%)
PERSISTENTE24	Día siguiente	21,09	54,39
MLP2A	Día siguiente	13,17	26,96
PCA124O	Día siguiente	13,12	26,68
Modelo24H	Día siguiente	9,86	2,43
[Bacher09]**	Día siguiente	11	12,55
[DaSilva11]	25h*	11,8	18,47
[Ciabattoni12b]	24h*	9,6	-0,21

*El horizonte es inferior al del ModeloDefinitivo24H, ya que sus horizontes (24h y 25h) son menores al correspondiente al día siguiente.

**El valor del RMSE ha sido estimado a partir de las gráficas proporcionadas por los autores.

Tabla 7. 36 Mejora del ModeloDefinitivo24H respecto a [Yona13]

Modelo Ref.	Horizonte	MAE (%)	Mejora _{ref,MAE} (%)
[Yona13]	24h*	7	30,14

*El horizonte es inferior al del ModeloDefinitivo24H, ya que su horizonte (24h) es menor al correspondiente al día siguiente

Se puede observar que de los modelos más eficientes de los descritos en el Estado del Arte, únicamente el descrito en [Ciabattoni12b] obtiene un error ligeramente menor, pero para un horizonte de predicción inferior. Si pasamos a compararlo con un modelo con unas características semejantes, el desarrollado en [Bacher09], el ModeloDefinitivo24H mejora aproximadamente en un 12,55% sus resultados.

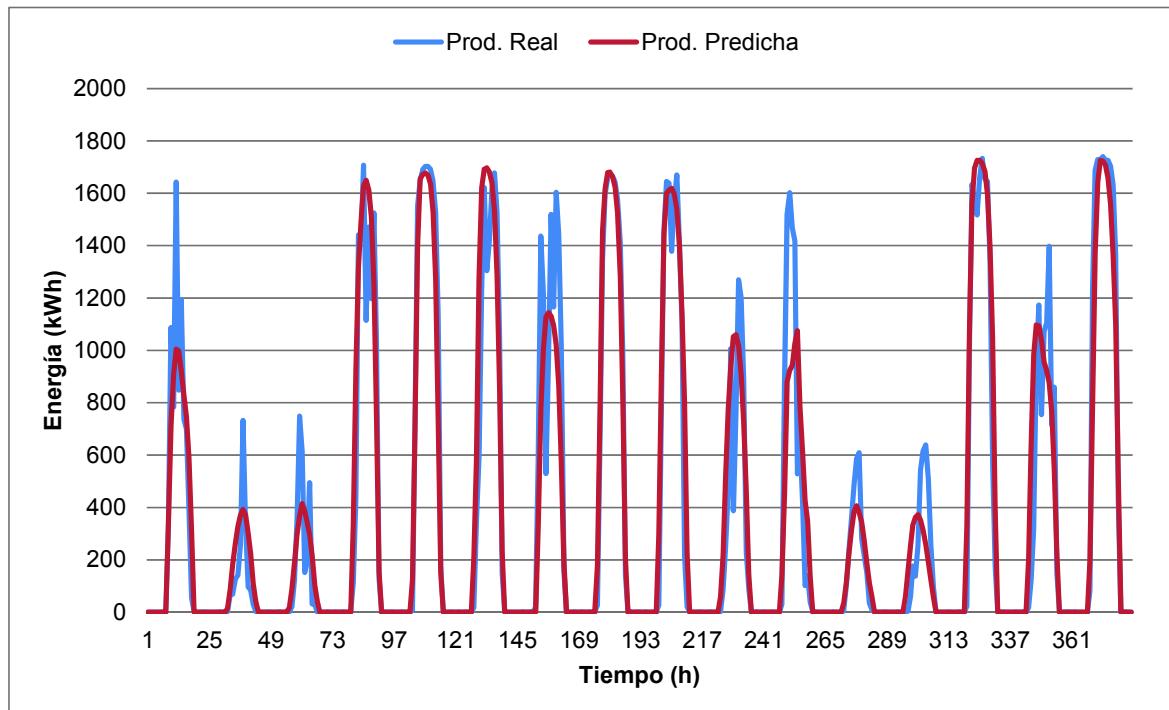


Figura 7. 9 Comparación entre la energía real generada y la predicha (ModeloDefinitivo24H)

Teniendo en cuenta que el comportamiento de los meses de Mayo-Septiembre es más regular, las predicciones de la producción fotovoltaica suelen ser más precisas. Por ello, se presenta en la Figura 7. 9, un gráfico de comparación entre la energía predicha y la real generada para un período con un comportamiento más irregular, concretamente, para los primeros 16 días de Marzo de 2011.

7.4.2 MODELODEFINITIVO48H

Centrándonos con mayor detalle en el ModeloDefinitivo48H desarrollado, podemos observar lo siguiente en cuanto a su error absoluto medio (MAE) y al error real medio (ME):

Tabla 7. 37 Errores MAE y ME para el ModeloDefinitivo48H

MAE		ME	
(kWh)	(%)	(kWh)	(%)
102,168	5,11	-25,850	-1,29

De forma que podemos observar que el error absoluto medio se encuentra en torno al 5,11%, y el error real medio cometido a lo largo de todo el período de testeo ha sido inferior al -1,29%.

Teniendo en cuenta que el comportamiento de los meses de Mayo-Septiembre es más regular, las predicciones de la producción fotovoltaica suelen ser más precisas. Por ello, se presenta en la Figura 7. 10, un gráfico de comparación entre la energía predicha y la real generada para un período con un comportamiento más irregular, concretamente, para la última semana de Enero y la primera de Febrero de 2011.

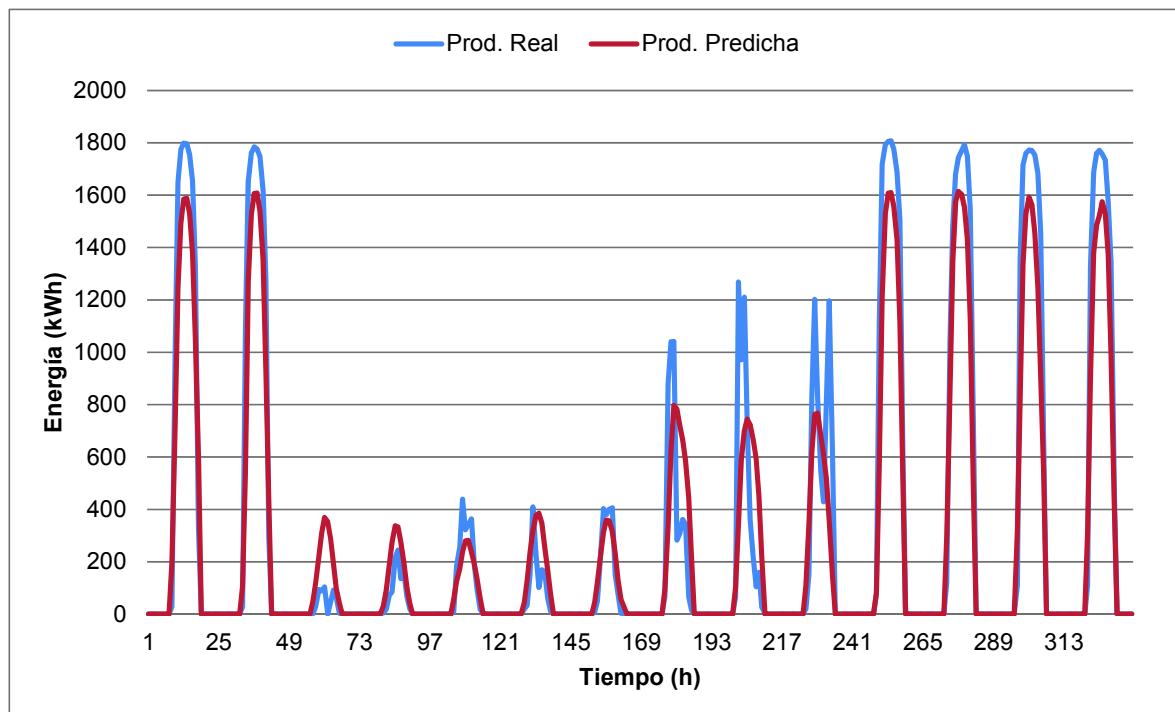


Figura 7. 10 Comparación entre la energía real generada y la predicha (ModeloDefinitivo48H)

7.4.3 MODELODEFINITIVO72H

Centrándonos con mayor detalle en el ModeloDefinitivo72H desarrollado, podemos observar lo siguiente en cuanto a su error absoluto medio (*MAE*) y al error real medio (*ME*):

Tabla 7. 38 Errores *MAE* y *ME* para el *ModeloDefinitivo72H*

MAE		ME	
(kWh)	(%)	(kWh)	(%)
106,971	5,35	-36,385	-1,82

De forma que podemos observar que el error absoluto medio se encuentra en torno al 5,35%, y el error real medio cometido a lo largo de todo el período de testeo ha sido inferior al -1,82%.

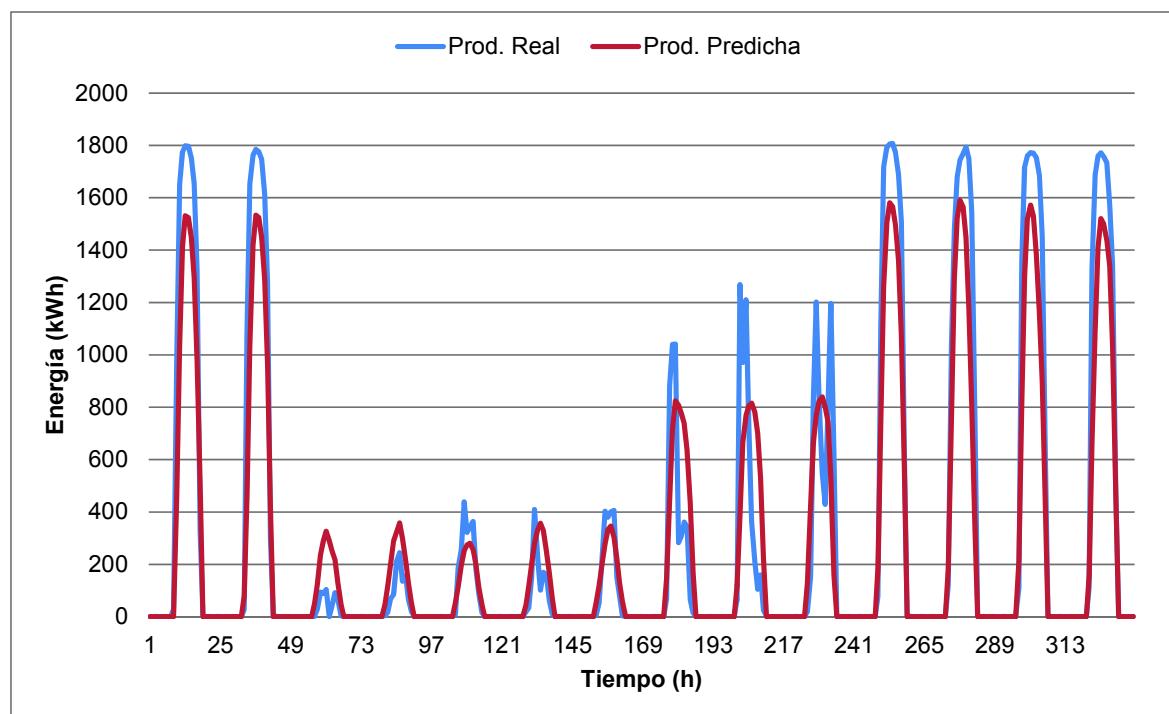


Figura 7. 11 Comparación entre la energía real generada y la predicha (*ModeloDefinitivo48H*)

Teniendo en cuenta que el comportamiento de los meses de Mayo-Septiembre es más regular, las predicciones de la producción fotovoltaica suelen ser más precisas. Por ello, se presenta en la Figura 7. 11, un gráfico de comparación entre la energía predicha y la real generada para un período con un comportamiento más irregular, concretamente, para la última semana de Enero y la primera de Febrero de 2011.

7.4.4 TABLAS RESUMEN

En este apartado aparecen tres tablas (Tabla 7. 40, Tabla 7. 41 y Tabla 7. 42) en las que se resumen las características de las redes neuronales que conforman los tres modelos definitivos.

A continuación aparece una tabla en la que se numeran las variables de entrada, a modo de leyenda, para poder hacer referencia a las entradas utilizadas por cada red neuronal en las tablas resumen.

Tabla 7. 39 Leyenda de variables de entrada

1	<i>DIACOS</i>	11	<i>RSWINC t</i>	21	<i>RSWINC t-1</i>	31	<i>RSWINC t+1</i>	41	<i>Idb-Ida maxd</i>
2	<i>DIASENO</i>	12	<i>VVTO t</i>	22	<i>VVTO t-1</i>	32	<i>VVTO t+1</i>	42	<i>TEMPMEDIA</i>
3	<i>HORACOS</i>	13	<i>COSVTO t</i>	23	<i>COSVTO t-1</i>	33	<i>COSVTO t+1</i>	43	<i>SIMESTACION</i>
4	<i>HORASENO</i>	14	<i>SENVTO t</i>	24	<i>SENVTO t-1</i>	34	<i>SENVTO t+1</i>	44	<i>Altura Solar ys</i>
5	<i>THS (K) t</i>	15	<i>THS (K) t-1</i>	25	<i>THS (K) t+1</i>	35	<i>SUNSHINE</i>	45	<i>Azimut ys</i>
6	<i>QS t</i>	16	<i>QS t-1</i>	26	<i>QS t+1</i>	36	<i>RADMEDIA</i>		
7	<i>CFRACH t</i>	17	<i>CFRACH t-1</i>	27	<i>CFRACH t+1</i>	37	<i>I0CORR</i>		
8	<i>CFRACL t</i>	18	<i>CFRACL t-1</i>	28	<i>CFRACL t+1</i>	38	<i>Idb-Ida</i>		
9	<i>CFRACM t</i>	19	<i>CFRACM t-1</i>	29	<i>CFRACM t+1</i>	39	<i>(I0N-RadN)^2</i>		
10	<i>RSWIN t</i>	20	<i>RSWIN t-1</i>	30	<i>RSWIN t+1</i>	40	<i>NDD</i>		

Tabla 7. 40 Resumen de las características de las redes neuronales que componen el ModeloDefinitivo24H

Red Neuronal	Nº de Neuronas en la capa de apr. no supervisado	Nº de Neuronas en la 1ª capa oculta	Nº de Neuronas en la 2ª capa oculta	Entradas utilizadas
RBFD124_1	16	62	17	24 (4, 5, 10, 11, 13, 14, 16, 18, 19, 20, 23, 24, 26, 28, 30, 33, 34, 36, 37, 38, 40, 43, 44, 45)
RBFD124_2	18	59	58	21 (1, 2, 4, 8, 9, 10, 13, 20, 22, 23, 24, 26, 27, 29, 32, 34, 37, 40, 41, 43, 44)
RBFD124_3	24	28	26	17 (2, 4, 7, 8, 12, 13, 16, 21, 22, 25, 26, 27, 30, 32, 36, 37, 42)
RBFD124_4	19	30	29	21 (2, 3, 4, 5, 7, 8, 11, 12, 13, 17, 19, 20, 21, 25, 26, 28, 31, 32, 35, 37, 44)
RBFD124_5	7	31	13	18 (2, 3, 4, 8, 12, 15, 19, 21, 25, 27, 28, 34, 35, 37, 39, 41, 43, 44)
MLPD224_1	-	3	51	26 (1, 3, 4, 5, 6, 7, 11, 13, 15, 18, 19, 20, 21, 23, 28, 29, 30, 32, 33, 35, 36, 39, 40, 43, 44, 45)
MLPD224_2	-	4	42	22 (3, 4, 10, 12, 17, 18, 19, 21, 22, 23, 25, 26, 27, 30, 31, 32, 37, 38, 39, 40, 41, 43)
MLPD224_3	-	79	29	19 (1, 3, 4, 7, 11, 12, 14, 15, 18, 20, 25, 30, 32, 35, 36, 37, 39, 44, 45)
MLPD224_4	-	5	25	24 (1, 2, 4, 6, 8, 9, 10, 11, 15, 16, 17, 19, 20, 26, 29, 32, 33, 34, 35, 36, 40, 42, 44, 45)
MLPD224_5	-	10	66	18 (3, 4, 5, 6, 7, 8, 10, 13, 22, 25, 27, 31, 35, 36, 38, 40, 41, 44)
RBFD324_1	17	50	8	21 (2, 4, 12, 13, 14, 16, 17, 19, 20, 21, 23, 26, 30, 31, 32, 34, 35, 36, 37, 40, 45)
RBFD324_2	17	33	12	22 (1, 2, 4, 6, 8, 9, 10, 12, 19, 20, 24, 27, 30, 31, 32, 33, 36, 37, 41, 42, 43, 44)
RBFD324_3	15	22	5	21 (2, 3, 4, 6, 12, 13, 15, 19, 20, 21, 22, 23, 26, 27, 30, 31, 32, 35, 36, 37, 39)
RBFD324_4	23	22	23	20 (2, 4, 5, 7, 10, 11, 14, 19, 20, 21, 22, 24, 26, 27, 29, 37, 39, 40, 41, 43)
RBFD324_5	18	28	11	21 (2, 3, 4, 7, 15, 19, 24, 26, 27, 28, 30, 31, 32, 33, 35, 36, 37, 38, 41, 42, 45)

Tabla 7. 41 Resumen de las características de las redes neuronales que componen el ModeloDefinitivo48H

Red Neuronal	Nº de Neuronas en la capa de apr. no supervisado	Nº de Neuronas en la 1 ^a capa oculta	Nº de Neuronas en la 2 ^a capa oculta	Entradas utilizadas
RBFID48_1	23	8	8	24 (3, 4, 9, 11, 12, 15, 16, 18, 20, 22, 23, 24, 27, 28, 29, 30, 33, 35, 38, 39, 40, 41, 43, 45)
RBFID48_2	18	62	3	25 (1, 3, 4, 5, 8, 12, 13, 14, 15, 17, 18, 21, 23, 26, 27, 29, 31, 32, 35, 37, 38, 43)
RBFID48_3	21	43	33	21 (1, 2, 4, 7, 11, 15, 16, 20, 26, 27, 28, 30, 31, 34, 35, 37, 40, 41, 43, 44, 45)
RBFID48_4	8	24	29	23 (1, 3, 4, 9, 11, 12, 16, 18, 22, 23, 27, 28, 29, 31, 33, 36, 37, 38, 39, 41, 42, 43, 44)
RBFID48_5	18	24	53	26 (2, 4, 5, 6, 8, 10, 11, 12, 13, 15, 17, 18, 20, 21, 23, 25, 26, 29, 30, 31, 33, 38, 40, 42, 44, 45)
MLPD248_1	-	3	39	16 (1, 4, 8, 11, 13, 14, 15, 16, 18, 19, 21, 26, 38, 41, 42, 43)
MLPD248_2	-	3	37	22 (3, 6, 7, 8, 9, 10, 11, 13, 14, 15, 19, 21, 24, 26, 28, 30, 32, 33, 38, 40, 41, 45)
MLPD248_3	-	6	52	24 (1, 4, 5, 6, 8, 9, 13, 16, 20, 21, 22, 23, 24, 27, 28, 31, 33, 35, 38, 40, 41, 42, 44, 45)
MLPD248_4	-	20	13	23 (1, 3, 9, 10, 13, 14, 15, 16, 17, 18, 20, 21, 26, 27, 31, 34, 36, 37, 38, 41, 42, 43, 45)
MLPD248_5	-	47	7	21 (1, 4, 5, 7, 9, 10, 12, 13, 15, 17, 18, 19, 20, 21, 29, 31, 32, 35, 37, 41, 42)
RBFDD48_1	8	6	63	17 (2, 6, 8, 9, 11, 12, 15, 21, 29, 30, 31, 33, 35, 37, 40, 44, 45)
RBFDD48_2	15	13	28	21 (1, 3, 4, 9, 10, 11, 15, 19, 20, 22, 24, 26, 30, 35, 36, 37, 40, 42, 43, 44, 45)
RBFDD48_3	9	60	5	27 (2, 3, 4, 5, 6, 10, 11, 13, 14, 15, 16, 19, 20, 21, 23, 24, 25, 26, 28, 31, 32, 33, 34, 39, 41, 44, 45)
RBED348_4	18	22	23	25 (1, 2, 3, 4, 5, 10, 12, 14, 15, 19, 20, 21, 22, 25, 26, 28, 30, 31, 32, 34, 35, 37, 38, 43, 45)
RBFDD48_5	17	45	3	26 (1, 3, 5, 8, 10, 11, 12, 14, 17, 19, 20, 21, 22, 28, 30, 31, 33, 34, 35, 37, 39, 40, 41, 42, 43, 44)

Tabla 7. 42 Resumen de las características de las redes neuronales que componen el ModeloDefinitivo72H

Red Neuronal	Nº de Neuronas en la capa de apr. no supervisado	Nº de Neuronas en la 1ª capa oculta	Nº de Neuronas en la 2ª capa oculta	Entradas utilizadas
RBFDD72_1	6	60	60	20 (3, 4, 6, 8, 10, 11, 12, 14, 16, 19, 20, 21, 28, 31, 33, 36, 37, 39, 44, 45)
RBFDD72_2	24	42	29	26 (1, 3, 4, 5, 6, 9, 10, 11, 12, 17, 20, 22, 25, 26, 28, 31, 32, 33, 35, 36, 38, 39, 40, 41, 43, 45)
RBFDD72_3	24	39	22	22 (1, 4, 5, 7, 8, 10, 11, 15, 17, 21, 22, 25, 26, 27, 29, 30, 32, 34, 35, 37, 38, 42)
RBFDD72_4	22	16	56	21 (2, 4, 6, 7, 8, 10, 12, 14, 15, 16, 18, 20, 21, 23, 26, 28, 30, 32, 37, 40, 44)
RBFDD72_5	22	42	19	21 (4, 5, 6, 10, 11, 17, 23, 24, 26, 27, 28, 31, 33, 35, 38, 39, 41, 42, 43, 44, 45)
MLPDD72_1	-	13	6	22 (1, 2, 3, 7, 8, 10, 11, 12, 13, 21, 23, 26, 30, 31, 34, 35, 36, 37, 41, 42, 44, 45)
MLPDD72_2	-	5	13	20 (1, 2, 5, 7, 8, 11, 12, 13, 19, 21, 22, 30, 31, 33, 34, 35, 36, 37, 42, 43)
MLPDD72_3	-	3	27	20 (2, 8, 9, 11, 14, 15, 24, 25, 26, 27, 28, 29, 30, 31, 32, 34, 39, 40, 42, 44)
MLPDD72_4	-	7	5	21 (2, 4, 5, 8, 13, 14, 15, 17, 19, 21, 22, 23, 27, 30, 31, 33, 34, 36, 41, 42, 43)
MLPDD72_5	-	8	58	20 (1, 2, 4, 12, 13, 15, 16, 18, 19, 28, 29, 32, 34, 35, 36, 37, 38, 39, 40, 44)
RBFDD372_1	17	47	32	23 (3, 6, 8, 10, 11, 13, 14, 15, 17, 19, 21, 23, 25, 27, 28, 29, 30, 32, 33, 37, 38, 39, 43)
RBFDD372_2	23	66	13	25 (1, 6, 8, 9, 10, 11, 12, 13, 14, 15, 20, 21, 22, 23, 25, 28, 30, 33, 34, 37, 38, 39, 40, 41, 44)
RBFDD372_3	15	13	8	26 (3, 8, 10, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 31, 32, 33, 35, 37, 38, 39, 44)
RBFDD372_4	9	52	58	18 (1, 3, 5, 10, 11, 15, 16, 17, 20, 28, 31, 32, 34, 37, 40, 42, 43, 45)
RBFDD372_5	8	46	5	19 (3, 10, 13, 14, 15, 16, 20, 21, 22, 27, 29, 30, 31, 35, 36, 39, 41, 43, 45)

8

CAPÍTULO

CONCLUSIONES

En este capítulo aparecen las conclusiones generales obtenidas a partir de las investigaciones vinculadas a la presente Tesis Doctoral, es decir, derivadas del desarrollo de los nuevos modelos y sistemas de predicción para instalaciones solares fotovoltaicas y del análisis de sus resultados. Al finalizar el capítulo se presentan las líneas, o sugerencias, para trabajos futuros, con el fin de mejorar los resultados obtenidos con los modelos de predicción desarrollados.

8.1 CONCLUSIONES DE LAS INVESTIGACIONES

A la vista de la evolución de la energía solar fotovoltaica, tanto a nivel mundial como nacional, y de los antecedentes expuestos y descritos en el *Capítulo 1*, la elección de la temática en la que se fundamenta la presente Tesis Doctoral queda totalmente justificada.

En cuanto a los modelos numéricos de predicción meteorológica, ha quedado fortalecida la idea de que los más adecuados para obtener las predicciones de las variables atmosféricas de mayor interés para la predicción en el corto plazo de la producción eléctrica fotovoltaica, son los modelos de meso-escala. Tal y como ha podido

verse a lo largo de este documento, los modelos atmosféricos utilizados son el MM5 y el WRF-NMM, modelos de meso-escala de dominio público, que gozan de crédito dentro de la comunidad científica especializada. Cuentan además con una ventaja de aplicación práctica relevante: puede implementarse, a coste cero, en sistemas informáticos de uso común, pudiendo ofrecer predicciones de las variables meteorológicas con poco esfuerzo de programación (incluso podrían instalarlo los propietarios o gestores de los parques solares fotovoltaicos).

Se han desarrollado modelos originales, que constituyen un nuevo sistema global de predicción, con un horizonte de hasta 3 días vista, ampliando así en gran medida los modelos publicados en la literatura internacional.

Para este modelo definitivo de predicción, compuesto por un amplio conjunto de modelos y que cubre tres horizontes de predicción distintos (un día, dos días y tres días vista), se ha determinado, en función del momento en que se realiza la predicción, del horizonte y del tipo de día, el modelo óptimo que logra los mejores resultados de predicción de la potencia eléctrica generada en el parque solar fotovoltaico. Así, el sistema definitivo dispone de modelos para realizar predicciones que servirían el día de mañana para presentar ofertas de venta de la energía eléctrica producida en el mercado eléctrico.

En cuanto a los modelos de predicción de series temporales estudiados, ha quedado patente, que las técnicas modernas (redes neuronales artificiales, algoritmos genéticos y sistemas de inferencia difusa) entroncadas en el conocido ámbito del llamado “soft-computing”, permiten simular el comportamiento de la producción horaria del sistema solar fotovoltaico de una forma mucho más precisa que las técnicas clásicas. Esto se debe principalmente a que la energía fotovoltaica generada presenta numerosas no linealidades, no pudiendo ser solventadas por los modelos clásicos debido a sus limitaciones. Siendo más precisos, los modelos que mejores resultados ofrecen son los basados en redes neuronales, y más en concreto, los que resultan de combinar varias redes neuronales.

Se ha realizado un profundo análisis y una amplia selección de modelos de redes neuronales, utilizándose en todos ellos un proceso de optimización basado en algoritmo genético, con selección óptima de entradas, del número de neuronas en capas ocultas, de valores de los parámetros del algoritmo de entrenamiento, del número de unidades de

retardo, del número de neuronas de función de base radial y del número de componentes principales, cuando fuera aplicable, todo ello con objeto de seleccionar la red neuronal idónea que logra un menor error de predicción. Ello ha permitido determinar las estructuras de las redes neuronales que resultan óptimas para la predicción de la producción eléctrica en parques solares fotovoltaicos.

Los modelos definitivos de predicción desarrollados utilizan un mínimo de variables explicativas, entre ellas las predicciones de variables meteorológicas obtenidas con un modelo atmosférico de libre distribución, ya sea el MM5 o el WRF-NMM.

Queda patente que la clasificación de las series temporales en diferentes subgrupos, en función del tipo de día pronosticado (día claro, nublado o muy nublado – lluvioso), mejora las predicciones y minimiza los errores en gran medida. La mejora de los resultados gracias a la aplicación de esta clasificación, queda patente en los modelos desarrollados en la etapa final de las investigaciones vinculadas a la presente Tesis Doctoral.

Por otro lado, el ajuste estadístico, filtrado de datos, realizado permite afinar las predicciones realizadas. Este filtrado de datos se trata, simplemente, de aplicar una regla lógica, que determina que el valor de la energía fotovoltaica producida es nula cuando no hay, o su valor es inapreciable, radiación solar en la superficie terrestre

Para obtener los modelos de predicción definitivos, teniendo en cuenta el horizonte de predicción y el tipo de día, se seleccionan las mejores redes y se obtiene como resultado final de la predicción el valor promedio de sus salidas. Esta optimización se basa en un concepto muy vinculado al *Data Mining*, pero apenas utilizado en la predicción de la producción eléctrica para parques solares fotovoltaicos, concretamente, en la suposición de que varios expertos, de forma consensuada, pueden llegar a un mejor pronóstico que el mejor de los expertos en solitario.

Los resultados obtenidos son prometedores, si bien, debido a las características propias de cada parque solar fotovoltaico, la comparación con otros modelos de la literatura internacional no puede realizarse con exactitud, a rasgos generales se ha desarrollado un modelo de predicción que proporciona unos resultados considerablemente mejores que los de otros modelos mucho más complejos de la literatura internacional (como los expuestos en el Capítulo 3).

De todo lo anterior, se obtiene una conclusión muy importante, que con los modelos de predicción generales (ya sean de ámbito nacional o regional) se obtienen peores resultados que si se desarrolla un modelo de predicción individual, es decir, para una localización concreta.

De la conclusión descrita en el párrafo anterior, se deduce que para desarrollar modelos de predicción de la producción de energía eléctrica por parte de un parque solar fotovoltaico, lo mejor sería realizar un estudio individualizado para cada instalación. Si se dispusiera de los datos históricos necesarios en cada instalación, siguiendo toda la metodología descrita en la presente Tesis Doctoral, se desarrollarían modelos de predicción con errores mínimos.

8.2 FUTURAS LÍNEAS DE INVESTIGACIÓN

Son varias las futuras líneas de investigación que se presentan a partir de las investigaciones descritas en la presente Tesis Doctoral. Algunas de estas líneas son continuación natural de los trabajos realizados hasta el momento. Mientras que otras líneas se centran en optimizar otros procesos vinculados. En el presente apartado se describen las de mayor relevancia e interés:

- **Utilización de Filtros Kalman:** Consistiría en la aplicación de filtros Kalman [Kalman60] para la mejora de las predicciones meteorológicas del modelo atmosférico. Se trata de una técnica estadística que adapta las salidas de los modelos numéricos a las características del lugar para el que se predice, permitiendo además corregir los errores sistemáticos inherentes en los modelos. La técnica estadística que se use debe permitir una revisión rápida de sus ecuaciones y coeficientes a los constantes cambios que hoy se introducen en los modelos. A diferencia de otros métodos estadísticos, que tienden a suavizar los pronósticos extremos en favor de un menor error medio de los que son más frecuentes, los filtros de Kalman adaptan los valores a las características del lugar.

- **Desarrollar y utilizar un algoritmo de predicción de nubes:** A lo largo del desarrollo de las investigaciones vinculadas a la obtención de los modelos de predicción, se ha consultado una gran cantidad de artículos relacionados con las predicciones meteorológicas de los modelos atmosféricos, además de otros relacionados con las predicciones de radiación. Ha quedado patente que la mayor dificultad es la detección de nubes, por lo que en la actualidad se están desarrollando diversos algoritmos para representar la presencia de nubes [Mathiesen13]. Por ello, con más tiempo, podría buscarse el modo de realizar uno de estos algoritmos con la mayor precisión posible, gracias a lo cual, añadiendo su resultado como una entrada de los modelos de predicción, podríamos conseguir reducir los errores obtenidos, obteniendo un modelo aún más preciso.
- **Aumentar los datos de entrenamiento:** La obtención de los datos de producción ha sido harto complicada, y se ha intentado conseguir por otras vías datos de producción de otros parques solares fotovoltaicos para modelos futuros. Esto es así no sólo por la desconfianza de los propietarios de los parques, sino también porque una gran cantidad de parques solares fotovoltaicos no dispone de dichos estadísticos (energía generada como mínimo hora a hora). Consiguiendo nuevos datos y ampliando la cantidad de datos de entrenamiento es factible pensar que podrían desarrollarse modelos de predicción con mejores resultados.
- **Uso de PSO para la optimización:** utilizar la optimización por nube o enjambre de partículas (*Particle Swarm Optimization, PSO*) como herramienta de optimización junto con los algoritmos genéticos. De esta forma se podrán combinar las ventajas de ambos, es decir, por un lado la PSO permite guardar la información del mejor individuo mientras que las mutaciones proporcionadas por los GA permiten mantener la diversidad de la población de la PSO.

- **Desarrollo de la aplicación PREFO-RED 2.0:** tomando como base la aplicación desarrollado en las investigaciones iniciales, PREFO-RED, desarrollar una nueva versión para que aplique los modelos definitivos desarrollados (ModeloDefinitivo24H, ModeloDefinitivo48H y ModeloDefinitivo72H). El funcionamiento sería similar al de la aplicación actual, pero habría que introducir la opción de elegir horizonte y tipo de día y, además, introducir los archivos de definición de las nuevas redes neuronales.

- **PREFO-RED 2.0 para dispositivos móviles:** desarrollar otras dos versiones de la aplicación comentada en el punto anterior, una compatible con iOS y otra con Android. De esta forma se otorga mayor comodidad a la hora obtener las predicciones de la producción fotovoltaica, ya que, hoy en día, el uso de smartphones y tablets está muy extendido.

- **Instalación del modelo atmosférico en un clúster de PCs:** En el caso de implementar uno de los modelos de predicción, si se hiciese necesario disponer de las predicciones del modelo atmosférico correspondiente (MM5 o WRF-NMM), en un tiempo inferior a 4 horas, podría instalarse el modelo atmosférico en un clúster de PCs trabajando en paralelo. De esta forma, si utilizásemos por ejemplo 4 PCs, trabajando en paralelo, el tiempo se disminuiría a una hora, que sería ya un valor muy reducido.

- **Instalación del modelo atmosférico en un clúster de PCs virtual:** La idea fundamental sería la misma que la descrita en el punto anterior, pero en este caso, se implementaría una red de equipos virtuales, aprovechando las modernas tecnologías de virtualización, con el fin de poder trabajar en paralelo en un mismo equipo.



REFERENCIAS

- [Akaike76] H. Akaike, “Canonical correlation analysis of time series and the use of an information criterion”, en D.G. Lainiotis y R.K. Mehra (Editores), “System identification: Advances and Case studies”, Academic Press, New York, 27-96, 1976.
- [Al-Alawi98] S. Al-Alawi, H. Al-Hinai, “An ANN-based approach for predicting global radiation in locations with no direct measurement instrumentation” *Renewable Energy*, vol. 14, pp. 199–204, 1998.
- [Al-Messabi12] N. Al-Messabi, Y. Li, I. El-Amin, C. Goh, “Forecasting of photovoltaic power yield using dynamic neural networks”, *Proceedings of the International Joint Conference on Neural Networks, IJCNN*, Brisbane, Australia, pp. 1-5, 2012.
- [Armstrong01] J.S. Armstrong (editor), “Principles of forecasting: a handbook for researches and practitioners”, Kluwer Academic Publishers, Boston, 2001.
- [ASTM03] ASTM, “G173-03 Standard Tables for Reference Solar Spectral Irradiances: Direct Normal and Hemispherical on 37° Tilted Surface” (www.astm.org), 2003.
- [Bacher09] P: Bacher, H. Madsen, H.A. Nielsen, “Online short-term solar power forecasting”, *Solar Energy*, vol. 83 (10), pp. 1772-1783, 2009.
- [Back96] A.D. Back, A.C. Tsoi, “Nonlinear system identification using discrete Laguerre functions”, *Journal of Systems Engineering*, vol. 6 (3), pp. 194-207, 1996.

- [Bannayan08] M. Bannayan, G. Hoogenboom, "Predicting realizations of daily weather data for climate forecasts using the non-parametric nearest-neighbour re-sampling technique", *International Journal of Climatology*, vol. 28 (10), pp. 1357–1368, 2008
- [Bellini09] A. Bellini, S. Bifaretti, V. Iacovone, and C. Cornaro, "Simplified model of a photovoltaic module", *Applied Electronics International Conference*, Pilzen, Czech Republic, pp. 47-52, 2009.
- [Blake95] J. Blake, P. Francino, J.M. Catot, I. Solé, "A comparative study for forecasting using neural networks vs genetically identified Box&Jenkins models", *Neural Computing & Applications*, vol. 3 (3), pp. 139-148, 1995.
- [BOE06] "Reglas de Funcionamiento del Mercado Diario e Intradíario de Producción de Energía Eléctrica", Resolución de 24 de mayo de 2006, de la Secretaría General de Energía, BOE de 30 de mayo de 2006.
- [Bofinger06] G.H.S. Bofinger, G. Heilscher, "Solar Electricity Forecast - Approaches and First Results", *21st European Photovoltaic Solar Energy Conference*, Dresden, Germany, 2006.
- [Box76] G.E.P. Box, G.M. Jenkins, "Time series Analysis – Forecasting and control", Englewood Cliffs, New Jersey, Prentice Hall, 1976.
- [Bunn85] D.W. Bunn, E.D. Farmer, "Comparative models for electrical load forecasting", John Wiley & Sons, Nueva York, 1985.
- [Cano96] J.M. Cano Izquierdo, Y.A. Dimitriadis, M.J. Araúzo, and J. López Coronado. "FasArt: A new neuro-fuzzy architecture for incremental learning in system identification", *Proc. Of the IFAC World Congress, IFAC96*, vol. F, pp. 133-138, San Francisco, USA, June 1996.
- [Capizzi12] G. Capizzi, C. Napoli, F. Bonano, "Innovative second-generation wavelets construction with recurrent neural networks for solar radiation forecasting", *IEEE Transactions on Neural Networks and Learning Systems*, vol. 23 (11), pp. 1805-1815, 2012
- [Chen11a] C. Chen, S. Duan, T. Cai, B. Liu, "Online 24-h solar power forecasting based on weather type classification using artificial neural network", *Solar Energy*, vol. 85 (11), pp. 2856-2870, 2011.

- [Chen11b] Z. Chen, S. Aghakhani, J. Man, and S. Dick, "ANCFIS: A Neuro-Fuzzy Architecture Employing Complex Fuzzy Sets," *IEEE Transactions on Fuzzy Systems*, vol. 19, pp. 305-322, 2011.
- [Chen13] S.X. Chen, H.B. Gooi, M.Q. Wang, "Solar radiation forecast based on fuzzy logic and neural networks", *Renewable Energy*, vol. 60, pp. 195-201, 2013.
- [Chiu94] S. Chiu, "Fuzzy model identification based on cluster estimation", *Journal of Intelligent and Fuzzy Systems*, vol. 2, pp. 267-278, 1994.
- [Chow12] S.K.H. Chow, E.W.M. Lee, D.H.W. Li, "Short-term prediction of photovoltaic energy generation by intelligent approach", *Energy and Buildings*, vol. 55, pp. 660-667, 2012.
- [Chowdhury87] B. Chowdhury, S. Rahman, "Forecasting sub-hourly solar irradiance for prediction of photovoltaic output", *IEEE Photovoltaic Specialist Conference*, New Orleans (USA), pp. 171–176, 1987.
- [Ciabattoni12a] L. Ciabattoni, G. Ippoliti, S. Longhi, M. Cavalletti, M. Rochetti, "Solar irradiation forecasting using RBF networks for PV systems with storage", *2012 IEEE International Conference on Industrial Technology, ICIT 2012*, pp. 699-704, 2012.
- [Ciabattoni12b] L. Ciabattoni, M. Grisostomi, G. Ippoliti, S. Longhi, E. Mainardi, "Online tuned neural networks for PV plant production forecasting", *IEEE Photovoltaic Specialists Conference*, pp. 2916-2921, 2012.
- [CNE10] Comisión Nacional de Energía (CNE), "Régimen especial de producción de energía eléctrica en España - Informe mensual de ventas de energía del régimen especial", Mayo 2010.
- [CNE13] Comisión Nacional de Energía (CNE), "Régimen especial de producción de energía eléctrica en España - Informe mensual de ventas de energía del régimen especial", 2013.
- [Cortes95] C. Cortes, V. Vapnik, "Support-vector networks", *Machine Learning*, vol. 20 (3), pp. 273-297, 1995.

- [Costa08] A. Costa, A. Crespo, J. Navarro, G. Lizcano, H. Madsen, E. Feitosa, “A review on the young history of the wind power short-term prediction”, *Renewable and Sustainable Energy Reviews*, vol. 12, No. 6, pp. 1725- 1744, Agosto 2008.
- [Craggs00] C. Craggs, E.M. Conway, N.M. Pearsall “Statistical investigation of the optimal averaging time for solar irradiance on horizontal and vertical surfaces in the UK”, *Solar Energy*, vol. 68 (2), pp. 179–187, 2000.
- [Curtright08] A.E. Curtright, M.G. Morgan, D.W. Keith, “Expert Assessments of Future Photovoltaic Technologies”, *Environmental Science and Technology*, vol. 42 (24), pp. 9031-9038, 2008.
- [Cybenko89] G. V. Cybenko, “Approximation by superpositions of a sigmoidal function”, *Mathematics of Control, Signals, and Systems (MCSS)*, vol. 2, pp. 303-314, 1989.
- [D'Andrea12] E. D'Andrea, B. Lazzerini, “Fuzzy forecasting of energy production in solar photovoltaic installations”, *IEEE International Conference on Fuzzy Systems*, pp. 1-8, 2012.
- [DaSilva11] J.G. Da Silva Fonseca, T. Oozeki, T. Takashima, G. Koshimizu, Y. Uchida, K. Ogimoto, “Photovoltaic power production forecasts with support vector regression: A study on the forecast horizon”, *IEEE Photovoltaic Specialists Conference*, pp. 2579-2583, 2011.
- [DaSilva12] J.G. Da Silva Fonseca, T. Oozeki, T. Takashima, G. Koshimizu, Y. Uchida, K. Ogimoto, “Use of support vector regression and numerically predicted cloudiness to forecast power output of a photovoltaic power plant in Kitakyushu, Japan”, *Progress in Photovoltaics: Research and Applications*, vol. 20 (7), pp. 874-882, 2012.
- [DeLurgio98] S.A. DeLurgio, “Forecasting Principles and Applications”, McGraw-Hill, Singapur, 1998.
- [Deng82] J.L. Deng, “Control problems of grey systems”, *Systems & Control Letters*, vol. 1(5), pp. 211–215, 1982.
- [Deng89] J.L. Deng, “Introduction to grey system theory”, *Journal of Grey System*, vol. 1, no. 1, 1-24, 1989.

- [Detyniecki12] M. Detyniecki, C. Marsala, A. Krishnan, M. Siegel, "Weather-based solar energy prediction", *IEEE International Conference on Fuzzy Systems*, pp. 1-7, 2012.
- [deVries92] A. deVries, J. Principe, "The gamma model: A new model for temporal processing", *Neural Networks*, vol. 5, pp 565-576, 1992.
- [Devroye94] L. Devroye, L. Györfi, A. Krzy'zak, G. Lugosi, "On the strong universal consistency of nearest neighbor regression function estimates", *The Annals of Statistics*, vol. 22 (3), pp. 1371–1385, 1994.
- [Diagne13] M. Diagne, M. David, P. Lauret, J. Boland, N. Schmutz, "Review of solar irradiance forecasting methods and a proposition for small-scale insular grids", *Renewable and Sustainable Energy Reviews*, vol. 27, p. 65-76, November, 2013.
- [Dick05] S. Dick, "Toward complex fuzzy logic," *IEEE Transactions on Fuzzy Systems*, vol. 13, pp. 405-414, 2005.
- [Ding11] M. Ding, L. Wang, R. Bi, "An ANN-based approach for forecasting the power output of photovoltaic system" *Procedia Environmental Sciences*, vol. 11, pp. 1308–1315, 2011.
- [Drews08] A. Drews, H.G. Beyer, U. Rindelhardt, "Quality of performance assessment of PV plants based on irradiation maps", *Solar Energy*, vol. 82, pp. 1067-1075, 2008.
- [Drucker97] H. Drucker, C.J.C. Burges, L. Kaufman, A., Smola, V. Vapnik, "Support vector regression machines", *Advances in Neural Information Processing Systems*, vol. 9, pp. 155–161, 1997.
- [Duda01] R.O. Duda, P.E. Hart, D.G. Stork, "Pattern classification" Wiley, 2001.
- [Dudhia05] J. Dudhia, D. Gill, K. Manning, W. Wang, C. Bruyere, "PSU/NCAR Mesoscale modelling system. Tutorial class notes and user's guide: MM5 modelling system version 3", National Center for Atmospheric Research, Camp Springs, Maryland, 2005.
- [Eberhart01] R. Eberhart, Y. Shi, "Particle Swarm Optimization: Developments, Applications and Resources," *Proceedings of the 2001 Congress on Evolutionary Computation*, vol.1, pp. 81–86, 2001.

- [Elman90] J.L. Elman, "Finding structure in time", *Cognitive Science*, vol. 14, pp. 179-211, 1990.
- [EPIA12] European PhotoVoltaic Industry Association (EPIA), "Global market outlook for photovoltaics until 2016", 2012.
- [EPIA13] European PhotoVoltaic Industry Association (EPIA), "Global market outlook for photovoltaics 2013 -2017", 2013.
- [EPIA14] European PhotoVoltaic Industry Association (EPIA), "Global market outlook for photovoltaics 2014 -2018", 2014.
- [Estebaranz96] J. Estebaranz, "Asimilación de la humedad del suelo en modelos numéricos". *IV Simposio Nacional de Predicción. Memorial Alfonso Ascaso*, Madrid, pp. 15-19, Abril 1996.
- [EurObserv14] EurObserv'ER, "Photovoltaic Barometer", 2014.
- [Fernández09] L.A. Fernández Jiménez, A. Falces de Andrés, M. Mendoza Villena, A. Muñoz Jiménez, P. Lara Santillán, P.J. Zorzano Santamaría, "Optimización del diseño de parques eólicos por medio de algoritmos genéticos y sistemas de información geográfica", *11ª Conferencia Hispano-Lusa de Ingeniería Eléctrica (11CHLIE)*, Julio 2009.
- [Fernández10] L.A. Fernández-Jiménez, A. Falces de Andrés, M. Mendoza-Villena, A. Muñoz-Jiménez, P. Lara-Santillán, P.J. Zorzano-Santamaría, "Diseño de parques eólicos. Optimización por medio de algoritmos genéticos y sistemas de información geográfica", *Revista Eolus*, vol. 47, pp. 12-20, 2010.
- [Fernández12] L.A. Fernández Jiménez, A. Muñoz Jiménez, A. Falces, M. Mendoza Villena, E. García Garrido, P.M. Lara Santillán, E. Zorzano Alba, P. Zorzano Santamaría, "Short-term power forecasting system for photovoltaic plants", *Renewable Energy*, vol. 44, pp. 311-317, 2012.
- [Ferreyra05] A. Ferreyra, "Redes Neuronales Difusas para modelado vía agrupamiento en-línea: Aplicación a un condensador de aspiración", *Tesis doctoral*, Instituto Politécnico Nacional, México, 2005.

- [Fix89] E. Fix, J.L. Hodges, "An Important Contribution to Nonparametric Discriminant Analysis and Density Estimation: Commentary on Fix and Hodges (1951)", *International Statistical Review / Revue Internationale de Statistique*, vol. 57 (3), pp. 233-238, 1989.
- [García96] J. García-Moya. "Una nueva parametrización de la convección en el modelo HIRLAM". *IV Simposio Nacional de Predicción. Memorial "Alfonso Ascaso"*. Madrid 15-19 Abril 1996.
- [Gast60] P.R. Gast, "Solar radiation", *Handbook of Geophysics*, McMillan, New York, pp. 14-30, 1960.
- [Glahn72] H. Glahn, D. Lowry, "The use of Model Output Statistics (MOS)" *Objective Weather Forecasting, Journal of Applied Meteorology*, vol. 11, pp. 1203-1211, 1972.
- [Goldberg89] D.E. Goldberg, "Genetic algorithms in search, optimization and machine learning", Addison-Wesley, Reading, Massachussets, 1989.
- [Graps95] A. Graps, "An Introduction to Wavelets", *IEEE Computational Science & Engineering*, vol. 2, pp. 50-61, 1995.
- [GREEN04] GREENPRO, "Energía Fotovoltaica, Manual sobre Tecnologías, Proyectos e Instalaciones", 2004.
- [Gueymard04]) C.A. Gueymard, "The sun's total and spectral irradiance for solar energy applications and solar radiation models", *Solar Energy*, vol. 76, pp. 423–453, 2004.
- [Haque13] A.U. Haque, M.H. Nehrir, P. Mandal, "Solar PV power generation forecast using a hybrid intelligent approach", *IEEE Power and Energy Society General Meeting*, pp. 1-5, 2013.
- [Härdle90] W. Härdle, "Applied nonparametric regression", Cambridge University Press, Cambridge (UK), 1990.
- [Haykin94] S. Haykin, "Neural Networks: A Comprehensive Foundation", Macmillan Publishing, New York, 1994.
- [Ho92] K.L. Ho, Y.Y. Hsu, C.C. Yang, "Short term load forecasting using a multilayer neural network with an adaptive learning algorithm", *IEEE Transactions on Power Systems*, vol. 7 (1), pp. 141-149, 1992.

- [Hottel58] H.C. Hottel and A. Whillier, "Evaluation of Flat-Plate Solar Collector Performance", *Trans. On the Conference of Use of Solar Energy*, vol. 2 (74), University of Arizona Press, 1958.
- [Hsu91] Y.Y. Hsu, C.C. Yang, "Design of artificial neural networks for short-term load forecasting II. Multilayer feedforward networks for peak load and valley load forecasting", *IEEE Proceedings - Generation, Transmission and Distribution*, vol. 138 (5), pp. 414-418, 1991.
- [IEA10] International Energy Agency, "Solar photovoltaic energy", Technology Roadmaps, 2010.
- [Inman13] R.H. Inman, H.T.C. Pedro, C.F.M. Coimbra, "Solar forecasting methods for renewable energy integration", *Progress in Energy and Combustion Science*, vol. 39 (6), pp. 535-576, 2013.
- [Iqbal83] M. Iqbal, "An Introduction to Solar Radiation", Academic, Toronto, 1983.
- [Izgi12] E. Izgi, A. Öztopal, B. Yerli, M. K. Kaymak, and A. D. Şahin, "Short-mid-term solar power prediction by using artificial neural networks," *Solar Energy*, vol. 86 (2), pp. 725–733, 2012.
- [Jang97] J.S.R. Jang, C.T. Sun, E. Mizutani, "Neuro-fuzzy and soft computing", Prentice Hall, Upper Saddle River, 1997.
- [Janjic01] Z.I. Janjic, "Nonsingular Implementation of the Mellor-Yamada Level 2.5 Scheme", *NCEP Meso model. NCEP Office Note*, vol. 437, pp. 61, 2001.
- [Janjic03a] Z.I. Janjic, "A Nonhydrostatic Model Based on a New Approach", *Meteorology and Atmospheric Physics*, vol. 82, pp. 271-285, 2003.
- [Janjic03b] Z.I. Janjic, "The NCEP WRF Core and Further Development of Its Physical Package", *5th International SRNWP Workshop on Non-Hydrostatic Modeling*, Bad Orb, 2003.
- [Janjic14] Z.I. Janjic, T. Black, M. Pyle et al., "WRF-NMM Version 3 Modelling System User's Guide", Development Testbed Center / National Centers for Environmental Prediction (DTC/NCEP), 2014.

- [Ji11] W. Ji, K.C. Chee, "Prediction of hourly solar radiation using a novel hybrid model of ARMA and TDNN", *Solar Energy*, vol. 85 (5), pp. 808–817, 2011.
- [Kadirkamanathan93] V. Kadirkamanathan, M. Niranjan, "A function estimation approach to sequential learning with neural network", *Neural Computation*, vol. 5, pp. 954–975, 1993.
- [Kalman60] R.E. Kalman, "A new approach to linear filtering and predictions problems", *Transactions of the ASME-Journal of Basic Engineering*, vol. 82, pp. 35-45, 1960.
- [Kärner09] O. Kärner, "ARIMA representation for daily solar irradiance and surface air temperature time series" *Journal of Atmospheric and Solar-Terrestrial Physics*, vol. 71 (8–9), pp. 841–847, 2009.
- [Kecman01] V. Kecman, "Learning and soft computing", MIT Press, Cambridge, Massachusetts, 2001.
- [Kennedy01] J. Kennedy, R. Eberhart, Y. Shi, "Swarm Intelligence", Morgan Kaufmann, San Meteo, 2001.
- [Kennedy95] J. Kennedy, R. Eberhart, "Particle Swarm Optimization," *IEEE International Conference on Neural Networks*, vol. 4, pp. 1942–1948, 1995.
- [Klucher79] T.M. Klucher, "Evaluation of Models to Predict Insolation on Tilted Surfaces", *Solar Energy*, vol. 23, pp. 111-114, 1979.
- [Koenker05] R. Koenker, "Quantile Regression", Cambridge University Press, Cambridge (UK), 2005.
- [Kohonen95] T. Kohonen, "Self organizing maps", Springer Verlag, New York, 1995.
- [Lee92] K.Y. Lee, Y.T. Cha, J.H. Park, "Short-term load forecasting using an artificial neural network", *IEEE Transactions on Power Systems*, vol. 7 (1), pp. 124-132, 1992.
- [Leng06] G. Leng, T.M. McGinnity, G. Prasad, "Design for self-organizing fuzzy neural networks based on genetic algorithms", *IEEE Transactions on Fuzzy Systems*, vol. 14 (6), pp. 755-766, 2006.

- [Li13] Y. Li, Z. Wang, J. Niu, "Forecast of power generation for grid-connected photovoltaic system based on grey theory and verification Model", *International Conference on Intelligent Control and Information Processing, ICICIP 2013*, pp. 129-133, 2013.
- [Li14] Y. Li, Y. Su, L.J. Shu, "An ARMAX Model for Forecasting the Power Output of a Grid Connected Photovoltaic System," *Renewable Energy*, vol. 66, pp. 78-89, 2014.
- [Liang07] M.R.H. Liang, J.H. Liao, "A Fuzzy-Optimization Approach for Generation Scheduling With Wind and Solar Energy Systems", *IEEE Transactions on Power Systems*, vol. 22 (4), pp. 1665-1674, 2007.
- [Liu10] W. Liu, D.B. Mitzi, M. Yuan, A.J. Kellock, S.J. Chey, O. Gunawan. "12% Efficiency CuIn_xSe_{1-x}S₂ Photovoltaic Device Prepared Using a Hydrazine Solution Process", *Chemistry of Materials*, vol. 22 (3), pp 1010–1014, 2010.
- [Liu60] B.Y.H. Liu, R.C. Jordan, "The Interrelationship and Characteristic Distribution of Direct, Diffuse and Total Solar Radiation", *Solar Energy*, vol. 4 (3), pp. 1-19, 1960.
- [Lora02] A. Lora, J. Santos, J. Santos, J. Ramos, A. Exposito, "Electricity market price forecasting: neural networks versus weighted-distance k nearest neighbours", in: A. Hameurlain, R. Cicchetti, R. Traunmüller (Eds.), Database and expert systems applications, *Lecture notes in computer science*, vol. 2453, Springer, Berlin/Heidelberg, pp. 157–211, 2002.
- [Lora03] A.T. Lora, J.C. Riquelme, J.L.M. Ramos, J.M.R. Santos, A.G. Exposito, "Influence of kNN-based load forecasting errors on optimal energy production" F.M. Pires, S. Abreu (Eds.), *Progress in artificial intelligence*, vol. 2902 Springer-Verlag Berlin, Berlin, pp. 189–203, 2003.
- [Lorenz07] E. Lorenz, D. Heinemann, H. Wickramarathne, H.G. Beyer, S. Bofinger, "Forecast of ensemble power production by grid-connected PV systems", *20th European PV Conference*, Milano, Italy, 2007.

- [Madsen05] H. Madsen, P. Pinson, G. Kariniotakis, H.A. Nielsen, T.S. Nielsen, “Standardizing the performance evaluation of short-term wind prediction models”, *Wind Engineering*, vol. 29 (6), pp. 475-489, 2005.
- [Madsen07] H. Madsen, “Time Series Analysis”, Chapman & Hall, London (UK), 2007.
- [Makridakis98] S. Makridakis, S.C. Wheelwright, R.J. Hyndman, “Forecasting. Methods and Applications”, John Wiley and Sons, Hoboken (NJ), 1998.
- [Mandal12] P. Mandal, S.T.S. Madhira, A. Ul-haque, J. Meng, R.L. Pineda, “Forecasting power output of solar photovoltaic system using wavelet transform and artificial intelligence techniques”, *Procedia Computer Science*, vol. 12, pp. 332-337, 2012.
- [Mathiesen13] P. Mathiesen, C. Collier, J. Kleissl, “A high-resolution, cloud-assimilating numerical weather prediction model for solar irradiance forecasting”, *Solar Energy*, vol. 92, pp. 47 – 61, 2013.
- [McQueen95] J.T. McQueen, R.R. Draxler, G.D. Rolph, “Influence of grid size and terrain resolution on wind field predictions from an operational mesoscale model”, *Journal of Applied Meteorology*, vol. 34 (10), pp. 2166-2181, 1995.
- [Mellit13] A. Mellit, S. Sağılam, S.A. Kalogirou, “Artificial neural network-based model for estimating the produced power of a photovoltaic module”, *Renewable Energy*, vol. 60, pp. 71-78, 2013.
- [Misiti07] M. Misiti, Y. Misiti, G. Oppenheim, J.M. Poggi, “Wavelets and their Applications”, Wiley-ISTE, NewPort Beach, California, 2007.
- [MMA10a] “Plan de Energías Renovables en España (PER) 2005-2010”. Ministerio de Medio Ambiente, España, 2010.
- [MMA10b] “Estrategia Española de Cambio Climático y Energía Limpia. Horizonte 2007-2012-2020”. Ministerio de Medio Ambiente, España, 2010.
- [MNRC06] Minister of Natural Resources Canada, “Clean Energy Project Analysis”, 3^a ed., 2001-2005, 2006.

- [Monteiro13a] C. Monteiro, T. Santos, L.A. Fernandez-Jimenez, I.J. Ramirez-Rosado, M.S. Terreros-Olarte, "Short-term power forecasting model for photovoltaic plants based on historical similarity", *Energies*, vol. 6 (5), pp. 2624-2643, 2013.
- [Monteiro13b] C. Monteiro, L.A. Fernandez-Jimenez, I.J. Ramirez-Rosado, A. Muñoz-Jimenez, P.M. Lara-Santillan, "Short-Term Forecasting Models for Photovoltaic Plants: Analytical versus Soft-Computing Techniques", *Mathematical Problems in Engineering*, vol. 2013, Article ID 767284, 9 pp., 2013.
- [Mori12] H. Mori, A. Takahasi, "A data mining method for selecting input variables for forecasting model of global solar radiation", *IEEE Power Engineering Society Transmission and Distribution Conference*, pp. 1-6, 2012.
- [Mörlen04] C. Mörhlen, "Uncertainty in wind energy forecasting", Universidad de Cork, Irlanda, 2004.
- [Muñoz09] A. Muñoz Jiménez, P. Zorzano Santamaría, L.A. Fernández Jiménez, E. Zorzano Alba, A. Yanguas Peña, E. García Garrido, "Modelos de predicción a corto plazo para sistemas fotovoltaicos", *11ª Conferencia Hispano-Lusa de Ingeniería Eléctrica (11CHLIE)*, Julio 2009.
- [Naciones98] "Protocolo de Kyoto de la Convención Marco de Las Naciones unidas sobre el Cambio Climático". Naciones Unidas, 1998.
- [Notton02] G. Notton, C. Cristofari, P. Poggi, and M. Muselli, "Calculation of solar irradiance profiles from hourly data to simulate energy systems behaviour", *Renewable Energy*, vol. 27 (1), pp. 123-142, 2002.
- [Oja89] E. Oja, "Neural networks, principal components and subspaces", *International Journal of Neural Systems*, vol. 1, pp. 61-68, 1989.
- [Orlanski75] I. Orlanski, "A rational subdivision of scales for atmospheric processes", *Bulletin of the American Meteorological Society*, vol. 56, pp. 527-530, 1975.
- [Park89] J. Park, I. Sandberg, "Universal approximation using radial basis function networks", *Neural Computation*, vol. 3, pp. 303-314, 1989.

- [Park91] D.C. Park, M.A. El-Sahrkawi, R.J. Marks, L.E. Atlas, M.J. Damborg, "Electric load forecasting using an artificial neural network", *IEEE Transactions on Power Systems*, vol. 6 (2), pp. 442-449, 1991.
- [Pedro12] H.T.C. Pedro, C.F.M. Coimbra, "Assessment of forecasting techniques for solar power production with no exogenous inputs" *Solar Energy*, vol. 86 (7), pp. 2017-2028, 2012.
- [Pelland11] S. Pelland, G. Galanis, G. Kallos, "Solar and photovoltaic forecasting through post-processing of the Global Environmental Multiscale numerical weather prediction model", *Progress in Photovoltaics: Research and Applications*, vol. 21 (3), pp. 284-296, 2011.
- [Peng92] T.M. Peng, N.F. Hubele, G.G. Karady, "Advancement in the application of neural networks for short-term load forecasting", *IEEE Transactions on Power Systems*, vol. 7 (1), pp. 250-257, 1992.
- [Piliougue14] M. Piliougue, D. Elizondo, L. Mora-López, M. Sidrach-de-Cardona, "Modelling photovoltaic modules with neural networks using angle of incidence and clearness index", *Progress in Photovoltaics: Research and Applications*, doi: 10.1002/pip.2449, 2014.
- [Platt91] J. Platt, "A resource allocating network for function interpolation", *Neural Computation*, vol. 3, pp. 213–225, 1991.
- [Principe00] J.C. Principe, N.R. Euliano, W.C. Lefebvre, "Neural and adaptive systems: fundamentals through simulations", John Wiley & Sons, New York, EEUU, 2000.
- [Prokop12] L. Prokop, S. Misák, T. Novosád, P. Krömer, J. Platos, V. Snásel, "Photovoltaic power plant output estimation by neural networks and fuzzy inference", *Lecture Notes in Computer Science*, 7435 LNCS, pp. 810-817, 2012.
- [Quan13] D.M. Quan, E. Ogliari, F. Grimaccia, S. Leva, M. Mussetta, "Hybrid model for hourly forecast of photovoltaic and wind power", *IEEE International Conference on Fuzzy Systems*, pp. 1-6, 2013.

- [Quaschning03] V. Quaschning, "Technology fundamentals: The sun as an energy resource", *Renewable Energy World*, vol. 6 (5), pp. 90–93, 2003.
- [Rabl85] A. Rabl, "Active Solar Collectors and Their Applications", Oxford University Press, New York, EEUU, 1985.
- [Rahman04] M. H. Rahman, J. Nakayama, K. Nakamura, S. Yamashiro, "A viable grid-connected PV-ECS system with load leveling function using a day-ahead weather forecast", *Power System Technology, PowerCon 2004, 2004 International Conference on*, vol. 1, pp. 311-316, 2004.
- [Rahman07] M. H. Rahman, S. Yamashiro, "Novel Distributed Power Generating System of PV-ECaSS Using Solar Energy Estimation", *Energy Conversion, IEEE Transactions*, vol. 22, pp. 358-367, 2007.
- [Ramot02] D. Ramot, R. Milo, M. Friedman, A. Kandel, "Complex fuzzy sets", *IEEE Transactions on Fuzzy Systems*, vol. 10, pp. 171-186, 2002.
- [Rao94] S. Rao, B. Kumthekar, "Recurrent Wavelet Networks", *IEEE International Conference on Neural Networks*, pp. 3143-3147, 1994.
- [REE13] Red Eléctrica de España (REE), "Informe: El Sistema Eléctrico Español 2012", 2013.
- [Reindl90] D.T. Reindl, W.A. Beckman, J.A. Duffie, "Diffuse Fraction Correlations" *Solar Energy*, vol. 45 (1), pp. 1-7, 1990.
- [Ripley96] B.D. Ripley, "Pattern recognition and neural networks" Cambridge University Press, 1996.
- [Sakawa02] M. Sakawa, "Genetic algorithms and fuzzy multiobjetive optimization", Kluwer academic publishers, Norwell, Massachusetts, 2002.
- [Salvador99] R. Salvador, J. Calbó, M.M. Millán, "Horizontal grid size selection and its influence on mesoscale model simulations" *Journal of Applied Meteorology*, vol. 38 (9), pp. 1311-1329, 1999.
- [Sanger89] T. Sanger, "Optimal unsupervised learning in a single layer linear feedforward neural network", *Neural Networks*, vol. 12, pp. 459-473, 1989.

- [Santos03] J.M. Santos, J.M. Pinazo, J. Canada, "Methodology for generating daily clearness index values K_t starting from the monthly average daily value K_t . Determining the daily sequence using stochastic models", *Renewable Energy*, vol. 28 (10), pp. 1523–1544, 2003.
- [SENAMHI02] Servicio Nacional de Meteorología e Hidrología del Perú (SENAMHI), "Predicción Numérica", 2002.
- [Seni10] G. Seni, J. Elder, "Ensemble Methods in Data Mining: Improving Accuracy through Combining Predictions", Morgan and Claypool Publishers, San Francisco, CA, EEUU, 2010.
- [Shi11] J. Shi, W-J. Lee, Y. Liu, Y. Yang, P. Wang, "Forecasting power output of photovoltaic systems based on weather classification and support vector machines", *IAS Annual Meeting (IEEE Industry Applications Society)*, 2011.
- [Shi12] J. Shi, W-J. Lee, Y. Liu, Y. Yang, P. Wang, "Forecasting power output of photovoltaic systems based on weather classification and support vector machines", *IEEE Transactions on Industry Applications*, vol. 48 (3), pp. 1064-1069, 2012.
- [Silverman89] B.W. Silverman, M.C. Jones, E. Fix, J.L. Hodges, "An important contribution to nonparametric discriminant analysis and density estimation: commentary on Fix and Hodges", *International Statistical Review/Revue Internationale de Statistique*, vol. 57 (3), pp. 233–238, 1989.
- [Stauffer90] D.R. Stauffer, N. L. Seaman, "Use of four dimensional data assimilation in a limited-area mesoscale model. Part I: Experiments with synoptic-scale data", *Monthly Weather Review*, vol. 118, pp. 1250-1277, 1990.
- [Stenger00] R.A. Stenger, "Sensitivity studies on a limited area mesoscale model: an examination of lateral boundary placement, grid resolution and nesting type", *Air Force Institute of Technology, Thesis for the degree of Master of Science in Meteorology*, 215 pp., 2000.
- [Takagi85] T. Takagi, M. Sugeno, "Fuzzy identification of systems and its applications to modeling and control", *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 15 (1), pp. 116-132, 1985.

- [Trafalis00] T.B. Trafalis, H.Y. Ince, "Support Vector Machine for Regression and Application to Financial Forecasting", *Proceedings of the IEEE-INNS-ENNS International Joint Conference on Neural Networks*, vol. 6, pp. 348-353, 2000.
- [Usaola04] J. Usaola, O. Ravelo, G. González, F. Soto, M.C Dávila, B. Díaz-Guerra, "Benefits for wind energy in electricity markets from using short term wind power prediction tools; a simulation study", *Wind Engineering*, vol. 28 (1), pp. 119-128, 2004.
- [Vapnik79] V. Vapnik, "Estimation of Dependencies Based on Empirical Data", Nauka, Moscow, Russia, 1979.
- [Voyant11] C. Voyant, M. Muselli, C. Paoli, M.-L. Nivet, "Optimization of an artificial neural network dedicated to the multivariate forecasting of daily global radiation" *Energy*, vol. 36 (1), pp. 348–359, 2011.
- [Walker08] J.S. Walker, "A Primer on Wavelets and Their Scientific Applications", Chapman & Hall/CRC, Eau Claire, Wisconsin, U.S.A., 2008.
- [Wang11] S. Wang, N. Zhang, Y. Zhao, J. Zhan, "Photovoltaic system power forecasting based on combined grey model and BP neural network", *2011 International Conference on Electrical and Control Engineering, ICECE 2011*, pp. 4623-4626, 2011.
- [Wang12] F. Wang, Z. Mi, S. Su, H. Zhao, "Short-Term Solar Irradiance Forecasting Model Based on Artificial Neural Network Using Statistical Feature Parameters", *Energies*, vol. 5 (5), pp. 1355-1370, 2012.
- [Wei90] W. Wei, "Time Series Analysis: Univariate and multivariate methods", Addison-Wesley, Reading, Massachusetts, 1990.
- [Wilson88] R.C. Willson, H.S. Hudson, "Solar luminosity variations in solar cycle 21", *Nature*, vol. 332, pp. 810–812, 1988.
- [WWEA09] World Wind Energy Association, "World Wind Energy Report 2008", 2009.
- [WWEA14] World Wind Energy Association, "Half-year Report 2013", 2014.

- [Xu12] R. Xu, H. Chen, X. Sun, "Short-term photovoltaic power forecasting with weighted support vector machine", *IEEE International Conference on Automation and Logistics (ICAL)*, pp. 248-253, 2012.
- [Yang13] Y. Yang, L. Dong, "Short-term PV generation system direct power prediction model on wavelet neural network and weather type clustering" *5th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC)*, pp. 207-211, 2013.
- [Yao99] X. Yao, "Evolving artificial neural networks", *Proceedings of the IEEE*, vol. 87 (9), pp. 1423-1447, 1999.
- [Yazdanbaksh13] O. Yazdanbaksh, A. Krahn, S. Dick, "Predicting solar power output using complex fuzzy logic", *Joint IFSA World Congress and NAFIPS Annual Meeting (IFSA/NAFIPS 2013)*, pp. 1243-1248, 2013.
- [Yona07] A. Yona, T. Senju, A.Y. Saber, T. Funabashi, H. Sekine, C.H. Kim, "Application of Neural Network to One-Day-Ahead 24 hours Generating Power Forecasting for Photovoltaic System", in *Intelligent Systems Applications to Power Systems (ISAP) 2007, International Conference*, pp. 1-6, 2007.
- [Yona13] A. Yona, T. Senju, T. Funabashi, C.H. Kim, "Determination method of insolation prediction with fuzzy and applying neural network for long-term ahead PV power output correction", *IEEE Transactions on Sustainable Energy*, vol. 4 (2), pp. 527-533, 2013.
- [Zadeh65] L.A. Zadeh, "Fuzzy sets", *Information and control*, vol. 8, pp. 338-353, 1965.
- [Zhang00] X. G. Zhang, "Statistical learning theory and support vector machine", *Acta automatica sinica*, vol. 26 (1), pp. 32-42, 2000.
- [Zhang12] N. Zhang, P. K. Behera, "Solar radiation prediction based on recurrent neural networks trained by Levenberg-Marquardt backpropagation learning algorithm", *IEEE PES Innovative Smart Grid Technologies*, pp. 1-7, 2012.

- [Zhang13] N. Zhang, P. K. Behera, C. Williams, “Solar radiation prediction based on particle swarm optimization and evolutionary algorithm using recurrent neural networks”, *SysCon 2013 - 7th Annual IEEE International Systems Conference*, pp. 280-286, 2013.
- [Zhang92] Q. Zhang, A. Benveniste, “Wavelet Networks”, *IEEE Transactions on Neural Networks*, vol. 3, pp. 889 – 898, 1992.

ANEXO 1

DESARROLLO DE LA APLICACIÓN INFORMÁTICA PREFO-RED

Durante el transcurso de las investigaciones iniciales a las que se hace referencia en la presente Tesis Doctoral, se ha desarrollado una aplicación informática para que las predicciones para el día siguiente de un parque solar fotovoltaico concreto puedan hacerse de manera sencilla y rápida. A esta aplicación se le ha llamado **PREFO-RED** (sistema de PREdicción de generación eléctrica FOtovoltaica para instalaciones solares conectadas a RED).

PREFO-RED no es una sola aplicación, sino que es un conjunto de aplicaciones y una serie de archivos, cuyo fin común es obtener las predicciones energéticas para una instalación solar fotovoltaica conectada a red concreta.

I.1 ESTRUCTURA DE PREFO-RED

A continuación, en la Figura A1. 1, podemos ver la estructura de carpetas y archivos que componen PREFO-RED.



Figura A1. 1 Estructura de carpetas de PREFO-RED

Seguidamente se describen de manera breve los diferentes archivos y directorios, posteriormente las aplicaciones y archivos más importantes se describirán con mayor detalle.

- **Ayuda:** dentro de este directorio nos encontramos con el archivo *Ayuda.pdf*, que se trata de un sencillo manual de uso de la aplicación general de PREFO-RED, el cuál puede consultarse desde dicha aplicación tal y como se comentará más adelante.
- **FTP:** dentro de este directorio se encuentra el archivo *Dirftp.txt*, siendo en este archivo de texto donde se almacenará la dirección del servidor ftp (o en su defecto la ruta del PC) desde la que se va a descargar el archivo de predicciones del MM5.
- **MM5:** directorio donde se almacenan los archivos de predicciones del MM5 descargados. El nombre de cada uno de estos archivos es la fecha de realización de las predicciones, con la máscara *AAAAMMDD*.
- **NEURO:** directorio (oculto) que contiene los archivos que definen el modelo de predicción desarrollado en las investigaciones iniciales, el MLP 2A. Estos archivos son *BestWeights.nsw* (que contiene los mejores pesos de las conexiones entre las

neuronas) y *Breadboard2.dll* (biblioteca donde se halla definida por completo la red neuronal).

- **Plantilla:** en el interior de este directorio (oculto) se halla el archivo *Plantilla.xls*, el cuál se utilizará como base para obtener el archivo de predicciones energéticas o resultados que se generará. En un apartado posterior se hablará con mayor detalle de este archivo.
- **Predicciones:** directorio donde se almacenan los archivos de predicciones energéticas objeto de PREFO-RED. El nombre de los archivos sigue el formato “*Predicción para AAAAMMDD.xls*” siendo la fecha la correspondiente al día para el cuál se realizan las predicciones (es decir, la fecha actual más un día).
- **Predecir.xls:** archivo (oculto) que contiene la macro encargada de aplicar el modelo de predicción MLP 2A y generar el archivo de resultados (predicciones energéticas). A este archivo y a su macro se les llama desde la aplicación general, tal y como veremos en un apartado posterior.
- **Instalar:** contiene el instalador de la aplicación general, que se autoejecuta al instalar todo el conjunto PREFO-RED.
- **Uninstall:** archivo que desinstala todo el conjunto PREFO-RED excepto la aplicación general.
- **Librerías:** librerías necesarias para PREFO-RED (el instalador las autoinstala).

PLANTILLA.XLS:

Tal y como se ha comentado con anterioridad, este archivo se utilizará como base para obtener el archivo de predicciones energéticas o resultados que se generará. A continuación paso a describir las características fundamentales de este archivo.

Está compuesto por tres hojas de cálculo (*Predicciones*, *Hoja 2* y *Hoja 3*) así como por un gráfico (*Gráfico de Predicciones*).

En la *Hoja 2* y en la *Hoja 3*, se trabaja con los datos de predicciones del MM5 extraídos por medio de la macro del archivo *Predice.xls*. Concretamente se pasan de un intervalo de 15 minutos a una hora, y posteriormente se obtiene el valor de las variables para los instantes $t-1$ y $t+1$.

El *Gráfico de Predicciones* se encuentra ya vinculado a las celdas correspondientes a las predicciones energéticas.

En cuanto a la hoja *Predicciones*, en ella nos encontramos con la tabla que recoge los valores normalizados del momento de la predicción, las variables atmosféricas (predicciones del MM5) para los instantes $t-1$, t y $t+1$, además de los valores finales (ya filtrados) de las predicciones energéticas. A continuación, en la Tabla A1. 1, podemos ver el modelo de tabla empleado.

Tabla A1. 1 Modelo de tabla de la hoja Predicciones

Hora	Tiempo _{seno}	Tiempo _{cos}	V.atmosféricas ($t-1$)	V.atmosféricas (t)	V.atmosféricas ($t+1$)	Epred (Wh)
0	x	x	x	x	x	x
a
23	x	x	x	x	x	x

Además, hay una columna donde se recogen las predicciones directas del modelo de predicción MLP 2A, las cuales se filtran posteriormente con la función aplicada en la columna correspondiente a las predicciones energéticas finales. Esta función es la descrita en la expresión (A1.1).

$$E_{Pred} = \text{SI}(SWOUT(t) = 0; 0 ; \text{SI}(MLP2A_{sal} < 0 ; 0; MLP2A_{sal})) \quad (\text{A1.1})$$

Siendo:

$SWOUT(t)$: variable atmosférica (top outgoing shortwave radiation) para instante t

$MLP2A_{sal}$: valor de la predicción directa del modelo MLP 2A en el instante t

E_{Pred} : predicción energética final (ya filtrada) para el instante t

Me parece importante destacar, también, la presencia de la matriz de datos traspuesta, ya que es preciso para asignar de manera correcta los datos de entrada al modelo de predicción desarrollado.

Por último, comentar que en el archivo de resultados generado a partir de esta plantilla, únicamente se incluirá la tabla con las variables atmosféricas (entradas) y las predicciones energéticas (salidas) además del *Gráfico de Predicciones* correspondiente.

I.2 APLICACIÓN GENERAL PREFO-RED

La aplicación general o central del conjunto PREFO-RED, se ha denominado aplicación general PREFO-RED, por ser el nexo de unión entre todas las aplicaciones y archivos que componen el conjunto, es decir, se encarga de enlazar las opciones de configuración, descarga de predicciones, generación de predicciones y presentación de los resultados.

Pese a todo, a continuación, en la Figura A1. 2, se muestra el fluograma de la aplicación general PREFO-RED, quedando explicado su funcionamiento de una forma esquemática.

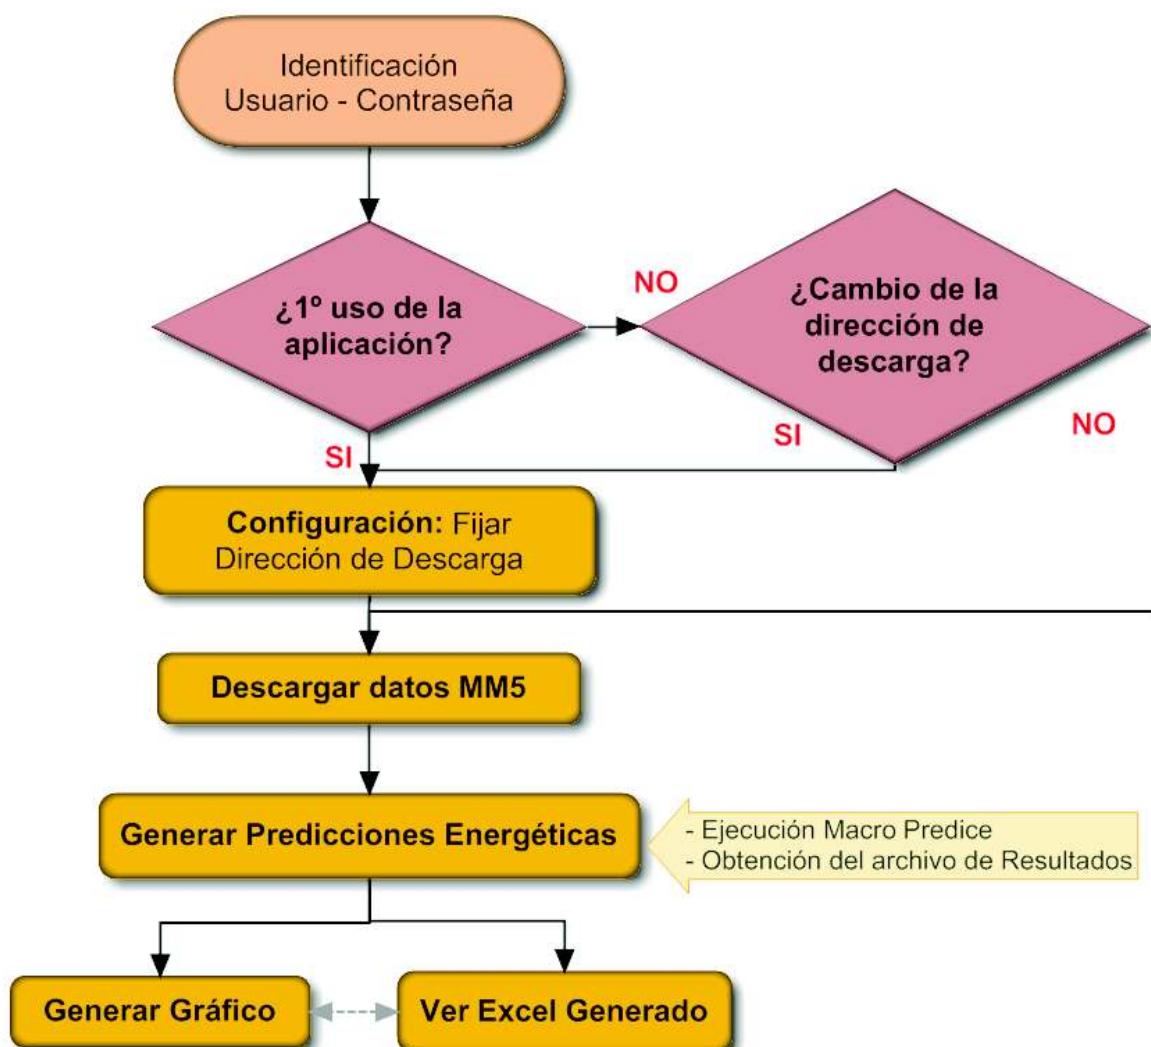


Figura A1. 2 Flujograma de funcionamiento de la aplicación general PREFO-RED

Se trata de una aplicación desarrollada en el lenguaje Visual Basic .NET, mediante el programa Microsoft Visual Basic 2005 Express Edition.

© Andrés Muñoz Jiménez, 2014

MODELOS DE PREDICCIÓN A CORTO PLAZO DE LA GENERACIÓN ELÉCTRICA EN INSTALACIONES FOTOVOLTAICAS

